

Unidad 2 · Del BI a la **inteligencia para decidir**: evaluación de la viabilidad de los proyectos de IA

Esta unidad no trata de *cómo* construir un modelo, sino de una decisión anterior y más estratégica: **¿vale la pena construirlo?** Antes de invertir tiempo, dinero y capacidad organizacional en un proyecto de Inteligencia Artificial, hay que evaluar de forma estructurada si es **viable** —técnica, organizativa y éticamente—. Para eso encadenamos seis herramientas: el modelo de las **4 V de los datos** (juzgar la materia prima), el marco **CRISP-DM** (ordenar el proceso), la decisión de **fabricar o comprar** tecnología, las **tres capas arquitectónicas**, los **criterios éticos** (privacidad, sesgos, discriminación) y la **hoja de ruta priorizada**. Donde la Unidad 1 te enseñó a *identificar* dónde la IA crea valor, esta Unidad 2 te enseña a *filtrar* esas ideas y quedarte con las ejecutables.

1. ¿Para qué estamos aquí? Del Business Intelligence a la inteligencia para decidir

El título marca un salto conceptual. **Business Intelligence (BI)** (*Business Intelligence, Inteligencia de Negocios*) es la disciplina clásica de mirar el pasado: se define una métrica, se construye un **modelo de datos** (un esquema de tablas y relaciones) y se generan **reportes** o **dashboards** que describen lo ya ocurrido. La **Inteligencia Artificial (IA)** aplicada a decisiones da un paso más: no solo describe el pasado, sino que **aprende patrones** para *predecir* o *recomendar* acciones futuras.

La diferencia práctica está en la **incertidumbre**. En BI el proceso es **predecible**: si tienes las ventas por mes, sabes de antemano que podrás graficarlas. En IA no puedes saber por adelantado si el modelo aprenderá patrones útiles —eso solo se descubre **probándolo con datos reales**—. Un proyecto de BI casi siempre "funciona"; uno de IA puede fracasar aunque esté perfectamente programado, simplemente porque los datos no contenían la señal necesaria.

ANALOGÍA

BI es leer el velocímetro y el cuentakilómetros: te dicen con certeza a qué velocidad vas y cuánto has recorrido. La IA es predecir a qué hora llegarás: depende de patrones (tráfico, clima, tu forma de manejar) que hay que *aprender* de viajes anteriores, y a veces el patrón simplemente no está en los datos que registraste.

¿Qué haremos? Prepararemos y evaluaremos los datos con el marco de las **4 V** y con **CRISP-DM**; compararemos formas de adquirir tecnología (**fabricar o comprar**); estudiaremos las **capas arquitectónicas**; aplicaremos **criterios éticos** para anticipar riesgos de privacidad, sesgos o discriminación; e integraremos todo en una **hoja de ruta priorizada** para decidir qué proyectos impulsar, ajustar o postergar.

¿Para qué nos servirá? Para actuar con criterio estratégico y evitar dos errores caros: lanzarse ignorando la calidad de los datos, la capacidad técnica o los **costos ocultos de infraestructura**; o quedarse paralizado sin distinguir qué iniciativas dan resultados rápidos y cuáles exigen más investigación. La meta es **priorizar con expectativas realistas**, equilibrando impacto, viabilidad y responsabilidad organizacional.

2. Dar prioridad a los datos: las preguntas que van antes del algoritmo

La primera regla es contraintuitiva para quien viene de la ingeniería: **en las etapas iniciales, lo importante no es la arquitectura ni el algoritmo, sino el objetivo del caso de uso y la disponibilidad de datos**. Muchas iniciativas fracasan **no por falta de tecnología, sino porque los datos son insuficientes, inconsistentes o simplemente no existen**.

Antes de discutir bases de datos o modelos, hay que definir el objetivo. El PDF da un ejemplo canónico que

reaparece toda la unidad: "Queremos utilizar datos históricos del **CRM** y del **ERP** para predecir qué clientes tienen riesgo de abandonar el servicio durante el próximo mes." Esa sola frase permite evaluar si el proyecto tiene fundamentos sólidos. De ella surgen las **preguntas fundamentales** de todo proyecto de IA:

- ¿Qué datos se necesitan exactamente?
- ¿Están disponibles?
- ¿Quién tiene el permiso **legal** y **técnico** para acceder a ellos?
- ¿La empresa es propietaria de esos datos o debe adquirirlos?
- ¿Existen registros históricos suficientes para entrenar un modelo?

La conclusión es afilada: **si estas preguntas no pueden responderse con claridad, probablemente el problema principal aún no sea construir un modelo de IA, sino mejorar la disponibilidad y la gobernanza de los datos.** A veces el "proyecto de IA" correcto es, en realidad, un proyecto previo de datos.

EJEMPLO

Un banco quiere predecir la fuga de clientes, pero los motivos de cierre se anotan a mano en un campo de texto libre, sin estandarizar, y solo el 30 % de los registros lo tiene lleno. Ningún modelo de IA arregla eso: primero hay que resolver la **gobernanza de datos** (definir el campo, hacerlo obligatorio, poblar el histórico).

3. CRISP-DM: el marco que ordena el proceso

Qué es. CRISP-DM (*Cross-Industry Standard Process for Data Mining*, "Proceso Estándar Intersectorial para la Minería de Datos") es la metodología más adoptada para estructurar proyectos de ciencia de datos. El PDF lo define como un proceso estándar intersectorial que *propone ciclos de iteración cortos entre la comprensión del negocio y la de los datos.*

Por qué existe. Los proyectos de IA, por su incertidumbre, no avanzan en línea recta. CRISP-DM da un **esqueleto iterativo y ágil**: en lugar de "primero todo el negocio, luego todos los datos, luego el modelo", propone ciclos cortos donde la **comprensión del negocio** y la **comprensión de los datos** avanzan *simultáneamente* y se retroalimentan. Antes de considerar algoritmos o infraestructura, la organización debe preguntarse si los datos contienen las **señales** necesarias.

Cómo funciona — Figura 1 (Ciclo de vida de minería de datos, IBM SPSS Modeler). La figura muestra un **círculo** con los **datos en el centro** y **seis fases** unidas por flechas que van y vuelven (no es una escalera, es un ciclo):

1. **Comprensión del negocio** (*Business Understanding*): definir el objetivo y traducirlo a un problema de datos. Flecha bidireccional con la fase 2.
2. **Comprensión de los datos** (*Data Understanding*): explorar qué datos hay, su calidad y si contienen la señal.
3. **Preparación de los datos** (*Data Preparation*): limpiar, integrar, transformar y etiquetar. La fase más laboriosa.
4. **Modelado** (*Modeling*): entrenar los algoritmos.
5. **Evaluación** (*Evaluation*): medir si el modelo cumple el objetivo de negocio, no solo el técnico. Desde aquí una flecha vuelve a la fase 1.
6. **Despliegue** (*Deployment*): poner el modelo en producción. El bucle exterior indica que el proceso es **continuo**: al desplegar se generan nuevos datos que reinician el ciclo.

ANALOGÍA

CRISP-DM es cocinar un plato nuevo sin receta fija. No decides el menú y compras a ciegas: pruebas qué ingredientes tienes (datos), ajustas el plato al mercado (negocio), cocinas una versión (modelo), la pruebas (evaluación) y, según el resultado, cambias ingredientes o incluso el plato. El "centro" de la cocina siempre es

la despena: los **datos**.

⚠ **Nota (curso vs. práctica actual).** El curso presenta CRISP-DM con seis fases que **terminan en el despliegue**, y así se evalúa: es correcto y vigente (la guía 1.0 se publicó en 1999–2000; consorcio SPSS, Daimler, NCR y OHRA). Pero la práctica moderna señala su **límite**: CRISP-DM **no cubre el ciclo de vida post-despliegue** —monitoreo continuo, reentrenamiento automático, versionado y gestión de la deriva de datos—. Eso lo cubren hoy **MLOps** y metodologías como **TDSP** (*Team Data Science Process, Microsoft*). Para el examen: CRISP-DM = 6 fases cíclicas. En la vida real: CRISP-DM + MLOps para lo que viene después.

4. Evaluar la preparación de los datos con el marco 4V

Confirmada la *disponibilidad* (sección 2), el siguiente paso es evaluar la *adecuación*. Tener datos **no** implica tener datos útiles: pueden existir, pero ser insuficientes, poco representativos, desactualizados o carecer de calidad. El **marco 4V** es una forma simple y ampliamente usada de evaluarlos sin entrar en detalles técnicos complejos. Sus cuatro dimensiones son **volumen, variedad, velocidad y veracidad**:

Dimensión	Qué evalúa	Señal de alarma
Volumen (<i>Volume</i>)	Cantidad de observaciones (filas) y profundidad de la información (atributos/columnas).	Muy pocos ejemplos para la técnica elegida.
Variedad (<i>Variety</i>)	Si los datos son representativos de todos los escenarios, incluidos los eventos raros.	Datos no estructurados sin preprocesar; escenarios ausentes.
Velocidad (<i>Velocity</i>)	Frecuencia con que los datos se actualizan.	Alta velocidad → más infraestructura y riesgo de deriva de datos.
Veracidad (<i>Veracity</i>)	Si los datos contienen la verdad fundamental (etiquetas correctas).	Sin etiquetas fiables no hay aprendizaje supervisado.

Volumen. Indica cuántas observaciones hay y cuántos atributos. Distintas técnicas exigen distinto volumen: una **regresión** simple puede requerir del orden de **cientos de filas**; el análisis de **texto o imágenes** suele necesitar **miles de ejemplos por categoría**. Formalmente, el tamaño de una tabla es filas por columnas, $V = n \times p$, donde n es el número de observaciones y p el de atributos; ambos importan, porque un modelo con muchas columnas (p grande) y pocas filas (n pequeño) tiende a *sobreajustar*.

EJEMPLO NUMÉRICO

Para clasificar reclamos en 5 categorías con un modelo de texto, "miles de ejemplos por categoría" significa apuntar a unos $5 \times 2\,000 = 10\,000$ reclamos ya etiquetados. Si solo tienes 300 en total (60 por categoría), el volumen es insuficiente y el proyecto es inviable *aunque* el algoritmo sea excelente.

Variedad. No basta con muchos datos: deben cubrir **todos los escenarios**, incluidos los **eventos raros** (fraudes, fallas, clientes atípicos). Además, la IA a menudo lidia con **datos no estructurados** (*unstructured data*) —texto, imágenes, audio— que exigen un preprocesamiento extenso para convertirlos en tablas que los algoritmos puedan "digerir".

ANALOGÍA

Entrenar solo con casos "normales" es estudiar para un examen viendo únicamente las preguntas fáciles: el día que aparece el caso raro (el fraude nunca visto), el modelo no sabe reaccionar.

Velocidad. Es la frecuencia de actualización. Los datos de **alta velocidad** (transacciones por segundo, sensores) exigen infraestructuras más robustas y presentan **mayor riesgo de deriva de datos**, lo que obliga a reentrenar los modelos con más frecuencia.

Veracidad (*Ground Truth*). Es la dimensión **más crítica para el aprendizaje supervisado** (*supervised*

learning), donde el modelo aprende de ejemplos etiquetados. Se refiere a si los datos contienen la "verdad fundamental" o **etiquetas**. Sin etiquetas precisas que le indiquen al modelo qué es "correcto" —por ejemplo, si un cliente **realmente se fugó**—, el sistema no tiene punto de referencia para aprender. Es el "profesor": si el profesor da respuestas equivocadas, el alumno aprende mal.

EJEMPLO

En el churn bancario, la etiqueta veraz sería "esta cuenta se cerró por decisión del cliente el 12/03". Si en el histórico las cuentas cerradas por fallecimiento, por fusión de sucursales y por decisión del cliente están todas marcadas igual como "baja", la **veracidad** es baja: el modelo aprenderá a predecir "bajas" mezcladas, no fuga real.

Figura 2 — Radar 4V (Zwingmann, 2024). El PDF muestra un **gráfico de radar** con cuatro ejes (Volumen arriba, Variedad a la derecha, Velocidad abajo, Veracidad a la izquierda) y escala de 0 a 5. Cada caso se puntúa en cada eje y se dibuja el polígono resultante; un caso con volumen y variedad altos pero velocidad y veracidad medias forma una figura alargada verticalmente. **El valor del 4V no es producir una medición exacta**, sino comparar casos entre sí y detectar debilidades temprano. Un proyecto puede tener alto impacto pero ser **inviable** si sus datos carecen de volumen o tienen baja veracidad; y un caso aparentemente simple puede volverse una **victoria rápida** si la organización ya tiene datos abundantes, estructurados y bien gobernados. Moraleja del PDF: *en muchos casos, la **gobernanza de los datos** puede ser más importante que la tecnología utilizada para el modelado.*

⚠ **Nota (4V del curso vs. las V del Big Data).** El curso usa **4V (volumen, variedad, velocidad, veracidad)**, la versión de Zwingmann para evaluar datos de IA. En el material complementario aparecen las **5 V del Big Data: Volumen, Velocidad, Variedad, Veracidad y Valor**. Linaje: el modelo original fue de **3V (volumen, velocidad, variedad)** de **Doug Laney** en 2001 (entonces en META Group, no en Gartner, que lo compró en 2005); la **Veracidad** se añadió después (atribuida a IBM, ~2012) y el **Valor** aún más tarde. Para el examen del curso: **4V**. Si preguntan por Big Data en general: **5V**, cuya quinta es **Valor** (el retorno que los datos aportan al negocio).

5. Fabricar o comprar servicios de IA (make or buy)

El problema. Construir una solución de IA desde cero es costoso y complejo. Además del desarrollo del modelo, hay que gestionar **infraestructura, almacenamiento, integración de datos, monitoreo y mantenimiento continuo**. Por eso muchas empresas combinan capacidades internas con servicios externos, según recursos, necesidades y **madurez tecnológica**. El PDF define **cuatro enfoques**, un espectro de **menos a más control (y responsabilidad) del cliente**:

Enfoque	Qué gestiona la empresa	Control	Ideal para
AlaaS (IA como Servicio)	Solo consume el modelo vía API	Bajo	Tareas generales, validar rápido
PaaS (Plataforma como Servicio)	Entrena modelos propios; no la infraestructura	Medio	Modelos propios sin operar servidores
IaaS (Infraestructura como Servicio)	Modelos, pipelines y herramientas	Alto	Equipos especializados en nube y ML
On-premise (Propiedad Integral)	Todo, internamente	Total	Entornos altamente regulados

IA como Servicio (AlaaS, AI as a Service). La organización **consume modelos preentrenados** de proveedores externos a través de **APIs** o servicios en la nube. Es la opción **más rápida y sencilla**, ideal para tareas generales como **reconocimiento de imágenes, análisis de sentimientos o transcripción de voz**. Su limitación: **bajo control y personalización** sobre el modelo.

Plataforma como Servicio (PaaS, Platform as a Service). La empresa usa **plataformas gestionadas de machine learning** para entrenar y desplegar **modelos propios** sin gestionar la infraestructura. Equilibra facilidad y flexibilidad; permite experimentar rápido con **AutoML** (automatización del entrenamiento y selección de modelos) y modelos preentrenados ajustables.

Infraestructura como Servicio (IaaS, Infrastructure as a Service). La organización **arrienda capacidad computacional** y gestiona directamente sus modelos, *pipelines* y herramientas. Ofrece **mayor flexibilidad y control**, pero requiere **equipos especializados** en nube y machine learning.

Propiedad Integral (On-premise). Toda la infraestructura, los datos y los modelos se gestionan **internamente**. Da **control total** y puede ser necesario en **entornos altamente regulados** (banca, salud, defensa), pero conlleva el **mayor nivel de complejidad, costo y demanda de talento especializado**.

ANALOGÍA (EL ESPECTRO COMPLETO)

Es la diferencia entre las formas de "tener comida". **AlaaS** = pedir delivery: rapidísimo, cero esfuerzo, pero comes lo que hay en el menú. **PaaS** = un meal kit (ingredientes cortados y receta a casa): cocinas —eliges el punto— pero no vas al mercado ni lavas ollas industriales. **IaaS** = arrendar una cocina profesional equipada: traes ingredientes, recetas y cocineros. **On-premise** = construir y ser dueño de tu restaurante: control absoluto, pero pagas arriendo, personal y cada reparación.

La decisión no es solo técnica. Depende del **presupuesto**, la **urgencia**, las **capacidades internas** y el **valor estratégico** que la IA tendrá para el negocio. Recomendación práctica: conviene **empezar con servicios administrados** (AlaaS/PaaS) para **validar rápido** antes de avanzar a arquitecturas más complejas (IaaS/on-premise).

⚠ **Nota (dónde encaja AlaaS en la nube clásica).** En el marco NIST estándar, los tres modelos de nube son **IaaS, PaaS y SaaS**. **AlaaS/MLaaS** no es categoría NIST: una **API de IA lista para usar** se comporta como capa **SaaS especializada**, mientras que una **plataforma de ML gestionada** (tipo SageMaker o Vertex AI) cae más cerca de **PaaS**. El orden de **responsabilidad compartida** del curso —**AlaaS/SaaS < PaaS < IaaS < On-premise** en control del cliente— es correcto y estándar.

6. Arquitecturas básicas de los sistemas de IA: las tres capas

Además de los datos y la infraestructura, evaluar la viabilidad exige entender —al menos conceptualmente— **cómo se estructura** una solución de IA. Aunque las arquitecturas reales son complejas, la mayoría de los sistemas modernos se explican con **tres capas**: usuario, análisis y datos.

Capa de usuario (User layer, 1 de 3). Es la forma en que personas o sistemas **interactúan** con la solución: un **dashboard** en **Power BI**, una **aplicación web**, un **chatbot**, una **API** o un **archivo automatizado**. Definirla **primero** ayuda a delimitar el **alcance** del proyecto y el **resultado esperado** para el usuario final.

Capa de análisis (Analytics layer, 2 de 3). Es el **núcleo** donde se ejecutan las capacidades de **machine learning**. Aquí residen los **modelos predictivos**, los **clasificadores**, los **sistemas de recomendación** y los algoritmos de **detección de anomalías** (*anomaly detection*). A veces combina **reglas de negocio tradicionales** con modelos de IA, formando **soluciones híbridas**.

Capa de datos (Data layer, 3 de 3). Incluye las **fuentes** y los **procesos** para preparar los datos: **bases de datos, archivos, APIs, sensores** o sistemas empresariales como **ERP** (*Enterprise Resource Planning*) y **CRM** (*Customer Relationship Management*). También cubre la **limpieza, integración, etiquetado y transformación** (la misma "Preparación de los datos" de CRISP-DM).

ANALOGÍA

Las tres capas son un restaurante: la **capa de datos** es la despensa y la cocina donde se preparan los

ingredientes; la **capa de análisis** es el chef que transforma ingredientes en platos (la inteligencia); la **capa de usuario** es el mesero y el plato servido, lo único que el comensal ve.

Ejemplo integrador. En un sistema de **predicción de fuga de clientes**: los datos provienen de **CRM y ERP** (capa de datos), son procesados por un **modelo de clasificación** (capa de análisis) y se muestran en un **dashboard** para los equipos comerciales (capa de usuario). En un **chatbot**, el flujo es **bidireccional**: las conversaciones generan **nuevos datos** que sirven para **reentrenar** y mejorar el modelo —cerrando el bucle de CRISP-DM—. Comprender estas capas no busca convertir a los responsables de negocio en ingenieros, sino permitirles **evaluar con claridad** la complejidad técnica, los componentes y los **riesgos de implementación**.

7. Consideraciones éticas: criticidad ética y de privacidad

Qué es (y qué no es). La ética en IA **no** trata de "máquinas conscientes" tomando decisiones morales, sino de la **responsabilidad de las personas y organizaciones** que diseñan, implementan y usan estos sistemas. Cada caso de uso puede tener consecuencias reales, por lo que las implicaciones éticas deben considerarse **desde las primeras etapas**.

No todos los sistemas tienen el mismo riesgo. Clasificar **tickets de soporte** tiene impacto menor; un **diagnóstico médico**, una **evaluación crediticia** o la **selección de candidatos** pueden influir directamente en la vida de las personas. El riesgo depende **tanto de la tecnología como del contexto**. El PDF propone **dos dimensiones**:

Criticidad ética (*Ethical criticality*). Evalúa si la decisión de la IA **afecta el bienestar, la libertad o la vida** de las personas. Un sistema que controla la **calidad de teclados** tiene **baja** criticidad; uno que determina **diagnósticos médicos** o **aprueba créditos** es **altamente crítico**.

Criticidad de la privacidad (*Privacy criticality*). Evalúa el **tipo de datos**, desde **datos de máquinas anónimos** hasta **datos personales altamente sensibles**. Punto sutil con olor a examen: **incluso si los datos son anónimos, el caso puede ser éticamente crítico si el resultado afecta la vida de las personas** —como en las **pruebas de medicamentos**—.

Estas dimensiones identifican qué proyectos requieren **mayor supervisión y control**. Un **control de calidad industrial** opera con bajo riesgo ético y de privacidad; un modelo de **scoring crediticio** puede afectar oportunidades económicas de **millones de personas** y usar información sensible, siendo de **alta criticidad**. La evaluación ética **no es un ejercicio único**: los modelos pueden **degradarse**, incorporar **sesgos** (*bias*) no previstos o producir efectos no deseados cuando cambia el entorno (la **deriva** otra vez). Por eso se necesitan mecanismos **permanentes** de **monitoreo, revisión y gobernanza**. Más que una evaluación "perfecta", importa contar con **criterios claros y consistentes** antes de desplegar.

Figura 3 — Matriz criticidad ética vs. privacidad (adaptada de Zwingmann, 2024). Dos ejes: **criticidad ética** horizontal (crece a la derecha) y **criticidad de privacidad** vertical (crece hacia arriba). Los casos se ubican en **tres bandas** según cuán personales sean los datos:

Banda (privacidad)	Casos de uso ubicados
Datos personales (superior)	Anuncios en redes sociales · Evaluación de riesgo crediticio · Predictor de abandono de clientes B2C · Servicios de inteligencia
Relacionados con personas (media)	Anuncios en línea · Tarificación de seguros · Predictor de abandono de clientes B2B · Drones de combate
Sin datos personales (inferior)	Predicciones del clima · Internet de las cosas · Conducción autónoma · Pruebas de medicamentos

La lectura: a medida que un caso sube (más datos personales) y se desplaza a la derecha (más impacto en la vida), aumenta la exigencia de supervisión. Un "predictor de abandono B2C" (personas) es más sensible que uno "B2B" (empresas), aunque técnicamente sean casi el mismo modelo. Y "pruebas de medicamentos"

ilustra el punto clave: datos poco personales pero **alta criticidad ética** —anonimato $\neq$ bajo riesgo—.

ANALOGÍA

Piensa en dos medidores cruzados: uno mide "cuánto puede dañar a una persona" y otro "cuán íntimos son los datos". Un control de calidad de teclados está en verde-verde; un scoring de crédito con datos personales está en rojo-rojo (máxima criticidad) y necesita "conducir con las dos manos": auditoría, explicabilidad y monitoreo.

Sesgos y discriminación. El sesgo aparece cuando el modelo aprende patrones injustos presentes en los datos históricos y los perpetúa como **discriminación algorítmica**.

EJEMPLO REAL

En 2018, **Amazon descartó** una herramienta interna de IA para filtrar currículums porque **penalizaba a las mujeres**: entrenada con CVs de la década previa (mayoritariamente de hombres), había "aprendido" a castigar términos como "*women's*". El sesgo no estaba en el código, sino en los datos —el riesgo que la evaluación de veracidad y ética busca anticipar—. Otro caso canónico es **COMPAS** (2016), algoritmo de riesgo de reincidencia en tribunales de EE. UU. que, según ProPublica, marcaba con más frecuencia a acusados negros como "alto riesgo".

⚠ **Nota (curso vs. estándar regulatorio europeo).** El curso reduce la ética a **dos dimensiones** (criticidad ética y de privacidad), una simplificación didáctica útil para priorizar. El estándar que el propio curso cita —las **Ethics Guidelines for Trustworthy AI** de la Comisión Europea (grupo AI HLEG, 2019)— define una **IA fiable** (*Trustworthy AI*) con **3 componentes** (legal, ética, robusta) y **7 requisitos**: (1) acción y supervisión humanas, (2) robustez técnica y seguridad, (3) privacidad y gobernanza de datos, (4) transparencia, (5) diversidad, no discriminación y equidad, (6) bienestar social y ambiental, (7) rendición de cuentas. Para el examen: **dos dimensiones**. Para la práctica: los **7 requisitos** europeos.

8. Crear una hoja de ruta de casos de uso priorizados

Evaluados el impacto potencial (Unidad 1) y la viabilidad técnica, de datos y ética (Unidad 2), la organización construye una **hoja de ruta priorizada**. El objetivo no es solo identificar ideas interesantes, sino **priorizar** las que combinan **mayor valor empresarial** con **mayores probabilidades de éxito**.

La herramienta: la matriz impacto vs. viabilidad. Cada caso se ubica en dos ejes: el **impacto** es el valor potencial para el negocio (aumento de ingresos, reducción de costos, mejora de experiencia de clientes); la **viabilidad** refleja qué tan factible es implementarlo, considerando **datos, infraestructura, capacidades internas y restricciones éticas**. No requiere métricas perfectas: en etapas iniciales conviene comparar **de manera relativa**. Conceptualmente, la prioridad puede pensarse como el producto $\text{Prioridad} \approx \text{Impacto} \times \text{Viabilidad}$: un caso de impacto altísimo pero viabilidad casi nula rinde poco (el producto se derrumba), igual que uno muy viable pero de impacto trivial.

Las cuatro categorías (los cuadrantes):

1. **Campeones** (*Champions*): **alto impacto y alta viabilidad**. Prioridad número uno.
2. **Victorias rápidas** (*Quick Wins*): **viabilidad alta pero impacto menor**. Útiles para generar confianza rápido.
3. **Casos de investigación**: **alto impacto pero baja viabilidad actual**. En el radar, sin inversión masiva inmediata.
4. **Reevaluar más tarde**: **bajo impacto y baja viabilidad**. Pueden consumir recursos sin aportar valor real.

Criterios prácticos adicionales. Conviene priorizar proyectos que **compartan las mismas fuentes de datos o capacidades tecnológicas** (reduce complejidad y acelera el aprendizaje organizacional), y **combinar iniciativas ambiciosas con proyectos simples** para mantener resultados visibles mientras se desarrollan capacidades avanzadas.

ANALOGÍA

La matriz es planificar reformas en una casa con presupuesto limitado. **Campeón**: cambiar ventanas viejas por eficientes (mucho ahorro, obra sencilla) → hazlo ya. **Victoria rápida**: pintar el living (barato, rápido, impacto modesto) → genera ánimo. **Caso de investigación**: instalar paneles solares (gran ahorro futuro, caro y complejo hoy) → cotiza, no ejecutes aún. **Reevaluar más tarde**: una fuente ornamental en el jardín → ni impacto ni facilidad, déjala.

9. Caso integrador: evaluación de viabilidad de un sistema de *scoring* de crédito

El PDF cierra aplicando **todos** los conceptos a un caso: una **institución financiera** que desea usar IA para **automatizar la aprobación de créditos** (**scoring de crédito**, *credit scoring*).

Paso 1 — Marco 4V. El **Volumen** es **alto** (millones de transacciones históricas). Pero la **Veracidad** es un **desafío importante**: muchos registros antiguos **no tienen una etiqueta clara de "incumplimiento"**, por cambios en los **sistemas legacy** (heredados y obsoletos). Hay muchos datos, pero de calidad de etiqueta dudosa —la dimensión más crítica para el aprendizaje supervisado—.

Paso 2 — Arquitectura (make or buy). La institución opta por una **PaaS**, para **mantener el control total del modelo** (la sensibilidad del negocio lo exige) **delegando la gestión de la infraestructura**. No usa **AlaaS** (perdería control sobre un modelo crítico) ni on-premise (asumiría complejidad innecesaria).

Paso 3 — Evaluación ética. Se clasifica como de **"máxima criticidad"**, porque usa **datos personales** y **afecta directamente el acceso de las personas a recursos financieros**. Esto **obliga** a incorporar una capa de **IA explicable** (*XAI*, *Explainable AI*) en la arquitectura, que permita al banco **justificar las decisiones de rechazo** ante clientes y reguladores.

Paso 4 — Matriz de priorización. El proyecto de **scoring** se clasifica como **caso de investigación**, por su **complejidad ética y de datos** (alto impacto, pero viabilidad comprometida por la baja veracidad de las etiquetas y la exigencia regulatoria). Por eso el banco decide **priorizar primero** un proyecto de **predicción de fuga** (**Champion**), que usa **datos menos sensibles** y es más viable y de menor riesgo.

La lección central. El proyecto "más deseable" (**scoring**) no siempre es el que se ejecuta primero. Un análisis estructurado —4V + arquitectura + ética + matriz— puede recomendar **empezar por un Champion más humilde** (**churn**) para generar capacidades y confianza, y dejar el **scoring** como caso de investigación hasta resolver la veracidad de los datos y la explicabilidad. La evaluación ética y de viabilidad son esenciales para priorizar de manera efectiva, alineando los proyectos con los valores organizacionales y minimizando riesgos.

10. Ejercicio práctico y conexión con la Unidad 1

El PDF propone un ejercicio que **retoma la Unidad 1**: allí identificaste un proceso donde la IA podría generar valor; aquí evalúas su **viabilidad** en cuatro pasos que resumen la unidad:

1. **Evaluación de datos con el marco 4V:** ¿hay suficiente **volumen** histórico? ¿los datos cubren la **variedad** de escenarios? ¿la **velocidad** de actualización basta? ¿existe **veracidad** (etiquetas/resultados históricos)?
2. **Viabilidad técnica:** ¿la organización ya posee los datos o debe obtenerlos? ¿basta un servicio existente (**AlaaS**) o hace falta desarrollar modelos propios? ¿qué tan complejo sería implementarlo?
3. **Consideraciones éticas:** riesgos de **privacidad**, **sesgos**, **decisiones automatizadas** e **impacto sobre personas**.
4. **Evaluación final:** clasificar como **Campeón**, **Victoria rápida**, **Caso de investigación** o **Reevaluar más tarde**, **justificando** la decisión.

La conexión es explícita: **Unidad 1 = dónde crea valor la IA (identificar oportunidades); Unidad 2 = cuáles de esas oportunidades son realmente ejecutables (filtrar y priorizar).** El objetivo no es diseñar la solución técnica, sino **evaluar críticamente la viabilidad real** antes de implementar.

11. Material complementario y contexto

El PDF incluye recursos que refuerzan la unidad. Los vídeos y el podcast ("**Vórtice tecnológico y disrupción empresarial**", del profesor Andrés Leiva, y "**Vórtice digital y competitividad empresarial**") introducen el **vórtice digital** (*digital vortex*): la idea de que la disrupción tecnológica funciona como un remolino que **atrae al centro** —fuerza a transformarse— a las empresas que no se adaptan. Es el "por qué importa" estratégico de la unidad: quien no evalúa e implementa IA con criterio queda absorbido por la competencia que sí lo hace. El artículo "**La metodología CRISP-DM en ciencia de datos**" (Instituto de Ingeniería del Conocimiento) confirma sus **seis fases fundamentales**; el vídeo "**Las 5 Vs del Big Data**" profundiza en Volumen, Velocidad, Variedad, Veracidad y **Valor**; y el documento "**Directrices éticas para una IA fiable**" (Comisión Europea) recoge los 7 requisitos de la nota [△](#) de la sección 7.

Bibliografía: Zwingmann, T. (2024), *Inteligencia empresarial basada en IA (AI-Powered Business Intelligence)*, O'Reilly Media; Calvo, J. & Escapa, C. (2025), *The AI Driven Business*, Libros de Cabecera; *Ethics guidelines for trustworthy AI*, Comisión Europea; *Metodología CRISP-DM en ciencia de datos*, Instituto de Ingeniería del Conocimiento.

Glosario

Término	Inglés	Definición en una línea
Business Intelligence (BI)	<i>Business Intelligence</i>	Disciplina que describe el pasado con métricas, reportes y dashboards de forma predecible.
Machine Learning	<i>Machine Learning</i>	Capacidad de un sistema de aprender patrones desde datos para predecir o clasificar.
Viabilidad de un proyecto de IA	<i>AI project feasibility</i>	Grado en que un proyecto es ejecutable según datos, infraestructura, capacidades y ética.
Gobernanza de datos	<i>Data governance</i>	Conjunto de reglas y procesos que aseguran datos disponibles, consistentes y confiables.
Vórtice digital	<i>Digital vortex</i>	Idea de que la disrupción tecnológica arrastra a transformarse a quien no se adapta.
CRISP-DM	<i>Cross-Industry Standard Process for Data Mining</i>	Metodología cíclica de 6 fases para estructurar proyectos de minería de datos e IA.
Comprensión del negocio	<i>Business Understanding</i>	Fase de CRISP-DM que define el objetivo de negocio y lo traduce a un problema de datos.
Comprensión de los datos	<i>Data Understanding</i>	Fase de CRISP-DM que explora qué datos hay, su calidad y si contienen la señal buscada.
Preparación de los datos	<i>Data Preparation</i>	Fase de CRISP-DM de limpieza, integración, transformación y etiquetado de datos.
Modelado	<i>Modeling</i>	Fase de CRISP-DM donde se entrenan los algoritmos.
Evaluación (fase CRISP-DM)	<i>Evaluation</i>	Fase de CRISP-DM que mide si el modelo cumple el objetivo de negocio, no solo el técnico.
Despliegue	<i>Deployment</i>	Fase de CRISP-DM que pone el modelo en producción para

		generar valor.
Marco 4V	<i>4V framework</i>	Herramienta que evalúa datos según volumen, variedad, velocidad y veracidad.
Volumen	<i>Volume</i>	Cantidad de observaciones (filas) y profundidad de atributos de los datos.
Variedad	<i>Variety</i>	Grado en que los datos representan todos los escenarios, incluidos los eventos raros.
Velocidad	<i>Velocity</i>	Frecuencia con que los datos se actualizan; a mayor velocidad, más riesgo de deriva.
Veracidad	<i>Veracity / Ground Truth</i>	Dimensión que mide si los datos tienen etiquetas correctas; la más crítica en aprendizaje supervisado.
Valor (5ª V)	<i>Value</i>	Quinta V del Big Data: el retorno o utilidad que los datos aportan al negocio.
Datos no estructurados	<i>Unstructured data</i>	Texto, imágenes o audio que requieren preprocesamiento para volverse tablas.
Aprendizaje supervisado	<i>Supervised learning</i>	Aprendizaje a partir de ejemplos etiquetados con la respuesta correcta.
Deriva de datos	<i>Data Drift</i>	Cambio de los datos de producción respecto a los de entrenamiento, que degrada la precisión.
Deriva de concepto	<i>Concept drift</i>	Cambio en la relación entrada→salida, que invalida el patrón aprendido por el modelo.
Fabricar o comprar	<i>Make or Buy</i>	Decisión de desarrollar la IA internamente o adquirir servicios externos.
IA como Servicio	<i>IaaS</i>	Consumo de modelos preentrenados vía API; rápido pero con bajo control.
Plataforma como Servicio	<i>PaaS</i>	Plataforma gestionada para entrenar modelos propios sin operar la infraestructura.
Infraestructura como Servicio	<i>IaaS</i>	Arriendo de cómputo donde la empresa gestiona modelos, pipelines y herramientas.
Propiedad Integral	<i>On-premise</i>	Gestión totalmente interna de infraestructura, datos y modelos; control y costo máximos.
AutoML	<i>AutoML</i>	Automatización del entrenamiento y selección de modelos de machine learning.
Capa de usuario	<i>User layer</i>	Capa donde personas o sistemas interactúan con la solución (dashboard, chatbot, API).
Capa de análisis	<i>Analytics layer</i>	Núcleo donde se ejecutan los modelos de machine learning y reglas de negocio.
Capa de datos	<i>Data layer</i>	Fuentes y procesos que preparan los datos antes de usarlos.
Dashboard	<i>Dashboard</i>	Panel visual que presenta resultados e indicadores al usuario final.
Chatbot	<i>Chatbot</i>	Interfaz conversacional cuyo flujo bidireccional genera datos para reentrenar el modelo.
API	<i>API</i>	Interfaz que permite a sistemas consumir o exponer servicios y datos.

ERP	<i>Enterprise Resource Planning</i>	Sistema empresarial que integra procesos como finanzas, inventario y operaciones.
CRM	<i>Customer Relationship Management</i>	Sistema que gestiona la relación e historial con los clientes.
Detección de anomalías	<i>Anomaly detection</i>	Técnica que identifica observaciones que se desvían del comportamiento esperado.
Criticidad ética	<i>Ethical criticality</i>	Dimensión que mide si la IA afecta el bienestar, la libertad o la vida de las personas.
Criticidad de la privacidad	<i>Privacy criticality</i>	Dimensión que mide cuán personales y sensibles son los datos utilizados.
Datos personales / sensibles	<i>Personal / sensitive data</i>	Información que identifica a una persona o revela aspectos íntimos de ella.
Sesgo	<i>Bias</i>	Patrón injusto que el modelo aprende de datos históricos y tiende a perpetuar.
Discriminación algorítmica	<i>Algorithmic discrimination</i>	Trato desigual e injusto producido por un modelo a partir de sus sesgos.
IA explicable	<i>Explainable AI (XAI)</i>	Enfoque que permite justificar y entender las decisiones de un modelo.
IA fiable	<i>Trustworthy AI</i>	IA legal, ética y robusta según los 7 requisitos de la Comisión Europea.
Hoja de ruta priorizada	<i>Prioritized roadmap</i>	Plan que ordena casos de uso según impacto y viabilidad.
Matriz impacto-viabilidad	<i>Impact-feasibility matrix</i>	Matriz que ubica cada caso según valor de negocio y facilidad de implementación.
Campeones	<i>Champions</i>	Casos de alto impacto y alta viabilidad; prioridad número uno.
Victorias rápidas	<i>Quick Wins</i>	Casos de alta viabilidad pero impacto menor; generan confianza rápido.
Casos de investigación	<i>Research cases</i>	Casos de alto impacto pero baja viabilidad actual; se mantienen en el radar.
Reevaluar más tarde	<i>Reassess later</i>	Casos de bajo impacto y baja viabilidad; consumen recursos sin aportar valor.
Scoring de crédito	<i>Credit scoring</i>	Uso de IA para evaluar y automatizar la aprobación de créditos.
Predicción de fuga de clientes	<i>Churn prediction</i>	Modelo que anticipa qué clientes abandonarán el servicio.
Sistemas legacy	<i>Legacy systems</i>	Sistemas heredados y obsoletos cuyos datos suelen tener baja veracidad.

Mapa conceptual

Viabilidad de proyectos de IA (Unidad 2)

- 1. Del BI a la inteligencia para decidir
 - Business Intelligence (BI) – describe el pasado, predecible
 - IA para decidir – predice/recomienda, incierta

- | └─ [se apoya en] Unidad 1: dónde la IA crea valor
- └─ 2. Dar prioridad a los datos
 - | └─ Preguntas fundamentales (disponibilidad, permiso, propiedad, histórico)
 - | └─ Gobernanza de datos – a veces el proyecto real es de datos, no de IA
- └─ 3. CRISP-DM (proceso cíclico, 6 fases)
 - | └─ Comprensión del negocio ≠ Comprensión de los datos
 - | └─ Preparación → Modelado → Evaluación → Despliegue
 - | └─ [datos en el centro] Figura 1 (IBM SPSS)
 - | └─ △ límite: no cubre post-despliegue → MLOps / TDSP
- └─ 4. Marco 4V (evalúa la materia prima)
 - | └─ Volumen (filas × atributos)
 - | └─ Variedad (representatividad, eventos raros, datos no estructurados)
 - | └─ Velocidad (actualización → riesgo de Deriva de datos)
 - | └─ Veracidad / Ground Truth (etiquetas → aprendizaje supervisado)
 - | └─ Figura 2 (radar, Zwingmann 2024)
 - | └─ △ 5 V del Big Data (agrega Valor)
- └─ 5. Fabricar o comprar (make or buy) – espectro de control
 - | └─ AIaaS (API, bajo control)
 - | └─ PaaS (modelos propios, sin infraestructura; AutoML)
 - | └─ IaaS (arrenda cómputo, alto control)
 - | └─ On-premise (todo interno, control total)
- └─ 6. Arquitectura en 3 capas
 - | └─ Capa de usuario (dashboard, chatbot, API)
 - | └─ Capa de análisis (ML: clasificadores, recomendación, anomalías)
 - | └─ Capa de datos (ERP, CRM, sensores; limpieza/etiquetado)
- └─ 7. Consideraciones éticas
 - | └─ Criticidad ética (impacto en las personas)
 - | └─ Criticidad de la privacidad (sensibilidad de los datos)
 - | └─ Sesgos → Discriminación algorítmica (Amazon 2018, COMPAS 2016)
 - | └─ Figura 3 (matriz criticidad, Zwingmann 2024)
 - | └─ △ EU Trustworthy AI: 3 componentes, 7 requisitos
- └─ 8. Hoja de ruta priorizada (matriz Impacto × Viabilidad)
 - | └─ Campeones (alto/alto) – prioridad 1
 - | └─ Victorias rápidas (viable/impacto menor)
 - | └─ Casos de investigación (alto impacto/baja viabilidad)
 - | └─ Reevaluar más tarde (bajo/bajo)
- └─ 9. Caso integrador: scoring de crédito
 - | └─ 4V: Volumen alto, Veracidad baja (sistemas legacy)
 - | └─ Arquitectura: PaaS (control del modelo)
 - | └─ Ética: máxima criticidad → IA explicable (XAI)
 - | └─ Matriz: caso de investigación → pivote a churn (Champion)

Notas de discrepancia △

△ **Discrepancia 1 — CRISP-DM y el post-despliegue.** El curso presenta CRISP-DM con 6 fases que terminan en el **despliegue** (correcto y vigente). Pero la práctica actual señala que **no cubre** el monitoreo, reentrenamiento, versionado y gestión de la deriva posteriores; eso lo abordan **MLOps** y **TDSP** (Microsoft). Regla de examen: fases de CRISP-DM = **6, terminan en Deployment**; operación continua de modelos = **MLOps**.

△ **Discrepancia 2 — 4V del curso vs. 5V del Big Data.** El cuerpo usa **4V** (volumen, variedad, velocidad,

veracidad); el material complementario usa **5V** (agrega **Valor**). El modelo original fue de **3V** de **Doug Laney (2001, META Group)** —no Gartner, que lo compró en 2005); la **Veracidad** la añadió IBM después. Regla de examen: en este curso, evaluar datos = **4V**; "las V del Big Data" = **5V** con Valor.

⚠ **Discrepancia 3 — Ética en 2 dimensiones vs. 7 requisitos europeos.** El curso reduce la ética a **crítica ética y crítica de privacidad** (útil para priorizar). El estándar citado —EU *Ethics Guidelines for Trustworthy AI*, 2019— define **3 componentes** (legal, ética, robusta) y **7 requisitos**. Regla de examen: para clasificar crítica, usa las **2 dimensiones**; si preguntan por el marco de IA fiable europeo, son **7 requisitos**.

⚠ **Discrepancia 4 — AlaaS y los modelos de nube NIST.** El curso trata **AlaaS, PaaS, IaaS y on-premise** como cuatro enfoques. En NIST, los modelos de nube son **IaaS/PaaS/SaaS**; **AlaaS** no es categoría NIST (una API de IA se comporta como **SaaS** especializado; una plataforma de ML gestionada, como **PaaS**). El orden de control del curso (**AlaaS < PaaS < IaaS < On-premise**) es correcto.