

Unidad 6 · Del prototipo a la producción

Dar los siguientes pasos: escalar, automatizar y operar soluciones de IA

Explicación completa del módulo — cubre el 100% de los conceptos del material · Universidad del Desarrollo / eClass

Dónde encaja esta unidad. Durante todo el curso trabajaste en la fase de *descubrimiento*: formular una hipótesis de negocio, explorar los datos, entrenar un modelo y comprobar en un prototipo que la IA aportaba valor. Esta unidad es el puente hacia lo que viene después de que el prototipo funciona: convertir ese experimento en un **producto que opera solo, todos los días, sin que nadie lo empuje a mano**. Es una unidad deliberadamente poco matemática y muy de ingeniería de sistemas y de organización: aquí el enemigo no es el error del modelo, sino la fricción de llevarlo a la realidad. Verás la distinción descubrimiento/entrega, los cuatro atributos que un sistema debe ganar para producción (escalabilidad, fiabilidad, rendimiento, mantenibilidad), las cinco dimensiones que hay que coordinar (personas, procesos, datos, tecnología, MLOps), la anatomía de un *pipeline* automatizado de IA, y un caso de retención de clientes que hilvana todo. Sigo el orden exacto del material y explico cada término con su nombre técnico, su porqué, su mecanismo, una analogía y un ejemplo concreto.

1 Conceptos clave del módulo

El material abre fijando seis términos que se usarán durante toda la unidad. Vale la pena dominarlos desde el inicio porque son el vocabulario con el que se discute todo lo demás. Los explico uno por uno, con más profundidad que la definición de una línea que trae la slide.

1.1 Descubrimiento *Discovery*

El **descubrimiento (discovery)** es la fase del proyecto centrada en la **rapidez por sobre la precisión**, cuyo objetivo es validar si existe información valiosa o señales predictivas en los datos. Dicho de otro modo: no busca construir bien, busca averiguar rápido si *vale la pena* construir.

Por qué existe: la mayoría de las ideas de datos suenan bien en una reunión y mueren al contacto con los datos reales. El descubrimiento es un filtro barato para matar temprano las malas ideas y confirmar las buenas antes de invertir en ingeniería cara. Su métrica no es "qué tan exacto es el modelo" sino "¿aprendimos si esto tiene futuro?".

Analogía

Es la cata en la cocina, no el servicio del restaurante. El chef prueba una salsa con una cuchara para decidir si la receta funciona: usa una muestra chica, la hace rápido, y si no sirve la bota sin drama. Nadie le exige que esa

cucharada esté emplatada para 200 comensales. Eso viene después.

Ejemplo

Tomas 10.000 filas de clientes en una planilla, entrenas un modelo en tu notebook en una tarde y ves que predice el abandono con una señal razonable. No está conectado a nada, corre solo cuando tú aprietas "play", y los datos los bajaste a mano. Perfecto: en descubrimiento eso es el éxito.

1.2 Entrega **Delivery**

La **entrega (delivery)** es la fase centrada en la **estabilidad, la integración y el escalamiento** del modelo para su uso diario por parte de los usuarios finales. Si el descubrimiento pregunta "¿sirve?", la entrega responde "hagámoslo funcionar para siempre, para todos y sin supervisión".

El giro de prioridades: lo que en descubrimiento era virtud (ir rápido, tomar atajos, hacer cosas a mano) en entrega es defecto. Aquí las prioridades se invierten: la precisión de la prueba ya no basta; ahora importan la consistencia, la seguridad y que el sistema aguante el uso real. Toda esta unidad trata, en el fondo, de qué cambia cuando cruzas esa frontera.

Analogía

Es pasar de la cucharada de salsa al restaurante abierto siete días a la semana: misma receta, pero ahora necesitas proveedores estables, cocina industrial, protocolo de higiene, personal que la reproduzca igual cada noche y que no colapse un sábado lleno. La receta era el 10% del problema; el restaurante es el otro 90%.

1.3 Mini trabajo ETL **ETL**

El material define **ETL** como un proceso automatizado que *lee los datos, los envía a un servicio de IA, transforma los resultados y los exporta de forma estructurada*. ETL son las siglas de **Extracción, Transformación y Carga (Extract, Transform, Load)**: el patrón clásico para mover datos desde donde nacen hasta donde se consumen, limpiándolos por el camino. Es el ladrillo con el que se construye toda la automatización que verás en la sección de *pipelines*.

Las tres letras: **Extraer** = sacar los datos de su fuente (una base, un archivo, una API). **Transformar** = limpiarlos, corregirlos, darles el formato que el destino necesita (y, en la versión de este curso, pasarlos por el modelo de IA). **Cargar** = depositar el resultado en su destino final (una tabla, un tablero, un repositorio).

Analogía

Es la cadena de una planta de jugos. *Extraer:* llegan camiones con naranjas de distintos huertos. *Transformar:* se lavan, se descartan las podridas, se exprimen, se estandariza el dulzor. *Cargar:* el jugo terminado se embotella y se pone en la góndola, listo para consumir. Nadie toma naranjas directo del camión; nadie alimenta un tablero con datos crudos.

⚠ Hay una actualización importante frente a este término (ETL vs. ELT) que desarrollo en la sección de discrepancias; el curso usa "ETL" en sentido amplio y es correcto para el examen, pero conviene conocer su primo moderno.

1.4 Operación asíncrona **Asynchronous operation**

La **operación asíncrona (asynchronous operation)** es un método de comunicación con servicios de IA donde **la respuesta no es inmediata**: se requiere una solicitud para enviar los datos y otra posterior para recuperar los

resultados una vez procesados. No preguntas y esperas colgado del teléfono; dejas el pedido y vuelves a buscarlo cuando está listo.

Por qué existe: muchos servicios de IA —transcribir un audio largo, analizar miles de comentarios, generar imágenes— tardan segundos o minutos. Si tu programa se quedara *bloqueado* esperando (modo **síncrono**), colapsaría en cuanto haya volumen. Lo asíncrono desacopla el "pedir" del "recibir", y así el sistema sigue trabajando mientras el resultado se cocina.

Analogía

Es la panadería con número de atención. *Síncrono* sería quedarte parado en el mesón mirando al panadero hasta que salga tu pan, bloqueando la fila. *Asíncrono* es sacar un número (primera solicitud), irte a hacer otras compras, y volver cuando llaman tu número a retirar (segunda solicitud). La panadería atiende a muchos a la vez porque nadie bloquea el mesón.

Ejemplo

Envías 5.000 comentarios a un servicio de análisis de sentimiento. Solicitud 1: "procesa este lote", y el servicio responde al instante con un `id_trabajo: 8842`. Tu sistema sigue con otras tareas. Dos minutos después, Solicitud 2: "¿está listo el 8842?" → el servicio devuelve los 5.000 resultados clasificados.

1.5 Deuda técnica **Technical debt**

La **deuda técnica (technical debt)**, según el curso, es el **costo futuro de mantener, actualizar e integrar** servicios de IA que se añaden a un ecosistema de negocios. Cada atajo que tomas hoy para salir rápido —un pegote de código, una conexión frágil, una configuración sin documentar— es un préstamo: te acelera ahora, pero cobra intereses después, cada vez que alguien tiene que tocar el sistema.

Por qué importa especialmente en IA: un sistema de IA no es solo código; es código + datos + modelo + servicios externos, todos cambiando. Eso multiplica los intereses de la deuda respecto de un software tradicional. La slide da la versión de una línea; en la sección de discrepancias amplío con el concepto canónico de la literatura (Sculley et al., Google, 2015), que es más rico y muy pedible en un examen.

Analogía

Es la tarjeta de crédito. Comprar hoy con la tarjeta (tomar el atajo) te resuelve el momento, pero si solo pagas el mínimo, los intereses crecen hasta que la cuota mensual te ahoga. La deuda técnica es exactamente eso, pero en código: cómoda de contraer, cara de arrastrar.

1.6 Inferencia por lotes **Batch inference**

La **inferencia por lotes (batch inference)** es la ejecución de predicciones sobre **grandes conjuntos de datos almacenados**, en contraposición a la inferencia en tiempo real. "Inferencia" es simplemente el acto de *usar* un modelo ya entrenado para producir una predicción (distinto de "entrenar", que es construirlo). "Por lotes" significa que juntas muchos casos y los procesas todos de una pasada, en un horario, en vez de uno por uno al instante.

El contraste que debes tener claro: la **inferencia en tiempo real (real-time / online inference)** responde caso a caso en milisegundos (el banco aprueba o rechaza *esta* transacción ahora). La inferencia por lotes procesa millones de casos juntos cuando no hay apuro (cada noche, calcula el riesgo de abandono de *toda* la cartera). Elegir bien entre ambas es una decisión de arquitectura central en producción.

Analogía

Batch es lavar toda la ropa de la semana el domingo en una sola tanda de lavadora: eficiente, barato por prenda, pero la ropa del lunes tiene que esperar al próximo domingo. Tiempo real es lavar a mano cada prenda apenas te la sacas: inmediato, pero carísimo si tienes que hacerlo mil veces al día.

Ejemplo

La telco del caso corre su modelo de churn *en batch*: cada madrugada procesa los 2.000.000 de clientes y deja actualizada una tabla con el riesgo de cada uno. El equipo comercial la consulta durante el día. No necesita saber el riesgo "al segundo"; necesita la foto fresca cada mañana. Batch es la elección correcta.

2 Descubrimiento versus entrega

Esta es la columna vertebral conceptual de la unidad. Hasta este punto del curso trabajaste principalmente en descubrimiento. En esa etapa el objetivo **no es construir sistemas perfectos, sino validar hipótesis de negocio y comprobar si la inteligencia artificial puede generar valor real para la organización**. El propósito es aprender con rapidez, experimentar y detectar tempranamente si una idea tiene potencial o si debe descartarse.

2.1 Las cuatro preguntas del descubrimiento

Durante el descubrimiento se busca responder cuatro preguntas fundamentales. Vale la pena leerlas como un embudo: si alguna falla, la idea probablemente no merece llegar a producción.

- **¿Existe realmente un problema de negocio relevante?** — que duela lo suficiente como para justificar la inversión.
- **¿Los datos disponibles permiten abordarlo?** — sin datos con señal, no hay modelo que valga.
- **¿La solución genera beneficios medibles?** — valor que se pueda cuantificar, no solo intuir.
- **¿Los usuarios encuentran valor en los resultados?** — si nadie usa la predicción, no sirve de nada.

En esta etapa **es aceptable** usar procesos manuales, muestras reducidas de datos y soluciones temporales. Lo importante es validar la oportunidad y reducir la incertidumbre. Esa tolerancia al "hecho a mano" es precisamente lo que hay que desmontar al pasar a producción.

2.2 La frontera: un prototipo exitoso no es una solución lista

Aquí está la idea más importante de la sección, y una de las que más huele a examen: **un prototipo exitoso no debe confundirse con una solución lista para producción**. Que la cata de salsa haya salido rica no significa que el restaurante esté listo para abrir. Cuando una iniciativa demuestra valor y empieza a generar interés dentro de la organización, entra en una etapa nueva: la **entrega**.

La entrega implica transformar una **prueba de concepto (proof of concept, PoC)** en un producto empresarial capaz de operar de manera confiable, segura y sostenible. Para ello es necesario **rediseñar** —no solo "pulir"— muchos de los componentes contruidos durante la experimentación, con el fin de asegurar cuatro cualidades: **escalabilidad, rendimiento, mantenibilidad y seguridad**. La palabra clave es rediseñar: buena parte del código del prototipo se bota y se vuelve a hacer bien, y eso no es un fracaso, es el proceso normal.

Huele a examen

Un prototipo valida *si la idea sirve*; la entrega asegura que *funcione siempre, para todos y sin supervisión*. El prototipo prioriza rapidez sobre precisión; la producción prioriza estabilidad, integración y escalamiento. Confundir ambos —creer que porque el notebook corrió una vez ya está listo— es el error que hace fracasar proyectos de IA.

3 Los desafíos de llevar la IA a la producción

El material arranca esta sección con una afirmación fuerte y verdadera: **la mayoría de los proyectos de IA fracasan no porque sus modelos sean incorrectos, sino porque la organización no logra operacionalizarlos adecuadamente**. La otra causa poderosa es la **calidad de los datos**: datos de mala calidad generan malos resultados, por muy bueno que sea el modelo (el clásico *garbage in, garbage out*). Un modelo que funciona en un entorno experimental debe luego integrarse en los procesos operativos de la empresa: automatizar la obtención de datos, controlar accesos, garantizar la calidad de la información, monitorear el rendimiento y asegurar que los resultados lleguen oportunamente a quienes deciden.

Dato que respalda la afirmación

La cifra exacta varía según la fuente y la metodología, pero el orden de magnitud es real: distintos análisis de la industria estiman que entre un 70% y un 90% de los proyectos de IA/ML no llegan a producción o no entregan el valor esperado. Gartner popularizó la cifra de que cerca del **85% de los proyectos de IA "fallan"**, y estudios más recientes sobre pilotos de IA generativa reportan tasas de fracaso igual de altas. Casi siempre la causa raíz no es el algoritmo, sino datos, integración y operación: exactamente lo que trata esta unidad. [confirmado por búsqueda, jul-2026]

Por esta razón, la transición hacia producción exige evaluar **cuatro atributos fundamentales**. Son cuatro lentes distintos para mirar la misma pregunta: "¿aguanta esto el mundo real?".

3.1 Escalabilidad **Scalability**

La **escalabilidad (scalability)** es la capacidad de una solución de IA para **crecer sin perder calidad operativa**. En un prototipo puede bastar con procesar una muestra pequeña para atender a pocos usuarios; en producción, la solución debe soportar mayor volumen de información, mayor frecuencia de uso y más áreas de la organización. El material la desglosa en tres niveles, y esa estructura de tres niveles es muy examinable:

Nivel	Qué debe aguantar	Ejemplo del salto prototipo → producción
Datos	Pasar de cientos o miles a millones de registros sin que el procesamiento se vuelva inviable.	De 10.000 filas en una planilla a 5.000.000 de registros diarios en una base.
Usuarios	Que el panel o la aplicación siga funcionando aunque lo consulten muchas personas al mismo tiempo.	De 3 analistas que abren un notebook a 500 usuarios de negocio consultando el mismo tablero a la vez.
Procesos	Que la solución pueda ejecutarse periódicamente: cada día, cada hora o cada vez que ingresan nuevos datos.	De correr "cuando me acuerdo" a un proceso agendado que se dispara solo cada madrugada.

La regla práctica: una solución con demasiadas acciones manuales **no escala**. Si el flujo depende de que una persona descargue archivos, los cargue en una plataforma, ejecute un notebook y luego actualice un *dashboard*, ese cuello de botella humano revienta apenas crece el volumen. La solución escalable usa **pipelines automáticos**, infraestructura adecuada y procesos estandarizados (justo lo que verás en la sección 5).

Analogía

Es la diferencia entre el puesto de completos de la esquina y una cadena de comida rápida. El puesto funciona porque el dueño hace todo a mano; sirve a 30 personas al día. Si mañana llegan 3.000, el dueño no da abasto: no es cosa de que corra más rápido, hay que rediseñar la operación con cocina en línea, procesos y varias sucursales. Escalar no es "hacer lo mismo más fuerte", es hacerlo distinto.

3.2 Fiabilidad **Reliability**

La **fiabilidad (reliability)** es la capacidad de una solución para **operar de forma estable y producir resultados consistentes**. No basta con que el modelo funcione una vez; debe funcionar correctamente *cada vez* que se ejecuta. Un prototipo tiene permiso de fallar; un sistema en producción, del que depende gente para decidir, no.

Cómo falla un sistema en producción: por motivos que nada tienen que ver con la calidad del modelo — cambios en la estructura de los datos, caídas de una API, errores en una conexión, problemas de permisos, falta de recursos computacionales o respuestas inesperadas del modelo. Una solución fiable **anticipa** estos escenarios con mecanismos de control: validar los datos de entrada, registrar errores (**logging**), generar alertas, mantener respaldos y definir qué ocurre cuando el sistema falla.

Ejemplo del material

Si un modelo de churn no puede ejecutarse por un problema en la fuente de datos, el equipo responsable debe **saberlo rápidamente** (una alerta salta) y contar con un procedimiento para corregirlo. La alternativa —que el tablero muestre datos viejos durante una semana sin que nadie se entere— es exactamente lo que la fiabilidad busca evitar.

La fiabilidad también incluye la **estabilidad de los resultados**. Si el modelo empieza a entregar predicciones incoherentes, cambia drásticamente su comportamiento o empeora su precisión, el sistema debe detectarlo. Por

eso el **monitoreo (monitoring)** es central en las soluciones de IA productivas: es el signo vital que avisa que algo se está descomponiendo antes de que el daño llegue al negocio.

Analogía

Un avión no vuela porque el piloto sea genial una vez; vuela porque tiene redundancia, listas de chequeo, alarmas y procedimientos para cada falla imaginable. La fiabilidad es esa cultura de "asumir que algo va a fallar y estar listo", trasladada al software.

3.3 Rendimiento **Performance**

El **rendimiento (performance)** se refiere a la **velocidad y eficiencia** con que la solución responde o procesa información. Una solución puede ser técnicamente correcta pero resultar *inútil si tarda demasiado* en entregar resultados. En IA y BI el rendimiento se observa en varios puntos: un dashboard debe cargar rápido, una consulta debe responder en segundos, un pipeline debe terminar dentro de una ventana operativa razonable, y un modelo predictivo debe generar resultados a tiempo para que se usen en la decisión.

Ejemplo del material

Si una empresa quiere detectar clientes con alta probabilidad de abandono **antes** de lanzar una campaña comercial, el modelo debe entregar las predicciones antes de que la campaña se ejecute. Si el procesamiento termina tarde —la campaña ya salió—, el valor de la solución cae a cero, aunque la predicción sea perfecta. El rendimiento no es un lujo técnico; es lo que hace que el resultado *llegue a tiempo para importar*.

Un matiz contraintuitivo: mejorar el rendimiento **no siempre significa usar más tecnología**. Muchas veces implica *simplificar* consultas, preprocesar datos, optimizar modelos o eliminar pasos innecesarios. El rendimiento depende de varios factores: tamaño de los datos, complejidad del modelo, eficiencia del código, arquitectura de datos, capacidad computacional y diseño del dashboard. Comprar un servidor más grande es la solución perezosa; a menudo la buena es podar lo que sobra.

Analogía

Un plato exquisito que llega frío y dos horas tarde es un mal plato. En la cocina, la rapidez no es opcional: es parte de la calidad. Y el cocinero experto no cocina "con más fuego", sino con mejor *mise en place* —todo preparado y ordenado de antemano— que es justamente "preprocesar datos".

3.4 Mantenibilidad **Maintainability**

La **mantenibilidad (maintainability)** es la facilidad con que una solución puede **corregirse, actualizarse y evolucionar** después de ser desplegada. El material la señala como *una de las diferencias más importantes entre un prototipo y un producto real*, y con razón: un prototipo suele construirse rápido, por una o pocas personas, con código poco documentado, decisiones implícitas, archivos manuales y configuraciones difíciles de reproducir. Eso es aceptable en exploración, inaceptable en producción.

Una solución mantenible debe estar **documentada, ordenada y diseñada para que otras personas puedan entenderla**. Debe dejar claro: de dónde vienen los datos, qué transformaciones se aplican, qué modelo se utiliza, cómo se actualiza, qué supuestos tiene y qué hacer si algo falla.

Modularidad

La mantenibilidad implica **modularidad (modularity)**: que cada componente cumpla una función clara —extracción, transformación, entrenamiento, inferencia, almacenamiento y visualización— de modo que si cambia una fuente de datos o se reemplaza un modelo, **no haya que reconstruir toda la solución**, solo la pieza afectada. Es diseñar el sistema en bloques desmontables en lugar de un monolito soldado.

Analogía

Modularidad es LEGO, no una escultura de mármol. Si a tu nave de LEGO le quieres cambiar el ala, sacas esa pieza y pones otra. En una escultura de mármol, cambiar un dedo te obliga a arriesgar toda la obra. El software modular te deja reemplazar el "ala" (el modelo, la fuente) sin rehacer la "nave" completa.

Por qué los modelos "envejecen"

En IA la mantenibilidad es especialmente crítica porque **los modelos envejecen**: los datos cambian, el negocio cambia, y decisiones que antes eran correctas dejan de serlo. Por eso una solución de IA debe estar preparada para ajustes, **reentrenamientos** y nuevas versiones. Este envejecimiento tiene nombre técnico —*data drift* y *concept drift*— que el curso ilustra con el ejemplo de la pandemia (sección 4.5) pero no bautiza; lo hago yo en la sección de discrepancias, porque es vocabulario que un especialista debe manejar.

Huele a examen

Los cuatro atributos, en una frase cada uno: **escalabilidad** = crecer sin perder calidad; **fiabilidad** = operar estable y consistente, detectando fallas; **rendimiento** = ser rápido y eficiente, entregar a tiempo; **mantenibilidad** = poder corregirse, actualizarse y evolucionar (documentación + modularidad). En conjunto, estos cuatro permiten que una solución de IA deje de ser un prototipo funcional y se convierta en una herramienta preparada para operar en condiciones reales.

4 Criterios de éxito: las cinco dimensiones de la entrega

Si la sección anterior mira el sistema (¿aguanta?), esta mira la **organización** (¿está lista la empresa para sostenerlo?). El material plantea que la implementación exitosa de soluciones de IA requiere equilibrar **cinco dimensiones que deben evolucionar de manera conjunta**. La palabra "conjunta" es clave: si una avanza y las otras se quedan, el sistema cojea.

No confundir con los cuatro atributos

Ojo con un punto que confunde a mucha gente: los **cuatro atributos** (sección 3) y las **cinco dimensiones** (esta sección) son dos marcos distintos, no una lista de nueve cosas. Los atributos describen *calidades técnicas del sistema*; las dimensiones describen *frentes de la organización que hay que coordinar*. Son dos lentes complementarios sobre el mismo problema. Es un cruce clásico de examen.

4.1 Personas **People**

La IA es, ante todo, un **proyecto organizacional**. Durante el prototipado puede participar un equipo reducido; pero cuando la solución avanza hacia producción, suelen incorporarse nuevas áreas: tecnología, infraestructura, seguridad, **gobernanza de datos**, áreas legales, patrocinadores de negocio y usuarios finales. Una gestión adecuada de **stakeholders** (todas las partes interesadas y afectadas por el proyecto) permite alinear expectativas, conseguir recursos y reducir la resistencia al cambio.

El material propone una herramienta concreta: clasificar a los actores según **dos dimensiones — nivel de influencia sobre el proyecto y nivel de interés en los resultados**. Esto permite definir estrategias de comunicación diferenciadas para patrocinadores, usuarios finales, equipos técnicos y áreas de soporte.

Nombre técnico (enriquecimiento)

Esa clasificación por influencia × interés es la **matriz de poder-interés de Mendelow** (power-interest matrix), un clásico de la gestión de proyectos. Sus cuatro cuadrantes dictan la estrategia: **alta influencia + alto interés** → gestionar de cerca (los jugadores clave, p. ej. el patrocinador ejecutivo); **alta influencia + bajo interés** → mantener satisfechos (p. ej. legal o seguridad); **baja influencia + alto interés** → mantener informados (p. ej. usuarios finales); **baja influencia + bajo interés** → monitorear con esfuerzo mínimo.

Analogía

Es como organizar un matrimonio. No tratas igual a los novios (alta influencia, alto interés: decides todo con ellos), a la tía que paga parte de la fiesta pero no quiere involucrarse en los detalles (mantenerla satisfecha), a los invitados (mantenerlos informados de fecha y lugar) y al proveedor de servilletas (monitorear). Un proyecto de IA es esa boda: gestionar personas es la mitad del trabajo.

4.2 Procesos Processes

Los proyectos de IA **también son proyectos de software** y, por lo tanto, deben ajustarse a los procesos formales de la organización. Dependiendo del contexto, pueden existir **metodologías ágiles**, oficinas de gestión de proyectos (**PMO, Project Management Office**), marcos de gobernanza o estándares de calidad que condicionen cómo se desarrolla y mantiene la solución. La incorporación *temprana* de las áreas de tecnología y gobierno evita problemas posteriores de cumplimiento, seguridad o integración.

Analogía

Puedes cocinar como quieras en tu casa, pero si abres un local, apareces bajo las reglas del Servicio de Salud: cadena de frío, registros, inspecciones. No es burocracia por molestar; es lo que permite que un tercero confíe en tu comida. Los procesos son ese "código sanitario" del software.

4.3 Datos Data

Los datos son el **activo fundamental** de cualquier sistema de IA. Durante la fase experimental es común cargar archivos manualmente o trabajar con muestras limitadas. En producción, en cambio, los flujos de datos deben ser **automáticos, consistentes y auditables**. La organización debe garantizar cinco cosas:

- **Disponibilidad permanente** de los datos (que estén siempre ahí cuando el sistema los pida).
- **Calidad y consistencia** de la información (sin errores ni contradicciones entre fuentes).
- **Accesos controlados** (quién puede ver y tocar qué).
- **Cumplimiento de regulaciones** de privacidad y protección de datos.
- **Integración** con las plataformas corporativas existentes.

El cambio de estatus: de este modo, los datos dejan de ser simplemente *insumos* para un modelo y pasan a convertirse en un **componente crítico de la operación**. Esto se apoya en el rol de los datos que trabajaste en módulos anteriores del curso, pero sube la vara: ya no basta con que los datos existan; deben fluir solos, limpios y vigilados.

4.4 Tecnología Technology

La infraestructura usada para crear prototipos **rara vez coincide** con la que se requiere en producción. Las plataformas productivas deben priorizar **seguridad, estabilidad, monitoreo y escalabilidad**. Por ello, muchas veces los componentes desarrollados durante la exploración deben reconstruirse o adaptarse antes de ser desplegados.

Huele a examen

La pregunta clave **no es qué tecnología usamos para crear el prototipo, sino qué tecnología necesitamos para operar la solución de forma sostenible durante los próximos años**. Es un cambio de horizonte: del "¿qué me sirve para probar hoy?" al "¿qué me va a aguantar años sin colapsar?".

Analogía

El andamio con que construyes una casa no es la casa. El andamio (la infraestructura del prototipo) es rápido de montar y sirve para levantar la obra, pero nadie vive en un andamio: es inseguro y provisorio. Para habitar hay que construir muros, instalación eléctrica certificada y cimientos. Confundir el andamio con la casa es el error tecnológico típico.

4.5 MLOps MLOps

MLOps (de *Machine Learning Operations*) es el conjunto de prácticas destinadas a **gestionar el ciclo de vida completo de los modelos de aprendizaje automático**. Su objetivo es garantizar que los modelos *continúen generando valor una vez desplegados*. Es, en esencia, aplicar al mundo de los modelos la misma disciplina que **DevOps** trajo al software tradicional: automatizar, versionar, monitorear y repetir de forma confiable. El material lista seis prácticas que lo componen:

Práctica	Qué resuelve
A. Versionamiento de modelos	Saber exactamente qué versión del modelo está corriendo y poder volver atrás si una nueva empeora.
B. Automatización de entrenamientos	Reentrenar sin que alguien lo haga a mano cada vez: el proceso se dispara solo.
C. Monitoreo del rendimiento	Vigilar en vivo si el modelo sigue acertando o se está degradando.
D. Detección de degradación	Alertar cuando la precisión cae porque la realidad cambió (drift).
E. Gestión de infraestructura	Administrar el cómputo, el almacenamiento y los servicios donde el modelo vive.
F. Reentrenamiento	Actualizar el modelo cuando cambian las condiciones del negocio o los datos.

El ejemplo de la pandemia (y su nombre técnico)

El material cierra con un ejemplo memorable: **la pandemia de COVID-19 mostró claramente la importancia de estas prácticas**. Muchos modelos que funcionaban correctamente comenzaron a deteriorarse porque *los patrones de comportamiento cambiaron drásticamente respecto de los datos con los que habían sido entrenados*. Un modelo de demanda entrenado con la vida pre-pandemia no tenía idea de qué hacer cuando, de un día para otro, todos dejaron de salir y empezaron a comprar papel higiénico por camiones.

Nombre técnico (enriquecimiento)

Ese fenómeno se llama **degradación del modelo (model decay)**, y sus dos causas tienen nombre propio: **data drift** (cambia la distribución de los datos de entrada — llegan clientes distintos) y **concept drift** (cambia la relación entre las entradas y lo que se predice — la misma persona ahora se comporta distinto). La pandemia fue el caso de libro de *concept drift*: la regla que conectaba "cómo es un cliente" con "qué va a comprar" se rompió de golpe. Lo desarrollo en discrepancias.

Analogía

MLOps es el mantenimiento del auto, no la compra del auto. Comprar el auto (entrenar el modelo) es un evento; mantenerlo andando —cambios de aceite, revisión técnica, alinear, avisar cuando algo suena raro— es lo que hace que sirva por años. Un modelo sin MLOps es un auto que nadie lleva nunca al taller: anda bien hasta que, un día, en la carretera, deja de andar.

Síntesis de la sección: cuando personas, procesos, datos, tecnología y MLOps evolucionan de manera coordinada, la organización reduce riesgos, asegura continuidad operativa y transforma la IA en una herramienta real de generación de valor. Ninguna de las cinco basta sola.

Preguntas de reflexión del material (pág. 11)

El módulo te invita a pensar tres preguntas, que ahora puedes responder con lo anterior: (1) *¿Por qué un prototipo exitoso no está necesariamente listo para producción?* → porque prototipo valida la idea, no garantiza escalabilidad, fiabilidad, rendimiento ni mantenibilidad. (2) *¿Cuál atributo es más crítico?* → depende del caso, pero la fiabilidad suele ser el piso: sin ella, nadie confía en el sistema. (3) *¿Por qué las cinco dimensiones deben evolucionar coordinadas?* → porque un frente rezagado (datos sucios, sin patrocinio, sin MLOps) hunde a los demás.

5 Automatización mediante pipelines de IA

Esta sección responde el "cómo" operativo de todo lo anterior. La IA productiva **automatiza el flujo de datos desde su origen hasta la toma de decisiones**. Para llevar la inteligencia artificial al entorno operativo, las organizaciones deben reemplazar las tareas manuales por **flujos automatizados** que abarcan desde la extracción y limpieza de datos hasta la ejecución de modelos y la visualización de resultados.

Un **pipeline (canalización de datos, data pipeline)** es precisamente eso: una tubería que conecta cada etapa, de modo que los datos avanzan solos de una a la siguiente sin intervención humana. El material subraya una idea de fondo: el verdadero valor de esta tecnología **no radica en usar herramientas aisladas, sino en integrar múltiples capas analíticas** (descriptiva, predictiva y diagnóstica) para transformar la información en una capacidad estratégica que impulse decisiones concretas.

5.1 Las seis etapas del flujo típico

Un flujo productivo típico incorpora seis etapas encadenadas. Nótese que las etapas 1 y 2 son el corazón del **ETL** que definimos en 1.3, la etapa 3 es el "cerebro" de IA, y las etapas 4-6 llevan el resultado hasta el usuario. Vale la pena memorizar la secuencia porque es la espina dorsal de la unidad.

#	Etapa	Qué ocurre y por qué importa
1	Extracción de datos desde fuentes corporativas	Se recopilan datos desde los sistemas de la organización — ERP (planificación de recursos, p. ej. SAP), CRM (gestión de clientes, p. ej. Salesforce), bases transaccionales, plataformas web o archivos. En ambientes productivos se ejecuta automáticamente mediante conexiones y procesos programados. Objetivo: obtener información relevante de forma consistente y confiable.
2	Preparación y transformación	Los datos extraídos suelen traer errores, duplicados, formatos inconsistentes o información incompleta. Se limpian, validan y transforman antes de alimentar a los modelos. Es la etapa que garantiza que la información sea consistente, confiable y adecuada para el análisis.
3	Ejecución de servicios o modelos de IA	Los datos ya preparados se envían a modelos de <i>machine learning</i> o servicios de IA para generar predicciones, clasificaciones, recomendaciones o análisis avanzados. Es el núcleo analítico de la solución. Puede involucrar modelos propios o servicios externos consumidos mediante APIs .
4	Conversión de resultados	Las respuestas de los modelos suelen venir en formatos técnicos poco interpretables por herramientas de negocio. Se transforman en tablas, indicadores o estructuras estandarizadas para que las plataformas de BI y los sistemas corporativos puedan consumirlas eficientemente.
5	Almacenamiento de resultados	Los resultados procesados se guardan en repositorios accesibles para otras aplicaciones, usuarios o procesos. Permite conservar históricos, hacer auditorías y reutilizar la información — y evita tener que ejecutar los modelos de nuevo cada vez que alguien quiere consultar el resultado.
6	Visualización y explotación	La información se presenta mediante dashboards , reportes o aplicaciones que facilitan la decisión. Los usuarios exploran resultados, identifican patrones, monitorean indicadores y actúan. <i>El valor de la IA se materializa aquí</i> : cuando el conocimiento se convierte en decisiones y acciones concretas.

Analogía

El pipeline es una línea de producción automatizada. La chapa entra por un extremo (extracción), se corta y limpia (preparación), pasa por la estación robótica que hace el trabajo pesado (ejecución del modelo), se ensambla en piezas reconocibles (conversión), se almacena en la bodega (almacenamiento) y sale el auto a la sala de ventas (visualización). Antes, un artesano hacía todo a mano, de a un auto; el pipeline hace mil, iguales, sin cansarse.

El caso de la IA generativa: cuando se usan servicios de **IA generativa**, **procesamiento de lenguaje natural (NLP)** o **visión computacional (computer vision)**, el flujo suele incluir además llamadas a **APIs externas** y mecanismos para gestionar **respuestas asíncronas** (justo la operación asíncrona de 1.4). La automatización permite reproducir análisis de forma consistente, reducir errores operativos y facilitar la escalabilidad — es decir, es el mecanismo que hace realidad los cuatro atributos de la sección 3.

5.2 Integrando capas analíticas para generar valor

Uno de los aprendizajes más importantes del módulo: los distintos servicios de IA **no deben verse como tecnologías aisladas**. Las mayores oportunidades aparecen cuando se combinan **múltiples capas analíticas** dentro de una misma solución. Por ejemplo, es posible transformar datos no estructurados en variables analíticas, que luego alimenten modelos predictivos, cuyos resultados finalmente se integren en paneles de BI para apoyar la decisión. Es el patrón exacto del caso de churn que viene en la sección 6.

El material enumera las capas que se apilan:

Capa	Qué aporta
Datos estructurados y no estructurados	La materia prima: tablas ordenadas (structured) + texto, audio, imagen libres (unstructured).
Analítica descriptiva	Responde <i>¿qué pasó?</i> — resume el pasado en indicadores (ventas del mes, tasa de abandono histórica).
Analítica diagnóstica	Responde <i>¿por qué pasó?</i> — busca causas y relaciones detrás de los números.
Analítica predictiva	Responde <i>¿qué va a pasar?</i> — proyecta el futuro (qué cliente abandonará).
Interfaces de usuario interactivas	La capa donde el negocio consume todo lo anterior y actúa (paneles, consultas en lenguaje natural).

La capa que el curso no menciona (enriquecimiento)

La progresión descriptiva → diagnóstica → predictiva tiene un cuarto peldaño estándar en la industria (el "modelo de ascendencia analítica" de Gartner): la **analítica prescriptiva**, que responde *¿qué debo hacer?* — no solo predice el abandono, sino que recomienda la acción óptima (a este cliente ofrécele un descuento; a este otro, una llamada). Es el destino natural del pipeline y vale la pena tenerlo en el radar. Lo detallo en discrepancias.

Conclusión de la sección: la automatización del flujo de datos y la conexión estratégica de múltiples capas analíticas permiten consolidar una **infraestructura robusta** que reduce errores y optimiza la toma de acciones. Así, la IA deja de ser una tecnología experimental y se convierte en una **capacidad empresarial integrada** en los procesos de decisión.

6 Caso aplicado: retención de clientes con IA e incrementos funcionales

El material aterriza toda la teoría en un caso que integra las tres capas (datos → analítica → usuario) y la estrategia de despliegue. Conviene leerlo como la síntesis práctica de la unidad.

El problema. Una empresa de telecomunicaciones enfrenta una creciente **pérdida de clientes**. Mes a mes, un número importante de usuarios cancela sus servicios, cambia de compañía o reduce la cantidad de productos contratados. El punto de dolor está en que *hasta ahora el equipo comercial solo revisaba reportes históricos de abandono*: sabía **cuántos** clientes se habían ido, pero no podía **anticipar quiénes** estaban en riesgo de hacerlo. Es la diferencia entre leer la autopsia y prevenir la enfermedad. La empresa decide avanzar hacia una solución

integrada de IA cuyo objetivo no es "usar IA por innovación", sino transformar información dispersa en decisiones concretas y accionables para marketing, ventas y experiencia de cliente.

6.1 Capa de datos

La organización reúne dos tipos de fuentes que, combinadas, dan una visión mucho más completa del cliente:

- **Datos estructurados:** contratos vigentes, antigüedad del cliente, información demográfica, historial de consumo, pagos mensuales, reclamos registrados, cambios de plan y uso de servicios adicionales. Permiten identificar patrones objetivos de comportamiento.
- **Datos no estructurados:** las **encuestas abiertas de satisfacción**, donde los clientes expresan libremente molestias y percepciones (problemas de cobertura, lentitud en la atención, cobros poco claros, insatisfacción con el soporte). Información valiosísima que *no puede analizarse fácilmente con métodos tradicionales si permanece solo como texto libre*.

La jugada: al combinar ambos tipos, la empresa ya no observa únicamente variables comerciales o transaccionales, sino también **señales asociadas a la experiencia, la percepción y el nivel de satisfacción**. Un cliente puede pagar puntual y consumir mucho —y aún así estar a un paso de irse porque está harto del servicio. Eso solo lo ves si escuchas lo que *dice*, no solo lo que *paga*.

6.2 Capa analítica

El equipo aplica **análisis de sentimiento (sentiment analysis)** para transformar las respuestas abiertas en **indicadores cuantificables**. Los comentarios se clasifican según su orientación —positiva, negativa o neutra— e incluso se asocian a temas específicos como precio, atención, calidad técnica o cobertura. Es el paso que convierte el texto libre (no estructurado) en variables numéricas que un modelo puede digerir: exactamente el patrón "no estructurado → variable analítica" de la sección 5.2.

Estos indicadores se integran a un **modelo predictivo de churn** — un modelo que estima la *probabilidad de que un cliente abandone la empresa en el futuro*. Al incorporar el sentimiento junto con las variables transaccionales, el modelo mejora su capacidad de anticipación.

Ejemplo del material + lectura numérica

El modelo puede detectar que un cliente con **alto consumo y pagos al día** igualmente presenta riesgo si sus comentarios muestran una percepción negativa sostenida del servicio. En números: sin sentimiento, ese cliente tendría un riesgo estimado de, digamos, 8%; al sumar tres encuestas seguidas con quejas de cobertura, el modelo lo reestima en 55%. Sin la capa de sentimiento, ese cliente rentable se habría ido sin que nadie lo viera venir.

El salto de mirada: esta capa permite pasar de una lectura **descriptiva** ("¿cuántos se fueron?") a una **predictiva** ("¿quiénes se van a ir y sobre cuáles conviene actuar con prioridad?"). La empresa deja de mirar el retrovisor y empieza a mirar el parabrisas.

6.3 Capa de usuario

Los resultados del modelo se integran en un **panel interactivo** consultable por los equipos de negocio. A través de esta interfaz, los usuarios pueden analizar tasas históricas de abandono, detectar anomalías en los indicadores,

estimar **ingresos en riesgo (revenue at risk)**, identificar segmentos vulnerables y consultar información mediante **lenguaje natural**.

Ejemplo del material

Un ejecutivo podría preguntarle al panel, en español llano, "¿cuáles son los segmentos con mayor riesgo de abandono durante el último trimestre?" o "¿qué zonas presentan un aumento inesperado de clientes insatisfechos?". La consulta en lenguaje natural hace que la información no quede encerrada en el equipo técnico, sino que se vuelva herramienta práctica de decisión para cualquiera.

A partir de estos resultados, **marketing** puede diseñar campañas más focalizadas y **ventas** aplicar ofertas de retención diferenciadas según el perfil del cliente. Un punto fino y muy examinable: **no todos los casos requieren la misma respuesta** — algunos clientes necesitan una mejora en el servicio, otros una compensación comercial y otros una atención personalizada. La predicción sin criterio humano de negocio es media herramienta.

6.4 Empezar con incrementos funcionales

La empresa comprende que adoptar IA con éxito **no significa implementar un gran proyecto cerrado desde el inicio**. Por el contrario, avanza mediante **incrementos funcionales**: etapas acotadas que entregan valor tangible y pueden ser usadas por los equipos desde ya. Un camino de implementación posible:

1. Formar el equipo responsable y conseguir **patrocinio interno** (sponsor).
2. Alinear a los **stakeholders** para definir objetivos, criterios de éxito y necesidades de negocio.
3. Construir los **flujos de datos** (el pipeline de la sección 5).
4. Desarrollar y validar los **modelos predictivos**.
5. Integrarlos gradualmente en procesos reales de marketing y ventas.
6. Crear **interfaces simples** (paneles, consultas en lenguaje natural) una vez que el modelo demuestra utilidad.
7. Desplegar de manera **progresiva**, empezando por algunos segmentos o zonas antes de escalar a toda la organización.
8. **Monitorear** resultados, revisar el desempeño del modelo y aplicar mejoras continuas.

Cada incremento entrega una **capacidad completa y utilizable**, evitando que la IA quede como un experimento aislado. Este enfoque reduce riesgos, facilita el aprendizaje organizacional y permite **capturar beneficios tempranamente**.

Analogía

Es construir un local y abrirlo por etapas en vez de tenerlo cerrado dos años esperando la inauguración perfecta. Abres primero la cafetería (un segmento), aprendes qué funciona, y con esa caja y ese aprendizaje abres el restaurante completo. Cada etapa ya te da clientes y plata, y cada error es chico y temprano. Es la máxima de iterar en vueltas cortas, aplicada a un despliegue de IA.

Huele a examen

La moraleja del caso: **el valor de la IA no está únicamente en predecir el abandono, sino en integrar esa predicción dentro de procesos reales de decisión**. Cuando la información se convierte en acciones concretas, la empresa puede anticiparse a la pérdida de clientes, proteger ingresos y mejorar la experiencia. La predicción es el medio; la acción de negocio es el fin.

7 Ejercicio práctico: del prototipo de retail a la operación

El módulo propone un ejercicio para aplicar los conceptos. El escenario: trabajas en una cadena nacional de **retail** que desarrolló con éxito un prototipo de IA para analizar comentarios de clientes y detectar señales tempranas de insatisfacción. Durante las pruebas, el sistema procesó archivos de texto *manualmente* y entregó buenos resultados. La gerencia decide ahora evaluar la transición hacia una solución operativa que procese automáticamente **miles de comentarios cada semana**, integre los resultados en los *dashboards* corporativos y permita a distintas áreas tomar decisiones. El objetivo del ejercicio **no es diseñar una arquitectura técnica completa**, sino comprender los desafíos de escalamiento, automatización y operación sostenible.

No hay respuestas cerradas, pero cada bloque de preguntas mapea directo a una sección de esta explicación. Uso ese mapeo como guía de estudio:

Bloque del ejercicio	Con qué de la unidad se responde
Descubrimiento vs. entrega (diferencias prototipo/producción, procesos manuales a eliminar)	Secciones 1.1–1.2 y 2: el prototipo procesaba a mano; en entrega hay que automatizar la ingesta, y el "hecho a mano" es justo lo primero que se elimina.
Escalabilidad y operación (crecer el volumen, atender varias áreas, riesgos de lo manual)	Sección 3.1: los tres niveles (datos/usuarios/procesos) y la regla "lo manual no escala".
Datos y automatización (etapas del pipeline, calidad y disponibilidad, datos con errores)	Secciones 4.3 y 5.1: las seis etapas y las cinco garantías sobre los datos.
MLOps y mantenibilidad (prácticas de continuidad, monitoreo, documentación)	Secciones 3.4 y 4.5: las seis prácticas de MLOps y la documentación/modularidad.
Personas, procesos y tecnología (stakeholders, desafíos organizacionales, equilibrio de tecnología)	Secciones 4.1, 4.2 y 4.4: la matriz de stakeholders y la pregunta tecnológica de sostenibilidad.
Reflexión final (evidencia de éxito, señales para rediseñar, por qué una solución precisa fracasa)	Sección 3 (encabezado): los proyectos fracasan por operacionalización y datos, no por el modelo.

8 Material complementario y bibliografía

El módulo remite a recursos para profundizar. Los reseño brevemente porque nombran conceptos que conviene tener ubicados:

- **MLOps en la práctica** — videos y textos sobre qué es MLOps y cómo lleva los modelos "del laboratorio a la producción", incluyendo su uso sobre **Azure Kubernetes Service (AKS)**, una plataforma para desplegar y

gestionar modelos de forma escalable mediante *contenedores* (Kubernetes orquesta muchos contenedores como un director de orquesta coordina músicos).

- **ETL** — textos que detallan la Extracción, Transformación y Carga como el proceso clave para integrar datos de diversas fuentes, limpiarlos y centralizarlos.
- **Pipelines de datos y Big Data** — el *pipeline de datos* como proceso automatizado para mover y transformar información entre sistemas, conectando fuentes de origen con destinos centrales, y su rol en **Big Data** (volumenes de datos tan grandes que exigen herramientas y arquitecturas especiales).

Bibliografía de la unidad

El material se apoya en dos libros de O'Reilly, ambos muy pertinentes al tema y verificados: **Zwingmann, T. (2024)**, *Inteligencia empresarial basada en IA: Mejore las predicciones, automatice la toma de decisiones e impulse el crecimiento* (título original *AI-Powered Business Intelligence*), que conecta modelos de ML con plataformas de BI —justo el hilo de esta unidad—; y **Haviv, Y. & Gift, N. (2023)**, *Implementing MLOps in the Enterprise: A Production-First Approach to AI and Machine Learning*, un manual de MLOps con enfoque "producción primero", que es exactamente la mentalidad del módulo. [confirmado por búsqueda]

9 ⚠️ Notas de discrepancia y actualización

El material del curso es correcto, pero en cinco puntos se queda en una versión simplificada o no nombra el tecnicismo estándar. Como te estás especializando, te conviene saber ambas cosas: **lo que responde el curso** (que es lo que se evalúa) y **lo que dice la práctica actual**. Cada nota cierra con una regla para el examen.

Discrepancia 1 · ETL vs. ELT

El curso dice: el proceso para mover e integrar datos es **ETL** (Extraer → Transformar → Cargar): se transforma *antes* de guardar.

La práctica actual añade: con los *data warehouses* y *data lakes* modernos en la nube (BigQuery, Snowflake, Databricks) se usa cada vez más **ELT** (Extraer → Cargar → Transformar): se carga el dato crudo primero y se transforma *después*, dentro del destino, aprovechando su potencia de cómputo. ELT es más flexible para Big Data y para cuando aún no sabes qué transformación necesitarás.

Regla para el examen: si preguntan por el proceso clásico de extracción-transformación-carga, la respuesta es **ETL**. Si el enunciado menciona "cargar primero el dato crudo en un data lake y transformar dentro del warehouse", es **ELT**. No son rivales; son el mismo trío en distinto orden, elegido según dónde vive la potencia de cómputo.

Discrepancia 2 · Deuda técnica en ML

El curso dice: deuda técnica = costo futuro de mantener, actualizar e integrar servicios de IA.

La literatura canónica añade: el paper de referencia, "*Hidden Technical Debt in Machine Learning Systems*" (Sculley et al., Google, NeurIPS 2015), muestra que en un sistema de ML real **solo una fracción pequeña del código es el modelo**; el resto es "plomería" (recolección de datos, verificación, servicio, monitoreo) que acumula deuda. Sus conceptos estrella: el **principio CACE** ("Changing Anything Changes Everything": cambiar cualquier entrada, dato o hiperparámetro puede alterar todo lo demás, porque nada es realmente independiente), el **glue code** (código pegamento que amarra servicios genéricos), los **pipeline jungles** (marañas de pasos de

preparación que nadie entiende) y los **consumidores no declarados** (equipos que usan la salida de tu modelo sin que lo sepas, y a los que rompes al actualizar).

Regla para el examen: con la definición del curso te basta para responder "qué es deuda técnica". Pero si te piden *por qué la IA acumula más deuda que el software normal*, la respuesta rica es CACE + el hecho de que el modelo es solo una fracción del sistema: los datos y las dependencias ocultas son la mayor fuente de deuda.

Discrepancia 3 · La "degradación" tiene nombre: data drift y concept drift

El curso dice: los modelos "envejecen" y se "degradan" cuando los patrones cambian (ejemplo COVID-19), y por eso hay que reentrenar.

La literatura precisa: ese envejecimiento se llama **degradación del modelo (model decay)** y tiene dos causas distintas: **data drift** — cambia la *distribución de los datos de entrada* (empiezan a llegar clientes de un perfil que el modelo casi no vio); y **concept drift** — cambia la *relación* entre las entradas y lo que se predice (las mismas variables ahora implican otra cosa). La pandemia fue concept drift puro: de un día para otro, "cómo era un cliente" dejó de predecir "qué compraría".

Regla para el examen: si el curso te pregunta por qué un modelo se degrada, responde con el ejemplo COVID y la idea de patrones que cambian. Si te dan a elegir el término técnico, distingue: cambian los *datos de entrada* → data drift; cambia la *regla que los conecta con el resultado* → concept drift. Ambos se combaten con monitoreo (detección de degradación) + reentrenamiento, que son prácticas de MLOps.

Discrepancia 4 · Operación asíncrona: sondeo no es la única forma

El curso dice: asíncrono = una solicitud para enviar y otra posterior para recuperar el resultado (esto es **sondeo / polling**: preguntar cada cierto rato "¿ya está?").

La práctica añade: el patrón más eficiente hoy suele ser el **webhook (callback)**: en vez de que tú preguntes repetidamente, le das al servicio una dirección y *él te avisa* cuando terminó. El polling es "llamar cada 5 minutos a ver si llegó el pedido"; el webhook es "que te manden un WhatsApp cuando llegue". A gran escala, el webhook ahorra un montón de llamadas inútiles.

Regla para el examen: la definición del curso (enviar y luego recuperar) es correcta y describe el polling. Si aparece la opción "el servicio notifica al terminar", eso es webhook/callback, también asíncrono y generalmente preferible en producción.

Discrepancia 5 · Falta el cuarto nivel de analítica: la prescriptiva

El curso dice: las capas analíticas son descriptiva, diagnóstica y predictiva.

El marco estándar añade: existe un cuarto nivel, la **analítica prescriptiva (prescriptive analytics)**, que responde "*¿qué debo hacer?*" — recomienda la acción óptima, no solo predice. En el caso de churn: la predictiva dice "este cliente se va a ir"; la prescriptiva dice "ofrécele este descuento específico porque maximiza la probabilidad de retenerlo al menor costo".

Regla para el examen: si el curso pide enumerar las capas, responde descriptiva/diagnóstica/predictiva (lo del material). Pero si te preguntan por el nivel más avanzado o "qué sigue después de predecir", es la **prescriptiva**.

10 Glosario del módulo

Todos los términos técnicos de la unidad, con su equivalente en inglés y una definición de una línea. Los marcados con ✦ son enriquecimientos que agregué (no están textualmente en el curso, pero completan el mapa del especialista); los demás salen directo del material.

Término	Inglés	Definición en una línea
Descubrimiento	Discovery	Fase centrada en la rapidez sobre la precisión: validar si hay señal valiosa en los datos.
Entrega	Delivery	Fase centrada en estabilidad, integración y escalamiento para uso diario del modelo.
Prototipo	Prototype	Versión experimental que prueba una idea rápido, sin exigencias de producción.
Prueba de concepto	Proof of Concept	Demostración acotada de que una solución es viable antes de invertir en ella.
Producción	Production	Entorno real donde la solución opera de forma confiable, segura y sostenible.
Inteligencia de negocios	Business Intelligence	Conjunto de datos, análisis y tableros para apoyar decisiones empresariales.
Machine Learning	Machine Learning	Modelos que aprenden patrones de los datos para predecir o clasificar.
Escalabilidad	Scalability	Capacidad de crecer en datos, usuarios y frecuencia sin perder calidad operativa.
Fiabilidad	Reliability	Operar de forma estable y consistente, anticipando y detectando fallas.
Rendimiento	Performance	Velocidad y eficiencia con que la solución responde o procesa información.
Mantenibilidad	Maintainability	Facilidad para corregir, actualizar y evolucionar la solución tras el despliegue.
Modularidad	Modularity	Diseño en componentes independientes, cada uno con una función clara.
Monitoreo	Monitoring	Vigilancia continua del comportamiento y la precisión del sistema en vivo.
Registro de errores	Logging	Dejar constancia de eventos y fallas para diagnosticar y auditar el sistema.

Stakeholders	Stakeholders	Partes interesadas y afectadas por el proyecto, dentro y fuera del equipo.
Matriz de poder-interés ↗	Power-interest matrix	Herramienta (Mendelow) que clasifica actores por influencia e interés para definir la comunicación.
Gobernanza de datos	Data governance	Políticas de calidad, acceso, privacidad y responsabilidad sobre los datos.
Procesos	Processes	Métodos y estándares formales que condicionan cómo se desarrolla y mantiene la solución.
Metodologías ágiles	Agile methodologies	Marcos de trabajo iterativos e incrementales para desarrollar software.
Oficina de gestión de proyectos	PMO	Área que estandariza y supervisa la gestión de proyectos en la organización.
Tecnología (infraestructura)	Technology	Plataforma sobre la que corre la solución; en producción prioriza seguridad y escala.
Calidad de datos	Data quality	Grado en que los datos son correctos, completos y consistentes; datos malos → resultados malos.
MLOps	MLOps	Prácticas para gestionar el ciclo de vida completo de los modelos de ML en producción.
Versionamiento de modelos	Model versioning	Controlar qué versión del modelo corre y poder volver a una anterior.
Automatización de entrenamiento	Training automation	Reentrenar el modelo mediante procesos automáticos, sin intervención manual.
Detección de degradación	Degradation detection	Alertar cuando la precisión cae porque la realidad cambió respecto del entrenamiento.
Reentrenamiento	Retraining	Actualizar el modelo con datos nuevos cuando cambian negocio o datos.
Degradación del modelo ↗	Model decay	Pérdida de precisión de un modelo con el tiempo al desactualizarse frente a la realidad.

Data drift ↗	Data drift	Cambia la distribución de los datos de entrada respecto de los de entrenamiento.
Concept drift ↗	Concept drift	Cambia la relación entre las entradas y lo que se predice (caso COVID-19).
Deuda técnica	Technical debt	Costo futuro de los atajos tomados hoy al construir e integrar la solución.
Principio CACE ↗	CACE principle	"Changing Anything Changes Everything": en ML nada es realmente independiente.
Pipeline de datos	Data pipeline	Flujo automatizado que conecta y transforma datos de origen a destino.
ETL	Extract, Transform, Load	Extraer datos, transformarlos y cargarlos limpios en su destino.
ELT ↗	Extract, Load, Transform	Variante moderna: cargar el dato crudo primero y transformarlo dentro del destino.
Extracción de datos	Data extraction	Recopilar datos desde las fuentes corporativas de forma consistente.
ERP	Enterprise Resource Planning	Sistema que integra los procesos y datos operativos de la empresa.
CRM	Customer Relationship Management	Sistema que gestiona la relación e información de los clientes.
Preparación y transformación	Data preparation	Limpiar, validar y dar formato a los datos antes de usarlos en modelos.
Ejecución de modelos de IA	Model execution	Enviar los datos preparados al modelo o servicio para generar el resultado (inferencia).
API	Application Programming Interface	Interfaz para que dos sistemas se comuniquen; permite consumir servicios de IA externos.
Conversión de resultados	Results conversion	Transformar la salida técnica del modelo en tablas o indicadores legibles por BI.
Almacenamiento de resultados	Results storage	Guardar resultados en repositorios para reutilizarlos, auditarlos y evitar recomputar.

Visualización y explotación	Visualization	Presentar la información en tableros o apps para que el usuario decida y actúe.
Dashboard	Dashboard	Tablero interactivo que resume indicadores para la toma de decisiones.
Operación asíncrona	Asynchronous operation	Comunicación en que se envía el pedido y se recupera el resultado más tarde.
Sondeo ↗	Polling	Preguntar repetidamente al servicio si el resultado ya está listo.
Webhook ↗	Webhook / Callback	El servicio notifica automáticamente al terminar, sin que haya que preguntar.
Inferencia por lotes	Batch inference	Predecir sobre grandes conjuntos almacenados, en horarios, no al instante.
Inferencia en tiempo real ↗	Real-time inference	Predecir caso a caso en milisegundos, en el momento en que se necesita.
Big Data	Big Data	Volúmenes de datos tan grandes que exigen arquitecturas y herramientas especiales.
Azure Kubernetes Service	AKS	Plataforma en la nube para desplegar y escalar modelos mediante contenedores.
Capas analíticas	Analytical layers	Niveles de análisis que se apilan para transformar datos en decisiones.
Datos estructurados	Structured data	Datos organizados en tablas con campos definidos (contratos, pagos).
Datos no estructurados	Unstructured data	Datos libres sin formato fijo (texto de encuestas, audio, imágenes).
Analítica descriptiva	Descriptive analytics	Responde "¿qué pasó?": resume el pasado en indicadores.
Analítica diagnóstica	Diagnostic analytics	Responde "¿por qué pasó?": busca causas detrás de los números.
Analítica predictiva	Predictive analytics	Responde "¿qué va a pasar?": proyecta el futuro a partir de patrones.

Analítica prescriptiva ↗	Prescriptive analytics	Responde "¿qué debo hacer?": recomienda la acción óptima.
IA generativa	Generative AI	Modelos que generan texto, imágenes u otros contenidos nuevos.
Procesamiento de lenguaje natural	NLP	Técnicas para que la máquina entienda y procese lenguaje humano.
Visión computacional	Computer Vision	Técnicas para que la máquina interprete imágenes y video.
Churn	Customer churn	Abandono de clientes: que cancelen, cambien de compañía o reduzcan productos.
Modelo predictivo de churn	Churn prediction model	Modelo que estima la probabilidad de que un cliente abandone en el futuro.
Análisis de sentimiento	Sentiment analysis	Clasificar texto libre como positivo, negativo o neutro, por temas.
Incrementos funcionales	Functional increments	Etapas acotadas que entregan valor tangible y usable desde ya.
Ingresos en riesgo	Revenue at risk	Estimación del dinero que se perdería si los clientes en riesgo se van.
Consulta en lenguaje natural	Natural language query	Preguntarle al panel en lenguaje cotidiano, sin escribir código.
Patrocinio interno	Internal sponsorship	Respaldo de un líder de la organización que da recursos y legitimidad al proyecto.

Total: 69 términos. En la Etapa 2 (HTML de estudio) hay exactamente una flashcard por cada uno.

11 Mapa conceptual del módulo

Árbol jerárquico de cómo se relacionan los conceptos. La raíz es la pregunta de la unidad; las seis ramas principales son sus grandes bloques. Las flechas → nombran la relación; los enlaces cruzados (líneas punteadas al pie) marcan relaciones reales que no son de jerarquía.

DEL PROTOTIPO A LA PRODUCCIÓN (¿cómo convertir un experimento de IA en un producto que opera solo?)

- 1. DESCUBRIMIENTO vs. ENTREGA [la frontera conceptual]
 - └ Descubrimiento — prioriza → rapidez sobre precisión (¿la idea sirve?)
 - └ Entrega — prioriza → estabilidad · integración · escalamiento
 - └ Prototipo / Prueba de concepto — se transforma en → producto
 - └ Producción — exige → rediseñar componentes del prototipo
- 2. CUATRO ATRIBUTOS DE PRODUCCIÓN [cualidades del sistema]
 - └ Escalabilidad — en 3 niveles → datos · usuarios · procesos
 - └ Fiabilidad — se sostiene con → monitoreo · logging · alertas · respaldos
 - └ Rendimiento — significa → rapidez y entregar a tiempo
 - └ Mantenibilidad — requiere → documentación · modularidad
- 3. CINCO DIMENSIONES DE LA ENTREGA [frentes de la organización]
 - └ Personas — se gestionan con → stakeholders · matriz poder-interés
 - └ Procesos — se alinean con → ágil · PMO · gobernanza
 - └ Datos — deben ser → disponibles · de calidad · gobernados
 - └ Tecnología — debe ser → sostenible por años (no la del prototipo)
 - └ MLOps — gestiona → el ciclo de vida del modelo
 - └ Versionamiento de modelos
 - └ Automatización de entrenamiento
 - └ Monitoreo del rendimiento
 - └ Detección de degradación — nombra → data drift / concept drift
 - └ Gestión de infraestructura
 - └ Reentrenamiento — responde a → ejemplo COVID-19
- 4. PIPELINE DE IA (AUTOMATIZACIÓN) [el "cómo" operativo]
 - └ 1) Extracción — desde → ERP · CRM · bases · web
 - └ 2) Preparación/transformación — es el → corazón del ETL (o ELT)
 - └ 3) Ejecución de modelos — vía → API (propios o externos)
 - └ 4) Conversión de resultados — para → que el BI los consuma
 - └ 5) Almacenamiento — permite → histórico · auditoría · reúso
 - └ 6) Visualización — materializa → el valor (dashboard, decisión)
 - └ Transversales: operación asíncrona (polling/webhook) · inferencia batch/tiempo-real
 - deuda técnica (CACE) · Big Data · AKS
- 5. CAPAS ANALÍTICAS [se apilan para generar valor]
 - └ Datos estructurados + no estructurados (la materia prima)
 - └ Descriptiva → Diagnóstica → Predictiva → [Prescriptiva +]
 - └ Servicios: IA generativa · NLP · Visión computacional
- 6. CASO: RETENCIÓN DE CLIENTES [síntesis práctica]
 - └ Capa de datos — combina → transaccional + encuestas abiertas
 - └ Capa analítica — sentiment analysis alimenta → modelo de churn
 - └ Capa de usuario — panel → revenue at risk · consulta en lenguaje natural
 - └ Incrementos funcionales — despliegue → progresivo, por segmentos

ENLACES CRUZADOS (relaciones no jerárquicas):

- Fiabilidad ····· Monitoreo ····· MLOps (detección de degradación) → el mismo hilo de "vigilar"
- Escalabilidad ····· Pipeline automático → "lo manual no escala"
- Mantenibilidad ····· Modularidad ····· etapas del Pipeline → bloques reemplazables

- Deuda técnica Mantenibilidad → los atajos se pagan al mantener
- Datos no estructurados Análisis de sentimiento (caso) → texto libre → variable
- Analítica predictiva Modelo de churn (caso) → "¿qué va a pasar?"
- Concept drift ejemplo COVID Reentrenamiento → por qué el modelo caduca

Explicación completa de la Unidad 6 — «Del prototipo a la producción» · Curso "Toma de decisiones basadas en datos con IA", Máster en IA (UDD / eClass) · Documento de estudio generado para cubrir el 100% de los conceptos del material, con enriquecimientos técnicos marcados ♦ y verificados en fuentes actuales.