

Unidad 1 · Introducción a la IA en el entorno empresarial

Esta unidad abre el módulo «Tecnologías de Inteligencia Artificial para Negocios» (tercer módulo del diplomado UDD «IA aplicada a los negocios»). Su función no es enseñar una técnica puntual, sino instalar el mapa completo: qué es la IA, cómo se ha clasificado su evolución en tres grandes fases, qué aspectos éticos la acompañan, dónde ya está generando valor medible en empresas reales y con qué herramientas se construye. Todo lo que viene después en el módulo —las tecnologías específicas de unidades posteriores— se apoya en el vocabulario que se fija aquí. La unidad también retoma, desde el ángulo de «tecnologías», conceptos que ya viste en **M1 U1** («Crear valor empresarial con IA»: IA, ML, IA estrecha frente a IA general, entrenamiento, parámetros, las tres V del dato, sesgo), en **M1 U3** (aprendizaje supervisado, aprendizaje profundo, red neuronal, PLN, transformador, visión por computador, CNN, aprendizaje por refuerzo) y en **M2 U5/U6** (ética de la IA, IA generativa, agentes). No se vuelve a definir esos conceptos desde cero: se los reconoce y se suma lo nuevo —IA simbólica, sistemas expertos, OCR, GPU, LLM, ajuste fino, generación de texto a imagen, RNN, TensorFlow, PyTorch, Hugging Face— sobre esa base.

Cómo leer esta unidad

El documento completo de esta unidad recorre, en el mismo orden del PDF del curso, los siguientes tramos: primero, los ocho **conceptos clave** que el curso pide dominar antes de leer nada más; luego el **Artículo 1**, que cuenta la historia de la IA en tres fases (1950–1970, 1980–2000 y 2000–presente); después el **Artículo 2**, sobre los aspectos éticos de la IA (privacidad, sesgos, rendición de cuentas) y sobre las aplicaciones avanzadas en logística, medicina y prevención de desastres, cerrando con las tres herramientas de implementación —TensorFlow, PyTorch y Hugging Face— y el video resumen; a continuación, tres **casos prácticos** narrativos (AutoTech en manufactura automotriz, ShopSmart en comercio electrónico y FinAI en banca), el video sobre ingeniería de prompts, el foro colaborativo y la bibliografía comentada; y finalmente un resumen de la unidad, el índice completo de discrepancias, el glosario y el mapa conceptual. Este primer tramo que tienes ahora cubre desde el inicio hasta el cierre del Artículo 1.

Antes de entrar en materia, una advertencia sobre el material: el PDF de 28 páginas que entrega la plataforma **eClass** de la Universidad del Desarrollo no trae todo el contenido de la unidad. Varios recursos existen únicamente en la versión online del curso —recursos interactivos, un video resumen y, en particular, un video completo del profesor **Rodrigo**

Pereira sobre ingeniería de prompts, con su PDF descargable— y no están disponibles para transcribir aquí. Donde corresponda, la explicación reconstruye esos contenidos a partir de principios generales del campo, marcando siempre con claridad qué es reconstrucción y qué es contenido literal del curso.

⚠ Nota (discrepancia 17): el curso deja fuera del PDF descargable dos recursos interactivos (uno sobre las aplicaciones de la tercera fase de la IA, otro sobre el caso FinAI), el video resumen del Artículo 2, y el video del profesor Rodrigo Pereira sobre prompts con su material descargable. La sección de prompts que verás más adelante en esta unidad está reconstruida con principios generales del campo, no con lo que dijo el profesor en el video. **Para el examen:** si una pregunta depende de contenido que solo está en la versión online, revísalo directamente ahí; según el propio aviso del curso, esos recursos podrían dejar de estar disponibles a partir del 30 de noviembre de 2026.

Antes de comenzar: objetivos

El PDF abre la unidad con tres preguntas de orientación que conviene tener presentes como hilo conductor, porque son literalmente los tres resultados de aprendizaje que se evalúan.

La primera pregunta es **¿para qué estamos aquí?** La respuesta del curso: introducir los conceptos fundamentales de la **Inteligencia Artificial** (*Artificial Intelligence, AI*) en el contexto empresarial, para preparar a quien estudia a **identificar oportunidades de innovación mediante IA**. Es una declaración de intención importante: esta unidad no busca que salgas sabiendo programar un modelo, sino que salgas con el radar entrenado para detectar, dentro de un negocio, en qué procesos una tecnología de IA podría intervenir con sentido.

La segunda pregunta es **¿qué haremos a lo largo de esta unidad?** El curso lista tres bloques de trabajo: revisar la **historia y evolución de la IA**, destacando sus hitos clave; explorar los **conceptos básicos** y la **clasificación de tecnologías** relacionadas con IA; y analizar **casos prácticos iniciales** de aplicación de IA en empresas. Esos tres bloques son, literalmente, el esqueleto de todo el documento que estás leyendo: los conceptos clave y el Artículo 1 cubren el segundo y el primer bloque; el Artículo 2 profundiza la clasificación de tecnologías con sus aplicaciones y herramientas; los tres casos narrativos —AutoTech, ShopSmart y FinAI— cubren el tercero.

La tercera pregunta es **¿para qué nos servirá este conocimiento?** Aquí el curso plantea tres beneficios: reconocer la IA como **catalizador de la competitividad empresarial**; aplicar un **marco conceptual básico para evaluar oportunidades de IA** en distintas áreas del negocio; y preparar el terreno para las **tecnologías específicas** que se van a abordar en las unidades posteriores del módulo. Esto último es clave para entender el rol de esta unidad dentro del máster completo: no es una unidad autosuficiente, es la base

sobre la que se construyen las unidades que vienen. Cada tecnología que aparezca más adelante en el módulo —ya sea una arquitectura de red, una plataforma de despliegue o un caso de uso más especializado— va a asumir que ya conoces con soltura los términos que se fijan aquí.

El PDF cierra esta sección introductoria con un aviso operativo, no conceptual, pero que vale la pena registrar: los recursos que el curso entrega como enlaces y códigos QR **podrían dejar de estar disponibles a partir del 30 de noviembre de 2026**. Esto afecta en particular a los recursos interactivos y a los dos videos mencionados en la nota anterior, así que conviene revisarlos antes de esa fecha si todavía no lo has hecho.

Conceptos clave

Antes de entrar al artículo histórico, el curso presenta ocho conceptos que funcionan como vocabulario base de todo el módulo. El orden en que aparecen no es casual: van de lo más general (qué es la IA) a lo más específico (un tipo concreto de modelo generativo), y cada concepto se apoya en el anterior. Los desarrollamos aquí con el nivel de profundidad que necesitas para manejarlos con soltura, no solo para reconocerlos.

Inteligencia Artificial: débil y fuerte

La **Inteligencia Artificial (IA)** (*Artificial Intelligence, AI*) es, según la definición que cita el curso (Russell & Norvig, 2020), el desarrollo de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana: razonar, aprender y tomar decisiones. Ya la trabajaste en M1 U1, así que no partimos de cero: ahí quedó establecido que la IA es el campo general, y que dentro de ese campo existen distintas técnicas (entre ellas el aprendizaje automático) para lograr que una máquina se comporte de forma «inteligente» en algún sentido acotado. Lo que agrega esta unidad es la distinción entre dos tipos de IA que probablemente escuchaste como IA estrecha e IA general en M1, pero que aquí el curso nombra con otros términos: **IA débil** (*Weak AI o Narrow AI*) y **IA fuerte** (*Strong AI*).

La IA débil es toda la IA que existe hoy en producción: sistemas diseñados para resolver una tarea específica —reconocer una cara, traducir un texto, recomendar un producto— y que no tienen ninguna comprensión general del mundo fuera de esa tarea. La IA fuerte, en cambio, es una idea teórica: una inteligencia artificial con capacidades comparables a las de un ser humano en cualquier dominio, capaz de razonar, planificar y aprender tareas completamente nuevas sin haber sido diseñada específicamente para ellas. Es importante remarcar el matiz: la IA fuerte no es un tipo de sistema que exista hoy con menor capacidad; es una categoría que, a la fecha, sigue siendo puramente conceptual. Cuando en el mundo real se habla de «superar a la IA fuerte» o de riesgos existenciales de la IA, casi siempre se está hablando de esta categoría teórica, no de ningún sistema desplegado.

ANALOGÍA

Piensa en la diferencia entre un especialista y un generalista extremo. Un cardiólogo brillante (IA débil) puede diagnosticar arritmias mejor que cualquier persona promedio, pero si le pides que arregle un auto no tiene ninguna ventaja sobre cualquier otro adulto sin entrenamiento mecánico. Una persona con inteligencia general (el equivalente humano de la IA fuerte) puede, en cambio, aprender a diagnosticar arritmias y también aprender a reparar un auto, transfiriendo razonamiento de un dominio a otro. Todos los sistemas de IA que usas hoy —el corrector de tu teléfono, el sistema de recomendación de una tienda, un chatbot— son especialistas: hacen una cosa muy bien y nada más.

EJEMPLO

Un sistema de detección de fraude bancario (como verás más adelante con el caso FinAI) puede superar a cualquier analista humano detectando patrones sospechosos en millones de transacciones por segundo. Pero ese mismo sistema no tiene ninguna capacidad de, por ejemplo, redactar el correo que le explica al cliente por qué se bloqueó su tarjeta: para eso se necesitaría otro sistema, entrenado para otra tarea. Esa fragmentación de capacidades es la firma distintiva de la IA débil.

Aprendizaje automático y sus tres tipos

El **Aprendizaje Automático** (*Machine Learning, ML*) es, según la definición del curso (Goodfellow, Bengio & Courville, 2016), la rama de la IA que permite a las computadoras aprender de los datos y mejorar su desempeño **sin ser programadas explícitamente**. Esta idea —programar sin escribir la regla a mano— ya la viste en M1 U1 como la diferencia entre programación tradicional y ML, así que aquí solo la reforzamos con el término técnico que le falta: lo opuesto al ML es la **programación explícita** (*explicit programming*), es decir, escribir a mano cada instrucción que el programa debe seguir para cada caso posible. El ML invierte esa lógica: en vez de escribir la regla, le muestras al sistema muchos ejemplos y dejas que él mismo encuentre el **patrón** (*pattern*) —la regularidad en los datos que sirve para predecir o decidir— y lo codifique en sus **parámetros** (*parameters*), los números internos que el modelo ajusta durante el entrenamiento y que en los modelos más grandes de hoy llegan a contarse por miles de millones.

El curso clasifica el ML en tres tipos según cómo es la interacción con los datos, algo que ya trabajaste en M1 U3 para el caso supervisado, pero que conviene tener los tres juntos y contrastados. El **aprendizaje supervisado** (*supervised learning*) entrena al modelo con ejemplos que ya traen la respuesta correcta —la etiqueta— para que aprenda a predecirla en casos nuevos; es el tipo que usarás, por ejemplo, cuando un modelo de crédito aprende de miles de solicitudes pasadas, cada una etiquetada como «pagó» o «no pagó», a predecir el riesgo de una solicitud nueva. El **aprendizaje no supervisado** (*unsupervised learning*) no tiene etiquetas: el modelo recibe solo los datos y su tarea es encontrar estructura por sí

mismo, típicamente agrupando casos parecidos o detectando patrones ocultos; es el enfoque natural cuando no sabes de antemano en qué categorías se dividen tus clientes y quieres que el propio sistema te lo sugiera. El **aprendizaje por refuerzo** (*reinforcement learning*) es distinto de los dos anteriores en su lógica: no hay un conjunto fijo de ejemplos correctos, sino un agente que actúa dentro de un entorno, recibe una recompensa o un castigo según el resultado de cada acción, y ajusta su comportamiento para maximizar la recompensa acumulada a lo largo del tiempo.

ANALOGÍA

El aprendizaje supervisado es como estudiar con un solucionario: tienes el ejercicio y la respuesta correcta al lado, y aprendes a resolver ejercicios parecidos comparando tu intento contra esa respuesta. El aprendizaje no supervisado es como que te entreguen una caja con cientos de fotografías sueltas y te pidan que las ordenes en pilas «que tengan sentido», sin decirte ningún criterio: tú decides, por semejanza, qué va junto. El aprendizaje por refuerzo es como aprender a andar en bicicleta: nadie te da la secuencia exacta de movimientos correctos, pero cada vez que te caes (castigo) o avanzas sin caerte (recompensa) ajustas tu forma de pedalear y de mantener el equilibrio, hasta que el comportamiento que maximiza «avanzar sin caerte» queda afinado.

EJEMPLO

Supongamos (cifra hipotética, solo para ilustrar el mecanismo) que un banco entrena un modelo con 100.000 solicitudes de crédito históricas, cada una etiquetada como «pagada a tiempo» o «con mora». Eso es aprendizaje supervisado: hay una etiqueta objetivo. Si, en cambio, el mismo banco le pide a un modelo que agrupe a esos 100.000 clientes en cinco perfiles de comportamiento de gasto sin decirle de antemano cuáles son esos perfiles, eso es no supervisado. Y si el banco despliega un sistema que decide en tiempo real a qué clientes ofrecerles qué promoción, y va ajustando esa política según cuántas promociones terminan siendo aceptadas, eso es aprendizaje por refuerzo.

Deep Learning

El **Deep Learning** o **aprendizaje profundo** es, según la definición del curso (LeCun, Bengio & Hinton, 2015), el uso de **redes neuronales** con **múltiples capas** para modelar datos complejos y detectar patrones de alto nivel; el curso lo describe como especialmente efectivo en reconocimiento facial, procesamiento del lenguaje y análisis de imágenes. Ya conociste la red neuronal como concepto en M1 U3; lo que aporta esta unidad es enmarcarlo dentro de la línea histórica completa de la IA, algo que retomaremos con más detalle en el Artículo 1 de esta misma unidad, donde el deep learning aparece como el motor de la tercera fase de la evolución de la IA.

La idea central que conviene fijar ahora es por qué «profundidad» —tener muchas capas— importa. Cada capa de una red neuronal aprende a reconocer rasgos algo más abstractos

que la capa anterior: en una red que procesa imágenes, las primeras capas podrían aprender a detectar bordes y contrastes simples, las capas intermedias combinan esos bordes en formas (un ojo, una rueda), y las capas finales combinan esas formas en conceptos completos (una cara, un auto). Ninguna de esas capas fue programada a mano para buscar «bordes» o «caras»: esa jerarquía de rasgos emerge del entrenamiento, ajustando los parámetros de cada capa para minimizar el error del modelo sobre los datos de ejemplo.

ANALOGÍA

Es como el proceso de leer un texto en un idioma que recién estás aprendiendo: primero reconoces letras sueltas, después combinas letras en sílabas, después sílabas en palabras, y solo al final combinas palabras en el sentido completo de la frase. Cada nivel de lectura se apoya en el nivel anterior y agrega una capa de abstracción. Una red neuronal profunda hace algo estructuralmente parecido con los datos que procesa, capa por capa.

Big Data y las tres V

El **Big Data** es, según la definición del curso (Mayer-Schönberger & Cukier, 2013), el manejo y análisis de grandes volúmenes de datos con alta velocidad y variedad, que requieren métodos avanzados para su procesamiento; su análisis permite descubrir patrones y tendencias útiles para la toma de decisiones. En M1 U1 ya trabajaste las **tres V del Big Data** (*Volume, Velocity, Variety*), así que aquí solo las repasamos rápido porque el curso las vuelve a nombrar en este punto de entrada: **volumen** (cuántos datos hay: de gigabytes a petabytes), **velocidad** (qué tan rápido se generan y hay que procesarlos: desde cargas por lotes hasta flujos en tiempo real) y **variedad** (qué tan distintos son sus formatos: texto, imágenes, sensores, transacciones, todo mezclado).

El punto que vale la pena subrayar en esta unidad es la relación causal entre Big Data y deep learning: las redes neuronales profundas necesitan enormes cantidades de datos de entrenamiento para ajustar sus millones o miles de millones de parámetros sin memorizar en vez de generalizar. El Big Data no es un tema aparte del deep learning: es la materia prima que lo hace posible. Sin el volumen de datos digitales que se empezó a generar desde los años 2000 —transacciones, clics, imágenes, texto en internet—, la tercera fase de la IA que verás en el Artículo 1 no habría tenido con qué entrenar sus modelos.

IA Generativa

La **IA Generativa** (*Generative AI*) es, según el curso (Brown et al., 2020), el conjunto de modelos avanzados que crean contenido nuevo —texto, imágenes— basándose en patrones aprendidos de datos previos; el curso da como ejemplos destacados a **GPT** y **GAN**. Ya viste esta categoría en M2 U6 («Perspectivas futuras de la IA»), donde apareció junto a la IA

multimodal y los agentes; aquí la retomamos desde el ángulo de «qué tecnologías concretas la implementan».

La diferencia de fondo entre un modelo generativo y los modelos que probablemente ya conoces (un modelo de clasificación o de regresión) es el tipo de salida: un modelo de clasificación te dice a qué categoría pertenece algo que ya existe («esta transacción es fraude o no lo es»); un modelo generativo produce algo que no existía antes, con una estructura estadísticamente parecida a la de sus datos de entrenamiento. El curso menciona dos familias como ejemplo: **GPT**, que desarrollamos en el concepto siguiente, y **GAN** (*Generative Adversarial Network*) o **red generativa antagónica**, una arquitectura en la que dos redes neuronales compiten entre sí: una, el generador, intenta producir contenido (por ejemplo, una imagen) que parezca real; la otra, el discriminador, intenta distinguir ese contenido generado del contenido real. Ambas redes se entrenan a la vez y mejoran una contra la otra: cada vez que el discriminador detecta una imagen falsa, el generador ajusta sus parámetros para engañarlo mejor la próxima vez, y cada vez que el generador logra engañarlo, el discriminador se vuelve más exigente.

ANALOGÍA

Una GAN es como un falsificador de billetes (el generador) compitiendo contra un detective de la policía especializado en detectar falsificaciones (el discriminador), ambos en un ciclo de mejora continua: cada billete falso que el detective detecta enseña al falsificador a hacer uno mejor, y cada falsificación que logra colar enseña al detective a fijarse en detalles más finos. Con miles de rondas de este juego, el falsificador termina produciendo billetes casi indistinguibles de los reales; en una GAN, ese «billete casi indistinguible» es la imagen o el contenido generado.

LLM: modelos de lenguaje a gran escala

Un **LLM** (*Large Language Model*) o **modelo de lenguaje a gran escala** es un modelo entrenado con grandes cantidades de texto para realizar tareas de generación de texto, traducción, resumen y análisis semántico —interpretar el significado de un texto, no solo sus palabras sueltas. El curso da como ejemplo a **GPT-4**, que utiliza estructuras de red neuronal avanzadas —en concreto, la arquitectura **transformer** que ya conociste en M1 U3 — para comprender y generar lenguaje natural, y cita para este ejemplo a Brown et al. (2020). Vale la pena fijar aquí el término completo: **GPT** son las siglas de *Generative Pre-trained Transformer* —«transformer generativo preentrenado»—, la familia de LLM de OpenAI de la que GPT-4 es un ejemplo: modelos transformer que se preentrenan sobre grandes cantidades de texto (el mismo proceso de preentrenamiento que desarrollamos en el siguiente concepto) para luego generar texto de forma autorregresiva, es decir, prediciendo una palabra a la vez a partir de todo lo escrito antes.

⚠ **Nota (discrepancia 5):** el curso cita a Brown et al. (2020) como referencia tanto para «IA Generativa» como para GPT-4, y en el Artículo 1 la vuelve a usar para «modelos generativos como GPT-4 y DALL·E». Pero Brown et al. (2020) es, en realidad, el paper que presentó **GPT-3** (con 175.000 millones de parámetros), no GPT-4: GPT-4 se lanzó recién el 14 de marzo de 2023, con un informe técnico de detalles deliberadamente limitados. **Para el examen:** si te piden el ejemplo de LLM, responde lo que dice el curso, GPT-4; si te piden qué describe la referencia Brown et al. 2020, la respuesta correcta es GPT-3 y el fenómeno de aprendizaje con pocos ejemplos que se explica más abajo, no GPT-4.

Vale la pena aprovechar esta nota para fijar un término que aparece asociado al mismo paper de Brown et al. (2020): el **aprendizaje con pocos ejemplos** (*few-shot learning*), la capacidad de un LLM de resolver una tarea nueva con solo unos pocos ejemplos dentro de la instrucción que se le da, sin necesidad de un reentrenamiento formal. Es la propiedad que hizo célebre a GPT-3: en vez de entrenar un modelo distinto para cada tarea (traducir, resumir, responder preguntas), bastaba con mostrarle dos o tres ejemplos de la tarea deseada dentro del mismo texto de entrada para que la resolviera razonablemente bien. Este concepto reaparecerá más adelante en esta unidad, en la sección sobre ingeniería de prompts.

Preentrenamiento y ajuste fino

El **preentrenamiento** (*pre-training*) consiste en entrenar un modelo de lenguaje con un conjunto de datos general y masivo —por ejemplo, una porción enorme de texto de internet—, sin apuntar todavía a ninguna tarea específica. El **ajuste fino** (*fine-tuning*), en cambio, toma ese modelo ya preentrenado y lo adapta a una tarea concreta utilizando un conjunto de datos más pequeño y relevante para esa tarea. Este proceso de dos etapas es, según el curso, lo que permite que modelos como GPT se especialicen en aplicaciones concretas.

Por qué existe esta separación en dos etapas, en vez de entrenar directamente para cada tarea: entrenar un modelo de lenguaje desde cero, sobre texto general, es extremadamente costoso en cómputo y en datos; hacerlo una sola vez y luego reutilizar ese conocimiento general para muchas tareas distintas —solo con un ajuste liviano— es mucho más eficiente. El modelo preentrenado ya «sabe» gramática, vocabulario, relaciones semánticas generales del idioma; el ajuste fino simplemente lo orienta hacia el vocabulario y el estilo de una tarea específica, como redactar respuestas de atención al cliente o resumir informes médicos.

⚠ **Nota (discrepancia 6):** el curso atribuye la técnica de ajuste fino a «Howard & Gugger (2018)». El paper que efectivamente introdujo el método de referencia para ajuste fino de modelos de lenguaje —conocido como ULMFiT, presentado en ACL 2018— tiene como autores reales a **Jeremy Howard y Sebastian Ruder**, no a ningún «Gugger». **Para el examen:** el concepto de preentrenamiento y ajuste fino que describe el curso es correcto;

si necesitas citar la referencia, el nombre correcto es Howard & Ruder (2018), no Howard & Guggen.

EJEMPLO

Supongamos (cifra hipotética) que una empresa quiere un modelo que redacte respuestas de soporte técnico en su tono de marca. En vez de entrenar una red neuronal de lenguaje desde cero —lo que podría exigir miles de millones de documentos de entrenamiento y semanas de cómputo—, toma un LLM ya preentrenado y lo ajusta con, digamos, 5.000 conversaciones reales de su propio historial de soporte. El resultado es un modelo que conserva todo el dominio general del idioma que aprendió en el preentrenamiento, pero que responde con el vocabulario, el tono y los procedimientos específicos de esa empresa.

Texto a imagen y DALL·E

El **texto a imagen** (*Text-to-Image*) es la generación de imágenes a partir de descripciones escritas. El curso lo ejemplifica con **DALL·E**, un modelo que —según describe el curso— combina **transformers** y **redes convolucionales** (*convolutional neural networks, CNN*) para interpretar el texto de entrada y producir una imagen coherente con esa descripción, con aplicaciones en diseño, publicidad y creación de contenido visual (Ramesh et al., 2021).

⚠ Nota (parte de discrepancia 7): la descripción del curso corresponde específicamente a la **primera versión de DALL·E**: su arquitectura combinaba un componente convolucional (un autoencoder variacional discreto) con un transformer autorregresivo, tal como lo documenta el paper de Ramesh et al. (2021) citado. Las versiones posteriores, DALL·E 2 y DALL·E 3, ya no funcionan así: usan **modelos de difusión**, una familia de técnicas distinta que genera la imagen partiendo de ruido aleatorio y «limpiándolo» de forma iterativa hasta llegar a una imagen coherente con el texto. **Para el examen:** si te piden la arquitectura de DALL·E tal como la describe el curso (transformer más redes convolucionales), esa descripción corresponde a DALL·E 1; ten presente que el enfoque cambió en las versiones siguientes.

Con esto quedan cerrados los ocho conceptos clave. Antes de avanzar al Artículo 1, conviene notar el hilo que los conecta: la IA (concepto general) se implementa mediante ML (una forma de que las máquinas aprendan de datos); dentro del ML, el deep learning es la técnica que domina hoy gracias a la disponibilidad de Big Data; y sobre esa misma base de deep learning se construye la IA generativa, cuyos representantes más visibles —los LLM como GPT y los modelos de texto a imagen como DALL·E— se entrenan en dos etapas, preentrenamiento y ajuste fino. Ese mismo hilo es, en esencia, el argumento del Artículo 1, que ahora vas a leer contado como una línea de tiempo.

Artículo 1: Introducción a la Inteligencia Artificial

El curso abre este artículo con una idea de encuadre que vale la pena citar casi literal, porque resume el argumento completo de la unidad: la **Inteligencia Artificial (IA) ha pasado de ser un concepto futurista a convertirse en un componente esencial de los negocios modernos**. Empresas de todos los tamaños la están aprovechando para **optimizar procesos, predecir comportamientos del mercado y mejorar la experiencia del cliente**. Un recuadro del material, atribuido a la instructora Daniela, retoma la definición formal ya vista en conceptos clave con una frase que añade matiz histórico: la IA es la capacidad de las máquinas para imitar procesos de inteligencia humana —el aprendizaje, el razonamiento y la resolución de problemas (Russell & Norvig, 2020)—, y ese campo, «que alguna vez fue dominio exclusivo de la ciencia ficción», hoy está impulsado por avances tecnológicos concretos en capacidad de cálculo y en algoritmos.

El cuerpo del artículo organiza la historia de la IA en tres fases. Esta periodización es, en sí misma, un dato de examen: el curso la usa como columna vertebral de toda la unidad, así que conviene memorizar los tres rangos de años exactos con los que trabaja el curso, aun cuando —como vas a ver en las notas de discrepancia— la historia real sea un poco más matizada.

Primera fase (1950-1970): sistemas basados en reglas

Durante este período, el curso explica que la IA se centró en la creación de sistemas programados para seguir **reglas específicas**, lo que se conoce como **IA simbólica o basada en reglas** (*symbolic o rule-based AI*). Estos sistemas funcionaban mediante un conjunto de instrucciones predefinidas que permitían resolver problemas en **contextos cerrados** (*closed-world context*): entornos acotados y totalmente especificados de antemano, donde el conjunto de reglas alcanza para cubrir todos los casos posibles. Es exactamente el opuesto conceptual del aprendizaje automático que viste en conceptos clave: aquí, un ingeniero se sienta a escribir a mano cada «si pasa esto, haz esto otro», sin que el sistema aprenda nada de datos.

El curso presenta dos ejemplos icónicos de esta fase. El primero es el programa desarrollado por **Arthur Samuel** en la década de 1950, que permitió a las computadoras jugar **damas** de manera autónoma: a través de un proceso descrito por el curso como «aprendizaje automático rudimentario», el programa evaluaba posibles movimientos y ajustaba su estrategia con el tiempo, convirtiéndose —dice el curso— en uno de los primeros intentos de aprendizaje de las máquinas. El segundo es **Logic Theorist**, un sistema creado por **Allen Newell y Herbert Simon**, capaz de demostrar teoremas matemáticos utilizando reglas lógicas; el curso lo presenta como precursor de la IA simbólica, que inspiró desarrollos posteriores en **sistemas expertos** y en la resolución automatizada de problemas (McCarthy, 2007).

⚠ **Nota (discrepancia 1):** hay una tensión interna en cómo el curso presenta el programa de Samuel: lo introduce como ejemplo icónico de la primera fase, «basada en reglas», pero en la misma frase reconoce que el programa usaba «aprendizaje automático rudimentario» y ajustaba su estrategia con el tiempo. Eso no es un sistema de reglas fijas: es, literalmente, aprendizaje. La evidencia histórica confirma esto último: el programa de Samuel aprendía jugando partidas contra sí mismo, y a Samuel se le atribuye haber popularizado el término «machine learning» en 1959. **Para el examen:** si te preguntan por el ejemplo característico de la primera fase «basada en reglas», responde Logic Theorist; si te preguntan por el primer programa que aprendía por su cuenta, responde el programa de damas de Samuel, dejando claro que técnicamente ya no encaja del todo en «solo reglas».

El curso valora estos avances con una lectura doble: por un lado, demostraron que las máquinas podían ejecutar tareas estructuradas con gran precisión; por otro, carecían por completo de **flexibilidad** para adaptarse a entornos que no estuvieran programados de antemano. A eso se sumaban las limitaciones computacionales de la época —baja capacidad de procesamiento y de almacenamiento—, que restringían severamente la **escalabilidad** (*scalability*) de estos sistemas: su capacidad de crecer en volumen de datos o de tareas sin colapsar. El resultado, según el curso, fue que durante la década de 1970 la IA simbólica entró en un período de estancamiento conocido como el «**invierno de la IA**» (*AI winter*), por la falta de avances significativos y la disminución del financiamiento para la investigación (Nilsson, 1998).

⚠ **Nota (discrepancia 2):** el curso simplifica la cronología en dos puntos. Primero, habla de un único «invierno de la IA» situado en la década de 1970; la historiografía del campo suele distinguir dos inviernos, uno de aproximadamente 1974 a 1980 (tras el informe Lighthill de 1973, que cuestionó duramente el financiamiento a la investigación en IA en el Reino Unido) y otro de aproximadamente 1987 a 1993. Segundo, el curso sitúa el arranque de la tercera fase (deep learning y modelos generativos) en el año 2000; el hito que la literatura técnica suele marcar como el verdadero despegue del deep learning moderno es 2012, con la aparición de la red AlexNet en la competencia ImageNet, que demostró de forma contundente la superioridad del aprendizaje profundo sobre los métodos anteriores de visión por computador. **Para el examen:** usa siempre las tres fases y los rangos de años tal como los da el curso (1950–1970 / 1980–2000 / 2000–presente); trata los dos inviernos y el hito de 2012 como contexto adicional, útil para entender mejor la historia, pero no como la periodización que se evalúa.

Segunda fase (1980–2000): surgimiento del Aprendizaje Automático

El curso marca el inicio de esta fase con un recuadro tipo «¿Sabías qué?»: la introducción de **redes neuronales** y de algoritmos de aprendizaje automático permitió a las máquinas

procesar datos y ajustarse automáticamente, un avance significativo respecto de los sistemas basados en reglas de la primera fase. Uno de los primeros hitos que destaca el curso: la aparición de **redes neuronales artificiales** capaces de aprender patrones sin ser programadas explícitamente para cada caso, es decir, el mismo principio de aprendizaje automático que viste en conceptos clave, ahora aplicado con una arquitectura inspirada — de forma simplificada— en el funcionamiento de las neuronas biológicas: unidades conectadas entre sí cuyos pesos se ajustan durante el entrenamiento.

El primer caso representativo que desarrolla el curso es el **Reconocimiento óptico de caracteres** u **OCR** (*Optical Character Recognition*): la tecnología que convierte texto escrito o impreso en una imagen —una página escaneada, por ejemplo— en texto digital editable. El curso dice que esta tecnología «revolucionó» la forma en que las organizaciones procesaban documentos escritos, y que empresas como **Xerox** la implementaron en los **años 90** para automatizar el escaneo de **cheques y documentos administrativos**. Según el curso, hoy gigantes como **Google** han mejorado esta tecnología a través de modelos como **Tesseract OCR**, usado en el reconocimiento de caracteres en múltiples idiomas y entornos.

 **Nota (discrepancia 4):** el curso da a entender que Tesseract es «un modelo de Google». En realidad, Tesseract nació en Hewlett-Packard entre 1985 y 1994, se liberó como proyecto de código abierto en 2005, y Google lo patrocinó activamente entre 2006 y 2017 —es decir, Google lo impulsó y lo mejoró, pero no lo creó ni es «su» modelo desde el origen—. El caso específico de Xerox automatizando el escaneo de cheques en los años 90 no se pudo verificar con una fuente confiable adicional al propio curso. **Para el examen:** define Tesseract como un motor de OCR de código abierto y multilingüe, impulsado por Google, no como un producto originalmente creado por Google.

El segundo caso representativo son los **sistemas expertos** (*expert systems*): programas diseñados para imitar la capacidad de decisión de especialistas humanos en áreas específicas, mediante reglas construidas a partir del conocimiento de esos especialistas. El curso destaca a **MYCIN**, desarrollado en la Universidad de **Stanford** en los años 70 y 80, capaz de diagnosticar **infecciones bacterianas** y recomendar tratamientos a partir de información médica. El curso afirma que «MYCIN demostró que la IA podía superar a médicos en ciertos diagnósticos», aunque su uso clínico nunca fue masivo debido, según el curso, a la resistencia de la industria y a limitaciones computacionales de la época.

 **Nota (discrepancia 3):** el curso ubica a MYCIN dentro de la segunda fase (1980–2000), pero el sistema se desarrolló en realidad durante los años 70, antes del rango que el propio curso asigna a esa fase (el curso lo sitúa correctamente al decir «años 70 y 80», pero lo encuadra en la fase 1980–2000, lo que genera una inconsistencia interna). Además, la afirmación de que «superó a médicos en ciertos diagnósticos» simplifica una evaluación real más matizada: un estudio de evaluación ciega (Yu et al., 1979, publicado en JAMA)

comparó las recomendaciones de MYCIN con las de un grupo de especialistas en infectología en casos concretos, con resultados favorables en ese estudio puntual, pero sin que existan cifras de esa comparación suficientemente verificadas para citar un porcentaje. Sobre por qué no se masificó su uso clínico, la explicación habitual en la literatura del campo incluye cuestiones de responsabilidad legal y ética —¿quién responde si el sistema se equivoca?— y de integración con el flujo de trabajo clínico real de la época, más que solo «resistencia de la industria». **Para el examen:** MYCIN es el ejemplo emblemático de sistema experto del curso —diagnóstico de infecciones bacterianas, desarrollado en Stanford—; si te piden las razones de su no uso clínico tal como las da el curso, cítalas textual (resistencia de la industria, limitaciones computacionales).

El tercer desarrollo que marca esta fase, según el curso, es el **hardware especializado para IA**. Surgieron los primeros **aceleradores de hardware** (*hardware accelerators*): procesadores especializados, por ejemplo en cálculos de matrices, fundamentales para mejorar la velocidad de entrenamiento de las redes neuronales. El curso presenta estos desarrollos como la base sobre la que se construyeron después las **GPU** (*Graphics Processing Unit, unidad de procesamiento gráfico*) de empresas como **NVIDIA**, que hoy son esenciales para entrenar modelos de deep learning con millones de parámetros (Russell & Norvig, 2020). Vale la pena entender por qué una GPU —diseñada originalmente para dibujar gráficos en pantalla, no para hacer ciencia de datos— resultó ser la pieza de hardware ideal para el deep learning: entrenar una red neuronal implica hacer, en paralelo, un número enorme de multiplicaciones de matrices relativamente simples, y eso es exactamente el tipo de cálculo que una GPU, diseñada para procesar millones de píxeles a la vez, hace mucho mejor que un procesador central tradicional, optimizado para tareas secuenciales más complejas.

ANALOGÍA

Un procesador central tradicional es como un cocinero experto que puede preparar un plato muy elaborado él solo, paso a paso, con gran precisión. Una GPU es como una cocina con miles de ayudantes, cada uno haciendo una tarea simple y repetitiva —pelar una papa, cortar una zanahoria— al mismo tiempo que todos los demás. Entrenar una red neuronal es, en esencia, hacer millones de operaciones simples y repetitivas en paralelo, así que conviene mucho más la cocina de mil ayudantes que el cocinero solitario, por brillante que sea.

Tercera fase (2000-presente): expansión del Deep Learning y modelos generativos

El curso abre esta fase con una cita destacada que reúne varios hitos: el auge del deep learning llevó al desarrollo de **AlphaGo** —un sistema de DeepMind que combinaba redes neuronales profundas con una técnica de búsqueda de jugadas, entrenado primero con partidas humanas y luego jugando contra sí mismo—, que venció a campeones humanos en

el juego de estrategia **Go** (Silver et al., 2016), un juego considerado durante décadas demasiado complejo en su número de combinaciones posibles para que una máquina lo dominara; y a **asistentes virtuales** (*virtual assistants*) como **Alexa y Siri**, software conversacional capaz de entender instrucciones habladas y ejecutar tareas en tiempo real, capaces de realizar tareas complejas en tiempo real. Modelos generativos como **GPT-4 y DALL·E** —según el curso— «revolucionaron la creación de contenido», permitiendo generar texto, imágenes y videos a partir de descripciones en lenguaje natural (Brown et al., 2020; la misma referencia ya señalada en la discrepancia 5 de conceptos clave).

 **Nota (discrepancia 8):** más adelante, en la lista de aplicaciones de esta fase, el curso describe a Tesla desarrollando «vehículos autónomos» que detectan obstáculos, interpretan señales de tránsito y toman decisiones en tiempo real. La evidencia disponible matiza esa afirmación: el sistema de asistencia de conducción de Tesla (conocido como FSD) corresponde al **nivel 2 de la escala SAE** de automatización —es decir, requiere supervisión activa del conductor humano en todo momento—, aunque la empresa ha comenzado a operar un servicio limitado de robotaxi sin conductor desde 2025 en zonas acotadas. Waymo, en cambio, sí opera bajo **nivel 4**: vehículos sin conductor dentro de zonas geográficas definidas. **Para el examen:** la definición del curso de «sistema autónomo» —un sistema que percibe su entorno y decide en tiempo real sin intervención humana directa— sigue siendo correcta como concepto; si te preguntan por niveles de autonomía, distingue la asistencia supervisada de nivel 2 (Tesla, tal como opera hoy en general) de la autonomía sin conductor de nivel 4 (Waymo, en sus zonas de operación).

El curso describe la tercera fase como caracterizada por el **uso intensivo del aprendizaje profundo**: redes neuronales profundas procesando grandes cantidades de datos, una tecnología que —según el curso— ha sido fundamental para cuatro grandes familias de aplicación. Vale la pena revisarlas una por una, porque el curso las trata como un recuadro autocontenido y son, en la práctica, un catálogo de las tecnologías que se profundizarán en unidades posteriores del módulo.

La primera es el **Procesamiento de Lenguaje Natural** o **PLN** (*Natural Language Processing, NLP*), el área de la IA que permite a las máquinas comprender y generar lenguaje humano —ya la conociste en M1 U3—. El curso menciona a **GPT** y **BERT** como modelos que han permitido avances en la comprensión del lenguaje, mejorando la interacción entre personas y máquinas mediante chatbots y asistentes virtuales. **BERT** es un modelo de **Google** basado en la arquitectura **transformer**, orientado específicamente a comprender el lenguaje en su contexto —a diferencia de GPT, que está orientado sobre todo a generar texto, BERT está optimizado para entender el significado de un texto ya existente, por ejemplo para mejorar un buscador—.

La segunda es la **Visión por computadora** (*Computer vision*), ya vista también en M1 U3: el área de la IA que permite a las máquinas interpretar imágenes y video. El curso

menciona dos herramientas: **YOLO** (*You Only Look Once*), una familia de modelos de **detección de objetos** (*object detection*) en tiempo real que analiza la imagen completa en una sola pasada —de ahí su nombre—, a diferencia de enfoques más antiguos que revisaban la imagen región por región de forma secuencial; y **OpenCV**, una biblioteca de código abierto ampliamente usada para procesar imágenes y video, y que sirve de base práctica para tareas como el **reconocimiento facial** (*facial recognition*), identificar o verificar a una persona a partir de una imagen de su rostro. El curso ejemplifica esta familia con la detección de objetos y la automatización en fábricas mediante análisis de imágenes (Redmon & Farhadi, 2018; este paper corresponde, específicamente, a YOLOv3, la tercera versión de esta familia de modelos).

La tercera son los **sistemas autónomos** (*autonomous systems*): sistemas que perciben su entorno y deciden en tiempo real sin intervención humana directa. El curso ejemplifica con Tesla, tal como se detalló en la nota de discrepancia 8 anterior, y cita a Bojarski et al. (2016), un trabajo técnico sobre aprendizaje de extremo a extremo para conducción autónoma que, cabe aclarar, es de la empresa **NVIDIA**, no de Tesla —aunque el curso lo cita junto al ejemplo de Tesla, la referencia técnica corresponde a otra compañía—. Un componente de hardware clave en estos sistemas es el **LIDAR** (*Light Detection and Ranging*): un sensor que mide distancias emitiendo pulsos láser y midiendo el tiempo que tardan en rebotar, con lo que construye un mapa tridimensional del entorno en tiempo real; es uno de los sensores que, junto con cámaras y radares, alimentan a las redes neuronales que procesan la conducción autónoma —un dato que retomarás más adelante en esta unidad, en la sección de herramientas de implementación—.

La cuarta es la **IA generativa** aplicada a contenido creativo. El curso menciona a **MidJourney y Stable Diffusion** como modelos que han transformado la industria creativa, permitiendo la generación automática de contenido visual y audiovisual. Ambos son, en esencia, la misma familia de modelos de difusión que se mencionó en la nota de discrepancia sobre DALL·E: parten de ruido aleatorio y lo van refinando iterativamente hasta producir una imagen coherente con una descripción de texto.

El material original incluye en este punto un **recurso interactivo** disponible solo en la versión online del curso, que profundiza en estas cuatro aplicaciones de la tercera fase con más detalle del que trae el PDF descargable; como se advirtió al inicio de esta unidad (discrepancia 17), ese recurso no está disponible para transcribir aquí.

El artículo cierra esta primera parte con un factor transversal a toda la tercera fase: el **poder computacional** (*computational power o compute*), la capacidad de cálculo disponible para entrenar modelos. El curso lo presenta como «un factor determinante» en la expansión de la IA, con empresas como **Google, Microsoft y NVIDIA** desarrollando hardware optimizado para el entrenamiento de modelos de machine learning y deep learning (Hennessy & Patterson, 2018). Este es el mismo hilo que ya viste con las GPU de la segunda fase: si en los años 80 y 90 el hardware especializado apenas empezaba a

acelerar el entrenamiento de redes relativamente pequeñas, en la tercera fase ese mismo tipo de hardware —escalado en órdenes de magnitud— es lo que hace posible entrenar modelos con miles de millones de parámetros sobre cantidades de datos que serían impensables de procesar con el cómputo de las fases anteriores. El crecimiento del poder computacional y el crecimiento del Big Data disponible son, en la práctica, las dos piernas sobre las que camina toda esta tercera fase.

Para cerrar el recorrido histórico, conviene ver las tres fases una al lado de la otra, porque el examen probablemente te va a pedir compararlas directamente.

Fase	Qué resolvía	Cómo lo hacía	Límite principal	Ejemplos del curso
Primera (1950–1970): IA simbólica / basada en reglas	Automatizar tareas estructuradas en entornos cerrados y bien definidos.	Instrucciones predefinidas escritas a mano por ingenieros; reglas lógicas explícitas.	Sin flexibilidad fuera de lo programado; poca capacidad de cómputo y almacenamiento; poca escalabilidad.	Logic Theorist (Newell y Simon); programa de damas de Samuel (que, pese a la ubicación del curso en esta fase, ya aprendía).
Segunda (1980–2000): surgimiento del aprendizaje automático	Que las máquinas aprendieran patrones directamente de los datos, en vez de seguir solo reglas fijas.	Redes neuronales artificiales tempranas; sistemas expertos con reglas derivadas del conocimiento de especialistas; primeros aceleradores de hardware.	Modelos todavía limitados por el hardware disponible; sistemas expertos costosos de mantener y de integrar en flujos de trabajo reales.	OCR con Xerox y Tesseract; sistema experto MYCIN; aceleradores de hardware precursores de la GPU.
Tercera (2000– presente): expansión del deep learning y modelos generativos	Procesar volúmenes masivos de datos complejos (texto, imagen, video) y generar contenido nuevo, no solo clasificarlo.	Redes neuronales profundas entrenadas con Big Data sobre GPU de alto rendimiento; arquitecturas transformer y de difusión.	Alto costo computacional y energético; riesgo de sesgos heredados de los datos de entrenamiento; cuestiones éticas y regulatorias abiertas (tema del Artículo 2).	AlphaGo; Alexa y Siri; GPT-4 y DALL·E; YOLO y OpenCV; Tesla; MidJourney y Stable Diffusion.

El argumento que atraviesa las tres fases, y que conviene tener como resumen mental antes de seguir con el resto de la unidad, es el siguiente: cada fase resolvió el cuello de botella de la fase anterior. La primera fase demostró que una máquina podía razonar con reglas, pero esas reglas había que escribirlas todas a mano, lo que no escalaba. La segunda fase resolvió eso dejando que la máquina aprendiera las reglas por sí misma a partir de datos, pero el hardware de la época no daba abasto para modelos grandes ni para datos

masivos. La tercera fase resolvió ese límite de hardware y de datos con GPU especializadas y con la explosión del Big Data, lo que permitió entrenar redes neuronales verdaderamente profundas, capaces no solo de clasificar sino de generar contenido nuevo. Ese mismo argumento —reglas escritas a mano, reglas aprendidas, rasgos aprendidos en profundidad creciente— es, de hecho, uno de los conceptos más difíciles de esta unidad, así que vale la pena releer este párrafo más de una vez hasta que quede completamente asentado.

Artículo 2: Aspectos éticos y desafíos de la IA

El primer artículo de la unidad mostró cómo la IA evolucionó de sistemas de reglas a modelos generativos capaces de crear texto e imágenes. Ese poder trae una contrapartida: cuanto más decide o genera un sistema por su cuenta, más preguntas abre sobre a quién beneficia, a quién puede perjudicar y quién responde cuando algo sale mal. El segundo artículo del módulo aborda justamente eso: los **aspectos éticos** de la IA, organizados en tres frentes que el curso presenta uno tras otro y que conviene entender como capas de un mismo problema: primero qué datos se recolectan y con qué autorización (privacidad), después qué hace el modelo con esos datos una vez entrenado (sesgos) y, por último, quién responde por las decisiones que el modelo termina tomando (rendición de cuentas y transparencia). Los tres frentes están conectados: un dato recolectado sin permiso puede terminar alimentando un modelo sesgado, y un modelo sesgado sin mecanismos de rendición de cuentas puede operar durante años sin que nadie lo corrija. Esta cadena — dato mal recolectado → modelo sesgado → decisión sin supervisión— es el hilo conductor de todo el artículo, y conviene tenerlo presente porque los tres casos que siguen (Clearview AI, Amazon y COMPAS) son, en el fondo, tres puntos distintos de esa misma cadena.

Privacidad de los datos

La **privacidad de los datos** (*data privacy*) es el derecho de una persona a controlar cómo se recolectan, almacenan y usan sus datos personales. Existe como concepto porque la IA moderna necesita datos en cantidad para funcionar —esto ya se vio en el módulo anterior con las tres V del Big Data— y esos datos casi siempre describen a personas reales: su rostro, sus hábitos de compra, su ubicación, su forma de escribir. El problema ético aparece cuando la recolección o el uso de esos datos ocurre sin que la persona lo sepa o lo autorice. El curso pone tres aplicaciones concretas donde el riesgo es alto: **reconocimiento facial** (*facial recognition*), análisis de comportamiento y publicidad personalizada. El reconocimiento facial es la tarea de identificar o verificar a una persona a partir de una imagen de su rostro: un modelo de visión por computador —la misma familia de técnicas que detecta objetos con YOLO, que se explicó en el Artículo 1— extrae de la foto un patrón numérico (algo así como una huella digital del rostro) y lo compara contra una base de datos de rostros ya conocidos. Cuando esa base de datos se construyó recopilando fotos de

personas sin que ellas lo supieran, el problema deja de ser solo técnico y pasa a ser un problema de consentimiento.

El ejemplo que usa el curso es **Clearview AI**, una empresa criticada por recopilar millones de imágenes de usuarios —extraídas de redes sociales y sitios web públicos— sin su consentimiento, para alimentar bases de datos usadas por fuerzas de seguridad y empresas privadas. La lógica del negocio de Clearview es simple de entender con una analogía: imagina un álbum de fotos gigantesco armado tomando, sin pedir permiso, cada foto pública que cualquier persona subió alguna vez a internet, y luego vendiendo el acceso a ese álbum —con una función de «buscar por cara»— a policías y empresas. Cada foto individual era pública, sí, pero nadie autorizó que se juntaran todas en un sistema de identificación masiva; ese salto, de «foto suelta y pública» a «base de datos de reconocimiento facial a escala mundial», es precisamente lo que generó la controversia.

 **Nota (discrepancia 10):** el curso dice que Clearview AI recopiló «millones» de imágenes; la evidencia verificada indica que la cifra supera los 30.000 millones de imágenes (dato de 2023), y que la empresa fue multada con 30,5 millones de euros por la autoridad de protección de datos de los Países Bajos en septiembre de 2024. **Para el examen:** si preguntan por el caso Clearview, responde con la idea del curso —recopilación masiva de imágenes sin consentimiento para bases de datos de seguridad—; si preguntan por una cifra o una consecuencia legal concreta, usa el dato verificado (más de 30.000 millones de imágenes; multa en Europa en 2024).

Frente a este tipo de riesgo, existen regulaciones que obligan a las empresas a operar con reglas claras. El curso menciona dos: el **GDPR** (*General Data Protection Regulation*), el Reglamento General de Protección de Datos de la Unión Europea, y la **CCPA** (*California Consumer Privacy Act*), la Ley de Privacidad del Consumidor de California. Ambas comparten la misma idea de fondo aunque operen en jurisdicciones distintas: obligan a las empresas a transparentar qué datos recolectan y para qué, y a obtener el **consentimiento informado** (*informed consent*) de los usuarios, es decir, una autorización explícita que la persona da sabiendo con precisión para qué se van a usar sus datos (no una casilla marcada sin leer, sino una autorización real, informada). El GDPR es la regulación más estricta y sirvió de modelo para leyes posteriores en el resto del mundo, incluido Chile.

 **Nota (discrepancia 9, parte privacidad):** el curso no menciona ley chilena alguna, pero como referencia local vale saber que Chile cuenta con la Ley 21.719 de protección de datos personales, publicada en diciembre de 2024, que entra en vigencia el 1 de diciembre de 2026 y crea la Agencia de Protección de Datos Personales (el gobierno evalúa una eventual postergación, pero esto no está confirmado). **Para el examen:** si la pregunta es sobre el curso, responde GDPR y CCPA; si preguntan por Chile, la Ley 21.719 es la respuesta correcta y entra en vigencia el 1-dic-2026.

El artículo cierra esta sección señalando que, pese a estas regulaciones, el desafío pendiente es el **uso indebido de datos** (*data misuse*) —usar datos personales para fines distintos de los autorizados— y la falta de supervisión efectiva en muchos países, es decir, que existan leyes no garantiza que se cumplan: hace falta fiscalización activa.

ANALOGÍA

Piensa en el consentimiento informado como la diferencia entre prestarle tu auto a un amigo diciéndole «llévalo al taller y devuélvelo mañana» y que ese amigo, sin avisarte, lo use además para hacer repartos toda la semana. El auto es el mismo, el préstamo inicial fue real, pero el uso que se le dio excede lo que autorizaste; eso es uso indebido de datos.

EJEMPLO

Supongamos —cifra hipotética para ilustrar la idea, no un dato del curso— que una tienda en línea recolecta el historial de navegación de 100.000 usuarios para «mejorar la experiencia de compra» (el fin autorizado) y, sin decírselo a nadie, vende ese mismo historial a una aseguradora que lo usa para ajustar primas de seguro de salud. El dato es el mismo; el consentimiento cubría solo el primer uso. Ese desfase entre lo autorizado y lo efectivamente hecho es exactamente el tipo de riesgo que el GDPR y la CCPA buscan cerrar.

Sesgos en los algoritmos

El segundo frente ético es el **sesgo algorítmico** (*algorithmic bias*): un error sistemático de un modelo que perpetúa discriminación, casi siempre porque hereda prejuicios ya presentes en los datos con los que fue entrenado. Para entender por qué existe conviene recordar cómo aprende un modelo de machine learning (visto en los conceptos clave de esta unidad y con más detalle en el módulo 1): el modelo no razona sobre lo que es justo, solo detecta patrones estadísticos en los datos de entrenamiento y los reproduce. Si esos datos contienen un patrón discriminatorio —aunque nadie lo haya puesto ahí a propósito—, el modelo lo aprende como si fuera una regla legítima del mundo. A esto se le llama **sesgo en datos históricos** (*historical data bias*): los prejuicios del pasado, registrados sin intención en los datos, terminan codificados en el modelo como si fueran conocimiento válido.

El caso que usa el curso es el sistema de contratación de **Amazon**: la empresa entrenó un modelo para evaluar currículos de candidatos a puestos técnicos usando como datos de entrenamiento los currículos de contrataciones exitosas de los diez años anteriores. Como esa industria había contratado históricamente más hombres que mujeres, el modelo aprendió —sin que nadie se lo indicara explícitamente— que los rasgos asociados a currículos «masculinos» predecían mejor el éxito, y terminó penalizando currículos que incluían términos asociados a mujeres (por ejemplo, mención de clubes o actividades

«femeninas»). Amazon detectó el problema y discontinuó el sistema antes de usarlo en decisiones reales.

EJEMPLO

La mecánica es más fácil de ver con números hipotéticos. Supongamos un conjunto de entrenamiento de 1.000 currículos de contrataciones pasadas, de los cuales 800 corresponden a hombres y 200 a mujeres. Aunque el modelo nunca reciba el campo «sexo» como dato de entrada, puede aprender a inferirlo indirectamente a partir de palabras correlacionadas (nombres de universidades, clubes, pasatiempos) y, como el 80% de los «casos de éxito» que vio eran hombres, terminará asignando puntajes más altos a currículos con ese perfil, no porque sean objetivamente mejores, sino porque el patrón numérico que detectó en los datos así lo indicaba. El sesgo no está en una línea de código maliciosa: está en la composición del conjunto de datos.

Para enfrentar este problema existen herramientas específicas. El curso menciona **AI Fairness 360**, un conjunto de bibliotecas de código abierto desarrolladas por IBM para detectar y mitigar sesgos en modelos de machine learning: en la práctica, son funciones que miden si un modelo trata de forma distinta a distintos grupos demográficos (por ejemplo, comparando la tasa de aprobación de crédito entre grupos) y ofrecen técnicas para corregir esas diferencias, ya sea ajustando los datos de entrenamiento, el proceso de entrenamiento o las predicciones finales del modelo.

El artículo agrega un segundo ejemplo, en el sector financiero: algoritmos de IA usados para evaluar la **solvencia** de clientes discriminaron a minorías étnicas al basarse en datos históricos con prejuicios sistémicos —el mismo mecanismo que en el caso Amazon, aplicado ahora al crédito en vez de a la contratación—. La conclusión del curso es que esto obliga a establecer **auditorías de algoritmos** (*algorithmic audit*) constantes en modelos usados para decisiones críticas: una auditoría de algoritmos es una revisión periódica e independiente de un modelo, hecha específicamente para detectar sesgos y errores antes de que causen daño a gran escala, de forma análoga a una auditoría contable, pero en vez de revisar libros de cuentas revisa las decisiones del modelo desagregadas por grupo.

ANALOGÍA

Un modelo sesgado es como un guardia de seguridad que nunca leyó un manual de discriminación, pero que llevó veinte años observando a quién detenían sus colegas en el pasado y, sin pensarlo, empezó a fijarse más en cierto tipo de personas porque «así es como siempre se ha hecho». El guardia no tiene mala intención explícita; simplemente aprendió el patrón equivocado de la experiencia equivocada. Auditar el algoritmo es como poner a otro observador a contar, con números, a quién detiene realmente el guardia, para confirmar si el patrón que aprendió es justo o no.

Rendición de cuentas y transparencia

El tercer frente cierra el círculo: si los datos pueden recolectarse mal y los modelos pueden heredar sesgos, hace falta un mecanismo para que alguien responda cuando el sistema toma una decisión dañina. A eso se le llama **rendición de cuentas** (*accountability*): los mecanismos que permiten identificar quién responde por las decisiones que toma un sistema de IA. Es un concepto distinto pero hermano de la **transparencia** (*transparency*) —que se pueda conocer cómo funciona un sistema de IA y con qué datos decide— y de la **explicabilidad** (*explainability*) —la capacidad de explicar, para un caso concreto, por qué el modelo tomó esa decisión específica y no otra—. Los tres conceptos suelen ir juntos: sin transparencia no se puede auditar, sin explicabilidad no se puede apelar una decisión concreta, y sin rendición de cuentas nadie tiene el incentivo de corregir el sistema aunque se detecten fallas.

El ejemplo del curso es **COMPAS**, un algoritmo usado en la justicia penal de Estados Unidos para predecir la **reincidencia** (*recidivism*) criminal, es decir, la probabilidad de que una persona vuelva a cometer un delito. Jueces y sistemas penitenciarios usaban el puntaje de COMPAS como uno de los insumos para decidir sobre libertad condicional o severidad de la sentencia. Investigaciones mostraron que COMPAS presentaba un sesgo racial significativo: clasificaba erróneamente a personas afroamericanas con mayor probabilidad de reincidencia que a personas blancas con delitos similares.

 **Nota (discrepancia 10, parte COMPAS):** el curso atribuye el hallazgo a «AI Now Institute (2023)»; el análisis original y más citado sobre COMPAS es de la organización periodística ProPublica (2016), que encontró una tasa de falsos positivos de 44,9% en acusados afroamericanos frente a 23,5% en acusados blancos (un **falso positivo** (*false positive*), aquí, es marcar como «alto riesgo de reincidir» a alguien que en realidad no reincidió). Northpointe, la empresa fabricante de COMPAS, rebatió ese análisis, y ProPublica publicó una réplica defendiendo su metodología; el debate de fondo es que existen varias definiciones matemáticas de «equidad» entre grupos que no pueden cumplirse todas a la vez cuando las tasas base de reincidencia difieren entre esos grupos, así que incluso un modelo «calibrado» correctamente puede verse injusto según otra definición de equidad. **Para el examen:** el caso a citar es COMPAS y el resultado es sesgo racial en la clasificación de reincidencia; si piden la cifra o la fuente, usa ProPublica (2016) con 44,9% frente a 23,5%.

Frente a este tipo de riesgo, el curso menciona que la Unión Europea «ha propuesto» regulaciones dentro de la **Ley de Inteligencia Artificial** (*EU AI Act*), estableciendo que los **sistemas de alto riesgo** (*high-risk AI system*) —sistemas cuyas decisiones afectan derechos o seguridad de las personas, como crédito, empleo o justicia penal— deben cumplir con estrictos requisitos de explicabilidad y auditoría para garantizar decisiones

justas y responsables. Un sistema como COMPAS, que decide sobre la libertad de una persona, es el ejemplo típico de sistema de alto riesgo.

⚠ Nota (discrepancia 9): el curso dice que la Unión Europea «ha propuesto» estas regulaciones, en tiempo condicional, como si todavía estuvieran en discusión. La evidencia indica que ya dejó de ser una propuesta: es el Reglamento (UE) 2024/1689 («Ley de IA de la UE»), en vigor desde el 1 de agosto de 2024, con aplicación escalonada (las prohibiciones de ciertos usos rigen desde febrero de 2025, y las obligaciones para modelos de propósito general desde agosto de 2025). Según reportes de mayo de 2026, hubo un acuerdo político para postergar las obligaciones de los sistemas de alto riesgo dentro de un paquete llamado «Digital Omnibus»: a diciembre de 2027 para sistemas independientes y a agosto de 2028 para IA embebida en productos ya regulados (este acuerdo está verificado, aunque su publicación final solo se encontró en una fuente, así que conviene decir «según reportes, ya adoptado» y no darlo por definitivo). El scoring crediticio — relevante para el caso FinAI que se revisa más adelante en esta unidad— es un ejemplo típico de sistema de alto riesgo bajo esta ley. **Para el examen:** responde con la idea del curso (sistemas de alto riesgo → explicabilidad y auditoría); si preguntan por el estado legal, la respuesta correcta es que ya es un reglamento vigente y en aplicación escalonada, no una propuesta.

EJEMPLO

Para ver por qué la explicabilidad importa en la práctica: si un banco rechaza un crédito usando un modelo de IA y la persona pregunta por qué, «transparencia» sería poder decir en general cómo funciona el modelo (qué variables usa, cómo fue entrenado); «explicabilidad» sería poder decir, para ese caso puntual, cuáles factores concretos pesaron más en el rechazo (por ejemplo, un historial de pagos irregular en los últimos seis meses); y «rendición de cuentas» sería que exista un responsable identificable —un área, un cargo, un proceso de apelación— ante quien esa persona pueda reclamar si considera que la decisión fue injusta. Los tres elementos son necesarios y ninguno reemplaza a los otros.

Aplicaciones avanzadas de la IA

Después de revisar los riesgos, el curso pasa a mostrar el otro lado de la moneda: casos donde la IA genera valor real y medible en sectores muy distintos entre sí. El curso agrupa estos casos en tres bloques —logística, medicina y prevención de desastres— y en cada uno el patrón se repite: se combinan datos de distinto tipo (sensores, imágenes, historiales), se les aplica una técnica de IA ya vista (visión por computador, deep learning, redes neuronales) y el resultado es una decisión o una alerta más rápida y más precisa que la que un proceso manual podría dar.

Logística predictiva

La **logística predictiva** (*predictive logistics*) es el uso de IA para anticipar la demanda de productos, ajustar inventarios y mejorar los tiempos de entrega, en vez de reaccionar después de que el problema ya ocurrió (por ejemplo, un producto agotado o un camión que llega vacío a un puerto). Existe porque las cadenas de suministro modernas mueven volúmenes y variables demasiado grandes para planificarse a mano con precisión: un modelo de ML puede procesar simultáneamente historiales de venta, estacionalidad, clima y eventos, y producir una proyección de demanda que un equipo humano no podría recalcular todos los días para miles de productos. El curso usa a **Amazon** como ejemplo de esto: la empresa utiliza IA para anticipar la demanda de productos, ajustando inventarios y mejorando los tiempos de entrega.

El segundo ejemplo es **Maersk**, que el curso describe como «la mayor empresa de transporte marítimo del mundo», y que ha implementado algoritmos de **optimización de rutas** (*route optimization*): elegir el recorrido de un barco combinando datos meteorológicos, niveles de tráfico marítimo y tiempos de carga y descarga en puertos, para minimizar tiempo y combustible. Gracias a esto, Maersk redujo sus costos operativos y su **huella de carbono** (*carbon footprint*) —las emisiones de gases de efecto invernadero asociadas a una operación— al optimizar la eficiencia del combustible de sus embarcaciones. La lógica es directa: una ruta más corta o que evita mal tiempo no solo ahorra tiempo, quema menos combustible, y menos combustible quemado significa menos emisiones; la eficiencia operativa y la reducción de huella de carbono son, en este caso, la misma decisión vista desde dos ángulos distintos.

⚠ Nota (discrepancia 11): el curso presenta a Maersk como «la mayor empresa de transporte marítimo del mundo». La evidencia indica que MSC (Mediterranean Shipping Company) superó a Maersk como la naviera con mayor capacidad desde enero de 2022. **Para el examen:** el caso Maersk vale como ejemplo de optimización de rutas con IA y reducción de huella de carbono; no afirmes que sigue siendo la número uno del mundo si te preguntan por el ranking actual.

El tercer ejemplo describe cómo la IA ayudó durante la pandemia de COVID-19: según el curso, **IBM Watson Supply Chain** ayudó a prever interrupciones en la distribución de bienes esenciales mediante el análisis en tiempo real de datos de proveedores, predicciones meteorológicas y fluctuaciones en la demanda, permitiendo a empresas y gobiernos planificar mejor la logística de suministros médicos y alimentos en tiempos críticos. Aquí la **cadena de suministro** (*supply chain*) —la red de proveedores, producción y distribución que lleva un producto hasta el cliente final— es el objeto que el sistema intenta proteger de quiebres: en una crisis, un modelo que detecta con anticipación que un proveedor clave va a fallar permite buscar un proveedor alternativo antes de que el producto desaparezca de las góndolas.

⚠ **Nota (discrepancia 12, parte Watson Supply Chain):** el curso presenta «IBM Watson Supply Chain» como un producto específico y vigente. No fue posible confirmar ese nombre exacto como producto de IBM; la línea de negocio documentada de la empresa en este ámbito es IBM Sterling Supply Chain. **Para el examen:** usa el ejemplo del curso como ilustración de IA aplicada a la resiliencia de cadenas de suministro durante crisis; no des por sentado el nombre exacto del producto si te lo preguntan como dato aislado.

El último ejemplo de esta sección son los **almacenes automatizados** (*automated warehouse*): bodegas donde robots inteligentes y sistemas de aprendizaje automático optimizan la colocación de productos en estanterías y reducen los tiempos de procesamiento de pedidos de comercio electrónico. El curso menciona a **Ocado** y **Walmart**. La mecánica, en términos simples, combina dos decisiones que antes hacía una persona: dónde guardar cada producto (para que los que se piden juntos con frecuencia queden cerca) y qué robot debe ir a buscar qué producto cuando llega un pedido; un modelo de ML aprende, a partir del historial de pedidos, qué combinaciones de productos conviene tener cerca entre sí, reduciendo la distancia total que recorren los robots por pedido.

ANALOGÍA

Un almacén automatizado bien optimizado se parece a un supermercado donde alguien reordenó los pasillos observando qué compran juntas las personas: si el pan y la mantequilla casi siempre se compran juntos, ponerlos cerca ahorra pasos a cada cliente. La diferencia es que aquí «el cliente» es un robot, «los pasos» son tiempo de proceso, y el reordenamiento no lo decide una persona por intuición sino un modelo que recalcula constantemente a partir de datos reales de pedidos.

EJEMPLO

Supongamos —cifra hipotética, no del curso— un almacén que procesa 10.000 pedidos diarios y que, antes de optimizar la disposición de productos, cada robot recorre en promedio 40 metros por pedido. Si el modelo de ML reordena las estanterías según patrones de compra conjunta y reduce ese recorrido promedio a 28 metros, el ahorro es de 30% en distancia recorrida por pedido; multiplicado por 10.000 pedidos diarios, son 120.000 metros menos de recorrido acumulado al día, que se traducen directamente en más pedidos despachados por hora con la misma flota de robots.

Medicina personalizada

La **medicina personalizada** (*personalized medicine*) es el enfoque de ajustar tratamientos médicos a cada paciente según sus datos clínicos y genómicos particulares, en vez de aplicar el mismo protocolo estándar a todos los pacientes con un diagnóstico similar. Existe

porque dos pacientes con el «mismo» diagnóstico pueden responder de forma muy distinta a un mismo tratamiento por diferencias genéticas, de historial clínico o de estilo de vida, y la IA permite procesar esa cantidad de variables individuales a una escala que antes solo era posible de forma muy limitada. El curso presenta cuatro ejemplos, cada uno con una técnica y un objetivo distinto.

El primero es **IBM Watson Health**, que analiza grandes volúmenes de datos médicos — historiales clínicos, resultados de pruebas y literatura científica— para ayudar a los médicos en la detección temprana de enfermedades como el cáncer, mejorando la precisión en diagnósticos y permitiendo tratamientos más eficaces. La idea de fondo es que ningún médico puede leer, en tiempo razonable, toda la literatura científica publicada sobre una enfermedad; un sistema de IA sí puede procesar ese volumen y señalar patrones o antecedentes relevantes para un caso puntual.

 **Nota (discrepancia 12, parte Watson Health):** el curso presenta a IBM Watson Health como un producto vigente de IBM. La evidencia indica que IBM vendió esa unidad de negocio a Francisco Partners en 2022; hoy opera bajo el nombre Merative. **Para el examen:** usa el caso como ejemplo de IA aplicada al análisis de historiales clínicos y detección temprana de enfermedades; el nombre «Watson Health» corresponde a la etapa en que era producto de IBM.

El segundo ejemplo es **Tempus**, una empresa de biotecnología que utiliza IA para analizar el **perfil genómico** (*genomic profile*) de los pacientes —la información genética de una persona, es decir, qué variantes tiene en su ADN— y sugerir terapias personalizadas basadas en datos clínicos. Gracias a esta tecnología, los oncólogos pueden determinar con mayor precisión qué tratamientos tendrán mayor probabilidad de éxito para cada paciente: en vez de probar un tratamiento estándar y esperar semanas para ver si funciona, el perfil genómico permite anticipar, antes de empezar, qué terapias son más compatibles con las mutaciones específicas del tumor de ese paciente.

El tercer ejemplo es **AlphaFold**, desarrollado por **DeepMind** (filial de Google): un sistema de IA capaz de predecir **estructuras de proteínas** con una precisión sin precedentes. Para entender por qué esto es relevante hace falta un paso atrás: las proteínas son las moléculas que hacen casi todo el trabajo dentro de una célula, y su función depende de la forma tridimensional en la que se pliegan a partir de su secuencia de aminoácidos (una especie de origami molecular). Durante décadas, determinar experimentalmente esa forma tridimensional en el laboratorio —con técnicas como la cristalografía de rayos X— podía tomar años por proteína. AlphaFold resuelve ese mismo problema con un modelo de deep learning entrenado con miles de estructuras ya conocidas, y predice la forma tridimensional de una proteína nueva a partir únicamente de su secuencia, en cuestión de horas o días. Este avance ha acelerado la investigación en enfermedades genéticas y el desarrollo de nuevos medicamentos, y gracias a AlphaFold los científicos han podido modelar proteínas

clave en enfermedades como el Alzheimer y la fibrosis quística, facilitando el diseño de fármacos dirigidos con mayor eficacia.

⚠ **Nota (discrepancia 14):** el curso dice que AlphaFold redujo el tiempo para descubrir fármacos «de varios años a solo unos meses». Lo que AlphaFold acelera con precisión es la determinación de la estructura de las proteínas (el paso que antes tomaba años de laboratorio y ahora toma horas o días); desarrollar y aprobar un fármaco completo, con ensayos clínicos incluidos, sigue tomando años incluso cuando la estructura ya se conoce. Como dato adicional: AlphaFold 2 ganó la competencia CASP14 en 2020, y ese trabajo valió el Nobel de Química 2024, compartido por Demis Hassabis y John Jumper (de DeepMind) junto con David Baker. **Para el examen:** AlphaFold = predicción de estructuras de proteínas que acelera la investigación, no el desarrollo completo de un fármaco; si preguntan qué gana el Nobel de Química 2024, es AlphaFold (Hassabis y Jumper) junto con David Baker.

ANALOGÍA

Predecir la estructura de una proteína a partir de su secuencia de aminoácidos es parecido a predecir cómo va a quedar plegada una sábana larguísima solo con la lista de sus dobleces posibles, sin poder desplegarla nunca físicamente: hay tantas formas posibles de plegarla que probarlas todas a mano tomaría más tiempo que la edad del universo. AlphaFold aprendió, viendo miles de sábanas ya plegadas y medidas en laboratorio, a intuir directamente la forma final sin tener que probar cada doblez posible.

El cuarto ejemplo es la **radiología** asistida por IA: empresas como **Qure.ai** y **Aidoc** desarrollaron modelos de visión por computador —la misma familia técnica detrás de YOLO, aplicada aquí a otro tipo de imagen— capaces de analizar radiografías y tomografías para detectar anomalías como fracturas, tumores y hemorragias cerebrales en cuestión de segundos, lo que se agrupa bajo el concepto de **imágenes médicas con IA** (*AI medical imaging*): el uso de visión por computador para detectar hallazgos clínicos en radiografías y tomografías. El valor no está solo en la precisión sino en la velocidad: en un hospital con alta carga de trabajo, un modelo que marca automáticamente los casos con mayor probabilidad de urgencia (por ejemplo, una hemorragia cerebral) permite que el radiólogo priorice esos casos primero, en vez de revisar todos los estudios en el orden en que llegaron.

Prevención de desastres

El tercer bloque de aplicaciones avanzadas es la **prevención de desastres**, donde la IA se usa para anticipar eventos naturales dañinos y dar tiempo de reacción. El concepto general que agrupa estos casos es el de **sistema de alerta temprana** (*early warning system*): un sistema que anticipa un desastre —inundación, incendio o sismo— para dar tiempo de evacuar o reaccionar antes de que ocurra el daño mayor. El patrón técnico se repite en los

tres casos que trae el curso: se combinan datos históricos y datos en tiempo real (imágenes satelitales, sensores, cámaras) y se les aplica un modelo entrenado para reconocer los patrones que preceden al desastre.

El primer caso es **Google AI**, que desarrolló sistemas para prever inundaciones en regiones vulnerables combinando datos meteorológicos históricos, imágenes satelitales y modelos de simulación climática. Este avance ha permitido a comunidades en India y Bangladesh recibir alertas con días de anticipación, lo que facilita la evacuación y reduce el impacto de las catástrofes naturales.

El segundo caso son los incendios forestales: empresas como **Chooch AI** y **Descartes Labs** desarrollaron modelos de visión por computador que identifican focos de incendio a partir de imágenes satelitales y drones, permitiendo una respuesta rápida de los equipos de emergencia y reduciendo el daño ecológico y económico. El curso agrega que en California, el **CAL FIRE** (Departamento de Silvicultura y Protección contra Incendios) integró IA en su red de cámaras de detección: mediante algoritmos de machine learning, las cámaras detectan el humo en etapas tempranas y alertan a los bomberos antes de que el fuego se expanda.

⚠ Nota (discrepancia 13, parte CAL FIRE): el curso no especifica con qué proveedor tecnológico trabaja CAL FIRE para su red de cámaras; el programa documentado es ALERTCalifornia, de la Universidad de California en San Diego, junto con la empresa DigitalPath, lanzado en 2023 y elegido entre los mejores inventos del año por la revista TIME. No se encontró evidencia de que Chooch AI o Descartes Labs trabajen directamente con CAL FIRE (el curso tampoco lo afirma de forma explícita, solo los menciona en el mismo párrafo temático). **Para el examen:** Chooch AI y Descartes Labs son ejemplos generales de visión por computador aplicada a detección de incendios con imágenes satelitales y drones; si preguntan específicamente por el socio tecnológico de CAL FIRE, la respuesta verificada es ALERTCalifornia/UC San Diego con DigitalPath.

El tercer caso es la **monitorización de terremotos y tsunamis**: el curso indica que el **USGS** (Servicio Geológico de Estados Unidos) «emplea redes neuronales» para analizar ondas sísmicas en tiempo real, con el sistema **ShakeAlert** —un sistema de alerta sísmica temprana que opera en la costa oeste de Estados Unidos y da segundos de anticipación a ciudades como San Francisco y Los Ángeles antes de que llegue la onda de mayor intensidad de un terremoto—.

⚠ Nota (discrepancia 13, parte ShakeAlert): el curso dice que el USGS «emplea redes neuronales» para ShakeAlert. La evidencia indica que ShakeAlert usa algoritmos sismológicos específicos —EPIC, FinDer y GFAST-PGD— y no redes neuronales; además, ShakeAlert cubre California, Oregón y Washington, no solo San Francisco y Los Ángeles (que son ejemplos de ciudades dentro de esa zona de cobertura). **Para el examen:**

ShakeAlert = sistema de alerta sísmica temprana del USGS con segundos de anticipación; si preguntan por la técnica exacta, es sismología algorítmica (EPIC, FinDer, GFAST-PGD), no redes neuronales.

ANALOGÍA

Un sistema de alerta temprana funciona como el zumbido de una tetera antes de que hierva toda el agua: no evita el evento (el agua igual hierve, el sismo igual ocurre), pero avisa con segundos u horas de anticipación para que alguien reaccione antes de que llegue lo peor. La diferencia entre ShakeAlert y una alerta de inundación es la ventana de tiempo: segundos en un sismo (porque las ondas sísmicas viajan muy rápido y el epicentro puede estar cerca), días en una inundación (porque el fenómeno climático que la origina se puede seguir con horas o días de antelación).

Herramientas de implementación en IA

Después de ver aplicaciones concretas, el curso baja un nivel más y muestra con qué herramientas de software se construyen esos modelos en la práctica. Las tres que presenta —TensorFlow, PyTorch y Hugging Face— son, en esencia, **bibliotecas de código abierto** (*open-source library*): conjuntos de herramientas de programación con el código fuente disponible públicamente y de uso gratuito, que cualquier equipo de ingeniería puede usar para construir, entrenar y desplegar modelos sin tener que programar desde cero las operaciones matemáticas básicas de una red neuronal. Que sean de código abierto es lo que explica su adopción masiva: una empresa pequeña puede usar la misma tecnología de base que usa Google o Meta internamente, sin pagar licencias, y una comunidad enorme de desarrolladores contribuye a mejorarlas y documentarlas.

TensorFlow

TensorFlow, desarrollado por Google, es una de las bibliotecas de código abierto más utilizadas para la implementación de modelos de aprendizaje automático y deep learning. Su flexibilidad y escalabilidad la hacen ideal tanto para investigaciones académicas como para aplicaciones comerciales a gran escala: «escalabilidad», aquí, significa que el mismo código que entrena un modelo pequeño en una laptop puede, con ajustes mínimos, entrenar un modelo mucho más grande repartido entre cientos de procesadores especializados (las GPU vistas en la historia de la IA, en el Artículo 1), sin tener que reescribir la lógica del modelo desde cero.

El curso da dos ejemplos de uso. El primero es **Airbnb**, que utiliza TensorFlow para ajustar dinámicamente los precios de habitaciones en función de la demanda y eventos locales, optimizando la conversión de reservas y maximizando los ingresos (esto conecta directamente con el concepto de precio dinámico que se revisará en el caso ShopSmart

más adelante en esta unidad). El segundo es **Stanford University**, que aplicó TensorFlow en la detección temprana de enfermedades pulmonares mediante el análisis de imágenes de rayos X con redes neuronales convolucionales, logrando tasas de precisión comparables a las de los radiólogos humanos.

⚠ **Nota (discrepancia 15, parte Airbnb):** no se encontró confirmación pública específica de que Airbnb use TensorFlow para su motor de precios dinámicos, aunque la empresa sí es conocida por usar machine learning intensivamente en esa área. Sobre el caso de Stanford, la evidencia coincide con lo que documenta la literatura como CheXNet (2017): una red convolucional de 121 capas entrenada para detectar neumonía en radiografías de tórax, comparada en su evaluación original contra cuatro radiólogos, con un desempeño (medido con la métrica F1) de 0,435 para el modelo frente a un promedio de 0,387 para los radiólogos; el framework exacto usado en ese estudio no se pudo confirmar. **Para el examen:** asocia TensorFlow con Google, flexibilidad y escalabilidad, y con el caso de Stanford y la detección de enfermedades pulmonares mediante CNN; trata el ejemplo de Airbnb como una ilustración del concepto de precio dinámico, no como un dato técnico verificado sobre su stack.

PyTorch

PyTorch, desarrollado por Meta (anteriormente Facebook), es altamente popular entre investigadores y desarrolladores debido a su facilidad de uso y su enfoque en la creación rápida de prototipos, lo que el curso llama **prototipado rápido** (*rapid prototyping*): construir versiones de prueba de un modelo en poco tiempo para validar una idea antes de invertir en una versión final optimizada. Es ampliamente empleado en procesamiento de lenguaje natural, visión por computador y generación de contenido con IA —los tres campos definidos en el bloque anterior de esta unidad—.

El curso menciona que **ChatGPT de OpenAI** se basa en modelos de lenguaje entrenados con PyTorch, y que su flexibilidad mejoró la generación de texto y la comprensión de contextos complejos. El segundo uso destacado es la conducción autónoma: empresas como **Tesla** y **Waymo** emplean esta biblioteca para el entrenamiento de redes neuronales que procesan información de cámaras, radares y sensores **LiDAR** (*Light Detection and Ranging*) en tiempo real, permitiendo a los vehículos interpretar su entorno y tomar decisiones seguras en la carretera. El LiDAR es un sensor que mide distancias emitiendo pulsos de luz láser y midiendo cuánto tardan en rebotar en los objetos alrededor; con miles de esos pulsos por segundo en distintas direcciones, el vehículo arma un mapa tridimensional de todo lo que lo rodea, mucho más preciso en profundidad que una cámara sola. Combinar cámaras (que ven color y texto, como señales de tránsito), radares (que funcionan bien con lluvia o niebla) y LiDAR (que da profundidad exacta) es lo que permite que un sistema de conducción autónoma «vea» el entorno con redundancia: si un sensor falla o se confunde, los otros pueden compensar.

⚠ Nota (discrepancia 15, parte PyTorch): el uso de PyTorch por Tesla y por OpenAI (en el entrenamiento de los modelos detrás de ChatGPT) sí está documentado; el uso específico de PyTorch por Waymo no se pudo confirmar con una fuente pública. **Para el examen:** asocia PyTorch con Meta, prototipado rápido y facilidad de uso, y con los casos de ChatGPT y Tesla; menciona Waymo como parte del ejemplo del curso, sin darlo por confirmado como dato técnico aislado.

ANALOGÍA

Si TensorFlow es como un taller industrial pensado para producir a gran escala con procesos ya afinados, PyTorch es más como un taller de prototipos: más flexible para probar ideas nuevas rápido, aunque escalarlas después a producción masiva requiera trabajo adicional. Con el tiempo ambas herramientas se han ido acercando en capacidades, pero esa diferencia de origen —producción a escala frente a investigación ágil— sigue explicando por qué cada una es popular en comunidades distintas: la industria y la academia de investigación, respectivamente.

Hugging Face

Hugging Face es una plataforma y comunidad enfocada en el desarrollo y optimización de modelos de IA, especialmente en procesamiento de lenguaje natural. A diferencia de TensorFlow y PyTorch, que son bibliotecas para construir y entrenar modelos desde sus piezas básicas, Hugging Face es sobre todo un repositorio y una comunidad: proporciona una vasta colección de **modelos preentrenados** (*pre-trained model*) —modelos que ya fueron entrenados por alguien más con grandes cantidades de datos y que un equipo puede reutilizar o ajustar en vez de entrenarlos desde cero— que facilitan tareas como traducción automática, **análisis de sentimientos** (*sentiment analysis*) y generación de texto. El análisis de sentimientos es la tarea de detectar si un texto expresa una opinión positiva, negativa o neutra (por ejemplo, clasificar automáticamente si una reseña de producto es favorable o desfavorable); es uno de los usos más comunes de los modelos de PLN preentrenados que ofrece la plataforma.

Reutilizar un modelo preentrenado en vez de entrenar uno propio desde cero es, en esencia, el mismo principio de ajuste fino que se definió en los conceptos clave de esta unidad, aplicado ahora a través de una plataforma que centraliza miles de esos modelos ya listos para descargar y adaptar.

El curso da dos ejemplos de uso. El primero es **Grammarly**, una aplicación de asistencia en escritura que emplea modelos de PLN para sugerencias gramaticales, corrección de estilo y detección de tono en textos en tiempo real; gracias a Hugging Face, Grammarly mejoró significativamente su capacidad de procesamiento y la personalización de sugerencias para cada usuario. El segundo ejemplo es la automatización del servicio al cliente: empresas

como **Zalando** y **Shopify** implementaron chatbots avanzados utilizando modelos preentrenados de esta plataforma, logrando reducir los tiempos de respuesta y mejorar la satisfacción de los clientes mediante respuestas más precisas y contextualizadas.

⚠ Nota (discrepancia 15, parte Hugging Face): no se encontró confirmación pública específica de que Grammarly, Zalando o Shopify usen Hugging Face en sus sistemas de producción, aunque el escenario descrito —modelos preentrenados de PLN para sugerencias de escritura y para chatbots— es plausible y coherente con el tipo de modelos que la plataforma ofrece; como dato verificado y más sólido, Hugging Face Hub aloja hoy más de 3 millones de modelos públicos. **Para el examen:** asocia Hugging Face con PLN, modelos preentrenados y su comunidad de código abierto; trata Grammarly, Zalando y Shopify como ejemplos ilustrativos del curso, no como datos técnicos confirmados.

Las tres herramientas comparten el mismo propósito general —dar la infraestructura de software para construir modelos de IA sin reinventar las operaciones matemáticas de base — pero difieren en su origen, su fortaleza principal y el tipo de proyecto para el que suele elegirse cada una:

Herramienta	Desarrollada por	Fortaleza principal	Casos del curso
TensorFlow	Google	Flexibilidad y escalabilidad para producción a gran escala, en investigación y comercio	Airbnb (precio dinámico), Stanford (CNN en rayos X)
PyTorch	Meta (antes Facebook)	Facilidad de uso y prototipado rápido, popular en investigación	ChatGPT (OpenAI), Tesla y Waymo (conducción autónoma)
Hugging Face	Comunidad Hugging Face	Plataforma con modelos preentrenados listos para reutilizar, sobre todo de PLN	Grammarly (escritura), Zalando y Shopify (chatbots)

Una forma útil de recordarlas para el examen es asociar cada una a una palabra clave: TensorFlow con «escala», PyTorch con «prototipo», y Hugging Face con «modelos ya listos». Las tres son complementarias más que competidoras: es común, en un proyecto real, entrenar un modelo con PyTorch o TensorFlow y luego publicarlo o descargar otro ya entrenado desde Hugging Face para no partir de cero.

Video resumen

El curso incluye, solo en la versión online (no viene incluido en el PDF), un video resumen de la unidad con su texto de apoyo. Ese texto repite, sin agregar contenido nuevo, los

mismos puntos que ya cubre esta explicación: la definición de Inteligencia Artificial como la capacidad de las máquinas para imitar procesos de inteligencia humana (aprendizaje, razonamiento y resolución de problemas); las tres fases históricas (sistemas basados en reglas, aprendizaje automático, deep learning y modelos generativos); el papel del poder computacional; y los riesgos de privacidad y uso indebido de datos revisados en el Artículo 2. No introduce ningún concepto, cifra o ejemplo adicional a los ya explicados en el artículo 1 y en este artículo 2, así que no requiere una sección aparte de contenido nuevo; queda registrado aquí únicamente para dejar constancia de que existe y de que es material de repaso, no de ampliación.

Caso 1: AutoTech

El PDF del curso deja atrás la exposición teórica y entra en el primero de tres casos narrativos: empresas ficticias que sirven de laboratorio para ver la IA aplicada. **AutoTech** es una empresa de la industria automotriz que enfrenta dos problemas operativos clásicos de cualquier planta: interrupciones de producción por **averías inesperadas** en la maquinaria y una **gestión ineficiente de inventarios**. El equipo protagonista está formado por Carlos (gerente de producción, quien sufre en carne propia cada parada de línea), Ana (ingeniera de datos, quien construye la solución técnica) y Luis (responsable de la cadena de suministro, quien traduce las predicciones en decisiones de compra). El caso avanza en tres pasos, cada uno con una tecnología distinta y una cifra de resultado, y conviene leerlo así: no como tres anécdotas sueltas, sino como una cadena donde cada paso ataca un cuello de botella distinto de la misma operación.

Paso 1: mantenimiento predictivo

Ana instaló **sensores IoT** (*Internet of Things sensors*) en las líneas de ensamblaje. Un sensor IoT es, en esencia, un dispositivo conectado a internet (o a una red local) que mide continuamente una variable física del mundo real —en este caso, vibración, temperatura y desgaste de piezas clave— y envía esa lectura como dato digital, en tiempo real, a un sistema que la puede analizar. La diferencia frente a una inspección tradicional es la frecuencia y el volumen: en lugar de que un técnico revise la máquina una vez por turno, el sensor entrega miles de lecturas por hora, generando exactamente el tipo de **Big Data** (definido en la sección de conceptos clave de esta unidad) sobre el que después trabaja el modelo.

Con esos datos, el equipo de Ana entrenó una **red neuronal** que los analizó junto con los **registros históricos** de fallas anteriores, y así aprendió a **predecir fallas antes de que ocurrieran**. Aquí conviene distinguir dos conceptos que el caso da por sentado: el **mantenimiento predictivo** (*predictive maintenance*) es anticipar una falla con datos de sensores y anticiparse a ella, mientras que el **mantenimiento correctivo** (*corrective maintenance*) es reparar recién después de que la máquina ya falló. El correctivo es

siempre más caro: no solo hay que arreglar la pieza, sino que mientras tanto la línea completa puede estar detenida, lo que se llama **tiempo de inactividad** (*downtime*), es decir, el tiempo en que una máquina o línea de producción no está produciendo. El mantenimiento predictivo no elimina las fallas —las piezas siguen desgastándose—, pero permite programarlas: cambiar la pieza en una ventana de mantenimiento planificada, con el repuesto ya en bodega y sin detener la línea a mitad de un turno productivo.

ANALOGÍA

Es la diferencia entre ir al dentista dos veces al año y esperar a que te duela una muela para recién entonces pedir hora. En el primer caso, el dentista detecta la caries incipiente con una radiografía (el «sensor») antes de que duela; en el segundo, terminas con una urgencia, probablemente más cara y con más tiempo perdido. La red neuronal de Ana hace ese chequeo preventivo, pero de forma continua y automática, sobre cientos de piezas a la vez.

El resultado que reporta el caso es una **reducción del 25% en tiempos de inactividad**, junto con mayor disponibilidad de maquinaria y menor costo de mantenimiento correctivo. Esa cifra por sí sola dice poco si no se traduce a algo concreto, así que vale la pena un ejemplo numérico —hipotético, el PDF no da esta cifra base— para dimensionarla.

EJEMPLO

Supongamos que, antes del proyecto, la planta de AutoTech acumulaba 400 horas de inactividad al mes entre todas sus líneas (esta cifra es un supuesto didáctico, no un dato del caso). Una reducción del 25% deja esas 400 horas en 300, es decir, 100 horas mensuales que antes se perdían y ahora se recuperan como producción efectiva. Si cada hora de línea detenida le costara a la empresa, hipotéticamente, 2.000 dólares en producción no realizada y personal ocioso, esas 100 horas recuperadas equivaldrían a 200.000 dólares mensuales, o 2,4 millones de dólares al año. El punto de este ejercicio no es la cifra exacta —que AutoTech no publica— sino mostrar por qué un gerente de producción como Carlos considera este tipo de proyecto una prioridad estratégica y no solo una mejora técnica.

Esta lógica de sensores más modelo predictivo conecta directamente con lo visto en el Módulo 2, Unidad 6 («Perspectivas futuras de la IA»), donde ya se introdujo el mantenimiento predictivo como una de las aplicaciones típicas del **IoT** combinado con IA en el borde de la red (*edge AI*): el caso de AutoTech es la puesta en práctica concreta, con cifras, de esa idea que antes quedó a nivel de concepto.

Paso 2: optimización de la cadena de suministro

El segundo paso lo lidera Luis junto con Ana: integran modelos de aprendizaje automático que anticipan la **demanda de autopartes** y ajustan las **órdenes de compra en tiempo**

real. El sistema, según el recuadro del PDF, priorizó proveedores con menor tiempo de entrega y mejores costos, eliminando retrasos. El resultado fue una **reducción del 30% en costos de almacenamiento**, menor desperdicio de piezas y mayor disponibilidad de componentes clave. Este paso pertenece conceptualmente a la cadena de suministro y a la logística predictiva que se desarrollan con más detalle —con sus propios ejemplos de Amazon y Maersk— en la sección de aplicaciones avanzadas de esta unidad; aquí basta con notar el mecanismo: el mismo tipo de modelo que predice una falla de máquina (aprender de patrones históricos para anticipar un evento futuro) sirve, con otros datos de entrada, para anticipar cuánto stock de una pieza específica se va a necesitar la semana siguiente. Es el mismo principio de fondo —predicción a partir de patrones— aplicado a dos problemas de negocio distintos.

Paso 3: automatización del control de calidad

El tercer paso usa **visión por computadora** (ya definida al hablar de la tercera fase de la historia de la IA, en esta misma unidad) para revisar pintura, alineación y ensamblaje, con una **precisión del 98%**. Esto es **control de calidad automatizado** (*automated quality control*): un sistema de visión artificial que inspecciona cada unidad que sale de la línea, comparando lo que ve —con cámaras de alta resolución— contra un patrón de referencia de cómo debería verse una pieza correctamente ensamblada, y marca automáticamente cualquier desviación (una raya de pintura, un panel mal alineado, un tornillo faltante) para revisión humana o rechazo directo. El resultado reportado es menos productos defectuosos y mayor satisfacción del cliente final. La cifra del 98% de precisión no debe leerse como «cero errores»: un sistema de visión de este tipo puede dejar pasar un defecto de cada 50, en promedio, o marcar como defectuoso algo que en realidad está bien (lo que en el caso de FinAI, más adelante, se llamará **falso positivo**); por eso, en la práctica industrial, este tipo de sistemas casi siempre trabaja como una primera capa de filtro y no como reemplazo total de la inspección humana en los casos límite.

Guía de respuesta

El caso cierra, como los otros dos, con tres preguntas para el foro de comentarios. Conviene desarrollarlas porque son representativas del tipo de razonamiento que se espera de alguien que evalúa oportunidades de IA en una empresa, más allá de conocer la tecnología.

1. ¿Cómo podría AutoTech expandir el uso de IA a otras áreas del negocio, como la logística y la personalización de vehículos? El patrón que ya funcionó en mantenimiento e inventario —sensores o registros que alimentan un modelo predictivo— se puede extender a logística de distribución (predecir tiempos de entrega a concesionarios, igual que Maersk predice tiempos de tránsito marítimo, tema que se ve en la sección de aplicaciones avanzadas) y a personalización de vehículos, donde un sistema de recomendación (el mismo tipo de tecnología que usa ShopSmart en el caso 2) podría sugerir configuraciones o paquetes de opciones según el perfil de compra del cliente. La

clave conceptual es que AutoTech ya tiene la infraestructura de datos —sensores, historiales, un equipo que sabe entrenar modelos— y ese activo es reutilizable para problemas de negocio muy distintos al que lo originó.

2. ¿Cuáles podrían ser los riesgos de depender completamente de predicciones algorítmicas en la producción? El riesgo central es que un modelo predictivo nunca tiene certeza absoluta: predice una probabilidad de falla, no una falla garantizada, y esa probabilidad puede estar mal calibrada si las condiciones cambian (una pieza nueva de un proveedor distinto, un cambio en el ritmo de producción) respecto a los datos históricos con los que se entrenó. Depender «completamente» del algoritmo, sin un criterio humano de respaldo, significa que un error sistemático del modelo —por ejemplo, subestimar el desgaste bajo un patrón de uso nuevo— puede pasar inadvertido hasta que la falla real ocurre, justo el escenario que el mantenimiento predictivo buscaba evitar. Por eso la práctica recomendada es mantener supervisión humana sobre las alertas críticas, un principio que esta unidad ya trató bajo el nombre de **rendición de cuentas** al hablar de decisiones automatizadas de alto impacto.

3. ¿Cómo se puede garantizar la calidad de los datos para mejorar la precisión del mantenimiento predictivo y la gestión de inventarios? La calidad de los datos de sensores depende de tres cosas: que estén bien calibrados (un sensor de vibración descalibrado genera ruido, no señal), que su frecuencia de muestreo sea suficiente para capturar el fenómeno que se quiere predecir (una falla que se desarrolla en minutos no se detecta con una lectura por hora) y que los registros históricos de fallas estén correctamente etiquetados —si una falla pasada se registró con la fecha o causa equivocada, el modelo aprende una relación falsa entre síntomas y falla real—. En la práctica, esto implica procesos de mantenimiento de sensores tan rigurosos como el mantenimiento de las máquinas que esos sensores vigilan.

Caso 2: ShopSmart

ShopSmart es una plataforma de comercio electrónico con presencia global que busca mejorar la experiencia de compra de sus clientes y aumentar sus tasas de conversión. El problema de partida lo detecta Mariana, directora de marketing: una alta tasa de **abandono de carrito** (*cart abandonment*), es decir, usuarios que agregan productos al carrito de compra pero no completan el pago, lo que a su vez produce un bajo **retorno sobre la inversión** (*Return on Investment, ROI*) en publicidad: el ROI mide cuánto gana una empresa por cada unidad monetaria invertida —en este caso, en campañas de marketing digital— y si muchos usuarios llegan gracias a la publicidad pero no compran, ese gasto publicitario rinde poco. Junto a Mariana trabajan Javier, especialista en IA, y Andrés, gerente de servicio al cliente. El caso desarrolla tres frentes de solución.

Sistemas de recomendación basados en IA

Javier implementó modelos que analizan el historial de navegación y de compras de cada usuario para predecir, mediante **redes neuronales**, qué productos tienen mayor probabilidad de compra para esa persona en particular, y así personalizar anuncios y correos electrónicos. Esto es un **sistema de recomendación** (*recommender system*): un modelo que, a partir del comportamiento pasado de un usuario (y a menudo del comportamiento de usuarios parecidos), predice qué otros productos le podrían interesar. El resultado que reporta el caso es un aumento del 35% en la **tasa de conversión** (*conversion rate*) —el porcentaje de visitantes que terminan comprando— entre clientes recurrentes, y una reducción del 20% en el abandono de carrito.

⚠ Nota (discrepancia 16): el curso dice que Javier implementó «modelos de procesamiento de lenguaje natural (PLN)» para analizar el historial de navegación y compras y de ahí generar las recomendaciones. La evidencia dice que los sistemas de recomendación típicos usan técnicas de **filtrado colaborativo** (comparar patrones de compra entre usuarios parecidos) y representaciones vectoriales de usuarios y productos, no PLN; el PLN entra cuando hay texto de por medio —búsquedas escritas, reseñas, descripciones de producto— que hay que interpretar semánticamente. **Para el examen:** si te preguntan qué técnica usó ShopSmart según el caso, responde lo que dice el curso: modelos de PLN sobre el historial de navegación y compras, combinados con redes neuronales para predecir probabilidad de compra.

ANALOGÍA

Un sistema de recomendación funciona como un vendedor de tienda con memoria perfecta de miles de clientes: recuerda que las personas que compraron zapatillas de trote también suelen comprar calcetines técnicos, y que tú, en particular, ya miraste tres veces una chaqueta impermeable sin comprarla. Con esa memoria agregada, te sugiere justo lo que tiene más probabilidad de interesarte, en vez de mostrarte el catálogo completo al azar.

Automatización del servicio al cliente

Andrés supervisó el desarrollo de **chatbots** impulsados por IA para responder preguntas frecuentes y asistir en el proceso de pago, integrados en redes sociales y WhatsApp. Este es un ejemplo de **chatbot aplicado**: un programa conversacional (definido de forma general en el bloque de conceptos clave de esta unidad) puesto a resolver un problema de negocio muy específico —reducir la fricción del proceso de compra y liberar al equipo humano de las preguntas repetitivas— en lugar de una conversación abierta. El resultado: reducción del 50% en el tiempo de espera de atención al cliente y aumento del 30% en la satisfacción del cliente.

Optimización del precio dinámico con IA

Por último, Javier implementó un modelo de machine learning que ajusta los precios según la demanda y las tendencias del mercado. Esto es **precio dinámico** (*dynamic pricing*): en lugar de un precio fijo, el modelo sube o baja el precio de un producto en función de señales como cuánta gente lo está viendo en ese momento, cuánto stock queda o cómo se mueve la demanda de productos similares. El resultado fue un aumento del margen de ganancia del 15% y mayor competitividad frente a otras plataformas de e-commerce.

EJEMPLO

Piensa en cómo varía el precio de un pasaje aéreo según la fecha en que lo compras: eso es precio dinámico llevado a un extremo muy visible. ShopSmart aplica la misma lógica a un producto de catálogo: si un modelo de zapatillas se está agotando y la demanda sube, el sistema puede subir ligeramente su precio; si el stock está sobrando y se acerca el fin de temporada, lo baja para liberar inventario antes de que pierda valor.

Guía de respuesta

1. ¿Qué otros sectores pueden beneficiarse de estrategias de personalización basadas en IA? Cualquier negocio con un catálogo amplio y datos de comportamiento del cliente es candidato: streaming de contenido (recomendar películas o series), banca (ya se ve en el caso de FinAI, con asistentes financieros personalizados), turismo (paquetes de viaje según historial de búsquedas) y educación (recomendar cursos o módulos según el progreso del alumno). El requisito común no es el rubro, sino tener suficiente historial de interacción por usuario como para que el modelo tenga patrones sobre los cuales aprender.

2. ¿Cómo puede ShopSmart garantizar que sus sistemas de recomendación sean justos y equitativos para todos los usuarios? Esta pregunta conecta directamente con el **sesgo algorítmico**, ya explicado en la sección de ética de esta unidad: un sistema de recomendación entrenado solo con el historial de los clientes que más compran puede terminar ignorando o tratando peor a segmentos de usuarios menos representados en los datos (por ejemplo, clientes nuevos, o de regiones con menor volumen histórico de ventas). Garantizar equidad implica, como se vio con AI Fairness 360, auditar el desempeño del modelo por segmento de usuario y no solo de forma agregada, y evitar que el sistema termine mostrando siempre las mismas categorías de producto a los mismos perfiles, reduciendo en la práctica las opciones que cada persona llega a ver.

3. ¿De qué manera la automatización del servicio al cliente puede influir en la percepción de marca por parte de los consumidores? Un chatbot bien diseñado, que resuelve rápido lo simple y deriva a un humano lo complejo, mejora la percepción de marca porque reduce la fricción y la espera —de ahí el 50% menos de tiempo de espera del caso—. Pero mal diseñado, un chatbot que atrapa al cliente en respuestas genéricas sin salida a un humano puede generar el efecto contrario: la sensación de que la empresa automatizó

el servicio para ahorrar costos, no para servir mejor. La diferencia entre ambos escenarios suele estar en si el sistema sabe reconocer sus propios límites y escalar el caso a tiempo.

Caso 3: FinAI

El tercer caso ocurre en un banco digital al que el curso identifica como **FinAI**. El equipo de analistas enfrenta un aumento de intentos de **fraude** y la necesidad de optimizar la **evaluación de riesgos crediticios**, sin poder procesar manualmente el volumen de solicitudes y transacciones en tiempo real, lo que generaba retrasos y vulnerabilidades de seguridad. El caso desarrolla tres soluciones.

Modelo de detección de fraudes

FinAI implementó un sistema basado en **redes neuronales recurrentes (RNN)** (*Recurrent Neural Network*) que analiza transacciones en tiempo real. Una RNN es un tipo de red neuronal diseñada para datos que llegan en secuencia —una transacción después de otra, en el tiempo— y que mantiene una especie de «memoria» de lo que vio antes en esa misma secuencia para interpretar mejor lo que ve ahora: no evalúa cada transacción de forma aislada, sino en el contexto de las transacciones anteriores de esa misma cuenta. Sobre esa base, el sistema usa **análisis de patrones** (*pattern analysis*) —comparar la actividad histórica del cliente con la actividad nueva— para identificar fraudes: si una tarjeta que normalmente hace compras de 20.000 pesos en el supermercado del barrio de pronto intenta una transferencia de varios millones a una cuenta desconocida en otro país, ese salto respecto al patrón habitual es la señal de alerta. El resultado reportado es una **reducción del fraude financiero del 40%**, con alertas preventivas enviadas a clientes y agentes del banco antes de procesar la transacción sospechosa, no después.

ANALOGÍA

Una RNN analizando transacciones es como un cajero de banco de toda la vida que conoce a sus clientes habituales: no necesita ver tu cédula para notar que «esto no es típico de ti». La diferencia es que la RNN «conoce» simultáneamente a millones de clientes y compara cada transacción nueva contra el historial completo de esa cuenta en milisegundos, algo que ningún equipo humano podría hacer a esa escala ni a esa velocidad.

Esta aplicación conecta con lo ya visto sobre **deep learning** al inicio de la unidad (donde se explicó que el aprendizaje profundo usa redes con múltiples capas para detectar patrones de alto nivel): la RNN de FinAI es, precisamente, un tipo específico de red profunda especializada en secuencias temporales, aplicada a un problema de negocio muy concreto.

Análisis crediticio con machine learning

FinAI también implementó un modelo que analiza comportamiento financiero, historial crediticio y factores externos —como estabilidad laboral y ubicación geográfica— para determinar la solvencia del cliente. Esto es **análisis crediticio** (*credit scoring*): estimar qué tan probable es que una persona pague un crédito, a partir de sus datos financieros y de comportamiento. El impacto operativo es notable: el tiempo de procesamiento de solicitudes de crédito bajó de **48 horas a menos de 5 minutos**, lo que permite decisiones más rápidas y basadas en datos. El resultado de negocio fue una disminución del **índice de morosidad** (*delinquency rate*) —la proporción de créditos con pagos atrasados— del 25%, además de un portafolio de préstamos optimizado mediante la clasificación de clientes por nivel de riesgo.

Este tipo de sistema es, precisamente, el ejemplo de manual de lo que la Unión Europea clasifica como un **sistema de alto riesgo** —concepto ya explicado en la sección de ética de esta unidad al hablar de la Ley de IA de la UE—: una decisión automatizada de crédito afecta directamente el acceso de una persona a la vivienda, a financiar un negocio o a una emergencia, y por eso exige los mismos estándares de explicabilidad y auditoría que ya se discutieron para COMPAS. Y así como el sesgo algorítmico en el sistema de contratación de Amazon (visto en la sección de ética) venía de datos históricos sesgados, un modelo de análisis crediticio entrenado con decisiones humanas pasadas puede heredar el mismo tipo de sesgo si, por ejemplo, cierto código postal fue históricamente rechazado con más frecuencia por razones que no tenían que ver con la verdadera capacidad de pago de sus habitantes.

Asistentes virtuales financieros

El tercer frente son chatbots y asistentes virtuales que brindan asesoría financiera personalizada —cómo mejorar el puntaje crediticio, cómo manejar mejor las finanzas propias— y alertas dentro de la aplicación móvil del banco sobre pagos pendientes, oportunidades de inversión y recomendaciones de ahorro. El resultado reportado es mayor compromiso de los clientes con su salud financiera y mayor retención de usuarios en los servicios bancarios. El PDF señala además que existe un recurso interactivo adicional sobre este caso disponible solo en la versión online de la clase, que no viene incluido en el documento revisado para esta explicación.

Falsos positivos: el costo oculto de un buen sistema antifraude

Un **falso positivo** (*false positive*) es una alerta que marca como sospechoso algo que en realidad es legítimo: por ejemplo, una compra real del cliente, hecha en un país donde está de viaje, que el sistema bloquea porque no coincide con su patrón habitual. Ningún sistema de detección de fraude —ni el de FinAI ni ningún otro— tiene cero falsos positivos y cero falsos negativos (fraudes reales que pasan sin ser detectados) al mismo tiempo: hay una

tensión entre ambos, y afinar el sistema para atrapar más fraude real casi siempre significa bloquear también más transacciones legítimas por error.

EJEMPLO

Supongamos —de nuevo, un ejercicio didáctico, no una cifra del caso— que FinAI procesa 100.000 transacciones al día y que el sistema marca 1.000 de ellas como sospechosas. Si, hipotéticamente, un 5% de esas alertas resultan ser falsos positivos, son 50 clientes al día cuya compra legítima quedó bloqueada o retrasada por una verificación adicional. Eso no invalida al sistema —evitar el 40% del fraude reportado en el caso probablemente vale mucho más que la molestia de esos 50 clientes—, pero explica por qué la pregunta 3 del foro de este caso, sobre cómo evitar falsos positivos que afecten la experiencia del cliente, es una pregunta de negocio tan relevante como la del propio fraude: cada falso positivo es, en la práctica, un cliente real momentáneamente tratado como sospechoso.

Chile ofrece un ejemplo reciente y verificado de esta misma tensión a escala país: según información de prensa de agosto de 2026, el fraude en medios de pago en Chile alcanzó los 98 millones de dólares en el primer semestre de ese año, con la banca usando IA para detectarlo; en paralelo, existe un estudio de la Universidad de Chile sobre el uso de IA para predecir riesgo crediticio, y Codelco ha apostado por IA para productividad y seguridad, aunque este último caso sin una cifra pública verificada. Son datos externos al PDF del curso, incluidos porque conectan directamente con lo que el caso FinAI describe: la misma tecnología —detección de fraude y análisis crediticio con IA— que el curso ilustra con un banco ficticio ya opera, con cifras reales, en el sistema financiero chileno.

Guía de respuesta

1. ¿Cuáles son los desafíos éticos en el uso de IA para evaluar la solvencia de un cliente? El desafío central es que un modelo de análisis crediticio puede parecer objetivo —«son solo números»— y sin embargo perpetuar discriminación si los datos históricos con los que se entrenó reflejan decisiones pasadas sesgadas, exactamente el mecanismo de **sesgo en datos históricos** visto en la sección de ética de esta unidad. A esto se suma la pregunta de **explicabilidad**: si a un cliente le rechazan un crédito, ¿puede el banco explicarle por qué, en términos que la persona entienda, o el modelo es una «caja negra»? La Ley de IA de la UE, al clasificar el scoring crediticio como sistema de alto riesgo, exige justamente eso.

2. ¿Qué medidas se deben tomar para evitar sesgos en los modelos de evaluación crediticia? Las mismas que ya se vieron para el caso general de sesgos algorítmicos: auditorías periódicas del desempeño del modelo por grupo demográfico (no solo en agregado), revisar que las variables usadas —como la ubicación geográfica que menciona el caso— no estén actuando como sustitutos indirectos de variables protegidas (como el nivel socioeconómico o el origen étnico de un barrio), y usar herramientas de detección de

sesgo como AI Fairness 360 antes de poner el modelo en producción, no después de que ya causó daño.

3. ¿Cómo puede FinAI garantizar que su sistema de detección de fraudes no genere falsos positivos que afecten la experiencia del cliente? Algunas medidas prácticas: calibrar el umbral de alerta según el costo relativo de cada tipo de error (un umbral muy sensible atrapa más fraude pero genera más falsos positivos, y viceversa); usar señales de contexto adicionales antes de bloquear de forma definitiva (por ejemplo, permitir que el cliente confirme la transacción por una notificación push en vez de bloquearla sin aviso); y medir explícitamente la tasa de falsos positivos como un indicador de éxito del sistema, tan importante como la tasa de fraude detectado, en vez de optimizar solo esta última.

Video: Estrategias para escribir prompts óptimos

⚠ Nota (discrepancia 17, sección prompts): el PDF del curso no incluye el contenido real de este video ni de su PDF descargable: solo indica que el profesor Rodrigo Pereira explora la **ingeniería de prompts** (*prompt engineering*) —cómo formular instrucciones de manera precisa y adecuada para obtener los resultados deseados— y remite a la versión online de la clase, disponible mediante un enlace o un código QR que el curso advierte podría dejar de funcionar después del 30 de noviembre de 2026. Lo que sigue en esta sección es una **reconstrucción** con principios generales de ingeniería de prompts, ampliamente aceptados en la práctica y en la literatura del campo, pero que no deben atribuirse textualmente al profesor Rodrigo Pereira: no sabemos qué dijo exactamente en el video. **Para el examen:** si preguntan qué explicó el profesor en el video, la respuesta honesta es que el PDF no lo registra; si preguntan por principios de ingeniería de prompts en general, los de abajo son un resumen estándar del área.

La **ingeniería de prompts** es la práctica de diseñar y refinar las instrucciones que se le dan a un modelo generativo —un LLM como GPT-4, o un modelo de texto a imagen como DALL·E— para maximizar la probabilidad de obtener el resultado que se busca. Existe porque estos modelos no «entienden» la intención de fondo de quien escribe: responden a patrones estadísticos aprendidos sobre cómo continuar un texto dado un contexto, y la calidad de ese contexto —el prompt— determina en gran medida la calidad de la respuesta. La siguiente tabla resume los componentes que la práctica reconoce como parte de un prompt bien construido.

Componente	Qué aporta
Rol	Le indica al modelo desde qué perspectiva responder (por ejemplo, «actúa como analista financiero senior»), lo que ajusta el vocabulario y el nivel de profundidad de la respuesta.
Contexto	Entrega la información de fondo necesaria (datos de la empresa, público objetivo, restricciones del negocio) para que la respuesta no sea genérica.
Tarea clara con verbo	Define exactamente qué se pide, con un verbo de acción («redacta», «compara», «clasifica»), evitando ambigüedad sobre qué se espera como resultado.
Formato de salida	Especifica cómo debe presentarse la respuesta (tabla, lista, extensión máxima, tono), reduciendo la necesidad de reformular después.
Ejemplos	Mostrar uno o más ejemplos del tipo de respuesta esperada (aprendizaje con pocos ejemplos, ver más abajo) mejora notablemente la precisión del resultado.
Restricciones	Indica qué evitar: extensión, tono, temas fuera de alcance, o qué información no se debe inventar.
Razonamiento por pasos	Pedir explícitamente que el modelo razone paso a paso mejora el desempeño en tareas complejas, en lugar de saltar directo a una respuesta.
Iteración y verificación	Refinar el prompt según la respuesta obtenida, y siempre verificar los datos entregados por el modelo, porque los LLM pueden generar información inventada con total seguridad (lo que se conoce como alucinación).

EJEMPLO

Prompt deficiente: «Escríbeme algo sobre IA para mi empresa». Este prompt no define rol, contexto, tarea concreta ni formato: el modelo tiene que adivinar de qué tipo de empresa se trata, para qué se usará el texto y qué tan largo debe ser, y lo más probable es que entregue un texto genérico e inútil.

Prompt bien construido: «Actúa como consultor de innovación tecnológica. Nuestra empresa es una pyme de logística con 40 empleados que reparte pedidos de e-commerce en una ciudad intermedia. Redacta, en un máximo de 300 palabras y en tono directo, tres oportunidades concretas de usar IA en nuestra operación de reparto, siguiendo el ejemplo del caso AutoTech visto en esta unidad (mantenimiento predictivo, optimización de rutas). Para cada oportunidad, indica el problema que resuelve y una estimación aproximada del esfuerzo de implementación (bajo, medio, alto)». Este segundo prompt define rol, contexto, tarea, formato, restricción de extensión y hasta un ejemplo de referencia (el caso

AutoTech), lo que reduce drásticamente el espacio de respuestas posibles y aumenta la probabilidad de obtener algo útil en el primer intento.

Una distinción central en ingeniería de prompts es la de **zero-shot** versus **few-shot** (*few-shot learning*): en zero-shot, se le pide al modelo que resuelva una tarea sin darle ningún ejemplo previo dentro del prompt, confiando en lo que aprendió durante su entrenamiento general; en few-shot, se incluyen uno o varios ejemplos de la tarea directamente en el prompt («aquí tienes tres ejemplos de cómo clasificar un correo como spam o no spam; ahora clasifica este cuarto correo»), y el modelo usa esos ejemplos como guía inmediata sin necesidad de un reentrenamiento. Esta capacidad de aprender una tarea nueva a partir de solo unos pocos ejemplos dentro del propio prompt —sin ajustar ni un solo parámetro del modelo— es, precisamente, lo que demostró el paper de Brown et al. (2020) sobre GPT-3, la misma referencia que el curso cita (de forma imprecisa, ver la discrepancia 5 en el índice al final de esta unidad) al hablar de GPT-4 y de IA generativa: el título del paper, «Language models are few-shot learners» (modelos de lenguaje que aprenden con pocos ejemplos), es literalmente sobre esto.

Foro colaborativo

El foro colaborativo de la unidad invita a reflexionar sobre el impacto de la inteligencia artificial en distintos sectores empresariales, con tres preguntas abiertas que resumen, en cierto modo, la tensión de fondo de toda la unidad: la IA como oportunidad de competitividad frente a la IA como fuente de riesgos que hay que gestionar.

1. ¿Qué oportunidades y desafíos observas en la implementación de IA en los negocios? Las oportunidades, según lo visto en esta unidad, son concretas y medibles: reducción de tiempos de inactividad (AutoTech), aumento de conversión (ShopSmart), reducción de fraude (FinAI), optimización de rutas logísticas (Maersk) y aceleración de investigación médica (AlphaFold), entre otras. Los desafíos son igual de concretos: la calidad de los datos de entrada (sin datos limpios, ningún modelo predictivo funciona bien), el riesgo de sesgo cuando los datos de entrenamiento reflejan decisiones humanas pasadas, y el costo —económico y organizacional— de construir la infraestructura de datos necesaria antes de poder entrenar cualquier modelo.

2. ¿Consideras que la IA reemplazará completamente algunos roles dentro de las empresas o simplemente transformará la manera en que se trabaja? Los tres casos de esta unidad sugieren más transformación que reemplazo total: en AutoTech, la IA no reemplazó a Carlos como gerente de producción, sino que le dio una herramienta para decidir mejor; en ShopSmart, los chatbots no eliminaron el rol de Andrés como gerente de servicio al cliente, sino que absorbieron las consultas repetitivas para que su equipo se enfocara en los casos complejos; en FinAI, el análisis crediticio automatizado no eliminó el criterio humano sobre casos límite, sino que redujo el tiempo de procesamiento de 48 horas

a minutos para que los analistas se enfocaran en las excepciones. El patrón consistente es que la IA absorbe la parte del trabajo que es repetitiva, de alto volumen y basada en patrones, dejando a las personas las decisiones que requieren juicio, contexto o responsabilidad ética —justamente el tipo de decisiones donde la **rendición de cuentas** y la **explicabilidad** importan más—.

3. ¿Cómo crees que las empresas pueden prepararse para adoptar IA de manera ética y eficiente? Con base en todo lo visto en esta unidad, la preparación tiene al menos tres componentes: (a) infraestructura de datos de calidad, porque ningún modelo es mejor que los datos con los que se entrena; (b) gobernanza y auditoría, siguiendo el ejemplo de herramientas como AI Fairness 360 y el estándar que fija la Ley de IA de la UE para sistemas de alto riesgo, aplicando ese mismo criterio aunque la empresa no opere en Europa; y (c) capacitación del equipo humano, no solo técnico sino también de negocio, para que quienes toman decisiones con apoyo de IA entiendan las limitaciones del modelo —incluyendo la posibilidad de falsos positivos, sesgos y alucinaciones— y no traten sus resultados como verdad absoluta.

Bibliografía comentada

El PDF cierra su parte de contenidos con una lista de ocho referencias. Vale la pena comentarlas una a una, porque varias de ellas ya aparecieron citadas a lo largo de la unidad y porque la revisión de esta explicación detectó dos problemas puntuales en esta lista.

Referencia (tal como aparece en el PDF)	Qué es y comentario
Russell, S., & Norvig, P. (2020). <i>Artificial Intelligence: A Modern Approach</i> . Pearson.	El manual de referencia estándar de inteligencia artificial a nivel universitario; es la fuente de la definición de IA usada al inicio de la unidad («capacidad de las máquinas para imitar procesos de inteligencia humana»). Cita correcta.
Goodfellow, I., Bengio, Y., & Courville, A. (2016). <i>Deep Learning</i> . MIT Press.	El libro de texto de referencia sobre aprendizaje profundo, escrito por tres de los investigadores más influyentes del área; respalda la definición de Aprendizaje Automático de esta unidad. Cita correcta.
LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. <i>Nature</i> , 521(7553), 436-444.	Artículo de revisión sobre deep learning, publicado por otros tres pioneros del área (los mismos LeCun, Bengio y Hinton que, junto con Goodfellow y Courville, dan forma casi completa a la bibliografía técnica de esta unidad). Respalda la definición de Deep Learning. Cita correcta.
Mayer-Schönberger, V., & Cukier, K. (2013). <i>Big Data: A Revolution That Will Transform How We Live, Work, and Think</i> . Houghton Mifflin Harcourt.	El libro de divulgación que popularizó el concepto de Big Data para audiencia general y de negocios; respalda la definición de Big Data de esta unidad. Cita correcta.
Brown, T. et al. (2020). Language models are few-shot learners. <i>Advances in Neural Information Processing Systems</i> , 33, 1877-1901.	Es el paper que presentó GPT-3 (175 mil millones de parámetros) y demostró su capacidad de aprendizaje con pocos ejemplos (few-shot), tema central de la sección de prompts de esta unidad. El curso la usa para hablar de GPT-4 y de la generación de texto, imágenes y video, lo cual es impreciso: GPT-4 se lanzó recién en marzo de 2023, tres años después de este paper, con un informe técnico que reveló pocos detalles (discrepancia 5 del índice). Además, esta referencia aparece duplicada en la lista del PDF: figura dos veces, una tras otra, de forma idéntica.
Howard, J., & Gugger, S. (2018). Universal language model fine-tuning for text classification. <i>Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics</i> , 328-339.	Corresponde al paper conocido como ULMFiT , que sistematizó la técnica de preentrenamiento y ajuste fino para modelos de lenguaje —justo el concepto que define esta unidad—. El problema es de autoría: el paper real (ACL 2018, identificador P18-1031) fue escrito por Jeremy Howard y Sebastian Ruder , no por «Gugger» (discrepancia 6 del índice). El concepto que ilustra —preentrenar en general y luego ajustar a una tarea específica— es correcto; solo el segundo autor está mal.

Referencia (tal como aparece en el PDF)	Qué es y comentario
Ramesh, A. et al. (2021). Zero-shot text-to-image generation. <i>Proceedings of the 38th International Conference on Machine Learning</i> .	Es el paper de DALL·E (la primera versión), que combinaba un transformer con un autoencoder convolucional discreto (dVAE) para generar imágenes desde texto; respalda directamente la definición de texto a imagen de esta unidad. Cita correcta en cuanto a autoría y tema, aunque vale precisar que las versiones posteriores, DALL·E 2 y DALL·E 3, ya no usan esa arquitectura original, sino modelos de difusión.

⚠ Nota (discrepancia 7, síntesis): más allá de los dos problemas puntuales de autoría y duplicación, la lista de ocho referencias del PDF es notoriamente incompleta frente a todos los nombres, empresas y estudios que el propio texto del curso menciona (Nilsson sobre el invierno de la IA, McCarthy sobre sistemas expertos, Silver et al. sobre AlphaGo, Redmon y Farhadi sobre YOLO, Bojarski et al. sobre conducción autónoma, Hennessy y Patterson sobre hardware, además de IBM, AI Now Institute y Amnesty International citados en el cuerpo del texto pero ausentes de la bibliografía). Sobre Bojarski et al. (2016), en particular: es un trabajo publicado por investigadores de **NVIDIA**, no de Tesla, aunque el PDF lo asocia implícitamente al ejemplo de conducción autónoma de Tesla. **Para el examen:** no trates esta lista de ocho referencias como el inventario completo de fuentes de la unidad; es solo la bibliografía formal, más corta que las menciones reales del texto.

Resumen de la unidad

El PDF cierra con un resumen de dos páginas que retoma, en pocas líneas, las ideas centrales de los dos artículos de la unidad. Vale la pena repasarlo en prosa, con las conexiones que ya se hicieron a lo largo de esta explicación, en vez de leerlo como una lista aislada de puntos.

La idea de partida es la definición de **Inteligencia Artificial** como la capacidad de las máquinas para imitar procesos de inteligencia humana —aprendizaje, razonamiento, resolución de problemas—, la misma definición de Russell y Norvig con la que abrió el artículo introductorio. Desde ahí, el resumen recorre las tres fases de la historia de la IA en el mismo orden en que se explicaron: la primera fase, de **IA simbólica o basada en reglas**, con sistemas programados para seguir instrucciones predefinidas y resolver problemas en contextos cerrados; la segunda fase, marcada por la introducción de **redes neuronales** y algoritmos de aprendizaje automático que permitieron a las máquinas procesar datos y ajustarse automáticamente —el resumen destaca aquí, como un hito propio, el desarrollo de redes neuronales artificiales capaces de aprender patrones sin ser programadas explícitamente—; y la tercera fase, caracterizada por el uso intensivo del

aprendizaje profundo, con redes neuronales profundas procesando grandes volúmenes de datos, impulsada por el crecimiento exponencial del **poder computacional** que empresas como Google, Microsoft y NVIDIA sostienen con hardware optimizado para entrenar modelos de machine learning y deep learning.

La segunda mitad del resumen retoma los riesgos y aplicaciones vistos en el artículo de ética y aplicaciones avanzadas: los riesgos de **privacidad** que trae el reconocimiento facial, el análisis de comportamiento y la publicidad personalizada; el problema de los **sesgos algorítmicos**, con el caso del sistema de contratación de Amazon como ejemplo representativo de cómo los datos históricos pueden perpetuar discriminación; y la necesidad de **rendición de cuentas** frente a decisiones automatizadas de consecuencias significativas, con la Ley de Inteligencia Artificial de la Unión Europea como intento regulatorio de exigir explicabilidad y auditoría a los sistemas de alto riesgo. Sobre las aplicaciones, el resumen destaca a Amazon anticipando demanda y ajustando inventarios, a Maersk optimizando rutas marítimas con datos meteorológicos y de tráfico, a IBM Watson Health apoyando la detección temprana de enfermedades como el cáncer, y a Google AI previniendo inundaciones combinando datos meteorológicos históricos, imágenes satelitales y modelos de simulación climática. Todos estos son, en esencia, el mismo patrón de fondo que ya se vio en los tres casos narrativos —AutoTech, ShopSmart y FinAI—: datos históricos más un modelo entrenado sobre ellos, aplicado a predecir o clasificar algo relevante para el negocio, con un resultado medible al final.

Índice de discrepancias

La siguiente tabla reúne, en un solo lugar, las diecisiete discrepancias identificadas entre lo que afirma el PDF del curso y lo que confirma la evidencia externa verificada para esta unidad. Cada una aparece explicada en detalle, con su nota  correspondiente, en el bloque de esta explicación donde surge el tema; aquí se presentan a modo de índice de repaso rápido antes del examen.

N	Tema	Qué dice el curso	Qué dice la evidencia	Regla de examen
1	Samuel y las reglas	Lo presenta como ejemplo icónico de la 1ª fase «basada en reglas».	Su programa aprendía jugando contra sí mismo; Samuel popularizó el término machine learning en 1959.	Para la 1ª fase, responde «IA simbólica» y cita Logic Theorist; si preguntan por el primer programa que aprendía, Samuel.
2	Cronología simplificada	Un solo «invierno de la IA» en los 70; 3ª fase desde el 2000.	Hubo dos inviernos (~1974–1980 y ~1987–1993); el despegue del deep learning moderno se fecha en 2012 (AlexNet).	En el examen usa las tres fases del curso; los dos inviernos son contexto adicional.
3	MYCIN, década y conclusión	Lo ubica en la 2ª fase (1980–2000) y dice que «superó a médicos».	Se desarrolló en los años 70; su evaluación ciega (Yu et al., 1979) lo comparó con expertos en ciertos casos, sin la generalización que sugiere el curso.	MYCIN = primer sistema experto emblemático, diagnóstico de infecciones bacterianas, Stanford.
4	Tesseract y Google	Dice que Google «mejoró el OCR a través de modelos como Tesseract».	Tesseract nació en HP (1985–1994), se liberó en 2005 y Google lo patrocinó entre 2006 y 2017.	Tesseract = OCR de código abierto y multilingüe, impulsado por Google, no creado por Google.
5	Brown et al. (2020)	La cita para GPT-4 y para creación de texto, imágenes y video.	El paper describe GPT-3 (175 mil millones de parámetros); GPT-4 salió en marzo de 2023.	Si piden el ejemplo de LLM, GPT-4; si piden la referencia, Brown et al. 2020 = GPT-3 y aprendizaje con pocos ejemplos.
6	Autor de fine-tuning	Cita «Howard & Gugger (2018)».	El paper ULMFiT (ACL 2018) es de Jeremy Howard y Sebastian Ruder.	El concepto es el mismo; en una cita, escribe Howard & Ruder.

N	Tema	Qué dice el curso	Qué dice la evidencia	Regla de examen
7	Bibliografía incompleta y duplicada	Ocho entradas, con Brown et al. repetida.	El texto cita muchos más nombres que no aparecen en la lista; Bojarski et al. (2016) es de NVIDIA, no de Tesla.	No trates la bibliografía como lista completa de fuentes de la unidad.
8	Tesla y autonomía	Habla de «vehículos autónomos» de Tesla.	El FSD de Tesla es asistencia supervisada (nivel 2 SAE); Waymo opera en nivel 4.	Sistemas autónomos = percibir y decidir en tiempo real; distingue asistencia (nivel 2) de autonomía sin conductor (nivel 4) si preguntan por niveles.
9	Ley de IA de la UE	Dice que la UE «ha propuesto» regulaciones.	Es el Reglamento (UE) 2024/1689, vigente desde agosto de 2024, con aplicación escalonada y una postergación de obligaciones de alto riesgo acordada en mayo de 2026.	Responde lo del curso (alto riesgo → explicabilidad y auditoría); si preguntan el estado, ya es ley vigente con aplicación escalonada.
10	Clearview y COMPAS: cifras	Habla de «millones» de imágenes de Clearview y cita AI Now (2023) para COMPAS.	Clearview superó los 30.000 millones de imágenes (multada en 2024); el análisis original de COMPAS es de ProPublica (2016): 44,9% de falsos positivos en afroamericanos vs. 23,5% en blancos.	La idea evaluada (falta de privacidad; sesgo racial y falta de transparencia) no cambia.
11	Maersk, «la mayor naviera»	La describe como «la mayor empresa de transporte marítimo del mundo».	MSC la superó en capacidad desde enero de 2022.	El caso vale como ejemplo de optimización de rutas; no afirmes el ranking actual.

N	Tema	Qué dice el curso	Qué dice la evidencia	Regla de examen
12	IBM Watson Health / Supply Chain	Los presenta como productos vigentes.	Watson Health se vendió en 2022 (hoy Merative); no se confirmó un producto llamado «Watson Supply Chain» (existe IBM Sterling Supply Chain).	Usa los ejemplos del curso como ilustración de IA en salud y en cadena de suministro, no como nombres de producto actuales.
13	ShakeAlert y redes neuronales	Dice que el USGS «emplea redes neuronales» en ShakeAlert.	ShakeAlert usa algoritmos sismológicos (EPIC, FinDer, GFAST-PGD), no redes neuronales; cubre California, Oregón y Washington.	ShakeAlert = alerta sísmica temprana con segundos de anticipación.
14	AlphaFold, qué acelera	Dice que redujo el descubrimiento de fármacos «de varios años a solo unos meses».	Lo que acelera es la determinación de la estructura de proteínas; el desarrollo completo de un fármaco sigue tomando años.	AlphaFold = predicción de estructuras de proteínas, no desarrollo completo de fármacos.
15	Casos de herramientas sin verificar	Airbnb con TensorFlow, Waymo con PyTorch, Grammarly y Zalando/Shopify con Hugging Face.	No se encontró confirmación pública de esos usos específicos (sí de Tesla y OpenAI con PyTorch, y de CheXNet de Stanford).	Memoriza la herramienta con su rasgo: TensorFlow (escalable, Google), PyTorch (prototipado, Meta), Hugging Face (modelos preentrenados de PLN).
16	PLN para recomendar en ShopSmart	Dice que Javier usó «modelos de PLN» para analizar navegación y compras.	Los sistemas de recomendación suelen usar filtrado colaborativo; el PLN entra cuando hay texto de por medio.	Si preguntan qué técnica usó ShopSmart, responde lo del curso: PLN y redes neuronales.

N	Tema	Qué dice el curso	Qué dice la evidencia	Regla de examen
17	Partes del PDF que faltan	Remite a recursos «solo online»: dos recursos interactivos (aplicaciones de la 3ª fase y caso FinAI), el video resumen, y el video y PDF del profesor Rodrigo Pereira sobre prompts.	Ninguno de esos recursos viene incluido en el documento revisado; la sección de prompts de esta explicación está reconstruida con principios generales, no con lo dicho por el profesor.	Antes del examen, revisa esos recursos en la versión online (disponible según el curso hasta el 30 de noviembre de 2026).

Glosario

Término	Inglés	Definición
Inteligencia Artificial (IA)	<i>Artificial Intelligence (AI)</i>	Desarrollo de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana: razonar, aprender y decidir.
IA débil	<i>Weak / Narrow AI</i>	IA enfocada en tareas específicas; es toda la IA que existe hoy en producción.
IA fuerte	<i>Strong AI / AGI</i>	Idea teórica de una inteligencia comparable a la humana en cualquier tarea; aún no existe.
Aprendizaje automático	<i>Machine Learning (ML)</i>	Rama de la IA que permite a las computadoras aprender de los datos y mejorar sin ser programadas explícitamente.
Programación explícita	<i>Explicit programming</i>	Escribir a mano cada regla que el programa sigue; lo opuesto a aprender la regla desde los datos.
Aprendizaje supervisado	<i>Supervised learning</i>	El modelo aprende de ejemplos con la respuesta correcta (etiqueta) para predecirla en casos nuevos.
Aprendizaje no supervisado	<i>Unsupervised learning</i>	El modelo busca estructura (grupos, patrones) en datos sin etiquetas.
Aprendizaje por refuerzo	<i>Reinforcement learning</i>	Un agente aprende por ensayo y error, maximizando la recompensa acumulada de sus acciones.
Big Data	<i>Big Data</i>	Manejo y análisis de grandes volúmenes de datos, de alta velocidad y variedad, que exigen métodos avanzados.
Las tres V del Big Data	<i>Volume, Velocity, Variety</i>	Volumen (cuántos datos), velocidad (qué tan rápido llegan) y variedad (qué tan distintos son sus formatos).
Patrón	<i>Pattern</i>	Regularidad en los datos que un modelo detecta y usa para predecir o decidir.
Parámetros	<i>Parameters</i>	Números internos que el modelo ajusta al entrenar; los modelos grandes tienen millones o miles de millones.

Término	Inglés	Definición
IA simbólica (basada en reglas)	<i>Symbolic / rule-based AI</i>	Primera fase: sistemas que siguen instrucciones predefinidas para resolver problemas en contextos cerrados.
Contexto cerrado	<i>Closed-world context</i>	Entorno acotado y totalmente especificado, donde las reglas cubren todos los casos posibles.
Programa de damas de Samuel	<i>Samuel's checkers program</i>	Programa de los años 50 que evaluaba jugadas y ajustaba su estrategia; uno de los primeros que aprendía.
Logic Theorist	<i>Logic Theorist</i>	Sistema de Newell y Simon que demostraba teoremas con reglas lógicas; precursor de la IA simbólica.
Escalabilidad	<i>Scalability</i>	Capacidad de un sistema de crecer en datos o tareas sin colapsar; faltó en la IA temprana.
Invierno de la IA	<i>AI winter</i>	Período de estancamiento y recorte de financiamiento; el curso lo sitúa en la década de 1970.
Sistema experto	<i>Expert system</i>	Programa que imita la decisión de un especialista humano en un área específica mediante reglas.
MYCIN	<i>MYCIN</i>	Sistema experto de Stanford que diagnosticaba infecciones bacterianas y recomendaba tratamientos.
Reconocimiento óptico de caracteres (OCR)	<i>Optical Character Recognition</i>	Tecnología que convierte texto escrito o impreso en una imagen en texto digital editable.
Tesseract OCR	<i>Tesseract OCR</i>	Motor de OCR de código abierto, multilingüe, nacido en HP y luego impulsado por Google.
Acelerador de hardware	<i>Hardware accelerator</i>	Procesador especializado (por ejemplo, en cálculos de matrices) que acelera el entrenamiento de redes neuronales.
GPU	<i>Graphics Processing Unit</i>	Unidad de procesamiento gráfico; hace miles de cálculos en paralelo y es esencial para entrenar deep learning.
AlphaGo	<i>AlphaGo</i>	Sistema de DeepMind que venció a campeones humanos de Go con deep learning y búsqueda

Término	Inglés	Definición
		(2016).
Asistente virtual	<i>Virtual assistant</i>	Software conversacional (Alexa, Siri) que entiende instrucciones y ejecuta tareas en tiempo real.
Poder computacional	<i>Computational power (compute)</i>	Capacidad de cálculo disponible; su crecimiento exponencial fue determinante en la expansión de la IA.
Aprendizaje profundo	<i>Deep Learning</i>	Uso de redes neuronales con múltiples capas para modelar datos complejos y detectar patrones de alto nivel.
Red neuronal artificial	<i>Artificial neural network</i>	Modelo de capas de unidades conectadas cuyos pesos se ajustan para aprender patrones sin reglas explícitas.
Red neuronal profunda	<i>Deep neural network</i>	Red neuronal con muchas capas ocultas; cada capa aprende rasgos más abstractos que la anterior.
Red neuronal convolucional (CNN)	<i>Convolutional Neural Network</i>	Red especializada en imágenes: filtros que recorren la imagen detectando bordes, formas y objetos.
Red neuronal recurrente (RNN)	<i>Recurrent Neural Network</i>	Red con memoria de lo anterior, adecuada para secuencias como transacciones en el tiempo.
Transformer	<i>Transformer</i>	Arquitectura basada en atención que procesa secuencias completas en paralelo; base de GPT y BERT.
Procesamiento de lenguaje natural (PLN)	<i>Natural Language Processing (NLP)</i>	Área de la IA que permite a las máquinas comprender y generar lenguaje humano.
BERT	<i>BERT</i>	Modelo de Google basado en transformers, orientado a comprender el lenguaje en contexto.
Visión por computadora	<i>Computer vision</i>	Área de la IA que permite a las máquinas interpretar imágenes y video.
YOLO	<i>You Only Look Once</i>	Familia de modelos de detección de objetos en tiempo real que analiza la imagen en una sola pasada.

Término	Inglés	Definición
OpenCV	<i>OpenCV</i>	Biblioteca abierta de visión por computadora para procesar imágenes y video.
Reconocimiento facial	<i>Facial recognition</i>	Identificar o verificar a una persona a partir de su rostro en una imagen.
Detección de objetos	<i>Object detection</i>	Localizar y clasificar objetos dentro de una imagen o video.
Sistema autónomo	<i>Autonomous system</i>	Sistema que percibe su entorno y decide en tiempo real sin intervención humana directa.
LiDAR	<i>Light Detection and Ranging</i>	Sensor que mide distancias con pulsos láser y arma un mapa 3D del entorno.
Sensores IoT	<i>Internet of Things sensors</i>	Dispositivos conectados que miden variables físicas (vibración, temperatura) y envían datos en tiempo real.
Análisis de patrones	<i>Pattern analysis</i>	Comparar la actividad nueva con la histórica para detectar desviaciones sospechosas.
IA generativa	<i>Generative AI</i>	IA que crea contenido nuevo (texto, imágenes, video) a partir de patrones aprendidos de datos previos.
Modelo de lenguaje a gran escala (LLM)	<i>Large Language Model</i>	Modelo entrenado con enormes cantidades de texto para generar, traducir, resumir y analizar lenguaje.
GPT	<i>Generative Pre-trained Transformer</i>	Familia de LLM de OpenAI: transformers preentrenados que generan texto (GPT-4 es un ejemplo).
GAN	<i>Generative Adversarial Network</i>	Dos redes que compiten: una genera contenido y otra intenta distinguirlo del real.
Preentrenamiento	<i>Pre-training</i>	Entrenar un modelo de lenguaje con un conjunto de datos general y masivo.
Ajuste fino	<i>Fine-tuning</i>	Adaptar un modelo preentrenado a una tarea específica con datos relevantes de esa tarea.
Texto a imagen	<i>Text-to-Image</i>	Generación de imágenes a partir de una descripción escrita.

Término	Inglés	Definición
DALL·E	<i>DALL·E</i>	Modelo de OpenAI que genera imágenes desde texto; su primera versión combinaba transformer y redes convolucionales.
Midjourney y Stable Diffusion	<i>Midjourney & Stable Diffusion</i>	Generadores de imágenes que transformaron la industria creativa.
Chatbot	<i>Chatbot</i>	Programa conversacional que responde preguntas y asiste a usuarios por texto o voz.
Análisis semántico	<i>Semantic analysis</i>	Interpretar el significado de un texto, no solo sus palabras.
Ingeniería de prompts	<i>Prompt engineering</i>	Formular instrucciones precisas para que un modelo generativo entregue el resultado deseado.
Aprendizaje con pocos ejemplos	<i>Few-shot learning</i>	Capacidad de un LLM de resolver una tarea con solo unos ejemplos dentro del prompt.
Privacidad de los datos	<i>Data privacy</i>	Derecho a controlar cómo se recolectan y usan los datos personales.
Consentimiento informado	<i>Informed consent</i>	Autorización explícita de la persona, sabiendo para qué se usarán sus datos.
Clearview AI	<i>Clearview AI</i>	Empresa criticada por recopilar imágenes de usuarios sin consentimiento para reconocimiento facial.
GDPR	<i>General Data Protection Regulation</i>	Reglamento General de Protección de Datos de la Unión Europea.
CCPA	<i>California Consumer Privacy Act</i>	Ley de Privacidad del Consumidor de California.
Uso indebido de datos	<i>Data misuse</i>	Usar datos personales para fines no autorizados o sin supervisión efectiva.
Sesgo algorítmico	<i>Algorithmic bias</i>	Error sistemático de un modelo que perpetúa discriminación, casi siempre heredado de datos históricos.

Término	Inglés	Definición
Sesgo en datos históricos	<i>Historical data bias</i>	Prejuicios del pasado registrados en los datos que el modelo aprende como si fueran regla.
AI Fairness 360	<i>AI Fairness 360</i>	Conjunto de bibliotecas de IBM para detectar y mitigar sesgos en modelos de ML.
Auditoría de algoritmos	<i>Algorithmic audit</i>	Revisión periódica e independiente de un modelo para detectar sesgos y errores en decisiones críticas.
Rendición de cuentas	<i>Accountability</i>	Mecanismos para que alguien responda por las decisiones que toma un sistema de IA.
Transparencia	<i>Transparency</i>	Que se pueda conocer cómo funciona un sistema de IA y con qué datos decide.
Explicabilidad	<i>Explainability</i>	Capacidad de explicar por qué un modelo tomó una decisión específica.
COMPAS	<i>COMPAS</i>	Algoritmo de la justicia penal de EE.UU. que predice reincidencia y mostró sesgo racial.
Reincidencia	<i>Recidivism</i>	Volver a cometer un delito; lo que COMPAS intenta predecir.
Ley de IA de la Unión Europea	<i>EU AI Act</i>	Regulación europea que clasifica la IA por riesgo y exige explicabilidad y auditoría a los sistemas de alto riesgo.
Sistema de alto riesgo	<i>High-risk AI system</i>	Sistema de IA cuyas decisiones afectan derechos o seguridad (crédito, empleo, justicia) y enfrenta exigencias estrictas.
Falso positivo	<i>False positive</i>	Alerta que marca como sospechoso algo legítimo, por ejemplo una compra real bloqueada como fraude.
Logística predictiva	<i>Predictive logistics</i>	Usar IA para anticipar demanda, ajustar inventarios y mejorar tiempos de entrega.
Optimización de rutas	<i>Route optimization</i>	Elegir recorridos con datos de clima, tráfico y tiempos de puerto para ahorrar costos y combustible.
Huella de carbono	<i>Carbon footprint</i>	Emisiones de gases de efecto invernadero asociadas a una operación.

Término	Inglés	Definición
Cadena de suministro	<i>Supply chain</i>	Red de proveedores, producción y distribución que lleva un producto hasta el cliente.
Almacén automatizado	<i>Automated warehouse</i>	Bodega con robots y ML que optimizan la colocación de productos y el procesamiento de pedidos.
Medicina personalizada	<i>Personalized medicine</i>	Tratamientos ajustados a cada paciente según sus datos clínicos y genómicos.
Perfil genómico	<i>Genomic profile</i>	Información genética de un paciente usada para elegir terapias con mayor probabilidad de éxito.
AlphaFold	<i>AlphaFold</i>	Sistema de DeepMind que predice la estructura 3D de proteínas con precisión sin precedentes.
Imágenes médicas con IA	<i>AI medical imaging</i>	Visión por computadora que detecta fracturas, tumores o hemorragias en radiografías y tomografías.
Sistema de alerta temprana	<i>Early warning system</i>	Sistema que anticipa un desastre (inundación, incendio, sismo) para dar tiempo de reacción.
ShakeAlert	<i>ShakeAlert</i>	Sistema de alerta sísmica temprana del USGS en la costa oeste de EE.UU.
Mantenimiento predictivo	<i>Predictive maintenance</i>	Predecir fallas de máquinas con datos de sensores antes de que ocurran.
Mantenimiento correctivo	<i>Corrective maintenance</i>	Reparar después de que la máquina falló; es más caro y detiene la producción.
Tiempo de inactividad	<i>Downtime</i>	Tiempo en que una máquina o línea está detenida y no produce.
Control de calidad automatizado	<i>Automated quality control</i>	Visión por computadora que inspecciona pintura, alineación y ensamblaje.
Sistema de recomendación	<i>Recommender system</i>	Modelo que predice qué productos tiene más probabilidad de comprar cada usuario.
Tasa de conversión	<i>Conversion rate</i>	Porcentaje de visitantes que terminan comprando.
Abandono de carrito	<i>Cart abandonment</i>	Cuando el usuario agrega productos pero no completa la compra.

Término	Inglés	Definición
Precio dinámico	<i>Dynamic pricing</i>	Ajuste automático del precio según demanda y tendencias del mercado.
Detección de fraude	<i>Fraud detection</i>	Identificar transacciones sospechosas en tiempo real antes de procesarlas.
Análisis crediticio	<i>Credit scoring</i>	Estimar la solvencia de un cliente con datos financieros, historial y factores externos.
Índice de morosidad	<i>Delinquency rate</i>	Proporción de créditos con pagos atrasados.
Retorno sobre la inversión (ROI)	<i>Return on Investment</i>	Cuánto gana una empresa por cada peso invertido, por ejemplo en publicidad.
Biblioteca de código abierto	<i>Open-source library</i>	Conjunto de herramientas de programación con código público y gratuito.
TensorFlow	<i>TensorFlow</i>	Biblioteca abierta de Google para ML y deep learning, flexible y escalable.
PyTorch	<i>PyTorch</i>	Biblioteca abierta creada por Meta, popular en investigación por su facilidad de uso y prototipado rápido.
Hugging Face	<i>Hugging Face</i>	Plataforma y comunidad con una enorme colección de modelos preentrenados, sobre todo de PLN.
Modelo preentrenado	<i>Pre-trained model</i>	Modelo ya entrenado que se reutiliza o ajusta en vez de entrenarlo desde cero.
Prototipado rápido	<i>Rapid prototyping</i>	Construir versiones de prueba en poco tiempo para validar una idea.
Análisis de sentimientos	<i>Sentiment analysis</i>	Detectar si un texto expresa una opinión positiva, negativa o neutra.

Mapa conceptual

Conexión con módulos anteriores: esta unidad se apoya en M1 U1 (IA, ML, IA estrecha vs IA general, entrenamiento/modelo/parámetros, tres V del dato, sesgo), M1 U3 (aprendizaje supervisado, deep learning, red neuronal, PLN, transformador, visión

por computador, CNN, aprendizaje por refuerzo), M1 U5 y M1 U6, M2 U5 (sesgo algorítmico, transparencia, explicabilidad, privacidad, consentimiento informado, rendición de cuentas) y M2 U6 (IA generativa, mantenimiento predictivo, edge AI). Esta unidad reabre esos conceptos desde el ángulo de "tecnologías" y agrega lo nuevo: IA simbólica, sistemas expertos, OCR, GPU, LLM, ajuste fino, texto a imagen, RNN, TensorFlow, PyTorch, Hugging Face.

IA en el entorno empresarial (raíz)

└ [define] Conceptos clave

- | └ Inteligencia Artificial → IA débil · IA fuerte
- | └ Aprendizaje automático (ml) → supervisado · no supervisado · por refuerzo
- | └ Deep Learning (dl) → redes de múltiples capas · CNN · RNN
- | └ Big Data (bigdata) → las tres V

└ [crea contenido con] IA generativa y LLM

- | └ IA generativa (genai) → GPT · GAN
- | └ LLM (llm) → GPT-4 · BERT (comprensión)
- | └ Preentrenamiento y ajuste fino (finetune)
- | └ Texto a imagen → DALL·E · Midjourney / Stable Diffusion
- | └ Ingeniería de prompts (prompts) – video del profesor Rodrigo Pereira, solo online

└ [evoluciona en] Historia y evolución

- | └ 1ª fase 1950-1970: IA simbólica
 - | | └ Damas de Arthur Samuel (samuel)
 - | | └ Logic Theorist
 - | | └ Límites: flexibilidad, cómputo, escalabilidad
 - | | └ Invierno de la IA
- | └ 2ª fase 1980-2000: aprendizaje automático
 - | | └ Redes neuronales artificiales (redes)
 - | | └ OCR → Xerox · Tesseract
 - | | └ Sistemas expertos → MYCIN
 - | | └ Hardware especializado → GPU (gpu)
- | └ 3ª fase 2000-hoy: deep learning y modelos generativos
 - | | └ AlphaGo · Alexa y Siri
 - | | └ PLN (GPT, BERT) · Visión (YOLO, OpenCV) (vision) · Sistemas autónomos (Tesla) (autonomos) · IA generativa creativa
 - | | └ Poder computacional (Google, Microsoft, NVIDIA) (compute)

└ [plantea] Ética y desafíos

- | └ Privacidad de los datos → Clearview AI · GDPR y CCPA (gdpr), más Ley 21.719 de Chile · uso indebido de datos
- | └ Sesgos (sesgo) → Amazon contratación · AI Fairness 360 · solvencia y minorías (sesgofin)
- | └ Rendición de cuentas y transparencia → COMPAS · Ley de IA de la UE (aiact)

- └ [se aplica en] Aplicaciones avanzadas
 - | └ Logística predictiva → Amazon demanda · Maersk rutas · Watson Supply Chain (COVID-19) · Ocado y Walmart
 - | └ Medicina personalizada → Watson Health · Tempus · AlphaFold · Radiología con Qure.ai y Aidoc (radiología)
 - | └ Prevención de desastres → Google inundaciones · incendios (Chooch, Descartes, CAL FIRE) · USGS ShakeAlert
- └ [se implementa con] Herramientas
 - | └ TensorFlow → Airbnb precios (airbnb) · Stanford rayos X con CNN
 - | └ PyTorch (pytorch) → ChatGPT · Tesla y Waymo
 - | └ Hugging Face (hf) → Grammarly · Zalando y Shopify
- └ [se practica en] Casos prácticos
 - └ AutoTech (industria automotriz) → Mantenimiento predictivo (mantpred, -25% inactividad) · Cadena de suministro (-30% almacenamiento) · Visión para control de calidad (98% precisión)
 - └ ShopSmart (e-commerce) → Sistema de recomendación (recom, +35% conversión / -20% abandono) · Chatbots de servicio (-50% espera / +30% satisfacción) · Precio dinámico (precio, +15% margen)
 - └ FinAI (banca y finanzas) → Detección de fraude con RNN (fraude, -40%) · Análisis crediticio con ML (credito, 48h → menos de 5 min; -25% morosidad) · Asistentes financieros
 - └ Foro colaborativo (reemplazo vs. transformación de roles)

Enlaces cruzados (relaciones no jerárquicas, líneas punteadas):

- samuel → ml: "en realidad ya aprendía"
- redes → dl: "se profundizan en"
- gpu → compute: "habilita"
- vision → radiologia: "se aplica en"
- autonomos → pytorch: "se entrenan con"
- pytorch → llm: "entrena (ChatGPT)"
- finetune → hf: "modelos preentrenados"
- prompts → llm: "instruye a"
- bigdata → mantpred: "datos de sensores IoT"
- fraude → dl: "usa RNN"
- recom → sesgo: "¿es justa?"
- credito → aiact: "es alto riesgo"
- credito → sesgofin: "riesgo de"
- precio → airbnb: "mismo patrón"
- gdpr → recom: "limita datos de"