

Unidad 2 · **Tecnologías clave para la IA generativa**

Esta unidad pertenece al curso «**Tecnologías de Inteligencia Artificial para Negocios**», el Tercer módulo del Diplomado UDD, y viene inmediatamente después de la Unidad 1, «Introducción a la IA en el entorno empresarial». Allí te presentaron el mapa general: qué es la IA, sus ramas, el Transformer, los LLM, el sesgo y la normativa. Aquí el curso cambia de pregunta. Ya no se trata de *qué es* la IA, sino de **cómo elegir la tecnología adecuada para un problema de negocio**, cómo aprende realmente un modelo, qué pueden y qué no pueden hacer los modelos generativos, qué riesgos traen y cómo se diseña un piloto que produzca evidencia para decidir.

El material combina tres artículos de divulgación, un caso narrativo (SurAndes Alimentos), una herramienta práctica (una matriz de ocho dimensiones con semáforo), un listado de 26 herramientas generativas y una experiencia con Teachable Machine. El objetivo final no es que programes un modelo, sino que desarrolles **criterio**: poder conversar con un equipo técnico con un lenguaje común y decidir antes de comprar o contratar nada.

Cómo leer esta unidad

Mapa de la unidad

La unidad se compone de las siguientes piezas, y esta explicación las recorre en el mismo orden en que aparecen en el PDF del curso.

Pieza	De qué trata	Idea que deja
Antes de comenzar y Conceptos clave	Propósito de la unidad y 13 definiciones base	Un vocabulario común: datos, modelo, entrenamiento, evaluación, inferencia
Artículo 1: «De las reglas a los modelos»	Cuándo basta una regla y cuándo conviene un modelo; los cinco componentes del aprendizaje; métrica y negocio	La tecnología se elige después de formular el problema
Artículo 2: «Tipos de aprendizaje»	Supervisado, no supervisado y por refuerzo	Cada enfoque responde a un tipo de dato y de objetivo
Artículo 3: «Implementación responsable de IA»	Modelos generativos, multimodalidad, Teachable Machine, riesgos, normativa chilena, criterios de piloto	Pasar del entusiasmo por la tecnología a la disciplina en la ejecución
Caso SurAndes Alimentos	Cinco propuestas, un solo piloto de doce semanas	Cómo se descarta y se prioriza con criterios éticos, operativos y de datos
Matriz de ocho dimensiones	Herramienta para diagnosticar una oportunidad de IA con semáforo	Completar la matriz antes de escoger herramienta
Listado de herramientas generativas	26 herramientas en cuatro áreas	Un mapa de referencia, que envejece rápido
Bibliografía y resumen	Fuentes y diez ideas de cierre	Checklist final de la unidad

Qué es nuevo y qué se reutiliza

Varias ideas ya las viste, y aquí se retoman solo en una frase. En la Unidad 1 de este módulo conociste la IA débil y fuerte, el machine learning, la existencia de aprendizaje supervisado, no supervisado y por refuerzo (presentada en una línea), el deep learning, el Transformer, los LLM y el preentrenamiento y ajuste fino, además del sesgo algorítmico (caso COMPAS) y la Ley 21.719. En el Módulo 1, Unidad 3, trabajaste el aprendizaje supervisado con característica, etiqueta, regresión, clasificación y métricas; en el Módulo 1, Unidad 6, el paso del prototipo a producción; y en el Módulo 2, Unidad 5, la ética, la supervisión humana (*human-in-the-loop*) y la gobernanza.

Lo nuevo de esta unidad es, sobre todo, la mirada de **decisión**. Se profundiza en el «cómo aprende un modelo» (los cinco componentes), se separa explícitamente el desempeño estadístico de la utilidad empresarial, se compara qué enfoque corresponde a cada necesidad, se explica por qué un modelo generativo produce lo «más probable» y no lo «verdadero», y se entrega una herramienta (la matriz y el semáforo) para decidir si una oportunidad de IA merece un piloto.

Las tres preguntas que enseña a responder la unidad

Si tuvieras que resumir la unidad en tres preguntas que un directivo debe poder responder, serían estas.

Primera: ¿qué resultado necesito producir? (formular el problema con un verbo y un resultado)

observable, antes de hablar de modelos). **Segunda: ¿qué tecnología corresponde a esa necesidad y qué condiciones críticas exige?** (reglas, supervisado, no supervisado, refuerzo, generativa o una arquitectura híbrida). **Tercera: ¿cómo sabré que funciona y qué riesgo asumo?** (línea base, métrica ligada al impacto real, controles humanos proporcionales). Todo el resto del material son herramientas para contestar estas tres preguntas con rigor.

Avisos sobre esta explicación

A lo largo del texto encontrarás **12 notas** ⚠ **de discrepancia**. Cada una señala un punto donde el curso dice una cosa y la literatura o la práctica actual matiza o corrige. La regla para estudiar es siempre la misma: primero la versión del curso, porque es la que se evalúa, y luego la nota con la «Regla de examen». Además, algunas piezas existen **solo en la versión online** (el video resumen, el video de Teachable Machine con su PDF descargable); esta explicación las reconstruye desde el texto del curso y la fuente original de la herramienta, y las marca como tales.

Un ejemplo recorrerá la parte conceptual de esta unidad para que las definiciones no queden abstractas: **predecir la demanda semanal de un producto envasado**. Las **características** serán la semana del año, el precio y si hubo promoción; la **etiqueta** será el número de unidades vendidas esa semana. Es un problema cercano al mundo de SurAndes Alimentos, el caso que verás más adelante.

Antes de comenzar

¿Para qué estamos aquí?

El curso declara su propósito así: comprender los fundamentos del **machine learning** y de la **IA generativa** para reconocer **qué aportan a los negocios, qué problemas pueden abordar y cuáles son sus límites**. La palabra importante es «límites». Un curso de tecnología para negocios no es un catálogo de promesas; es un entrenamiento para saber cuándo una herramienta sirve y cuándo no.

El foco es desarrollar **criterio** para tres cosas: distinguir tecnologías, evaluar oportunidades y **conversar con equipos técnicos con un lenguaje común**. Piensa en el gerente que se reúne con un equipo de datos y escucha «tenemos un clasificador con buen *accuracy* pero poco *recall*». Si no conoce el vocabulario, aprueba o rechaza a ciegas. Si lo conoce, puede preguntar lo correcto: «¿Qué errores son los que no detectamos y cuánto nos cuestan?». Las secciones que siguen te dan ese vocabulario.

ANALOGÍA

Un gerente de una constructora no necesita saber calcular una viga, pero sí debe entender qué es la carga admisible, qué es un factor de seguridad y por qué no se puede «apretar» el presupuesto de acero sin consecuencias. Con la IA ocurre igual: no se te pide programar redes neuronales, sino entender sus conceptos de ingeniería lo bastante bien como para contratar, supervisar y decidir.

¿Qué haremos?

La unidad propone un recorrido de seis actividades. Primero, revisar brevemente la evolución de la IA. Segundo, estudiar los conceptos de **datos, modelo, entrenamiento, evaluación e inferencia**. Tercero,

comparar los aprendizajes **supervisado, no supervisado y por refuerzo**. Cuarto, analizar cómo los modelos generativos producen **texto, imágenes, audio, video y código**. Quinto, experimentar con **Teachable Machine** para construir un clasificador sencillo y observar cómo la **cantidad, diversidad y calidad** de los ejemplos influyen en sus resultados. Sexto, cerrar con criterios de **aplicación empresarial y uso responsable**.

Observa que el experimento con Teachable Machine está pensado para que veas un principio que de otro modo parece abstracto: el modelo solo sabe lo que sus ejemplos le muestran. Si cambias los ejemplos, cambia el comportamiento. Esa es probablemente la lección más útil de toda la unidad.

¿Para qué nos servirá?

El curso enumera cinco beneficios concretos, que conviene leer como un listado de competencias evaluables:

1. **Formular mejor los problemas antes de seleccionar una herramienta.** Muchos proyectos fracasan porque se compró la herramienta antes de entender el problema.
2. **Reconocer cuándo se necesita predecir, clasificar, agrupar, recomendar o generar contenido.** Son los verbos de negocio que luego se traducen en tecnología: predecir (estimar un valor), clasificar (asignar una categoría), agrupar (descubrir segmentos), recomendar (sugerir una acción) y generar (producir un contenido nuevo).
3. **Identificar los datos mínimos para una prueba.** No se necesita un lago de datos para un piloto, pero sí los datos pertinentes.
4. **Detectar riesgos de sesgo, privacidad, propiedad intelectual y confiabilidad.** Son los cuatro riesgos que el curso pone en primer plano.
5. **Definir controles humanos acordes con el impacto de la decisión.** La supervisión humana no es todo o nada: se gradúa según lo que está en juego.

Aviso del curso: los recursos en enlaces y códigos QR podrían no estar disponibles **desde el 30 de noviembre de 2026**. Si hay material online que quieras conservar (por ejemplo, los videos), descárgalo o revísalo antes de esa fecha.

Conceptos clave

El curso abre con trece definiciones. Las transcribo tal como las da el curso, porque son las que se evalúan, y luego las desarrollo. Los diez primeros conceptos de esta lista, más el deep learning, se explican aquí con todo detalle; los tres tipos de aprendizaje (supervisado, no supervisado, por refuerzo) se definen en un párrafo cada uno, y la sección «Tipos de aprendizaje» de esta explicación, los desarrolla a fondo.

1. Inteligencia Artificial (IA)

Definición del curso: campo que reúne tecnologías capaces de realizar tareas asociadas con **percepción, lenguaje, aprendizaje, razonamiento o decisión**.

La definición no dice «máquinas que piensan». Habla de un **campo** y de **tareas asociadas** a capacidades humanas. Esa formulación es deliberadamente práctica: no discute si la máquina «entiende», solo si realiza tareas que normalmente requerirían percibir (ver, oír), usar lenguaje, aprender, razonar o decidir. Por eso la IA es un campo amplio y heterogéneo: dentro caben desde un sistema de reglas bien construido hasta un modelo generativo con miles de millones de parámetros. Este punto vuelve en el Artículo 1 con la idea de «una familia de tecnologías».

¿Por qué existe como categoría? Porque agrupa técnicas muy distintas que persiguen un mismo tipo de resultado. Para el directivo, lo útil es no confundir la etiqueta general con una tecnología específica: decir «queremos IA» es tan vago como decir «queremos un vehículo» sin precisar si necesitas una bicicleta o un camión.

ANALOGÍA

«IA» es como «medicina»: un campo enorme con especialidades muy distintas. Nadie diría «necesito medicina»; dirías si necesitas un cardiólogo, un kinesiólogo o un cirujano. De igual modo, la pregunta útil es qué rama de la IA responde a tu problema.

Conexión: en la Unidad 1 de este módulo viste la distinción entre IA débil (tareas específicas) e IA fuerte (hipotética, de propósito general). Todas las aplicaciones empresariales de esta unidad son IA débil.

2. Machine Learning (ML)

Definición del curso: enfoque que entrena modelos con datos para producir **predicciones, clasificaciones o contenido**, sin programar una regla específica para cada situación.

La frase clave es «sin programar una regla específica para cada situación». En el software tradicional, una persona escribe las reglas y el computador las ejecuta. En ML, la persona entrega **ejemplos** y el algoritmo **infiere las reglas** (en forma de relaciones matemáticas). Esto resuelve un problema práctico: hay tareas donde las reglas son demasiado numerosas, sutiles o cambiantes como para escribirlas a mano. Nadie sabe escribir, línea por línea, las reglas que distinguen una foto de un envase con sello incompleto de una con sello correcto bajo todas las luces y ángulos posibles; pero sí se pueden reunir miles de fotos etiquetadas y dejar que el modelo ajuste su comportamiento.

Con nuestro hilo conductor: en lugar de escribir «si hay promoción, vende 30 % más», se entrega al algoritmo el historial de semanas con su precio, su promoción y las unidades vendidas, y él descubre cuánto efecto tiene cada factor, incluyendo combinaciones que nadie había anticipado.

ANALOGÍA

Enseñar a un niño a reconocer perros. No le entregas una lista de reglas («cuatro patas, cola, hocico...»), que sería frágil porque un gato cumple las mismas. Le muestras muchos perros y muchos no-perros hasta que internaliza el patrón. Ese es el espíritu del ML: aprender del ejemplo en lugar de seguir instrucciones explícitas.

Conexión: el ML es una **parte** de la IA, no sinónimo de ella (el Artículo 1 lo desarrolla). Y dentro del ML, el deep learning es un subcampo (concepto 13).

3. Modelo

Definición del curso: representación matemática aprendida a partir de datos que transforma una **entrada** en una predicción, clasificación o contenido.

Un **modelo** (*model*) es, en esencia, una función: recibe una entrada y devuelve una salida. Lo que lo distingue de una función programada a mano es que su comportamiento no fue escrito por una persona, sino **aprendido**, es decir, determinado por el ajuste de sus **parámetros** sobre los datos. Un modelo es la «huella» que dejó el entrenamiento: números (los parámetros) organizados según una estructura matemática (la arquitectura).

Para el modelo de demanda más simple, la función podría ser una recta: unidades vendidas = $a + b \cdot$ (descuento). Los números a y b son los parámetros; la forma «recta» es la estructura. Un modelo de lenguaje es lo mismo en esencia, pero con una estructura enormemente más rica y miles de millones de parámetros.

Esta idea coincide con la definición que usa el Artículo 1 y que cita a Google for Developers, y que verás completa en ese apartado: «una relación matemática derivada de datos que se utiliza para desarrollar predicciones».

ANALOGÍA

Un modelo es como una receta que se ajustó probando. El «formato» de la receta (ingredientes, pasos) es la estructura; las cantidades exactas que quedaron después de muchas pruebas son los parámetros. Cuando alguien te entrega la receta, no necesitas volver a hacer las pruebas: solo la aplicas. Aplicarla es la inferencia.

4. Datos de entrenamiento

Definición del curso: ejemplos utilizados para ajustar el modelo y permitirle aprender patrones.

Los **datos de entrenamiento** (*training data*) son la materia prima del aprendizaje. Cada ejemplo describe un caso concreto del problema. Su calidad determina el techo de lo que el modelo puede lograr: un modelo no puede aprender lo que sus ejemplos no muestran, ni corregir errores sistemáticos que los datos contienen. Por eso, en el curso, la calidad, cantidad y diversidad de los ejemplos aparece una y otra vez, y por eso Teachable Machine está diseñada para que lo observes de primera mano.

En el ejemplo de demanda, los datos de entrenamiento serían, por ejemplo, 156 semanas (tres años) de historial, una fila por semana. Si en esos tres años nunca hubo una promoción de más de 10 %, el modelo no tiene evidencia sobre qué pasa con una promoción de 40 %, y cualquier cosa que diga sobre ella será extrapolación sin respaldo.

Un detalle que importa: los datos de entrenamiento se usan para *ajustar* el modelo; no deben usarse para *evaluarlo* (concepto 8). Esa separación es una de las ideas más importantes de toda la unidad.

5. Característica

Definición del curso: variable o atributo que el modelo utiliza como entrada, como **antigüedad**, **frecuencia de compra**, **píxeles** o **palabras**.

Una **característica** (*feature*) es cada dato de entrada que describe un ejemplo. Los cuatro ejemplos del curso muestran su variedad: antigüedad y frecuencia de compra son columnas de una tabla (datos **tabulares**); los píxeles son los valores numéricos de una imagen; las palabras son los elementos de un texto. Esto es relevante: «característica» no significa solo «columna de una planilla». En una imagen, las entradas son los valores de brillo y color de cada píxel; en un texto, las palabras o fragmentos de palabras.

En nuestro ejemplo de demanda semanal, las características son tres: la **semana** del año (que captura estacionalidad), el **precio** y la **promoción** (sí o no). Elegir bien las características es en parte conocimiento del negocio: ¿importa el clima? ¿los feriados? ¿el precio de la competencia? El analista de negocio y el científico de datos deciden juntos.

ANALOGÍA

Para tasar una casa, un tasador mira características: metros cuadrados, barrio, antigüedad, número de dormitorios. Si ignora una variable importante (por ejemplo, la cercanía al metro), su tasación será peor aunque sea muy cuidadoso. El modelo se comporta igual: solo puede usar lo que se le entrega como entrada.

Conexión: en el Módulo 1, Unidad 3, ya trabajaste con características y etiquetas en aprendizaje supervisado; aquí se retoma para el ciclo completo de aprendizaje.

6. Etiqueta

Definición del curso: resultado conocido que acompaña un ejemplo en aprendizaje supervisado, como **fraude, defecto o nivel de demanda**.

La **etiqueta** (*label*) es la «respuesta correcta» asociada a cada ejemplo. Es lo que el modelo intenta aprender a predecir a partir de las características. Los ejemplos del curso muestran dos naturalezas: *fraude* y *defecto* son categorías (esta transacción es o no es fraude; este envase es correcto o defectuoso); *nivel de demanda* puede ser un número o una categoría (alta, media, baja).

En el ejemplo de la demanda, la etiqueta es el número de **unidades vendidas** esa semana. Cada fila del historial tiene sus características (semana, precio, promoción) y su etiqueta (las unidades que realmente se vendieron). Precisamente porque la etiqueta es «conocida» en el historial, el modelo puede comparar su predicción con la respuesta real y corregirse. Sin etiquetas, esa comparación no existe y se entra en el terreno del aprendizaje no supervisado.

Un punto de calidad que el curso destaca más adelante: las etiquetas deben ser **confiables**. Si fueron asignadas con criterios inconsistentes, errores de registro o decisiones sesgadas, el modelo aprenderá esos mismos problemas. Etiquetar fotos de envases con «sello incompleto» exige que distintos inspectores usen el mismo criterio.

7. Entrenamiento

Definición del curso: proceso mediante el cual se ajustan los **parámetros** del modelo a partir de los datos disponibles.

El **entrenamiento** (*training*) es el momento en que el modelo «aprende». Matemáticamente, es un problema de optimización: hay que encontrar los valores de los parámetros que hacen que las predicciones del modelo se parezcan lo más posible a los resultados esperados. Para poder hacerlo, hace falta (a) una forma de medir cuán lejos están las predicciones de los resultados reales y (b) un procedimiento para mover los parámetros en la dirección que reduce esa distancia. Ambas ideas son precisas y conviene verlas con números, porque son el corazón de cualquier modelo que «aprende».

Complemento matemático: la función de pérdida y el descenso por gradiente

El curso dice que el algoritmo ajusta los parámetros «para reducir la diferencia entre sus resultados y los resultados esperados». Esa «diferencia» se formaliza con una **función de pérdida** (*loss function*). Una de las más usadas para predecir valores numéricos es el **error cuadrático medio** (*mean squared error*, MSE):

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i(\theta))^2$$

Desglosemos cada símbolo.

- θ (theta) representa los **parámetros** del modelo, es decir, los números que se ajustan durante el entrenamiento. Puede ser un solo número o millones.
- n es la cantidad de ejemplos de entrenamiento, y el índice i recorre cada uno de ellos, de 1 hasta n .
- y_i es la **etiqueta real** del ejemplo i (por ejemplo, las unidades que de verdad se vendieron esa semana).
- $\hat{y}_i(\theta)$ (se lee «y sombrero») es la **predicción del modelo** para ese mismo ejemplo. Se escribe con (θ) para recordar que depende de los parámetros: si cambian los parámetros, cambia la predicción.
- $y_i - \hat{y}_i(\theta)$ es el **error** del ejemplo i : cuánto se equivocó el modelo.
- El **cuadrado** hace dos cosas: evita que errores positivos y negativos se cancelen entre sí, y castiga con más fuerza los errores grandes (un error de 10 pesa cien veces más que uno de 1).
- $\sum$ suma los errores cuadráticos de todos los ejemplos, y $\frac{1}{n}$ saca el promedio.

La intuición: $L(\theta)$ es un número que resume «qué tan mal lo hace el modelo con estos parámetros». Entrenar es buscar el θ que hace L lo más pequeña posible.

EJEMPLO NUMÉRICO

Supongamos, de forma ilustrativa, que tres semanas de ventas de un producto envasado se explican con un solo factor: el **nivel de promoción** x (1 = sin promoción, 2 = descuento moderado, 3 = descuento fuerte). Las unidades vendidas fueron $y = 100, 210, 290$. Usamos el modelo más simple posible, una proporcionalidad: $\hat{y} = \theta x$, con un único parámetro θ (unidades por nivel de promoción).

Con $\theta = 50$: las predicciones son 50, 100 y 150. Los errores son $100 - 50 = 50$, $210 - 100 = 110$ y $290 - 150 = 140$. Los cuadrados son 2.500, 12.100 y 19.600, cuya suma es 34.200. Dividido por $n = 3$: $L(50) = 11.400$.

Con $\theta = 100$: las predicciones son 100, 200 y 300. Los errores son 0, 10 y -10. Los cuadrados son 0,

100 y 100, suma 200. Dividido por 3: $L(100) \approx 66,7$.

La pérdida bajó de 11.400 a unos 66,7. **Entrenar es, exactamente, elegir el valor del parámetro que reduce la pérdida:** el modelo con $\theta = 100$ describe mucho mejor el historial que el de $\theta = 50$. (El mejor valor posible para estos tres datos es $\theta \approx 99,29$, con $L \approx 64,3$; está cerca de 100 porque los datos casi siguen una proporcionalidad exacta.)

Falta resolver el cómo: ¿cómo encuentra el algoritmo el mejor θ si no puede probar todos los valores? La respuesta más usada es el **descenso por gradiente** (*gradient descent*), cuya regla de actualización es:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L$$

- La flecha $\leftarrow$ significa «se reemplaza por»: el parámetro se actualiza en cada paso.
- $\nabla_{\theta} L$ es el **gradiente** de la pérdida respecto de los parámetros: indica en qué dirección, y con qué pendiente, *sube* la pérdida al mover cada parámetro. Con un solo parámetro es simplemente la derivada $\frac{dL}{d\theta}$.
- El signo menos hace que nos movamos en dirección contraria al gradiente, es decir, hacia donde la pérdida *baja*.
- η (eta) es la **tasa de aprendizaje** (*learning rate*): el tamaño del paso. Si es muy grande, el algoritmo «salta» por encima del mínimo y puede oscilar o divergir; si es muy pequeña, avanza tan despacio que el entrenamiento se vuelve ineficiente.

ANALOGÍA

Imagina que estás en una ladera con niebla y quieres llegar al valle. No ves el fondo, pero con el pie sientes hacia dónde baja el terreno. En cada paso te mueves en esa dirección. La pendiente que sientes es el gradiente; el largo de tu paso es la tasa de aprendizaje; la altura del terreno bajo tus pies es la pérdida. Repetir el paso muchas veces te lleva al valle.

EJEMPLO NUMÉRICO

Con el mismo ejemplo, el gradiente de L para el modelo $\hat{y} = \theta x$ es $\frac{dL}{d\theta} = -\frac{2}{n} \sum_i (y_i - \theta x_i) x_i$. En $\theta = 50$ los errores eran 50, 110 y 140, y los x eran 1, 2 y 3, de modo que $\sum (y_i - \theta x_i) x_i = 50 \cdot 1 + 110 \cdot 2 + 140 \cdot 3 = 690$, y el gradiente vale $-\frac{2}{3} \cdot 690 = -460$. Es negativo: significa que aumentar θ reduce la pérdida. Con una tasa de aprendizaje $\eta = 0,01$, el nuevo valor es $\theta = 50 - 0,01 \cdot (-460) = 54,6$, y la pérdida baja de 11.400 a unos 9.383. Si se repite el paso, θ pasa a 58,8; luego 62,6; luego 66,0; y así sucesivamente acercándose a 99. Cada paso es pequeño porque η lo es; con un η razonable el modelo converge al valor adecuado.

Parámetros frente a hiperparámetros

Aquí aparece una distinción que el equipo técnico usa a diario. Los **parámetros** (θ) son los números que el algoritmo **aprende** de los datos. Los **hiperparámetros** (*hyperparameters*) son ajustes que **fija la persona antes de entrenar** y que gobiernan cómo se entrena: la tasa de aprendizaje η es el ejemplo

clásico, junto con el número de pasadas por los datos (épocas) y el tamaño de lote. El panel avanzado de Teachable Machine, que verás más adelante, justamente expone épocas, tamaño de lote y tasa de aprendizaje. Regla simple: **los parámetros los aprende el modelo; los hiperparámetros los elige el equipo.**

Esta idea responde también a la definición del curso sobre «entrenamiento»: se ajustan los **parámetros**, no los hiperparámetros. Si en un examen aparece «¿qué se ajusta durante el entrenamiento?», la respuesta es los parámetros del modelo.

8. Evaluación

Definición del curso: medición del desempeño del modelo con **datos distintos** de los utilizados para entrenarlo.

La **evaluación** (*evaluation*) responde a la pregunta: «¿funciona de verdad con casos que no vio?». La condición central es que los datos sean **distintos** de los de entrenamiento. La razón es sencilla: un modelo puede ajustarse tanto a sus ejemplos que los «memorice», y evaluarlo con esos mismos ejemplos solo mediría su memoria, no su capacidad de funcionar en la realidad. Medirlo con datos nuevos estima su capacidad de **generalizar** (*generalization*), que es lo que el negocio necesita.

ANALOGÍA

Un estudiante que se aprende de memoria las respuestas de la guía de ejercicios obtiene 100 % si el examen repite la guía, pero no ha demostrado que domina la materia. Para saberlo, el profesor pone problemas que el alumno no ha visto. Evaluar con datos distintos es poner ese examen sorpresa.

EJEMPLO NUMÉRICO

Con el historial de 156 semanas de demanda, una práctica habitual es entrenar con las primeras 124 semanas y reservar las últimas 32 (aproximadamente 20 %) para evaluar. Supongamos que el error promedio sobre las semanas de entrenamiento es de 8 unidades, pero sobre las 32 semanas reservadas es de 45. Esa brecha avisa que el modelo se ajustó a particularidades del pasado que no se repiten. Si hubiéramos evaluado solo con las semanas de entrenamiento, habríamos creído que el error era de 8.

Conexión: el Artículo 1 formaliza esta idea como el cuarto de los cinco componentes del aprendizaje, y el resumen de la unidad insiste en la «evaluación con muestras independientes». Teachable Machine, además, separa por sí misma una fracción de los ejemplos para validar (ver la discrepancia 5 en la sección de Teachable Machine).

9. Inferencia

Definición del curso: uso del modelo ya entrenado para producir un resultado frente a una **entrada nueva**.

La **inferencia** (*inference*) es la fase en que el modelo trabaja «en producción»: ya no aprende, solo aplica lo aprendido. Los parámetros están fijos. Se le entrega una entrada que no estaba en los datos de entrenamiento (la semana próxima, la foto de un envase recién salido de la línea, una consulta de un

cliente) y devuelve una predicción, una categoría o un contenido. Para un modelo de lenguaje, la inferencia es lo que ocurre cada vez que escribes una pregunta y recibes una respuesta.

Distinguir entrenamiento de inferencia importa en términos de negocio. El entrenamiento suele ser puntual (o periódico), intensivo en cómputo y requiere datos etiquetados; la inferencia ocurre muchas veces, debe ser rápida y confiable, y su costo se repite con cada uso. Un modelo que aprende con la carga de datos de ayer y responde hoy en la línea de envasado tiene dos «vidas» con requisitos distintos.

ANALOGÍA

El entrenamiento es el tiempo que un médico pasa estudiando en la universidad y haciendo residencia; la inferencia es su consulta de cada día, cuando aplica lo que sabe a un paciente nuevo. En consulta ya no vuelve a la universidad entre un paciente y otro.

Ciclo completo con el ejemplo: se *entrena* el modelo con el historial; se *evalúa* con semanas reservadas; y cada lunes se hace *inferencia* con el precio y la promoción planificados para la semana que comienza, obteniendo la demanda esperada.

10. Aprendizaje supervisado

Definición del curso: aprendizaje con ejemplos etiquetados. Se emplea principalmente para **regresión y clasificación**.

Es el enfoque en que el modelo aprende de pares «entrada, respuesta correcta». Si la respuesta es un número, el problema es de **regresión** (la demanda semanal, un tiempo de despacho); si es una categoría, de **clasificación** (fraude o no, correcto o defectuoso). Nuestro modelo de demanda semanal es un caso de regresión supervisada. La sección «Tipos de aprendizaje» lo desarrolla a fondo, con su tabla de cuatro problemas y la exigencia de etiquetas confiables.

11. Aprendizaje no supervisado

Definición del curso: aprendizaje con datos sin etiquetas, orientado a encontrar **patrones, similitudes o agrupaciones**.

Aquí no hay «respuesta correcta» que imitar: el modelo explora la estructura interna de los datos. Un ejemplo típico es agrupar clientes con comportamientos de compra parecidos, sin haber definido antes los grupos. La sección «Tipos de aprendizaje» lo desarrolla con la técnica de *clustering* y las precauciones para interpretar los grupos que aparecen.

12. Aprendizaje por refuerzo

Definición del curso: aprendizaje basado en **acciones, recompensas y penalizaciones** dentro de un **entorno**.

Un agente actúa en un entorno, recibe recompensas o penalizaciones según el resultado y, con la experiencia, aprende a elegir mejores acciones. Es distinto de los dos anteriores porque no hay un conjunto fijo de ejemplos: el propio agente genera su experiencia actuando. La sección «Tipos de

aprendizaje» lo desarrolla, incluida la advertencia sobre las recompensas mal definidas y su discrepancia asociada.

13. Deep Learning

Definición del curso: subcampo del machine learning que utiliza **redes neuronales con múltiples capas** para aprender patrones complejos.

El **deep learning** (*aprendizaje profundo*) es un subconjunto del ML, no un sinónimo. Una **red neuronal** es una estructura de cálculo organizada en capas de unidades simples; cada capa transforma la salida de la anterior. La palabra «profundo» se refiere al **número de capas**: con muchas capas, la red puede construir representaciones cada vez más abstractas. En una imagen, las primeras capas pueden captar bordes, las intermedias formas y las últimas objetos completos. Por eso el deep learning domina cuando las entradas son imágenes, audio o texto, donde las características no vienen ya «listas» en una tabla.

¿Por qué existe? Porque en tareas como reconocer imágenes o procesar lenguaje, diseñar a mano las características útiles es casi imposible. Una red profunda las aprende por sí misma durante el entrenamiento, usando los mismos principios que acabas de ver: función de pérdida, descenso por gradiente, evaluación con datos distintos. El precio es que necesita muchos datos y mucho cómputo, y es más opaca (más difícil de explicar).

ANALOGÍA

Piensa en una línea de producción de varias estaciones: la primera estación solo reconoce piezas básicas, la segunda las ensambla en subconjuntos, la tercera en el producto terminado. Cada estación recibe el resultado de la anterior. Una red profunda es una línea de muchas estaciones, y cada una aprende su función durante el entrenamiento.

Conexión: en la Unidad 1 de este módulo viste las redes convolucionales (CNN), las recurrentes (RNN) y el Transformer como tipos de red profunda. Todos los modelos generativos de la unidad que viene son deep learning.

Artículo 1: De las reglas a los modelos — cómo elegir la tecnología de IA adecuada

El primer artículo establece la idea que organiza toda la unidad: **formular el problema de negocio antes de elegir tecnología**. Su bajada promete responder tres cosas: cuándo usar reglas o ML, cómo aprende un modelo y cómo medir su impacto real, todo ello «sin dejarse llevar por modas».

El recuadro azul: el orden correcto de las decisiones

El artículo abre con un recuadro azul que conviene leer completo:

CITA DEL CURSO

«La conversación sobre inteligencia artificial suele mezclar conceptos, productos y promesas. Para trabajar con criterio conviene ordenar el campo desde una pregunta básica: ¿qué resultado

necesitamos producir? Algunas situaciones requieren una regla estable; otras, una predicción construida a partir de datos; otras, la generación de un contenido. La tecnología se escoge **después de formular el problema.**»

Hay tres ideas en el recuadro. La primera es un diagnóstico: el debate sobre IA mezcla **conceptos** (qué es un modelo), **productos** (qué vende un proveedor) y **promesas** (lo que se espera que haga). Esa mezcla lleva a decisiones por moda. La segunda es un método: partir de la pregunta «¿qué resultado necesitamos producir?». La tercera es una clasificación de tres tipos de necesidad: una **regla estable**, una **predicción** construida a partir de datos, o la **generación de contenido**. De allí sale el principio rector: **la tecnología se escoge después de formular el problema.**

ANALOGÍA

Nadie va a una ferretería a «comprar herramientas»; va a colgar un cuadro, y entonces decide entre un martillo y un taladro. Quien llega con el taladro más moderno y busca dónde usarlo está dejándose llevar por la moda. En IA, quien decide primero «queremos un LLM» y luego busca un problema repite ese error.

Una familia de tecnologías

El curso insiste en que la IA es una **familia** y no una sola técnica. Incluye seis ramas:

Rama	Qué hace	Ejemplo empresarial
Métodos basados en reglas	Ejecuta instrucciones explícitas escritas por personas	Bloquear una operación si supera un límite normativo definido
Técnicas de búsqueda y optimización	Explora alternativas y elige la mejor según un criterio	Armar la mejor ruta de reparto con restricciones de capacidad
Machine learning	Aprende relaciones a partir de datos y las aplica a casos nuevos	Predecir la demanda semanal de un producto
Procesamiento de lenguaje	Trabaja con texto y habla humanos	Clasificar reclamos de clientes por tema
Visión computacional	Interpreta imágenes y video	Detectar sellos incompletos en una línea de envasado
Sistemas generativos	Producen contenido nuevo (texto, imagen, audio, video, código)	Redactar el borrador de una ficha de producto

El curso precisa dos relaciones jerárquicas. El **ML es una parte** de este campo: entrena software para aprender relaciones a partir de datos y producir resultados frente a casos nuevos. El **deep learning** es, a su vez, un **subcampo del ML** basado en redes neuronales de múltiples capas. Visualízalo como círculos anidados: la IA contiene al ML, y el ML contiene al deep learning. Pero las ramas del campo no son un árbol limpio: el procesamiento de lenguaje y la visión computacional hoy se resuelven en gran medida

con ML y deep learning, y los sistemas generativos son una aplicación del deep learning. Los «círculos» sirven para entender, no para clasificar de forma rígida.

La utilidad práctica de ver la familia completa es evitar el sesgo de herramienta: no todo problema de IA es un problema de ML, y no todo problema de ML requiere un modelo generativo. Una regla bien escrita es IA en el sentido del curso (tecnología que realiza una tarea asociada con decisión), y puede ser exactamente lo que se necesita.

«Estas categorías se superponen»

El curso advierte que las categorías anteriores **se superponen**. Un **asistente generativo**, por ejemplo, puede combinar:

- un **modelo de lenguaje** que redacta la respuesta,
- un **clasificador** que decide si la consulta es una queja, una cotización o una pregunta técnica,
- un sistema de **búsqueda documental** que recupera fragmentos de las fichas técnicas aprobadas, y
- **reglas de seguridad** que bloquean ciertos temas o formatos de respuesta.

Las etiquetas, dice el curso, sirven para **comprender capacidades**, aunque una solución real puede reunir varios componentes. La consecuencia para el negocio es doble. Primero, cuando un proveedor dice «es IA generativa», eso no te dice cuántas piezas lleva dentro ni cómo se controlan. Segundo, el riesgo de una solución se evalúa pieza por pieza: el modelo de lenguaje puede confabular, el clasificador puede tener sesgo, el buscador puede recuperar un documento obsoleto y las reglas pueden estar incompletas. Más adelante, la tabla de necesidades incluirá justamente una fila para la **arquitectura híbrida**.

ANALOGÍA

Un auto no es «un motor»: es motor, frenos, dirección, cinturones y electrónica. Decir «el auto es de gasolina» describe una de sus piezas, pero no basta para juzgar su seguridad. Un asistente generativo es igual: la etiqueta describe el motor, no el vehículo completo.

El recuadro «Pregunta de negocio»

El artículo incluye un recuadro de método que merece memorizarse: **antes de hablar de modelos, define la tarea con un verbo y un resultado observable**. El curso da seis verbos, que aquí desarrollo con un ejemplo de SurAndes (la empresa de productos envasados del caso):

Verbo	Resultado observable	Ejemplo
Predecir	Un número o una categoría futura	Predecir las unidades que se demandarán la próxima semana de un producto
Clasificar	Una etiqueta de entre un conjunto conocido	Clasificar reclamos de clientes en urgentes y no urgentes
Agrupar	Grupos de casos parecidos, aún sin nombre	Agrupar clientes por frecuencia, volumen y mezcla de productos
Recomendar	Una acción sugerida a una persona	Recomendar al vendedor qué producto ofrecer a un cliente
Generar	Un contenido nuevo (texto, imagen, etc.)	Generar un borrador de ficha de producto o de propuesta comercial
Detectar	Una anomalía señalada	Detectar un envase con un sello inusual en la línea de envasado

Observa que el recuadro agrega «detectar una anomalía» como sexto verbo, mientras que la sección «¿Para qué nos servirá?» enumera cinco (predecir, clasificar, agrupar, recomendar, generar). No hay contradicción: el recuadro del Artículo 1 simplemente amplía la lista.

La virtud del verbo es que obliga a precisión. «Mejorar la atención al cliente» no es una tarea; «clasificar los reclamos entrantes por urgencia en menos de un minuto» sí lo es. Y el **resultado observable** es lo que permite medir: si no puedes decir cómo verías que la tarea salió bien, aún no has definido el problema.

De las reglas a los modelos

Cómo funciona un sistema basado en reglas

En un sistema tradicional, una persona programa **instrucciones explícitas**: «si ocurre A, ejecute B». Este esquema funciona de forma excelente cuando las reglas son **conocidas, estables y fáciles de mantener**. El curso da un ejemplo: una plataforma que **bloquea una operación si supera un límite normativo claramente definido**. Es una situación en que la regla existe, la fija un regulador o una política, no cambia a diario y se puede verificar. Aquí un modelo no aporta nada: la decisión es determinista, auditable y barata.

Cómo funciona el aprendizaje automático

En ML, el esquema cambia. El equipo entrega **ejemplos y una definición del resultado esperado**; el modelo ajusta **relaciones matemáticas** para capturar patrones; luego esas relaciones se usan para estimar resultados en casos nuevos. La persona ya no escribe la regla: escribe la *tarea* y aporta la *evidencia*.

El curso cita aquí a Google for Developers para definir **modelo**. La definición original, en inglés, dice:

CITA (GOOGLE FOR DEVELOPERS)

«A model is a mathematical relationship derived from data that an ML system uses to make predictions.»

Traducción: «Un modelo es una relación matemática derivada de datos que un sistema de ML utiliza para hacer predicciones.» (El curso la presenta como «una relación matemática derivada de datos que se utiliza para desarrollar predicciones» y la atribuye a Google for Developers, 2026a.)

Compárala con la definición de «modelo» de los conceptos clave: ambas insisten en tres elementos. Es una **relación matemática** (no un texto ni un programa con reglas escritas), **derivada de datos** (aprendida, no declarada) y destinada a **producir predicciones** frente a entradas nuevas.

La elección no es una moda

El curso formula una advertencia que vale la pena subrayar: si una política puede expresarse con **tres reglas claras y auditables**, un modelo puede **agregar costo y opacidad**. Cada palabra pesa. **Costo**, porque un modelo requiere datos, personas especializadas, infraestructura y mantenimiento (los datos cambian y el modelo debe reentrenarse). **Opacidad**, porque un conjunto de parámetros es mucho más difícil de explicar a un auditor que tres reglas legibles. Y «auditables» es la condición clave: una regla se puede inspeccionar y justificar; un modelo, mucho menos.

¿Cuándo aporta valor el ML? Cuando se cumplen dos condiciones a la vez: las relaciones a capturar son **numerosas, variables o difíciles de programar manualmente**, y **existen datos pertinentes** para aprenderlas. El curso lo resume en una frase que conviene tener presente: **no siempre vale la pena usar ML si las reglas y procesos ya son simples y conocidos**. La segunda condición es tan importante como la primera: un problema difícil de programar, pero sin datos, tampoco se resuelve con ML.

EJEMPLO NUMÉRICO

Supongamos, de forma ilustrativa, que SurAndes quiere decidir si un lote de envases se envía a revisión. La política vigente dice: «se revisa si la temperatura del sellado superó el umbral en más de 3 mediciones del lote». Es una regla clara y auditable; implementarla cuesta, digamos, una tarde de programación. Un modelo que aprendiera la misma decisión requeriría miles de lotes etiquetados, un equipo para mantenerlo y una explicación al auditor de por qué decidió lo que decidió. En cambio, para estimar la demanda semanal de 200 productos, con estacionalidad, promociones, feriados y precios cruzados, escribir las reglas a mano es inviable, y el ML sí aporta valor.

Conexión: el texto de apoyo del video resumen repite este criterio: si una necesidad se resuelve con políticas estables y explícitas, la automatización convencional por reglas resulta más eficiente, económica y transparente que el ML.

¿Cómo aprende un modelo? Los cinco componentes

El curso descompone el aprendizaje en cinco componentes encadenados. Los cinco son evaluables, así que conviene dominarlos en orden: **datos, representación, entrenamiento, evaluación, inferencia**.

1. Datos

Se reúnen ejemplos del problema. Pueden ser **registros de tablas, textos, imágenes, audio, video o señales de sensores**. La variedad de formatos es importante: el ML no se limita a datos «de planilla».

2. Representación

Se define **qué elementos funcionan como entradas**. El curso distingue dos situaciones. En datos de **tablas** (datos **tabulares**), esas entradas se llaman **características**: cada columna relevante (antigüedad, frecuencia de compra, precio, promoción). En **imágenes**, el modelo procesa **valores de píxeles y patrones visuales**: una fotografía es, para el computador, una grilla de números que indican el color y brillo de cada punto, y el modelo busca patrones en esa grilla.

EJEMPLO NUMÉRICO

Una fotografía en blanco y negro de 100×100 píxeles se representa como 10.000 números (uno por píxel, por ejemplo entre 0 y 255). Si es a color con tres canales (rojo, verde, azul), son 30.000 números. Esos números son la «representación» de la imagen. En cambio, una fila de datos de demanda semanal puede representarse con solo tres números (semana, precio, promoción). La representación determina qué puede «ver» el modelo.

3. Entrenamiento

El algoritmo ajusta los **parámetros** para **reducir la diferencia** entre sus resultados y los resultados esperados. Es exactamente el procedimiento de la función de pérdida y el descenso por gradiente que desarrollamos arriba: medir la distancia (pérdida) y mover los parámetros en la dirección que la reduce.

4. Evaluación

Se prueba con ejemplos que el modelo **no utilizó para entrenarse**; esa separación permite estimar su capacidad de **generalizar**. Si evaluaras con los mismos datos de entrenamiento, el modelo parecería excelente aunque solo hubiera memorizado.

5. Inferencia

El modelo entrenado recibe una **entrada nueva** y entrega una predicción, categoría o contenido.

El ciclo no es lineal en la práctica: si la evaluación revela que el desempeño es pobre, se vuelve a los datos (conseguir más o mejores ejemplos), a la representación (cambiar las características) o al entrenamiento (ajustar hiperparámetros). Los cinco componentes forman un ciclo de mejora.

ANALOGÍA

Preparar a un deportista para una competencia: los *datos* son sus entrenamientos registrados; la *representación* es qué se mide (tiempos, frecuencia cardíaca, fuerza); el *entrenamiento* es el trabajo diario que corrige sus errores; la *evaluación* es una competencia de prueba contra rivales que no conoce; y la *inferencia* es la competencia real. Si solo entrenara contra los mismos compañeros de siempre, no sabría cómo rinde ante desconocidos.

Relación entre datos y contexto

El curso aporta aquí una de las ideas más importantes del artículo: un conjunto de datos **numeroso puede seguir siendo insuficiente si repite las mismas condiciones**. La cantidad no sustituye a la diversidad.

El ejemplo del curso es una **cámara de bodega** que debe reconocer productos. Reconocer un producto en una bodega real exige que los ejemplos cubran **ángulos, distancias, iluminación, fondos y variaciones reales del embalaje**. Si todas las fotos se tomaron de frente, con luz de día y sobre un estante vacío, el modelo funcionará bien en esas condiciones y mal cuando un operario deje el producto de costado, de noche o entre cajas apiladas. El conjunto puede tener cien mil fotos, pero sigue «repitiendo las mismas condiciones».

El curso respalda la idea citando a Google: el **tamaño y la diversidad** del conjunto influyen en la **capacidad de generalización** (Google for Developers, 2025). La **generalización** es la capacidad de funcionar bien con casos nuevos, no solo con los vistos en el entrenamiento.

Sobreajuste

El problema opuesto a generalizar se llama **sobreajuste** (*overfitting*): el modelo «memoriza» los datos de entrenamiento tan de cerca que falla con datos nuevos. Según el material de Google, sus causas típicas son datos poco representativos y una complejidad excesiva del modelo, y su señal característica es que la pérdida sobre los datos de entrenamiento sigue bajando mientras la pérdida sobre los datos de validación empieza a subir. Es el caso del estudiante que se aprende la guía de memoria. Este concepto no aparece con ese nombre en el PDF del curso, pero explica con precisión lo que el curso describe con otras palabras (un conjunto numeroso pero repetitivo, evaluación con datos distintos).

ANALOGÍA

Un traje a medida cosido sobre un maniquí idéntico a una sola persona queda perfecto para esa persona, pero a cualquier otro le queda pésimo. El sobreajuste es un modelo «a medida» de sus datos de entrenamiento.

Una regla práctica de Google

Google ofrece una regla empírica para vincular la cantidad de datos con la complejidad del modelo: conviene contar con al menos **uno o dos órdenes de magnitud más ejemplos que parámetros entrenables** (es decir, entre 10 y 100 veces más ejemplos que parámetros). Es una regla práctica, no una ley exacta. Su sentido es intuitivo: un modelo con muchos parámetros y pocos ejemplos tiene «demasiada libertad» para ajustarse a casos particulares.

EJEMPLO NUMÉRICO

Si un modelo simple de demanda tiene 4 parámetros entrenables, la regla sugiere contar con unos 40 a 400 ejemplos; las 156 semanas del historial caben cómodamente en ese rango. Si en cambio quisiéramos ajustar un modelo con 5.000 parámetros con solo esas 156 semanas, tendríamos muchos más parámetros que ejemplos: el modelo podría memorizar el historial entero y fallar con la semana siguiente. Es el motivo por el que, con pocos datos, se prefieren modelos simples.

Conexión: esta relación entre cantidad, diversidad y generalización será el telón de fondo del caso SurAndes (la propuesta de inspección visual cuenta con 18.000 fotografías, pero las etiquetadas provienen principalmente del turno diurno y de dos productos) y del experimento con Teachable Machine.

Separar desempeño estadístico y utilidad empresarial

Este es, según la ordenación de la unidad, el concepto más difícil del Artículo 1, y uno de los más valiosos. El curso afirma: un modelo puede alcanzar una **buena precisión promedio** y, sin embargo, **fallar en el segmento más relevante, generar demasiadas alertas falsas o producir un error costoso**. La conclusión es que **la métrica debe representar el riesgo y la decisión que se quiere apoyar**.

Las tres fallas que menciona el curso son distintas. En la primera, un buen promedio global esconde un mal resultado en la parte que importa (por ejemplo, un modelo que acierta en los productos de alta rotación, que son mayoría, pero falla en los de alto margen, que son pocos). En la segunda, el modelo detecta bien, pero emite tantas alertas falsas que los operarios dejan de creerle (*fatiga de alertas*). En la tercera, los errores son pocos pero muy caros, por ejemplo, dejar pasar un envase defectuoso a un cliente institucional.

⚠ Nota (discrepancia 4): el curso dice que un modelo puede tener «buena **precisión promedio**» y fallar en el segmento relevante. En la terminología técnica estándar (la que usa Google), eso que el curso llama «precisión promedio» es la **exactitud** (*accuracy*): la proporción de aciertos sobre el total. La **precisión** (*precision*) es otra métrica: de todos los casos que el modelo marcó como positivos, cuántos lo eran realmente. La idea del curso es correcta (una métrica global puede esconder fallas costosas); solo que la palabra «precisión» está usada de forma coloquial. **Regla de examen:** si la pregunta usa el lenguaje del curso, «precisión promedio» significa acierto global; si es un ejercicio técnico, distingue siempre exactitud, precisión y sensibilidad (*recall*).

Complemento matemático: matriz de confusión, exactitud, precisión y sensibilidad

Para hablar con rigor de «qué tipo de error comete un modelo» se usa la **matriz de confusión** (*confusion matrix*), que cuenta los resultados de un clasificador en cuatro casilleros. Tomemos una inspección de envases donde «defectuoso» es la clase positiva (lo que queremos detectar):

	El modelo dice «defectuoso»	El modelo dice «correcto»
Realmente defectuoso	VP (verdadero positivo): defecto detectado	FN (falso negativo): defecto que se escapó
Realmente correcto	FP (falso positivo): alerta falsa	VN (verdadero negativo): correcto, bien clasificado

A partir de esos cuatro conteos se calculan las métricas:

$$\text{Exactitud} = \frac{VP + VN}{VP + VN + FP + FN} \quad \text{Precisión} = \frac{VP}{VP + FP} \quad \text{Sensibilidad} = \frac{VP}{VP + FN}$$

- **Exactitud** (*accuracy*): de *todos* los casos, qué proporción clasificó bien (en el numerador, los aciertos de ambas clases; en el denominador, el total). Es la «precisión promedio» del curso.
- **Precisión** (*precision*): de los casos que el modelo marcó como positivos, qué proporción lo era de verdad. Mide qué tan confiable es una alerta. Una precisión baja significa muchas alertas falsas.
- **Sensibilidad** (*recall*): de los casos que realmente eran positivos, qué proporción detectó el modelo. Mide cuántos defectos reales se escapan. Una sensibilidad baja significa muchos falsos negativos.

ANALOGÍA

Un guardia que revisa mochilas en una entrada. Su *sensibilidad* es cuántos objetos prohibidos realmente detecta de los que pasan. Su *precisión* es, de las mochilas que detiene, cuántas realmente llevaban algo prohibido. Un guardia que detiene a todos tiene sensibilidad perfecta pero precisión pésima; uno que no detiene a nadie tiene cero falsas alarmas pero deja pasar todo.

EJEMPLO NUMÉRICO: EL MODELO QUE DICE «TODO CORRECTO»

Supongamos, de forma ilustrativa, una inspección de **1.000 envases**, de los cuales **20 son defectuosos** (un 2 %). Un modelo trivial que responde siempre «correcto» tendría: VP = 0, FN = 20, FP = 0 y VN = 980. Su exactitud es $\frac{0+980}{1000} = 98\%$. Su sensibilidad es $\frac{0}{0+20} = 0\%$: no detecta ni uno de los defectos. (Su precisión ni siquiera se puede calcular: no emite ninguna alerta, así que el cociente sería 0/0.) Es un modelo con 98 % de exactitud y completamente inútil para el negocio.

Este es el corazón del argumento del curso. Cuando los casos de interés son raros, una métrica global como la exactitud queda dominada por la clase mayoritaria y «esconde» el fracaso en el segmento relevante.

EJEMPLO NUMÉRICO: UN MODELO ÚTIL

Ahora un modelo ilustrativo que sí trabaja: de los 20 defectuosos detecta 16 (VP = 16, FN = 4) y, de los 980 correctos, emite 24 alertas falsas (FP = 24, VN = 956). Las métricas son: exactitud $\frac{16+956}{1000} = 97,2\%$; precisión $\frac{16}{16+24} = 40\%$; sensibilidad $\frac{16}{16+4} = 80\%$.

Observa algo contraintuitivo: el modelo útil tiene una exactitud **menor** (97,2 %) que el modelo inútil (98 %). Si el criterio de selección fuera la exactitud, elegiríamos el peor. Además, su precisión es de solo 40 %: de cada 10 alertas, 6 son falsas. Eso tiene un costo operativo (alguien debe revisar esas alertas), pero a cambio detecta el 80 % de los defectos. Qué equilibrio conviene depende del costo de cada tipo de error.

EJEMPLO NUMÉRICO: COSTO ESPERADO DEL ERROR

Asignemos costos ilustrativos, que en la práctica debe estimar el negocio: un **falso positivo** (revisar manualmente un envase correcto) cuesta 1 unidad de costo; un **falso negativo** (dejar pasar un envase defectuoso a un cliente) cuesta **50 veces** más, es decir, 50 unidades. El costo total de errores es $\text{Costo} = 50 \cdot FN + 1 \cdot FP$.

Modelo «todo correcto»: $50 \cdot 20 + 1 \cdot 0 = 1.000$ unidades.

Modelo útil: $50 \cdot 4 + 1 \cdot 24 = 224$ unidades.

El modelo con peor exactitud tiene un costo de error 4,5 veces menor (224 frente a 1.000). La métrica que representa el negocio no es la exactitud, sino el costo esperado del error, o una métrica como la sensibilidad cuando dejar pasar un defecto es lo grave. **Por eso «la métrica debe representar el riesgo y la decisión que se quiere apoyar»:** la elección de la métrica es una decisión de negocio, no solo técnica.

Dos cautelas para usar estas ideas con honestidad. Primera: los números del ejemplo son ilustrativos, no datos del curso ni de ninguna empresa. Segunda: no existe una métrica «correcta» universal; si el costo de una alerta falsa fuera alto y el de un defecto bajo, la ponderación se invertiría y convendría un modelo con mayor precisión. Lo que cambia entre casos es el **costo de cada error**, y por eso la conversación entre negocio y equipo técnico debe partir por ahí. En el Módulo 1, Unidad 3, ya viste las métricas de clasificación; aquí se aplican a la decisión de negocio, y en el Módulo 2, Unidad 5, a la supervisión humana de los errores.

El recuadro naranja: cierre del artículo

El artículo termina con un recuadro naranja que sintetiza su mensaje:

CITA DEL CURSO

«En definitiva, la IA no debe abordarse como un fin en sí mismo ni como una respuesta automática a cualquier problema corporativo. El **verdadero valor** surge al definir con claridad la tarea de negocio, evaluar si la complejidad justifica un modelo y garantizar que la métrica de éxito responda al impacto real en la operación, y no solo a la precisión estadística.»

Descompón la cita en tres exigencias, todas evaluables. **Uno:** definir con claridad la **tarea de negocio** (el verbo y el resultado observable). **Dos:** evaluar si la **complejidad justifica un modelo** (si tres reglas auditables bastan, no hace falta). **Tres:** garantizar que la **métrica de éxito responda al impacto real** en la operación y no solo a la precisión estadística. Observa que la cita vuelve a usar la «precisión estadística» en el sentido general de desempeño de laboratorio, en línea con la discrepancia 4: lo que el curso contrapone es el desempeño estadístico y el impacto en la operación.

Con esto, el Artículo 1 deja instalada la mentalidad con la que se leerá el resto de la unidad: la pregunta nunca es «¿qué IA usamos?», sino «¿qué resultado necesitamos, qué evidencia tenemos y cómo sabremos que funcionó?». La sección siguiente entra en la segunda pregunta, la de **qué tipo de aprendizaje** corresponde a cada necesidad, con los tres enfoques que aquí solo se definieron en un párrafo.

Artículo 2 · Tipos de aprendizaje en IA: supervisado, no supervisado y por refuerzo

El artículo se presenta con una bajada que ya fija su promesa: «Conoce las diferencias entre aprendizaje supervisado, no supervisado y por refuerzo: tres enfoques esenciales para transformar datos en

predicciones, patrones y decisiones según la meta de tu proyecto». La introducción añade la idea que organiza todo lo que sigue: para seleccionar la tecnología de inteligencia artificial adecuada, el punto de partida es comprender **cómo aprende cada modelo según los datos disponibles y el objetivo perseguido**. Cada enfoque ofrece capacidades distintas para transformar información en **predicciones, agrupaciones o decisiones estratégicas** dentro de una organización.

Dicho de otro modo, la pregunta de selección no es «¿qué algoritmo está de moda?», sino dos preguntas previas: ¿qué tipo de dato tengo? (con respuesta conocida, sin respuesta, o solo la posibilidad de probar y observar consecuencias) y ¿qué quiero obtener? (un número, una categoría, grupos desconocidos o una secuencia de decisiones). En el artículo anterior (*De las reglas a los modelos*, ver «Conceptos clave» y el Artículo 1 de esta explicación) vimos el ciclo datos → representación → entrenamiento → evaluación → inferencia. Aquí se abre el interior del paso de entrenamiento: según qué información acompañe a los datos, el «entrenamiento» toma tres formas radicalmente distintas. En la Unidad 1 de este módulo los tres enfoques aparecieron en una sola línea; en el Módulo 1, Unidad 3, el supervisado se trabajó con más detalle (características, etiquetas, métricas). Ahora los comparamos de frente.

⚠ Nota (discrepancia 1): ¿tres o cuatro tipos de aprendizaje? El curso presenta **tres** enfoques (supervisado, no supervisado y por refuerzo) y trata lo generativo aparte, en el artículo siguiente («De predecir a generar»). Sin embargo, la misma fuente que el curso cita, *Google for Developers (What is Machine Learning?)*, clasifica los sistemas de ML en **cuatro** categorías: supervisado, no supervisado, por refuerzo **e IA generativa**, y aclara que un sistema puede pertenecer a **una o más** de ellas. No es una contradicción de fondo, sino de criterio de clasificación: el curso separa «cómo se aprende a partir de las etiquetas» de «qué se produce». **Regla de examen:** si preguntan por los «tipos de aprendizaje» según el curso, son tres; si preguntan cómo los clasifica Google, son cuatro (se suma la generativa); y en ambos casos las categorías **no son mutuamente excluyentes**. Esto conecta con la advertencia del Artículo 1: «estas categorías se superponen».

Aprendizaje supervisado

El **aprendizaje supervisado** (*supervised learning*) utiliza ejemplos que incluyen **la respuesta conocida**. Cada ejemplo trae dos partes: las **características** (*features*), es decir, los atributos de entrada (antigüedad del cliente, frecuencia de compra, píxeles, palabras), y la **etiqueta** (*label*), el resultado ya conocido (fraude o no fraude, nivel de demanda, defecto o no defecto). El modelo aprende **relaciones entre las características y la etiqueta**. Después se evalúa comparando sus predicciones con **resultados reales que no vio durante el entrenamiento** (Google for Developers, 2025). Esa última frase es la misma separación entre entrenamiento y evaluación que el Artículo 1 presentó como condición para estimar la **generalización**: si evaluáramos con los mismos ejemplos usados para entrenar, el modelo podría sacar buena nota simplemente por haberlos memorizado.

ANALOGÍA

Un estudiante que prepara una prueba con una guía de ejercicios resueltos. Cada ejercicio trae el enunciado (características) y la solución (etiqueta). Estudia hasta captar la relación entre uno y otra. El día de la prueba se le entregan ejercicios nuevos, que no estaban en la guía: eso es la evaluación con

datos no vistos. Si solo hubiese memorizado las soluciones de la guía, fracasaría en la prueba; si entendió la relación, resuelve ejercicios inéditos.

El curso identifica las **dos tareas más comunes** del aprendizaje supervisado, que se distinguen exclusivamente por el tipo de la etiqueta que se quiere estimar:

La **regresión** (*regression*) estima un **valor numérico**, como la demanda semanal, el tiempo de entrega o el costo esperado. La salida pertenece a un rango continuo: 1.240 unidades, 37,5 minutos, 18.900 pesos. La **clasificación** (*classification*) estima una **categoría**, como fraude probable, reclamo urgente, producto defectuoso o cliente con riesgo de abandono. La salida pertenece a un conjunto finito de clases: «fraude» o «legítimo», «urgente», «normal» o «bajo».

Una regla práctica para recordarlo: pregúntate si tiene sentido calcular un promedio o una diferencia con la salida. Si «el doble de 20 minutos» y «la mitad» tienen sentido, probablemente es regresión; si la salida es un nombre de grupo, es clasificación. Los ejemplos del curso (demanda semanal, tiempo de entrega y costo esperado para la regresión; fraude probable, reclamo urgente, producto defectuoso y cliente con riesgo de abandono para la clasificación) se retoman más abajo en la tabla de problemas.

La tabla de cuatro problemas supervisados

El curso resume el supervisado con una tabla que cruza el problema de negocio con los datos que exige, la salida esperada y el tipo de tarea. La reproducimos íntegra:

Problema	Datos necesarios	Salida esperada	Tipo
Predecir ventas de una sucursal	Historial de ventas, fechas, promociones y contexto	Número de unidades	Regresión
Detectar correos sospechosos	Correos previamente marcados	Spam o legítimo	Clasificación
Identificar defectos visuales	Imágenes etiquetadas por tipo de defecto	Categoría del producto	Clasificación
Estimar tiempo de despacho	Rutas, carga, clima y tiempos observados	Minutos estimados	Regresión

Leamos la tabla fila por fila, porque cada una trae una pequeña lección sobre cómo se «formula» un problema supervisado.

Fila 1: predecir ventas de una sucursal (regresión). Las características son el historial de ventas, las fechas (día de la semana, mes, feriados), las promociones y el contexto (por ejemplo, el clima o eventos locales). La etiqueta es el número de unidades que efectivamente se vendieron en cada período. Es regresión porque la respuesta es una cantidad. ¿Qué pasaría si se formulara al revés, como clasificación? Podríamos pedir «ventas altas / medias / bajas». No es un error absurdo, pero se pierde información: el equipo de abastecimiento necesita saber cuántas unidades pedir, no solo en qué tramo caerá la demanda. Es el caso típico en que la clasificación es una versión más tosca de una regresión, útil solo si la decisión de negocio realmente trabaja por tramos.

Fila 2: detectar correos sospechosos (clasificación). Los datos son correos **previamente marcados** por personas o por reglas: cada correo trae su etiqueta «spam» o «legítimo». La salida es una de dos categorías. Es clasificación porque no existe un «grado numérico de spam» que alguien haya medido; hay una decisión binaria. Si se formulara como regresión, habría que inventar un puntaje continuo (por ejemplo, de 0 a 100) y alguien tendría que haberlo asignado a cada correo histórico, lo que no ocurre. Nótese que muchos clasificadores sí calculan internamente una probabilidad, pero la *tarea* sigue siendo clasificar: el puntaje se convierte en categoría con un umbral.

Fila 3: identificar defectos visuales (clasificación). Los datos son imágenes etiquetadas por tipo de defecto; la salida es la categoría del producto («correcto», «abolladura», etc.). Es clasificación porque la respuesta es un nombre de clase. Esta fila será clave en el caso SurAndes (Propuesta A), donde el clasificador de envases tiene exactamente esa forma. Formularla como regresión («cuánto defecto tiene el envase, de 0 a 10») exigiría un sistema de puntuación que el área de calidad no usa; y además mezclaría defectos de naturaleza distinta (un sello incompleto y una etiqueta desplazada no son «más» o «menos» del mismo defecto).

Fila 4: estimar tiempo de despacho (regresión). Los datos son rutas, carga, clima y tiempos observados; la salida son minutos estimados. Es regresión porque el resultado es un número continuo. Formularlo como clasificación («a tiempo» / «atrasado») sería legítimo si lo único que interesa es la alerta de retraso, pero la persona que planifica rutas pierde la información de cuánto se atrasará.

EJEMPLO NUMÉRICO

Supongamos (cifras ilustrativas) que un modelo de regresión estima el despacho de un pedido en 42 minutos y el tiempo real fue 50. El error es de 8 minutos, una cantidad con significado operativo directo. Si el mismo problema se formula como clasificación «a tiempo / atrasado» con un límite de 45 minutos, la predicción «a tiempo» se marca como correcta para cualquier valor real hasta 45, pero 50 sería «atrasado»: el modelo fallaría por una diferencia de pocos minutos y no sabríamos si falló por 1 minuto o por 40. La elección entre regresión y clasificación decide qué información sobrevive.

La lección común de las cuatro filas es la que el Artículo 1 puso en el recuadro «Pregunta de negocio»: la tarea se define con **un verbo y un resultado observable**. «Predecir una cantidad» y «clasificar una categoría» son dos verbos distintos que conducen a dos tareas distintas, aunque ambas sean supervisadas y ambas exijan datos con la respuesta conocida.

El requisito principal: etiquetas confiables

El curso es explícito: el principal requisito del aprendizaje supervisado es contar con **etiquetas confiables**. Si las respuestas históricas reflejan **decisiones sesgadas, criterios inconsistentes o errores de registro**, el modelo aprenderá parte de esos problemas. El modelo no tiene forma de saber que una etiqueta es incorrecta: para él, la etiqueta es la verdad. Por eso el curso concluye que la revisión del origen y la calidad de las etiquetas es una tarea **tanto de negocio como técnica**: el equipo técnico puede detectar inconsistencias estadísticas, pero solo quien conoce el negocio sabe cómo se decidió realmente cada etiqueta y si ese criterio es el que se quiere replicar.

Cada uno de los tres problemas tiene su propia cara:

Las **decisiones sesgadas** aparecen cuando la etiqueta es el resultado de juicios humanos con prejuicios o con incentivos particulares. En la Unidad 1 vimos el caso COMPAS: si los datos históricos reflejan quién fue detenido o condenado más a menudo, el modelo aprende esa pauta como si fuera un hecho sobre las personas. Los **criterios inconsistentes** aparecen cuando distintas personas (o el mismo evaluador en distintos turnos) usan reglas diferentes para etiquetar. Los **errores de registro** son más banales: casillas mal marcadas, estados cerrados por conveniencia, campos completados al apuro.

EJEMPLO NUMÉRICO

Supongamos que una empresa quiere un modelo que clasifique reclamos como «urgente» o «normal», y entrena con 10.000 reclamos históricos. Al revisar, descubre que el turno de la mañana marcó como «urgente» el 20 % de los reclamos y el turno de la tarde solo el 5 %, aunque los reclamos son comparables. Eso son criterios inconsistentes: unos 15 de cada 100 reclamos tienen una etiqueta que depende del turno y no del contenido. Un modelo entrenado con esos datos aprenderá a reproducir la diferencia entre turnos (por ejemplo, usando la hora del reclamo como pista) y fallará con los reclamos que merecen atención inmediata pero llegaron por la tarde. La solución es de negocio antes que técnica: unificar el criterio de urgencia, reetiquetar una muestra y recién entonces entrenar.

Este punto conecta con el recuadro del Artículo 1 sobre la métrica: un modelo puede mostrar una exactitud alta respecto de las etiquetas históricas y aun así ser inútil, porque las etiquetas mismas estaban equivocadas. Y se conecta con la pregunta de foro al final del artículo, que veremos más abajo.

Aprendizaje no supervisado

El curso destaca, en un recuadro de cita, la definición central:

«El aprendizaje no supervisado trabaja con datos sin una respuesta predefinida. Busca estructuras, similitudes o agrupaciones. Una técnica frecuente es el clustering, que reúne casos parecidos y permite explorar segmentos que no estaban definidos previamente (Google for Developers, 2026a).»

El **aprendizaje no supervisado** (*unsupervised learning*) no tiene etiqueta que predecir. No hay «respuesta correcta» contra la cual comparar. El algoritmo recibe solo las características y busca **estructura** en ellas: qué casos se parecen entre sí, qué variables se mueven juntas, qué observaciones se alejan del resto. La técnica más frecuente es el **clustering** o **agrupamiento** (*clustering*): reunir casos parecidos en **grupos** (clusters) sin que nadie haya definido los grupos de antemano.

ANALOGÍA

Imagina que te entregan una caja con mil fotos de una boda, sin ninguna indicación, y te piden «ordénalas». Sin que nadie te diga las categorías, empiezas a separar: las del brindis, las del baile, las de los niños, las de la ceremonia. Las categorías las descubres tú mirando los parecidos. Pero el nombre «momentos del baile» lo pones tú, porque conoces la boda. Un algoritmo de clustering hace la primera mitad (agrupar por parecido); la segunda (nombrar y decidir qué hacer con cada grupo) es trabajo humano.

Los **cuatro usos empresariales** que nombra el curso son:

1. **Explorar patrones de compra:** descubrir tipos de comportamiento de clientes que nadie había definido.
2. **Agrupar puntos de venta con comportamientos semejantes:** por ejemplo, para diseñar políticas de surtido por grupo en lugar de sucursal por sucursal.
3. **Identificar temas recurrentes en grandes colecciones de documentos:** reclamos, contratos o correos que ningún equipo podría leer completos.
4. **Detectar casos atípicos:** observaciones que no pertenecen a ningún grupo habitual, útiles para detectar errores, fraudes o situaciones nuevas.

Aquí aparece la frase que el curso quiere que se recuerde: **«El modelo encuentra grupos; la interpretación y el nombre que finalmente se asigna a cada grupo requieren conocimiento del negocio»**. El algoritmo entrega etiquetas numéricas («grupo 1», «grupo 2», «grupo 3»). Decidir que el grupo 2 son «clientes ocasionales de alto ticket» y que conviene tratarlos con una oferta distinta es una operación de interpretación que el modelo no puede hacer solo.

Los segmentos no son verdades naturales

La segunda advertencia es igual de importante: **los segmentos descubiertos no son verdades naturales**. Dependen de las **variables seleccionadas** en su construcción, de la **escala y calidad de los datos** y de las **decisiones metodológicas** (cuántos grupos pedir, qué medida de distancia usar, qué algoritmo emplear). Por eso deben **validarse** con evidencia adicional y con personas que conozcan el contexto.

La palabra «escala» es la menos evidente, y conviene verla con números, porque muestra que una decisión aparentemente técnica (en qué unidad se mide una variable) puede cambiar los grupos que el algoritmo «descubre». La mayoría de los algoritmos de clustering se basan en una **distancia** entre casos; la más usada es la distancia euclidiana, que para dos clientes a y b descritos por p variables es:

Complemento matemático: distancia euclidiana y efecto de la escala

$$d(a, b) = \sqrt{\sum_{j=1}^p (a_j - b_j)^2}$$

Desglose: a y b son dos clientes; a_j y b_j son los valores de la variable j en cada uno (por ejemplo, frecuencia de compra o gasto); la resta mide cuánto difieren en esa variable; el cuadrado elimina el signo y hace que las diferencias grandes pesen mucho más que las pequeñas; la suma Σ acumula el aporte de todas las variables; y la raíz cuadrada devuelve el resultado a la unidad original. La intuición es el teorema de Pitágoras generalizado: la distancia en línea recta entre dos puntos. Lo relevante es que **todas las variables se suman en la misma bolsa**: si una de ellas tiene números mucho más grandes que las demás, gobierna la suma.

EJEMPLO NUMÉRICO

Supongamos cinco clientes ilustrativos, descritos por **frecuencia de compra** (veces al mes) y **gasto mensual** (en pesos):

Cliente	Frecuencia (veces/mes)	Gasto mensual (pesos)
A	4	120.000
B	12	121.000
C	5	150.000
D	8	90.000
E	6	100.000

Sin normalizar. La distancia entre A y B es la raíz de $(4-12)^2 + (120.000-121.000)^2 = 64 + 1.000.000 = 1.000.064$, es decir, $\approx 1.000,03$. La distancia entre A y C es la raíz de $(4-5)^2 + (120.000-150.000)^2 = 1 + 900.000.000$, es decir, $\approx 30.000,00$. Y entre B y C, $\approx 29.000,00$. El gasto (miles de pesos) aplasta a la frecuencia (unidades): A y B quedan «casi iguales» (distancia ≈ 1.000) pese a que A compra 4 veces al mes y B, 12, y A queda «lejísimos» de C (≈ 30.000) aunque ambos compren con frecuencia parecida (4 y 5). Prácticamente solo importó el gasto.

Estandarizando. Se transforma cada variable restando su media y dividiendo por su desviación estándar (la *puntuación z*). Para estos cinco clientes: frecuencia, media 7 y desviación 2,83; gasto, media 116.200 y desviación 20.634. Los valores estandarizados (frecuencia, gasto) son: A (-1,06; 0,18), B (1,77; 0,23), C (-0,71; 1,64). Ahora las distancias son: A-B $\approx 2,83$; A-C $\approx 1,50$; B-C $\approx 2,85$. El orden se invirtió: con las variables en igualdad de condiciones, **A queda más cerca de C que de B**, porque ahora la frecuencia (que separa a A de B por casi 3 desviaciones) pesa tanto como el gasto. (Cálculos verificados con Python.)

La moraleja es doble. Primero, un algoritmo de clustering que se alimente con variables en pesos y en «veces al mes» sin normalizar, agrupará casi solo por gasto, y el equipo comercial leerá esos grupos como «tipos de cliente» cuando en realidad son «rangos de gasto». Segundo, estandarizar tampoco es «la» respuesta correcta: es una decisión metodológica (¿queremos que frecuencia y gasto pesen igual?) que debe discutirse con quien conoce el negocio. De ahí la frase del curso: los grupos **dependen** de las variables, la escala, la calidad de los datos y las decisiones metodológicas, y por eso hay que **validarlos** (por ejemplo, comprobando que los grupos son estables al cambiar la muestra, que se distinguen en variables que no se usaron para construirlos y que las personas del negocio los reconocen y pueden actuar sobre ellos).

Este es exactamente el problema de la Propuesta B del caso SurAndes: segmentar clientes por frecuencia, volumen, estacionalidad, forma de pago y mezcla de productos. Variables en unidades muy distintas, datos con identificadores inconsistentes tras una migración y necesidad de validación experta: todo lo que acabamos de ver se juntaba en un solo caso (el caso SurAndes lo retoma).

Aprendizaje por refuerzo

En el **aprendizaje por refuerzo** (*reinforcement learning*) ya no hay una tabla de respuestas conocidas ni una colección de datos estática que explorar. Hay un **agente** (*agent*) que realiza **acciones** (*actions*) en un **entorno** (*environment*) y recibe **recompensas o penalizaciones** (*reward / penalty*). Con la

experiencia, el agente aprende una **política** (*policy*): una regla que dice qué acción tomar en cada situación, orientada a **maximizar la recompensa acumulada** (*cumulative reward*). El curso señala que se ha utilizado en **juegos, robótica, control y problemas de optimización secuencial** (Google for Developers, 2026a).

Cada término tiene un papel preciso. El *agente* es quien decide. El *entorno* es todo aquello con lo que el agente interactúa y que responde a sus acciones (un tablero, un robot en una bodega, un sistema de despacho). Las *acciones* son las decisiones disponibles. La *recompensa* es la señal numérica que indica qué tan bueno fue lo que ocurrió (positiva) o qué tan malo (penalización, valor negativo). La *política* es el producto del aprendizaje: el «manual de conducta» del agente. Y la *recompensa acumulada* es el criterio de éxito: no importa una recompensa aislada, sino la suma a lo largo del tiempo, de modo que un sacrificio hoy puede ser correcto si rinde más mañana.

ANALOGÍA

Entrenar a un perro con premios. Nadie le entrega una tabla de «respuestas correctas» (como en el supervisado) ni le pide que agrupe cosas por parecido (como en el no supervisado). El perro hace cosas (acciones) en un lugar (entorno) y recibe una galleta o un «no» (recompensa o penalización). Con el tiempo aprende qué conducta conviene en cada situación (política) para obtener más galletas a lo largo del día (recompensa acumulada). Y si el entrenador premia sin querer una conducta no deseada, el perro la aprenderá igual: la recompensa define lo que el agente persigue, no lo que el entrenador «quiso decir».

El ejemplo empresarial del curso es una **secuencia de decisiones logísticas**: ajustar, paso a paso, asignaciones y rutas considerando la **puntualidad** en la entrega, el **costo del traslado** y la **evaluación del usuario** del nivel de servicio. Aquí cada decisión (a qué vehículo asignar un pedido, en qué orden despachar) cambia el estado del sistema y las decisiones siguientes, por eso es «optimización secuencial»: no se trata de acertar una predicción aislada, sino de que la cadena completa de decisiones sea buena.

Complemento matemático: recompensa acumulada descontada

El curso habla de «maximizar la recompensa acumulada» sin escribirla. La forma estándar de formalizarlo es el **retorno descontado** (*discounted return*):

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

Desglose: t es el instante de decisión actual; G_t es el retorno, es decir, el valor total que el agente espera obtener a partir de t ; r_{t+k+1} es la recompensa recibida $k+1$ pasos después de t (la primera recompensa posterior a la acción es r_{t+1}); la suma recorre todos los pasos futuros ($k = 0, 1, 2, \dots$); y γ (gamma) es el **factor de descuento**, un número entre 0 y 1 que se eleva a la potencia k , de modo que cada paso más lejano en el tiempo pesa menos. Si $\gamma = 0$ el agente es miope: solo cuenta la recompensa inmediata. Si γ se acerca a 1, el agente es visor: valora casi igual el futuro lejano. La intuición es la del dinero en el tiempo: una recompensa hoy vale más que la misma recompensa dentro de un año, tanto por incertidumbre como por preferencia.

EJEMPLO NUMÉRICO

Supongamos (ilustrativo) que un sistema de despacho recibe, tras cuatro decisiones sucesivas, estas recompensas: +3 (entrega puntual), -2 (retraso por tráfico), +4 (ahorro de combustible) y +6 (cliente satisfecho). Con $\gamma = 0,9$ los pesos son $0,9^0 = 1$; $0,9^1 = 0,9$; $0,9^2 = 0,81$; $0,9^3 = 0,729$. El retorno es $G = 3 \cdot 1 + (-2) \cdot 0,9 + 4 \cdot 0,81 + 6 \cdot 0,729 = 3 - 1,8 + 3,24 + 4,374 = 8,814$. Sin descuento ($\gamma = 1$) sería 11. Si el mismo conjunto de recompensas llegara en otro orden (+6, +4, -2, +3), el retorno sería $6 + 3,6 - 1,62 + 2,187 = 10,167$: **el orden importa**, y por eso el agente aprende a preferir secuencias que traen las buenas recompensas antes. (Verificado con Python.)

Recompensa incompleta y por qué suele quedar fuera de los primeros pilotos

La formulación del refuerzo **exige definir cuidadosamente el entorno, las acciones posibles y la recompensa**. El curso advierte: **una recompensa incompleta puede incentivar conductas inconvenientes**. El agente optimiza lo que se le premia, no lo que quisimos decir. Un caso documentado lo ilustra: en 2016 OpenAI publicó el ejemplo del juego de carreras *CoastRunners*, en que el objetivo real era terminar la carrera, pero el puntaje se otorgaba por golpear objetivos en el camino. El agente aprendió a dar vueltas en una laguna donde esos objetivos reaparecen, y obtuvo alrededor de un **20 % más de puntaje** que los jugadores humanos que sí terminaban la carrera, **sin terminarla**, chocando e incendiándose en el proceso. Había maximizado la recompensa a la perfección, y había fracasado en el objetivo. En una operación logística el equivalente sería, por ejemplo, premiar solo la puntualidad: el agente podría aprender a asignar siempre los vehículos más caros o a rechazar los pedidos difíciles, porque eso aumenta su puntaje aunque dañe el negocio.

Por esta razón, y por su **complejidad y costo de experimentación** (equivocarse en el mundo real cuesta pedidos, clientes y dinero; y para aprender hacen falta muchísimas interacciones), el refuerzo suele quedar **fuera de los primeros pilotos** de una organización. Así lo recogerá la tabla de tecnologías que veremos más adelante, cuya condición crítica para el refuerzo es un **entorno seguro, recompensa bien definida y capacidad de simular**. Y se verá en el caso SurAndes: la Propuesta D (despacho dinámico) se descarta, precisamente, por no tener simulador.

⚠ Nota (discrepancia 2): tras decir que el refuerzo queda fuera de los primeros pilotos, el curso agrega que «cobra un gran protagonismo una vez en producción». La fuente citada (Google for Developers) no respalda esa afirmación: ilustra el refuerzo con juegos (por ejemplo, AlphaGo) y robótica, y la propia literatura (como el caso *CoastRunners*) muestra que el refuerzo es frágil ante recompensas mal especificadas. Lo bien fundado es lo otro: exige entorno, simulador y recompensa bien definida. **Regla de examen:** responde que el refuerzo rara vez es el primer piloto por su complejidad y costo, y que necesita un entorno seguro o un simulador; no uses como argumento que «en producción domina».

Cierre del artículo: el recuadro rosado

El artículo cierra con un recuadro rosado que condensa su mensaje: «Entender las diferencias entre supervisado, no supervisado y por refuerzo permite seleccionar la herramienta correcta para cada reto operativo. Más allá de la complejidad técnica, el éxito dependerá de contar con **datos de calidad**,

validar el contexto del negocio y asegurar que el comportamiento del modelo responda a los **objetivos estratégicos** de la organización.»

Tres condiciones de éxito, que se leen con las tres secciones anteriores: los **datos de calidad** son el requisito del supervisado (etiquetas confiables) y de todo el ciclo (el Artículo 1 ya había dicho que un conjunto numeroso puede seguir siendo insuficiente si repite las mismas condiciones); **validar el contexto del negocio** es el requisito del no supervisado (los grupos no son verdades naturales); y asegurar que el comportamiento del modelo responda a los **objetivos estratégicos** es el requisito del refuerzo (la recompensa debe representar lo que de verdad se quiere). La tabla siguiente sintetiza el artículo, como lectura de repaso propia de esta explicación (no es una tabla del curso):

Enfoque	¿Qué recibe?	¿Qué produce?	Requisito crítico
Supervisado	Ejemplos con respuesta conocida (etiqueta)	Un número (regresión) o una categoría (clasificación)	Etiquetas confiables y evaluación con datos no vistos
No supervisado	Datos sin respuesta predefinida	Grupos, estructuras, casos atípicos	Variables pertinentes e interpretación y validación expertas
Por refuerzo	Experiencia de acciones, recompensas y penalizaciones en un entorno	Una política que maximiza la recompensa acumulada	Entorno seguro, recompensa bien definida, capacidad de simular

Participa con tu comentario

La pregunta de foro del artículo es: *Pensando en los proyectos que tienes en mente, ¿cuentas hoy con el tipo y la calidad de datos necesarios para que un modelo aprenda, o el primer paso es replantear la forma en que registras la información?*

Una buena respuesta no es un «sí» o un «no», sino un pequeño diagnóstico con cuatro movimientos. Primero, **nombra el proyecto y formula la tarea** con un verbo y un resultado observable (por ejemplo, «predecir la demanda semanal por sucursal» o «clasificar reclamos como urgentes o normales»), de modo que se vea qué tipo de aprendizaje correspondería: regresión, clasificación, agrupamiento. Segundo, **revisa el tipo de dato**: ¿existe la etiqueta, es decir, el resultado histórico que quiero predecir? Si no existe, quizá lo que corresponde sea explorar con aprendizaje no supervisado o, antes, empezar a registrarla. Tercero, **evalúa la calidad** con las tres fallas que nombra el curso: ¿las etiquetas reflejan decisiones sesgadas, criterios inconsistentes o errores de registro? ¿Hay quiebres (como una migración de sistema) que cambiaron los identificadores? Cuarto, **decide el primer paso**: si hay datos suficientes y confiables, diseñar un piloto con línea base; si no, el primer paso legítimo es **replantear el registro de la información** (qué se anota, quién lo anota, con qué criterio, desde cuándo). Reconocer que el primer paso es mejorar el registro no es una respuesta pobre: es muchas veces la respuesta correcta, y es coherente con el cierre del artículo.

Artículo 3 · Implementación responsable de IA

El tercer artículo cambia de escala. La bajada lo anuncia: explora «la evolución de la IA hacia modelos generativos y multimodales: cómo elegir la tecnología adecuada, gestionar sus riesgos éticos o legales y diseñar pruebas piloto con impacto real». La introducción describe el recorrido: el avance de la IA ha pasado de **modelos capaces de predecir valores** a **sistemas capaces de generar y procesar información en múltiples formatos**. Pero aprovechar esa capacidad «va más allá de adoptar herramientas de moda»: exige comprender **cómo funcionan las arquitecturas actuales**, evaluar la **viabilidad** de cada tecnología según el problema real y **anticipar los riesgos éticos, legales y operativos en cada etapa** de implementación.

Esta explicación divide el artículo en dos mitades. La primera, que cubre esta sección, llega hasta el experimento con Teachable Machine; la segunda trata los riesgos, los marcos (UNESCO, NIST), el contexto chileno, la propiedad intelectual y los criterios de piloto. Lo que sigue se apoya en la Unidad 1 de este módulo, donde ya conocimos el Transformer, los LLM, el preentrenamiento y el ajuste fino, y donde se presentó la IA generativa; aquí se explica *por qué* generan lo que generan, y cómo elegir entre las tecnologías.

De predecir a generar

El curso separa dos familias. Los **modelos predictivos** (*predictive models*) buscan **estimar un valor o una categoría**: son los de regresión y clasificación que acabamos de ver. Los **modelos generativos** (*generative models*) aprenden **regularidades de grandes colecciones de datos** para producir **contenido nuevo relacionado con una entrada**. Pueden generar **texto, código, imágenes, audio y video**, además de **transformar contenidos entre modalidades** (por ejemplo, de texto a imagen, o de audio a texto) (Google for Developers, 2026a).

La diferencia no está en el uso de datos (ambos aprenden de datos), sino en la *forma de la salida*. Un modelo predictivo devuelve una salida pequeña y acotada: un número, una de pocas categorías. Un modelo generativo devuelve una salida abierta y estructurada: un párrafo, una imagen, una canción. Y aprende, en lugar de la relación «característica → etiqueta», la **distribución** de los propios datos: qué cosas suelen ir con qué, qué palabra suele seguir a cuál, qué píxeles suelen acompañar a otros.

ANALOGÍA

Un tasador y un escritor. El tasador (modelo predictivo) examina una casa y entrega un número: el precio. El escritor (modelo generativo) que ha leído miles de avisos inmobiliarios recibe una descripción y redacta un aviso nuevo, que no copia ninguno, pero que «suenan» como los que ha leído. Ninguno de los dos «sabe» la verdad en sentido estricto: el primero estima a partir de casos anteriores, el segundo compone a partir de patrones.

Esta distinción conecta con la tabla de tecnologías que veremos más abajo («crear, transformar o sintetizar contenido» corresponde a IA generativa) y con la discrepancia 1: la generativa es una categoría aparte para el curso, pero para Google es una cuarta categoría de sistemas de ML, y puede combinarse con las otras.

La arquitectura Transformer y el mecanismo de atención

Para producir lenguaje humano, muchos modelos actuales utilizan la arquitectura **Transformer**, presentada en **2017**. Su **mecanismo de atención** (*attention mechanism*) permite **ponderar relaciones entre elementos del contexto** y sustenta gran parte de los modelos de lenguaje contemporáneos (**Vaswani et al., 2017**). En la Unidad 1 de este módulo ya presentamos el Transformer como la arquitectura detrás de los LLM y de GPT; aquí vemos qué hace su pieza central.

El artículo de Vaswani et al. (*Attention Is All You Need*, presentado en NIPS 2017) propuso una arquitectura basada **solo en atención, sin recurrencia ni convoluciones**, y se presentó para **traducción automática**. Antes se usaban redes recurrentes (RNN), que procesan el texto palabra por palabra en orden; el Transformer, en cambio, mira todas las palabras de la secuencia a la vez y decide, para cada una, a cuáles de las demás conviene «prestar atención».

ANALOGÍA

Lees la frase «El banco rechazó el préstamo porque este no tenía fondos». Para saber a qué se refiere «este», no lees todo con igual intensidad: tu atención se concentra en «banco» y «préstamo» y se desentiende de «el» o «porque». La atención de un Transformer hace algo parecido de forma numérica: para cada palabra calcula cuánto pesa cada una de las otras y combina la información en consecuencia.

Complemento matemático: la atención escalada

El curso dice «ponderar relaciones» sin mostrar cómo. La forma estándar del paper es la **atención escalada por producto punto** (*scaled dot-product attention*):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Desglose símbolo por símbolo. Cada elemento de la secuencia (cada «token», es decir, cada trozo de texto: una palabra o parte de ella) se transforma en tres vectores. La **consulta** Q (*query*) es lo que ese token «busca». La **clave** K (*key*) es lo que ese token «ofrece» para ser encontrado. El **valor** V (*value*) es la información que ese token aporta si es elegido. Matricialmente, cada fila de Q , K y V corresponde a un token.

El producto QK^T (K transpuesta, T) calcula, para cada par de tokens, un producto punto entre la consulta de uno y la clave del otro: un número grande indica que se «parecen» o «se buscan». Es una tabla de puntajes de relación entre todos los pares. Se divide por $\sqrt{d_k}$, donde d_k es la dimensión de las claves, para que los puntajes no crezcan sin control cuando los vectores son largos (un producto punto de vectores largos tiene mayor magnitud, y eso empujaría a la función siguiente a saturarse). La función **softmax** convierte, *fila por fila*, esos puntajes en **pesos de atención** positivos que suman 1 (más abajo la vemos en detalle). Por último, multiplicar por V produce, para cada token, un promedio ponderado de los valores de todos los tokens: aquellos con más peso aportan más.

EJEMPLO NUMÉRICO

Supongamos 3 tokens y $d_k = 2$ (valores ilustrativos, no de un modelo real):

- $Q = K$ con filas (1, 0), (0, 1) y (1, 1).
- V con filas (1, 2), (3, 0) y (0, 1).

Paso 1, QK^T : filas (1, 0, 1), (0, 1, 1) y (1, 1, 2). Paso 2, dividir por $\sqrt{2} \approx 1,414$: filas (0,707; 0; 0,707), (0; 0,707; 0,707) y (0,707; 0,707; 1,414). Paso 3, softmax por fila. Para la primera: $e^{0,707} \approx 2,028$, $e^0 = 1$, $e^{0,707} \approx 2,028$; suma $\approx 5,056$; pesos $\approx 0,401$; 0,198; 0,401. Los pesos de atención de las tres filas, redondeados, son:

Token (fila)	Peso hacia token 1	Peso hacia token 2	Peso hacia token 3
Token 1	0,401	0,198	0,401
Token 2	0,198	0,401	0,401
Token 3	0,248	0,248	0,503

Cada fila suma 1 (salvo redondeo). El token 3, cuya consulta (1, 1) coincide con ambas claves, reparte su atención de forma más pareja entre los dos primeros y se la «guarda» en parte a sí mismo (0,503). Paso 4, multiplicar por V : la salida del token 1 es $0,401 \cdot (1, 2) + 0,198 \cdot (3, 0) + 0,401 \cdot (0, 1) \approx (0,99; 1,20)$: una mezcla de los valores de los tres tokens, con más peso en los suyos. (Cálculos verificados con Python.)

En un Transformer real esto se repite con muchas «cabezas» de atención en paralelo y en decenas de capas, con vectores de cientos o miles de dimensiones, pero el mecanismo es el de este ejemplo. Lo importante para el curso es la idea: **el modelo decide, para cada elemento, cuánto atender a cada otro elemento del contexto**, y lo hace con pesos aprendidos durante el entrenamiento.

Generar secuencias probables, no consultar una fuente verdadera

El curso destaca, en un recuadro, la idea que más importa para un gestor:

«Para este curso, basta comprender que estos sistemas generan secuencias a partir de patrones estadísticos y contexto con los que han sido entrenados; no consultan automáticamente una fuente verdadera cada vez que responden. Es decir, infieren qué es lo más probable que se debiesen responder dadas ciertas condiciones de consulta o enunciación.»

Leámosla con cuidado, porque es probablemente la idea más evaluable de toda la unidad. Un modelo de lenguaje **genera secuencias**, token por token, y en cada paso elige (o muestrea) el siguiente token según qué tan **probable** es dado el contexto. Esa probabilidad proviene de los **patrones estadísticos** aprendidos durante el entrenamiento. Y la frase clave: **no consulta automáticamente una fuente verdadera**. No hay, dentro del modelo, una base de datos de hechos verificados a la que recurra antes de contestar. Lo que hay es una enorme maquinaria de asociaciones aprendidas. De ahí que pueda ser fluido y convincente y, a la vez, equivocarse con aplomo, lo que la sección de riesgos llama **confabulación** (se profundiza en la sección de riesgos).

El ejemplo del rey

El curso lo ilustra así. Si se dice la expresión «El rey tiene sobre su cabeza una...», la respuesta más probable es «corona». Si se dice «El hijo del rey es el...», la más probable es «príncipe». Y, llevado más

allá, el modelo podría inferir, a su vez, que el príncipe probablemente sucederá al rey una vez que este fallezca. En los tres casos no hay consulta a ninguna fuente: hay completar la frase con lo que estadísticamente suele seguir. El tercero es el más interesante, porque muestra cómo una cadena de asociaciones probables puede parecer razonamiento.

Complemento matemático: la predicción del siguiente token con softmax

Formalmente, el modelo no «elige» una palabra: asigna a cada palabra posible de su vocabulario un puntaje, llamado **logit** (*logit*), y luego los convierte en probabilidades con la función **softmax**:

$$P(w_i \mid \text{contexto}) = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

Desglose: w_i es la i -ésima palabra candidata; «contexto» es todo lo que el modelo ya leyó (la frase hasta ese punto); z_i es el logit de la palabra i , un número real cualquiera (puede ser negativo) que produce la red; e^{z_i} lo convierte en un número positivo y amplifica las diferencias (un puntaje mayor se vuelve proporcionalmente mucho más grande); y el denominador, la suma sobre todas las palabras j , normaliza para que todas las probabilidades sumen 1. La intuición: softmax es un «reparto de probabilidad» que favorece a los puntajes altos de manera exponencial.

EJEMPLO NUMÉRICO

Para «El rey tiene sobre su cabeza una...», supongamos (logits ilustrativos) $z = 4,0$ para «corona», $2,0$ para «gorra», $1,5$ para «sombrero» y $-1,0$ para «mesa». Los exponenciales son: $e^4 \approx 54,60$; $e^2 \approx 7,39$; $e^{1,5} \approx 4,48$; $e^{-1} \approx 0,37$; suma $\approx 66,84$. Las probabilidades son: corona $\approx 81,7 \%$, gorra $\approx 11,1 \%$, sombrero $\approx 6,7 \%$, mesa $\approx 0,6 \%$. Aunque «gorra» y «sombrero» son plausibles, «corona» recibe la mayor parte de la probabilidad porque su puntaje es mucho más alto. Y «mesa» no queda en cero: no es imposible para el modelo, solo muy improbable. (Verificado con Python.)

Un parámetro frecuente, la **temperatura** (*temperature*), divide los logits antes del softmax: con temperatura baja (por ejemplo, $0,5$) la distribución se concentra aún más en «corona» ($\approx 97,6 \%$ con los mismos logits), y con temperatura alta (por ejemplo, 2) se reparte más ($\approx 57,6 \%$ para «corona»), lo que da respuestas más variadas y también más arriesgadas. Esto explica por qué la misma pregunta puede recibir respuestas distintas.

Con esto se aclara el sentido de «infieren qué es lo más probable»: no es un modo coloquial de hablar, sino una descripción literal del mecanismo. Y se aclara la sutileza del ejemplo del príncipe: que «el príncipe sucederá al rey» no es una deducción lógica, sino una asociación frecuente en los textos con los que se entrenó el modelo.

 **Nota (discrepancia 6):** el curso dice que los sistemas generativos «no consultan automáticamente una fuente verdadera». Eso es cierto para el *modelo* tomado solo, pero no siempre para el *producto*: muchos asistentes actuales combinan el modelo con **búsqueda o con documentos** (el propio listado de herramientas del curso describe a Perplexity respondiendo con citas y enlaces a fuentes). Eso **reduce, pero no elimina**, la confabulación. Además, el ejemplo del príncipe que «sucederá al rey» es asociación estadística, no razonamiento garantizado. **Regla de examen:** responde lo que dice el curso (generan lo

más probable, no verifican por sí mismos la veracidad) y, si preguntan cómo mitigar, agrega que se pueden conectar fuentes verificables al sistema y que, aun así, se debe verificar el resultado.

Prompt: tarea, información y condiciones de salida

«Una instrucción o **prompt** entrega una tarea, información y condiciones de salida a los modelos. En esta unidad se utilizarán instrucciones sencillas para observar capacidades.» Esta es la definición del curso, y tiene tres componentes que conviene reconocer en cualquier instrucción. La **tarea** es lo que se pide hacer (redactar, resumir, clasificar, traducir). La **información** es el material sobre el que se trabaja y el contexto necesario (la ficha técnica, el público, el tono). Las **condiciones de salida** son las restricciones sobre el resultado (formato, extensión, lo que no debe incluir). Dado que el modelo infiere lo más probable según el contexto, un prompt es, en el fondo, **construir el contexto** que hace más probable la respuesta que se necesita. En la Unidad 1 se presentó la ingeniería de prompts; aquí se fija solo su anatomía.

EJEMPLO

Un prompt sencillo en el contexto de una ficha de producto: «Redacta una descripción de 60 palabras para la ficha de un jugo de manzana en botella de 500 ml, dirigida a clientes de supermercado. Usa solo estos datos: ingredientes: jugo de manzana y vitamina C; conservación: refrigerar después de abrir. Tono cercano, sin afirmaciones de salud. Si falta un dato, indícalo en lugar de inventarlo.» Aquí la **tarea** es redactar una descripción; la **información** son el producto, el público y los datos aportados; las **condiciones de salida** son la extensión, el tono, la restricción de afirmaciones y la instrucción de no inventar. Fíjate en que la última condición es una defensa directa contra la confabulación: se le da al modelo una salida legítima para el caso en que no tenga el dato. (Producto y datos son ilustrativos.)

Multimodalidad

Un modelo **multimodal** (*multimodal model*) puede procesar información de distintos tipos. Puede **recibir texto e imagen, analizar audio o video y generar una salida en otra modalidad**. El curso incorpora la definición de **Google Cloud**: la multimodalidad es la capacidad de **procesar modalidades como imágenes, videos y texto, y de combinar entradas y salidas diversas** (Google Cloud, s. f.-b). Una «modalidad» es un tipo de dato o canal: texto, imagen, audio, video, código. Un ejemplo ilustrativo de la propia documentación de Google Cloud: dar a un modelo la foto de un plato de galletas y obtener la receta escrita; entrada visual, salida textual.

Los **cuatro usos empresariales** que menciona el curso muestran el alcance:

1. **Analizar una fotografía de un producto junto con su ficha técnica:** cruzar lo que se ve con lo que dice el documento (por ejemplo, verificar si el envase fotografiado corresponde a la descripción).
2. **Convertir una reunión en transcripción y tareas:** de audio a texto, y de texto a una lista de acciones con responsables.
3. **Revisar un documento con tablas e imágenes:** procesar a la vez el texto, los cuadros y las figuras.
4. **Generar piezas adaptadas a distintos canales:** a partir de una misma información, producir el correo, la publicación en redes y el guion de video, cada uno con su formato.

La advertencia del curso es de control: **el control debe considerar cada modalidad**. Revisar el texto de una salida no basta si la salida incluye una imagen: **una imagen convincente puede contener un error que pasa inadvertido en una revisión superficial**. Piensa en una pieza publicitaria generada para un envase de alimentos: el texto del eslogan es correcto, pero la imagen muestra un envase con una etiqueta ilegible o con un símbolo regulatorio deformado. Un revisor que solo leyó el texto aprobó el material. El control, entonces, no puede quedarse en la modalidad más cómoda de revisar; debe cubrir imagen, audio y video con el mismo cuidado (y en la sección de riesgos veremos que los *deepfakes* son una versión extrema de este problema).

¿Qué tecnología corresponde a cada necesidad?

El curso propone una formulación útil: **vincular la tarea, la evidencia disponible y el tipo de salida**. Y una matriz que «funciona como orientación inicial» y que, «por supuesto, no reemplaza una evaluación técnica ni jurídica». La reproducimos completa:

Necesidad	Enfoque inicial	Condición crítica
Aplicar una política estable y explícita	Reglas o automatización convencional	Reglas completas, auditables y mantenibles
Predecir un número o una categoría conocida	Aprendizaje supervisado	Ejemplos históricos etiquetados y representativos
Explorar patrones o grupos desconocidos	Aprendizaje no supervisado	Variables pertinentes e interpretación experta
Optimizar decisiones sucesivas con retroalimentación	Aprendizaje por refuerzo	Entorno seguro, recompensa bien definida y capacidad de simular
Crear, transformar o sintetizar contenido	IA generativa	Instrucciones, fuentes, validación y derechos de uso
Resolver una tarea que combina lo anterior	Arquitectura híbrida	Diseño de flujo, integración, controles y responsables

La tabla es, en realidad, un resumen de todo lo visto en los tres artículos, y se lee mejor fila por fila.

Fila 1, política estable y explícita → reglas. Si la política puede escribirse completa («se bloquea toda operación que supere el límite normativo X»), una regla es más barata, transparente y auditable que un modelo. La condición crítica es que las reglas sean **completas, auditables y mantenibles**: si no se pueden enumerar todos los casos, o cambian a diario, el enfoque falla. Es el principio del Artículo 1: tres reglas claras no necesitan un modelo.

Fila 2, predecir un número o una categoría conocida → supervisado. Es el caso de la regresión y la clasificación de las páginas anteriores. La condición crítica retoma lo de las etiquetas: **ejemplos históricos etiquetados y representativos**. «Representativos» es la palabra que vincula con la diversidad de los datos vista en el Artículo 1.

Fila 3, explorar patrones o grupos desconocidos → no supervisado. Cuando no existe una etiqueta que predecir y se quiere descubrir estructura. La condición crítica: **variables pertinentes e interpretación experta**, exactamente las dos advertencias del apartado de segmentos («no son verdades naturales»).

Fila 4, optimizar decisiones sucesivas con retroalimentación → refuerzo. Decisiones encadenadas donde cada una afecta a la siguiente y se recibe retroalimentación (recompensa). La condición crítica es la más exigente: **entorno seguro, recompensa bien definida y capacidad de simular**, lo que explica por qué suele quedar fuera de los primeros pilotos.

Fila 5, crear, transformar o sintetizar contenido → IA generativa. Redactar, resumir, traducir, reformatear, generar imágenes. La condición crítica son cuatro: **instrucciones** (un buen prompt), **fuentes** (de dónde viene la información que se le da al modelo, porque no consulta una fuente verdadera por sí solo), **validación** (alguien revisa el resultado) y **derechos de uso** (propiedad intelectual de lo que entra y de lo que sale).

Fila 6, resolver una tarea que combina lo anterior → arquitectura híbrida. Es la fila que reconoce la advertencia del Artículo 1: **«estas categorías se superponen»**. Un asistente generativo real puede combinar un modelo de lenguaje, un clasificador (para enrutar la consulta), búsqueda documental (para traer fuentes) y reglas de seguridad (para bloquear lo inaceptable). Una **arquitectura híbrida** (*hybrid architecture*) es justamente eso: varios componentes de distinto tipo trabajando juntos. La condición crítica deja de ser técnica en sentido estrecho: **diseño de flujo, integración, controles y responsables**. Cuando la solución mezcla piezas, lo que falla suele ser el pegamento (quién recibe qué, quién revisa, qué pasa si un componente se equivoca), y por eso la condición se pone en el diseño y en las personas.

EJEMPLO

Supongamos un asistente de atención al cliente de una empresa de alimentos. Un componente de **reglas** detecta palabras que exigen derivación inmediata (por ejemplo, una reacción alérgica). Un **clasificador supervisado** asigna la consulta a un tema (pedido, reclamo, información de producto). Un componente de **búsqueda documental** trae el fragmento pertinente de la ficha técnica aprobada. Un **modelo generativo** redacta la respuesta usando solo ese fragmento. Y una persona revisa los casos que el sistema marca como dudosos. Ninguna de las piezas por sí sola resuelve la tarea; el sistema completo sí, y su riesgo depende del diseño del flujo.

Una solución de IA también puede ser innecesaria

El curso agrega un contrapeso a todo el entusiasmo: «Una solución de IA también puede ser innecesaria». Propone **cinco comprobaciones** antes de seguir adelante:

1. **¿El problema tiene suficiente frecuencia, costo o escala?** Un problema que ocurre dos veces al año o que cuesta poco no justifica el desarrollo y mantenimiento de un modelo. Ejemplo: si el equipo corrige a mano 15 errores de facturación al mes y cada uno toma 10 minutos, son 2,5 horas mensuales; difícilmente una solución con modelo se pague sola.
2. **¿Existe una línea base?** Es decir, una medida de cómo funciona hoy el proceso (tiempo, costo, calidad o riesgo). Sin ella no se puede saber si la IA mejoró algo. Ejemplo: si no se sabe cuánto

demora hoy redactar una ficha de producto, un piloto de generación de fichas no tiene con qué compararse.

3. **¿Los datos están disponibles?** Que existan, que se pueda acceder a ellos y que se cuente con los permisos. Ejemplo: querer predecir el abandono de clientes cuando el registro de bajas no se lleva, o las bases están dispersas y con identificadores inconsistentes.
4. **¿El error puede controlarse?** Es decir, si hay una forma de detectar y contener las equivocaciones antes de que causen daño. Ejemplo: un borrador publicitario revisado por una persona antes de publicarse tiene un error controlable; una recomendación de crédito automática sin revisión, no.
5. **¿La organización podrá mantener la solución una vez terminado el piloto?** Los modelos requieren monitoreo, actualización y responsables. Ejemplo: un piloto que depende de un único especialista externo y que nadie en la empresa sabe operar corre riesgo de morir al terminar el contrato.

Un «no» a cualquiera de ellas no obliga a descartar la idea, pero sí obliga a resolver la brecha antes. Es el mismo espíritu del semáforo de la matriz de oportunidades (que cierra la unidad): amarillo es «resolver brechas antes de probar».

Experimentación con Teachable Machine

Teachable Machine es, según el curso, una herramienta web de **Google** que permite crear modelos de **clasificación de imágenes, sonidos y poses sin escribir código**. Fue diseñada para hacer **accesible** la experimentación con machine learning y facilitar la comprensión de la relación entre **ejemplos, entrenamiento y clasificación** (Carney et al., 2020; Google, s. f.).

El artículo de Carney et al. (presentado en CHI 2020, *Teachable Machine: Approachable Web-Based Tool for Exploring Machine Learning Classification*) agrega datos técnicos que ayudan a entender lo que ocurre «bajo el capó». La herramienta usa **aprendizaje por transferencia** (*transfer learning*) sobre **MobileNet**, un modelo base ya preentrenado con 1.000 clases de imágenes: en lugar de entrenar una red desde cero (lo que exigiría millones de imágenes), se aprovecha lo que MobileNet ya aprendió a «ver» (bordes, texturas, formas) y solo se ajusta la parte final para distinguir las clases del usuario. Eso es lo que permite que unos pocos ejemplos sean suficientes. En la Unidad 1 vimos el preentrenamiento y el ajuste fino en los LLM: el principio es el mismo, partir de un modelo ya entrenado y adaptarlo a una tarea. Además, el entrenamiento se hace **en el navegador**, sin que los datos tengan que salir del computador (un detalle relevante para la privacidad), y el modelo puede exportarse (con TensorFlow.js). La herramienta ofrece un panel avanzado con épocas, tamaño de lote y tasa de aprendizaje, y **retiene el 15 % de las muestras de cada clase como conjunto de validación**, de modo que el 85 % restante se usa para entrenar.

EJEMPLO NUMÉRICO

Supongamos que para la clase «botella con tapa» capturas 40 imágenes. La herramienta retiene el 15 %, es decir, 6 imágenes, para validar, y entrena con las 34 restantes. Si en cada una de las tres clases capturas 40 imágenes, el conjunto total es de 120: unas 102 para entrenar y 18 para validar. El resultado de la validación se calcula sobre esas 18 imágenes, que el modelo no usó para ajustarse. (Cifras ilustrativas; el 15 % proviene de la descripción de la herramienta.)

El curso recomienda comenzar con una **clasificación de imágenes** de **dos o tres clases observables**: capturar ejemplos, entrenar el modelo y probar condiciones nuevas. El propósito: observar de manera directa **cómo cambian los resultados cuando cambia el conjunto de datos**. Es un experimento de aprendizaje supervisado en miniatura: cada clase es una etiqueta, cada imagen un ejemplo. Y el curso advierte: **por sí sola, la plataforma no produce un sistema listo para operar**. Teachable Machine enseña los conceptos y sirve para prototipar una idea; entre un prototipo así y una solución en operación faltan datos representativos, integración con los sistemas, monitoreo, responsables y controles (es el salto «del prototipo a producción» del Módulo 1, Unidad 6).

Los siete pasos sugeridos

El curso propone «testear de esta forma» con siete pasos:

1. Definir clases claramente distinguibles, por ejemplo, botella con tapa, botella sin tapa y fondo vacío.
2. Reunir suficientes ejemplos por clase, variando ángulo, distancia, iluminación y fondo.
3. Entrenar el modelo y revisar la distribución de muestras utilizadas para entrenamiento y prueba.
4. Probar objetos y condiciones que el modelo no haya visto.
5. Registrar errores, confusiones y cambios de confianza.
6. Agregar ejemplos que representen los casos difíciles y volver a entrenar.
7. Explicar qué podría salir mal si el modelo se aplicara en una operación real.

Veamos cada paso en prosa, con lo que se espera observar y usando el ejemplo del curso.

Paso 1: definir clases claramente distinguibles. Las tres clases son «botella con tapa», «botella sin tapa» y «fondo vacío». Las dos primeras difieren en un detalle visual pequeño (la tapa); la tercera, «fondo vacío», es una clase de control: enseña al modelo qué hacer cuando no hay ninguna botella, y evita que fuerce una respuesta. «Claramente distinguibles» significa que una persona podría clasificar cada foto sin dudar; si ni siquiera una persona puede, el modelo tampoco tendrá una regla estable que aprender. Esto es el requisito de «etiquetas confiables» aplicado a pequeña escala.

Paso 2: reunir suficientes ejemplos, variando ángulo, distancia, iluminación y fondo. Aquí se aplica lo que el Artículo 1 dijo sobre los datos y el contexto: un conjunto numeroso puede ser insuficiente si repite las mismas condiciones. En la práctica, se fotografía la botella de frente, de lado y desde arriba; cerca y lejos; con luz natural y con luz artificial; sobre una mesa, un escritorio y una estantería. Lo que se espera observar después es un modelo que reconoce la tapa en contextos variados; si todas las fotos se tomaron en las mismas condiciones, el modelo se verá excelente en la herramienta y flojo en cuanto cambie algo.

Paso 3: entrenar y revisar la distribución de muestras para entrenamiento y prueba. Se entrena el modelo y se revisa cuántas muestras tiene cada clase y cuántas quedaron para validar. Qué buscar: que las clases estén razonablemente equilibradas (si hay 100 fotos de «con tapa» y 10 de «sin tapa», el modelo tendrá tendencia a decir «con tapa») y que la proporción reservada para validar sea la que se cree. En la herramienta se retiene el 15 % de cada clase (ver discrepancia 5, más abajo).

Paso 4: probar objetos y condiciones que el modelo no haya visto. Es el paso decisivo. Se prueba con otra botella, con una taza, con la mano del usuario, con otra pared, con otra luz. Qué observar: el

modelo muestra para cada imagen un porcentaje de confianza por clase. Con ejemplos conocidos suele estar muy seguro; con condiciones nuevas, la seguridad puede caer, o peor, mantenerse alta y equivocarse. Esto es la evaluación con datos no vistos del Artículo 1, hecha con las manos.

Paso 5: registrar errores, confusiones y cambios de confianza. No basta mirar si «funciona»: se lleva un registro. Qué fotos se clasificaron mal, qué clase se confundió con cuál (por ejemplo, «sin tapa» con «fondo vacío» cuando la botella está lejos) y cómo varió la confianza al cambiar la condición. Ese registro es la materia prima del paso siguiente y el germen de una matriz de confusión.

Paso 6: agregar ejemplos que representen los casos difíciles y volver a entrenar. Si el modelo confunde botellas lejanas, se agregan ejemplos de botellas lejanas. Qué observar: que los errores del registro disminuyan para esos casos, y que la confianza sea más coherente. Es la lección práctica sobre cómo cambian los resultados cuando cambia el conjunto de datos, y la razón por la que la calidad de los datos pesa tanto como el algoritmo.

Paso 7: explicar qué podría salir mal si el modelo se aplicara en una operación real. Es el paso de criterio, no de técnica. Qué podría fallar: otra iluminación en la bodega, un envase de otra marca, una tapa de otro color, una cámara en otra posición, botellas sucias o mojadas. Y qué costo tendría cada error. Este paso conecta el experimento con la gestión de riesgos y con las preguntas del piloto («¿qué error es tolerable y cuál sería inaceptable?»).

Observación clave: el modelo aprende correlaciones, y puede aprender atajos

El curso resume la enseñanza central del ejercicio en un recuadro: «**Observación clave.** El modelo aprende correlaciones presentes en los ejemplos. Si todas las fotografías de una clase tienen un fondo distinto, puede aprender el fondo y no el objeto. La prueba con condiciones nuevas permite detectar este tipo de atajos.»

La clave está en la palabra **correlaciones**. Un modelo no «entiende» qué es una botella: encuentra señales en los datos que se asocian con cada etiqueta. Si por casualidad todas las fotos de «botella con tapa» se tomaron sobre una mesa blanca y todas las de «sin tapa» sobre una mesa de madera, el fondo es una señal más fácil de aprender que la tapa, y el modelo la usará. Esa señal espuria se llama **atajo** (*shortcut learning*). En el entrenamiento, el modelo acierta; en la realidad, donde el fondo ya no acompaña a la clase, falla. (La frase del curso «un fondo distinto» debe entenderse como un fondo que distingue a esa clase de las demás, es decir, que es consistente dentro de la clase y distinto entre clases.)

EJEMPLO

El ejemplo clásico de la literatura es el clasificador de «husky contra lobo» de Ribeiro, Singh y Guestrin (2016). Sus autores mostraron un clasificador que predecía «lobo» cuando había **nieve** en el fondo de la imagen: había aprendido la nieve, no el animal. Un matiz importante: ese modelo fue **construido a propósito** con unas 20 imágenes sesgadas, para probar si las personas lograban detectar el problema al ver las explicaciones del modelo. No es un accidente de un sistema real, sino una demostración deliberada; pero ilustra con claridad un fallo muy real. En nuestro experimento de la botella, el equivalente sería un clasificador que aprendió «mesa blanca = con tapa». La prueba con una botella con tapa sobre una mesa de madera lo delataría de inmediato.

Esta observación explica el diseño completo de los siete pasos: el paso 2 (variar las condiciones) previene los atajos, y el paso 4 (probar condiciones no vistas) los detecta. Y, más allá del ejercicio, es el fundamento de por qué, en el caso SurAndes, la Propuesta A (inspección visual de envases) tenía una brecha: sus fotos etiquetadas provenían principalmente del turno diurno y de dos productos, de modo que el modelo podría aprender la luz del turno o el diseño de esos dos envases y no el defecto.

⚠ Nota (discrepancia 5): «entrenamiento y prueba» y alcance de Teachable Machine. El paso 3 del curso habla de revisar la distribución de muestras «utilizadas para entrenamiento y prueba». Según el artículo de Carney et al. (2020), la herramienta retiene automáticamente el **15 %** de las muestras de cada clase como **conjunto de validación**, que no es lo mismo que un conjunto de prueba independiente. Esa porción retenida sirve para seguir el desempeño durante el entrenamiento, pero el modelo sigue trabajando con las condiciones de las mismas sesiones de captura. Por eso el paso 4 (probar objetos y condiciones nuevas) es el que realmente hace de prueba. **Regla de examen:** usa las palabras del curso; en un proyecto real, separa entrenamiento, validación y prueba, con la prueba reservada y tomada en condiciones independientes.

Con esto termina la primera mitad del artículo. A continuación, la sección «Riesgos y uso responsable» retoma la idea con la que cierra el experimento: «qué podría salir mal» tiene un nombre por cada tipo de falla (sesgo, confabulación, privacidad, propiedad intelectual, *deepfakes*, sobreconfianza) y un control proporcional al impacto.

Riesgos y uso responsable

Hasta aquí el Artículo 3 explicó qué pueden hacer las tecnologías y cómo elegir entre ellas. Esta sección responde la pregunta que cualquier directivo se hace inmediatamente después: *¿y qué puede salir mal?* El curso lo formula en una frase que conviene memorizar: el uso responsable de IA **requiere decisiones concretas a lo largo del ciclo de vida de la solución** desarrollada e implementada. La palabra clave es «concretas». No basta con declarar valores en un documento institucional; hay que decidir, en cada etapa, quién revisa, qué datos entran, qué se prohíbe automatizar y qué se hace cuando algo falla.

El **ciclo de vida de la IA** (*AI lifecycle*) es la secuencia completa por la que pasa una solución: se formula el problema, se reúnen datos, se diseña y entrena el modelo, se evalúa, se pone en uso y se mantiene o se retira. Ya lo vimos en versión reducida en el Artículo 1, cuando describimos los cinco componentes de cómo aprende un modelo (datos, representación, entrenamiento, evaluación, inferencia); aquí se amplía hacia los extremos: antes de los datos hay una decisión de negocio, y después de la inferencia hay operación, monitoreo y eventualmente cierre. La idea de fondo es que el riesgo no se concentra en un solo momento. Un sesgo puede entrar en la recolección de datos, una confabulación puede aparecer durante el uso, una filtración de información puede ocurrir al cargar un documento y una sobreconfianza puede instalarse meses después, cuando el equipo se acostumbró a no revisar. Por eso los marcos que cita el curso piensan el riesgo *a lo largo* del ciclo y no como una auditoría final.

ANALOGÍA

Piense en la inocuidad de una planta de alimentos. Nadie la garantiza con una inspección al final de la línea; se controla en la recepción de materias primas, en el proceso, en el envasado, en el despacho y

en el reclamo del cliente. Con la IA ocurre lo mismo: un control único al final llega tarde, porque muchas decisiones críticas (qué datos se usaron, qué se permitió cargar, quién aprueba) ya se tomaron antes.

Los principios de la UNESCO que nombra el curso

El curso afirma que la **UNESCO** plantea principios de **proporcionalidad, seguridad, privacidad, responsabilidad, transparencia, supervisión humana, sostenibilidad y equidad** (UNESCO, 2021). Los **Principios UNESCO** (*UNESCO AI ethics principles*) provienen de la Recomendación sobre la Ética de la Inteligencia Artificial, un instrumento internacional que no es una ley, sino un marco de referencia que orienta políticas públicas y prácticas de las organizaciones. Recorramos cada uno de los ocho, con un ejemplo de empresa de alimentos o de retail para que se vea qué significa en una decisión real.

1. Proporcionalidad. Los medios empleados no deben exceder lo necesario para el fin legítimo que se persigue. Una cadena de supermercados que quiere predecir la demanda de yogur no necesita analizar el rostro de sus clientes: el dato sobre ventas por sucursal alcanza. Este principio es el que sostiene la idea, ya vista, de que una solución de IA puede ser innecesaria, y es también el antecedente directo de la gestión «proporcional al impacto» que el curso desarrolla más abajo.

2. Seguridad. Los sistemas deben protegerse frente a daños, fallas y usos indebidos, incluida la seguridad de la información que procesan. Un ejemplo: un asistente interno que responde consultas de ventas no debe poder acceder a las planillas de remuneraciones por un simple descuido de permisos.

3. Privacidad. Protege los datos personales de clientes, trabajadores y terceros durante todo su ciclo de uso. Un retailer que entrena un modelo con historiales de compra debe poder explicar con qué finalidad los usa y limitar quién los ve. Se desarrolla como riesgo más abajo.

4. Responsabilidad. Debe poder identificarse quién responde por el sistema y por sus resultados; una máquina no es un responsable. Si un chatbot de reclamos promete una devolución que la empresa no ofrece, hay una persona o un área que responde. Es lo que el curso llama, en los criterios de piloto, «quién responde por la decisión final».

5. Transparencia. Las personas deben poder saber cuándo interactúan con un sistema de IA y comprender, en un nivel razonable, cómo se llegó a un resultado. Un ejemplo sencillo: si un correo de postventa fue redactado por IA y revisado por un ejecutivo, la empresa define si lo informa y cómo; si un cliente conversa con un asistente virtual, debería saberlo.

6. Supervisión humana. Las decisiones relevantes no se delegan por completo a un sistema; una persona con criterio y autoridad puede revisarlas, corregirlas y detenerlas. Es el principio que el curso retoma en su cierre: «la supervisión humana mantenga el control sobre las decisiones críticas». En la Unidad 5 del Módulo 2 vimos esta idea bajo el nombre de *human-in-the-loop*.

7. Sostenibilidad. Los sistemas deben evaluarse también por su impacto ambiental y social de largo plazo. Entrenar y operar modelos grandes consume energía y recursos de cómputo; una empresa que multiplica pilotos sin criterio multiplica ese costo.

8. Equidad. El sistema no debe tratar de manera injustamente desigual a personas o grupos. Si un modelo que prioriza candidatos a un crédito de consumo en una tienda por departamentos rinde peor

con ciertos segmentos, hay un problema de equidad que se mide y se corrige. Conecta de inmediato con el riesgo de sesgo.

⚠ **Nota (discrepancia 3):** el curso nombra **ocho** principios de la UNESCO, pero la Recomendación sobre la Ética de la Inteligencia Artificial, adoptada en noviembre de 2021 por 193 Estados, establece **cuatro valores y diez principios**. Los diez son: (1) proporcionalidad e inocuidad; (2) seguridad y protección; (3) derecho a la privacidad y protección de datos; (4) gobernanza y colaboración adaptativas y de múltiples partes interesadas; (5) responsabilidad y rendición de cuentas; (6) transparencia y explicabilidad; (7) supervisión y decisión humanas; (8) sostenibilidad; (9) sensibilización y educación; (10) equidad y no discriminación. Faltan, por tanto, en la lista del curso dos principios completos, **sensibilización y educación** y **gobernanza y colaboración adaptativas**, y los nombres que usa el curso son versiones abreviadas de los oficiales (por ejemplo, «transparencia» es «transparencia y explicabilidad» y «equidad» es «equidad y no discriminación»). **Regla de examen:** si la pregunta dice «según el curso», responda los ocho; si pregunta cuántos principios tiene la Recomendación de la UNESCO, responda diez.

NIST: gestionar el riesgo desde el diseño hasta la evaluación

La segunda referencia es el **Instituto Nacional de Estándares y Tecnología de Estados Unidos (NIST)**. El curso dice que NIST propone **gestionar riesgos desde el diseño, desarrollo, uso y evaluación** de los sistemas (NIST, 2024). El **Marco de gestión de riesgos de NIST** (*NIST AI Risk Management Framework*) es un marco voluntario que ayuda a las organizaciones a identificar, medir y reducir los riesgos de la IA; el documento que cita el curso es su perfil específico para IA generativa. Las cuatro etapas que menciona el curso describen cuatro momentos de una misma preocupación:

- **Diseño:** se decide qué problema se resuelve, con qué datos y qué impacto potencial tiene; aquí se elige, por ejemplo, no automatizar una decisión laboral.
- **Desarrollo:** se construye, se entrena o se configura el sistema; se documentan los datos y los límites conocidos.
- **Uso:** se opera con personas reales; aparecen la sobreconfianza, la carga de documentos y los usos no previstos.
- **Evaluación:** se mide si el sistema cumple lo prometido, para quién y con qué errores, y se decide ajustar, escalar o detener.

Más abajo, en la discrepancia 10, veremos que el marco de NIST se organiza además en cuatro funciones distintas de estas cuatro etapas; no hay que confundirlas.

Los seis riesgos que el curso ordena en una tabla

El curso resume el terreno en una tabla de tres columnas: el riesgo, cómo aparece y un control inicial. La reproducimos completa porque es una de las piezas con más «olor a examen» de la unidad, y luego desarrollamos cada fila.

Riesgo	Cómo aparece	Control inicial
Sesgo	Datos poco representativos, etiquetas históricas o desempeño desigual entre grupos	Revisar cobertura, comparar desempeño por segmentos y documentar límites
Confabulación	Contenido falso o inconsistente presentado con seguridad	Verificar fuentes y prohibir uso automático en decisiones críticas
Privacidad	Carga, inferencia o exposición de datos personales y sensibles	Minimizar datos, anonimizar y utilizar entornos autorizados
Propiedad intelectual	Uso o generación de material protegido, marcas o secretos comerciales	Revisar licencias, procedencia, contratos y uso previsto
Deepfakes e integridad	Audio, imagen o video sintético capaz de inducir a error	Etiquetar contenido, preservar trazabilidad y verificar procedencia
Sobreconfianza	Delegación excesiva o aceptación de resultados sin revisión	Asignar responsables, umbrales de escalamiento y revisión humana

Dos observaciones sobre la forma de la tabla antes de entrar al detalle. Primero, la columna central describe *cómo aparece* el riesgo, no su definición teórica: el curso quiere que usted aprenda a reconocerlo en una operación, con sus síntomas concretos. Segundo, la columna final se llama «control *inicial*»: son los primeros pasos razonables, no una garantía. Ningún control elimina el riesgo; lo reduce a un nivel que la organización decide si acepta.

Sesgo

El **sesgo** (*bias*) es una desviación sistemática del sistema que produce resultados peores o injustos para ciertas personas, grupos o situaciones. En la Unidad 1 de este módulo vimos el **sesgo algorítmico** y el caso COMPAS, el sistema que estimaba la reincidencia de personas procesadas y que mostró tasas de error desiguales entre grupos. No repetimos ese caso; lo que aporta esta unidad es una tabla de *cómo aparece* el sesgo en el trabajo cotidiano, que tiene tres vías.

La primera vía son los **datos poco representativos**: el modelo aprendió de una muestra que no refleja a quienes lo usarán. Es la misma idea de diversidad y representatividad que el Artículo 1 aplicó a la cámara de bodega, ahora vista como riesgo de equidad. La segunda son las **etiquetas históricas**: en el aprendizaje supervisado, el Artículo 2 advirtió que si las respuestas del pasado reflejan decisiones sesgadas, criterios inconsistentes o errores de registro, el modelo aprenderá parte de esos problemas. La tercera es el **desempeño desigual entre grupos**: el modelo puede tener una buena exactitud global y, sin embargo, fallar más con un subconjunto. Esta tercera vía es la versión de equidad de la distinción entre desempeño estadístico y utilidad empresarial.

El control inicial tiene tres verbos, y vale la pena distinguirlos: **revisar cobertura** (¿qué casos, grupos o condiciones están realmente en los datos?), **comparar desempeño por segmentos** (no basta el promedio; se mide por separado en cada grupo relevante) y **documentar límites** (dejar por escrito para qué casos el sistema no está validado, de modo que nadie lo use fuera de ese territorio).

EJEMPLO

Suponga que una cadena de retail entrena un modelo que decide a qué clientes ofrecer una tarjeta de crédito de la tienda, usando como etiqueta «aprobado por analistas en los últimos cinco años». Si en ese período los analistas aprobaban menos solicitudes de ciertas comunas por prejuicio o por criterios informales, el modelo copiará esa conducta con apariencia de objetividad. El control no consiste en afinar el modelo, sino en examinar de dónde vinieron las etiquetas, medir las tasas de aprobación por segmento y dejar documentado el límite: «no validado para solicitantes sin historial en el sistema». Esta es, además, una decisión crediticia, el tipo de uso que el curso ubica en el extremo de máximo control.

Confabulación

La **confabulación** (*confabulation*; también llamada *alucinación*, *hallucination*) es, según NIST, la producción de contenido falso o erróneo presentado con falsa certeza de veracidad. En la formulación literal del documento de NIST de 2024, se trata de sistemas de IA generativa que generan y presentan con confianza contenido erróneo o falso en respuesta a prompts. Note los dos componentes que hacen a la confabulación peligrosa: el contenido es *falso o inconsistente* y además se presenta *con seguridad*. Una respuesta incorrecta que dudara de sí misma sería un problema menor; el problema es que suena igual de convincente que una respuesta correcta.

¿Por qué ocurre? La explicación está en lo que ya aprendimos en el Artículo 3 al estudiar de predecir a generar: estos sistemas *generan secuencias a partir de patrones estadísticos y contexto, no consultan automáticamente una fuente verdadera, e infieren qué es lo más probable* dado el contexto. NIST lo expresa diciendo que los modelos **aproximan distribuciones estadísticas** de sus datos de entrenamiento: producen lo que es estadísticamente plausible, y lo plausible no coincide siempre con lo verdadero. Cuando el modelo completa «el rey tiene sobre su cabeza una...» con «corona», la plausibilidad y la verdad coinciden. Cuando se le pregunta por el código de un producto específico, por la cláusula exacta de un contrato o por el contenido de una ficha técnica que nunca vio, la respuesta más probable es un texto con la *forma* correcta (un código con el formato habitual, una cláusula con el lenguaje típico) y un *contenido* inventado. No hay mala intención ni «mentira»: hay un mecanismo que optimiza plausibilidad.

ANALOGÍA

Es como un estudiante muy aplicado que en un examen oral no sabe la respuesta, pero ha leído tanto que sabe cómo suena una respuesta correcta, y responde con total aplomo. El profesor que no conoce el tema podría creerle. La confabulación es esa fluidez sin respaldo.

El control inicial de la tabla es doble: **verificar fuentes y prohibir el uso automático en decisiones críticas**. Lo primero convierte la salida del modelo en una *hipótesis* que una persona contrasta con una fuente confiable; lo segundo establece que, donde un error es costoso (alérgenos, cifras de un contrato, un diagnóstico), el texto generado nunca se publica ni se ejecuta sin revisión. Hay una conexión con una nota que veremos en el índice de discrepancias del curso: el modelo base no consulta fuentes, pero muchos productos actuales lo combinan con búsqueda o documentos, lo que reduce la confabulación sin eliminarla; por eso el control sigue siendo verificar.

EJEMPLO

Un fabricante de alimentos pide a un asistente un borrador de la etiqueta de un nuevo snack. El asistente escribe «sin gluten» porque es una afirmación frecuente en productos de ese tipo, aunque la receta lleva avena sin certificar. El texto es fluido y el error es grave. Con el control del curso, el borrador se contrasta con la ficha técnica aprobada y la afirmación sobre alérgenos jamás se publica sin visto bueno humano. Este mismo razonamiento será el que salve a la Propuesta C del caso SurAndes.

Privacidad

La **privacidad** (*privacy*) es la protección de los datos personales y sensibles de las personas frente a usos no previstos, no autorizados o desproporcionados. En la tabla del curso aparece de tres maneras: **carga** (alguien pega en un asistente un archivo con datos de clientes), **inferencia** (el sistema deduce atributos que nadie declaró, como un estado de salud o una situación económica, a partir de otros datos) y **exposición** (la información queda visible para quien no debía verla, o se reutiliza para otra finalidad). La inferencia merece atención especial: un sistema puede violar la privacidad aun sin que ningún dato «sensible» haya sido entregado, simplemente porque dedujo lo que la persona no quiso revelar.

Los controles iniciales son tres, con un orden lógico. **Minimizar datos** (*data minimization*) significa recoger y usar solo los datos estrictamente necesarios para el fin; lo que no se entrega al sistema no puede filtrarse. **Anonimizar** (*anonymization*) es transformar los datos de modo que no permitan identificar a las personas; conviene saber que anonimizar bien es difícil, porque la combinación de varios datos aparentemente inocuos puede reidentificar a alguien. Y **utilizar entornos autorizados** significa que la información de la empresa se procesa solo en herramientas aprobadas, con contratos, configuraciones de retención y acceso definidos, y no en cuentas personales gratuitas.

EJEMPLO

Una analista del equipo comercial de SurAndes (la empresa ficticia del caso que veremos) quiere que un asistente le resuma las quejas de clientes y copia en la conversación una planilla con nombres, correos y montos. La secuencia de controles sería: primero, preguntarse si el resumen requiere los nombres (casi nunca) y eliminarlos; segundo, reemplazar los identificadores restantes por códigos; tercero, hacer el análisis en la herramienta autorizada por la empresa y no en una cuenta personal. Fíjese en que el caso del curso destaca justamente que SurAndes carece de un inventario completo de información personal: sin saber dónde están los datos personales, no se puede minimizar ni anonimizar.

Propiedad intelectual

La **propiedad intelectual** (*intellectual property*) reúne los derechos sobre creaciones y signos distintivos: obras con derecho de autor, marcas, diseños y también los **secretos comerciales**, que son información valiosa que la empresa protege manteniéndola reservada. Según la tabla, el riesgo aparece en el **uso o la generación de material protegido, marcas o secretos comerciales**, y eso abarca tres frentes distintos que conviene separar. Primero, el que *entra*: alguien carga en un asistente un contrato, una fórmula o un plan de producto confidencial; si la herramienta no es la adecuada, un secreto

comercial puede quedar fuera del control de la empresa. Segundo, el que *sale*: el contenido generado puede parecerse a obras protegidas, usar un estilo, una marca o un personaje ajeno, y la empresa lo publicaría bajo su nombre. Tercero, el que *se entrena*: la procedencia de los datos con los que se construyó el modelo importa, y por eso la procedencia y los contratos aparecen en el control.

El control inicial son cuatro revisiones: **licencias** (qué permite la herramienta y el contenido que se usa), **procedencia** (de dónde viene cada insumo), **contratos** (qué se pactó con proveedores y clientes sobre uso y titularidad) y **uso previsto** (no es igual un borrador interno que una campaña publicitaria nacional). El curso aclara que la situación *varía según jurisdicción, contrato, plataforma y tipo de contenido*, de modo que no hay una respuesta universal: la pregunta se responde caso a caso y, en lo relevante, con asesoría jurídica. Más abajo veremos la guía de la OMPI.

EJEMPLO

Un equipo de marketing de una cadena de retail genera con IA una imagen para un afiche y el resultado se parece sospechosamente al personaje de una marca conocida. Aun si nadie lo hizo con mala fe, publicarlo expone a la empresa. La secuencia sana es: revisar las condiciones de uso de la herramienta (¿qué derechos otorga sobre lo generado?), guardar el prompt y la fecha como respaldo de procedencia, y pasar el material por la revisión de quien responde por la marca antes de publicar.

Deepfakes e integridad

Un **deepfake** es un contenido sintético (audio, imagen o video generado o alterado por IA) que imita de forma convincente a una persona o un hecho real. La **integridad de la información** (*information integrity*) es la propiedad de que lo que circula sea auténtico, no alterado y atribuible a su origen. Esta fila de la tabla cubre el riesgo de que material **sintético capaz de inducir a error** dañe la confianza. Hay dos direcciones: que la empresa sea *víctima* (un audio falso que imita la voz de un gerente para ordenar una transferencia, un video falso de un directivo anunciando algo falso, una imagen alterada de un producto) y que la empresa *produzca* contenido sintético sin advertirlo, con lo que debilita la confianza de sus clientes.

El control inicial se organiza en tres acciones: **etiquetar** el contenido sintético que la propia empresa publica; **preservar la trazabilidad** (*traceability*), es decir, poder reconstruir cómo se produjo un contenido (qué herramienta, qué insumos, quién lo aprobó); y **verificar la procedencia** de lo que se recibe, por ejemplo confirmando por un segundo canal una instrucción inusual recibida en audio o video. Conecta con el listado de herramientas del curso, que incluye generación de voz y avatares con clonación de voces: la misma tecnología que permite un doblaje útil permite una suplantación.

EJEMPLO

El área de finanzas de una empresa de alimentos recibe un audio que parece de la gerente general pidiendo urgente una transferencia a un proveedor nuevo. El control de procedencia es un procedimiento simple: ninguna instrucción de pago recibida por audio se ejecuta sin una confirmación por un segundo canal previamente acordado. Del lado de la producción, si la empresa usa avatares sintéticos para videos de capacitación, los rotula como tales y guarda el registro de cómo se hicieron.

Sobreconfianza

La **sobreconfianza** (*overreliance*) es la tendencia a delegar demasiado en el sistema o a aceptar sus resultados sin revisarlos. Es el único riesgo de la tabla que reside en las personas y no en la tecnología, y por eso es el más silencioso: puede existir aun cuando el modelo sea bueno. Se alimenta del sesgo de automatización (creer que «lo dijo el sistema, entonces está bien»), de la fluidez de las respuestas, de la presión por ahorrar tiempo y de la rutina: el primer mes todos revisan, el quinto mes casi nadie lo hace.

Los controles son tres, y los tres son organizacionales. **Asignar responsables**: cada uso tiene un nombre propio, no «el área». **Fijar umbrales de escalamiento** (*escalation thresholds*): condiciones objetivas que obligan a pasar el caso a una persona de mayor jerarquía o a un experto, por ejemplo cuando el monto supera cierta cifra, cuando el sistema no tiene suficiente confianza, cuando se trata de un cliente estratégico o cuando involucra alérgenos. Y **mantener revisión humana** (*human oversight*) efectiva: una revisión que ocurre de verdad, con tiempo y autoridad para rechazar, no un clic automático.

ANALOGÍA

Es el conductor que, con un buen sistema de asistencia al manejo, deja de mirar el camino. El sistema funciona casi siempre; el peligro está en el «casi», y en que el conductor ya no está preparado para intervenir. Los umbrales de escalamiento son las condiciones en que el vehículo exige que el conductor retome el volante.

NIST: el vocabulario completo de riesgos

Tras la tabla, el curso vuelve a NIST con un párrafo que sirve de puente. Dice que NIST **denomina alucinación o confabulación** a la producción de contenido falso o erróneo con falsa certeza de veracidad, y que además **identifica riesgos de privacidad, sesgo, integridad de la información, propiedad intelectual y configuración de la relación entre personas y sistemas** (NIST, 2024). Si compara esa lista con la tabla de seis filas, verá que cinco coinciden (confabulación, privacidad, sesgo, integridad de la información, propiedad intelectual) y que la última, la **configuración de la relación entre personas y sistemas** (en el perfil de NIST, la «configuración humano-IA»), es el equivalente técnico de lo que el curso llama sobreconfianza: cómo se diseña la interacción entre las personas y el sistema determina si las personas lo usan con criterio o lo obedecen. Es una observación útil, porque muestra que la sobreconfianza no se resuelve solo con capacitación: también depende del diseño de la interfaz, de los avisos, de los registros y de lo que el sistema permite hacer sin intervención humana.

⚠ Nota (discrepancia 10): el curso presenta cinco o seis riesgos de NIST y habla de gestionarlos «desde el diseño, desarrollo, uso y evaluación». El documento de NIST (AI 600-1, perfil de IA generativa, julio de 2024) enumera en realidad **doce riesgos**: químico, biológico, radiológico y nuclear (QBRN); confabulación; contenido peligroso, violento o de odio; privacidad de datos; impacto ambiental; sesgo dañino u homogeneización; configuración humano-IA; integridad de la información; seguridad de la información; propiedad intelectual; contenido obsceno, degradante o abusivo; y cadena de valor e integración de componentes. Además, el marco base, el **AI RMF 1.0** (enero de 2023), se organiza en **cuatro funciones**: **Gobernar** (*Govern*), **Mapear** (*Map*), **Medir** (*Measure*) y **Gestionar** (*Manage*), que no

son lo mismo que las cuatro etapas «diseño, desarrollo, uso y evaluación» del curso (esas describen momentos del ciclo de vida; las funciones describen actividades de gestión que se repiten en todos los momentos). **Regla de examen:** la definición de confabulación del curso es fiel a NIST; si preguntan por la estructura del marco, responda las cuatro funciones, Gobernar, Mapear, Medir y Gestionar; si preguntan por lo que dice el curso, desde el diseño, desarrollo, uso y evaluación.

La gestión debe ser proporcional al impacto

Aquí está una de las ideas más importantes de todo el artículo, y el curso la dice con un contraste: **la gestión debe ser proporcional al impacto**. Un **borrador publicitario admite corrección**; una **recomendación clínica, crediticia o laboral exige controles mucho más rigurosos**. La **proporcionalidad** (*proportionality*) significa que el nivel de control, revisión y documentación crece con la gravedad de las consecuencias de un error: sobre las personas, la operación, la reputación o el cumplimiento. Es el mismo principio de la UNESCO que vimos arriba y la misma lógica de la columna «Riesgo» de la matriz de oportunidad que usted verá más adelante.

¿Qué hace que un uso sea de mayor o menor impacto? Tres preguntas lo ordenan: *¿qué tan grave es el daño si el sistema se equivoca?*, *¿qué tan reversible es?* (un borrador se corrige antes de publicarse; un crédito negado o un despido ya ocurrieron) y *¿a cuántas personas afecta y qué margen tienen de apelar?* La tabla siguiente es una ilustración nuestra, no del curso, que aplica esas preguntas a cuatro casos de uso.

Caso de uso (ilustrativo)	Impacto de un error	Reversibilidad	Nivel de control que pide
Borrador de un texto publicitario	Bajo: se corrige antes de publicar	Alta	Revisión editorial habitual por quien responde de la marca
Ficha de producto con ingredientes y alérgenos	Medio a alto: un error de alérgenos afecta la salud de consumidores	Media (se puede corregir, pero el daño puede ocurrir antes)	Fuente aprobada obligatoria, revisor con nombre propio y cero errores de alérgenos publicados
Recomendación de aprobar o rechazar un crédito	Alto: afecta el acceso a financiamiento de una persona	Baja	Decisión final humana, pruebas de sesgo por segmento, trazabilidad completa y vía de apelación; asesoría jurídica
Apoyo a una decisión laboral (selección o despido)	Alto: afecta el empleo y la dignidad de una persona	Baja	Máxima exigencia: sin decisión automática, revisión humana con autoridad, consentimiento y justificación de la relación entre dato y desempeño; en el caso extremo, no usar

Un cálculo sencillo ayuda a ver por qué la proporcionalidad no es una cuestión de estilo. Supongamos (cifras ilustrativas, no del curso) que un asistente produce 10.000 textos al mes y que un 4 % contiene algún error. Eso son 400 errores al mes. Si cada error en un borrador publicitario se detecta en la revisión y cuesta unos 2 dólares de tiempo corregir, el costo esperado mensual es $400 \times 2 = 800$ dólares. Si, en cambio, el mismo 4 % de error afectara a 10.000 recomendaciones de crédito y cada error no detectado costara en promedio 3.000 dólares entre pérdidas, reclamos y sanciones, el costo esperado sería $400 \times 3.000 = 1.200.000$ dólares. La tasa de error es idéntica; la diferencia es de mil quinientas veces, y proviene solo del impacto. Por eso un control razonable para el primer caso (una lectura rápida) sería gravemente insuficiente para el segundo.

EJEMPLO NUMÉRICO

Costo esperado = número de errores $\times$ costo por error. Primer caso: $10.000 \times 0,04 = 400$ errores; $400 \times 2 = 800$ dólares. Segundo caso: los mismos 400 errores, pero $400 \times 3.000 = 1.200.000$ dólares. Cociente: $1.200.000 / 800 = 1.500$. (Cifras supuestas para ilustrar el principio; ninguna proviene del curso.)

Esto conecta con la advertencia del Artículo 1: la métrica debe representar el riesgo y la decisión que se quiere apoyar. Una tasa de error del 4 % no significa nada hasta que se responde: ¿cuánto cuesta cada error y quién lo paga?

Chile: de la Ley 19.628 a la Ley 21.719

Recuadro del curso (Chile): «En Chile, el tratamiento de datos personales se rige actualmente por la Ley 19.628. La Ley 21.719, publicada en diciembre de 2024, moderniza este marco y entra en vigor el 1 de diciembre de 2026. Entre otros aspectos, refuerza principios de licitud, finalidad, seguridad y responsabilidad, y crea la Agencia de Protección de Datos Personales (Biblioteca del Congreso Nacional de Chile, 2024). Las organizaciones deben revisar sus obligaciones específicas con asesoría jurídica.»

La **Ley 19.628** (*Chilean Law 19,628*), de 1999, es la ley general de protección de la vida privada que durante más de dos décadas ha regido el tratamiento de datos personales en Chile. La **Ley 21.719** (*Chilean Law 21,719*) la moderniza. Según el recuadro y los datos verificados del curso, fue publicada en diciembre de 2024 (el 13 de diciembre) y, de acuerdo con el texto legal, entra en vigor el 1 de diciembre de 2026. En la Unidad 1 de este módulo ya la presentamos en el contexto de la privacidad; aquí la usamos como marco concreto para el riesgo de privacidad que acabamos de ver. Los cuatro principios que el curso destaca tienen una traducción empresarial directa:

- **Licitud:** el tratamiento de datos personales necesita una base que lo permita, como el consentimiento u otra habilitación legal. No basta con que «los datos estén disponibles».
- **Finalidad:** los datos se recogen y usan para fines determinados y legítimos, y no para cualquier otro que se le ocurra a la empresa después. Un dato entregado para despachar un pedido no se reutiliza automáticamente para entrenar un modelo.

- **Seguridad:** el responsable debe proteger los datos con medidas técnicas y organizativas, lo que incluye decidir en qué herramientas pueden cargarse.
- **Responsabilidad:** la organización debe poder demostrar que cumple, con registros y procedimientos, no solo declararlo.

La ley crea además la **Agencia de Protección de Datos Personales** (*Personal Data Protection Agency*), un organismo encargado de fiscalizar y sancionar. Según los datos que complementan el curso, el régimen de sanciones contempla multas expresadas en UTM (Unidades Tributarias Mensuales, la unidad de reajuste que usa el Estado chileno) de hasta 5.000 UTM para infracciones leves, 10.000 UTM para graves y 20.000 UTM para gravísimas. Estas cifras de multas no están en el PDF y provienen de fuentes secundarias, de modo que conviene confirmarlas con asesoría jurídica antes de citarlas en un documento formal. La conclusión práctica es la que dice el propio curso: las organizaciones deben **revisar sus obligaciones específicas con asesoría jurídica**; el curso no pretende reemplazar ese consejo.

⚠ Nota (discrepancia 7): el curso dice que la Ley 21.719 entra en vigor el 1 de diciembre de 2026, y esa es la fecha legal vigente. Sin embargo, el 1 de septiembre de 2026 el Gobierno ingresó al Senado un proyecto de ley para **postergar la vigencia al 1 de diciembre de 2027**, que a fines de septiembre de 2026 seguía en trámite y sin aprobarse (fuente secundaria). En paralelo, el proyecto de ley de IA (boletín 16821-19) fue aprobado por la Cámara, está en segundo trámite en el Senado y todavía no es ley. **Regla de examen:** responda 1 de diciembre de 2026 (lo que dice la ley publicada) y agregue, si la pregunta lo permite, que existe un proyecto de postergación en trámite. En la práctica profesional, confirme la fecha vigente antes de planificar el cumplimiento.

Propiedad intelectual y la guía de la OMPI

El curso cierra el tramo normativo con la propiedad intelectual: su tratamiento **varía según jurisdicción, contrato, plataforma y tipo de contenido**, y la **Organización Mundial de la Propiedad Intelectual (OMPI)** (*WIPO*) recomienda cuatro prácticas al adoptar IA generativa (OMPI, 2024). Según los datos complementarios, la OMPI publicó una guía con principios rectores y una lista de verificación (checklist); es una guía de orientación, no una norma. Las cuatro prácticas son una secuencia de trabajo:

1. **Identificar los activos involucrados.** ¿Qué contenidos, marcas, bases de datos, fórmulas o documentos confidenciales participan, como entrada o como salida? Sin un inventario de activos no se puede protegerlos.
2. **Revisar las condiciones de uso.** Cada herramienta tiene términos sobre qué hace con lo que se le entrega y quién tiene derechos sobre lo que produce. Esas condiciones cambian, y no son iguales entre una cuenta gratuita y un contrato empresarial.
3. **Mantener trazabilidad.** Registrar qué se generó, con qué herramienta, con qué insumos y quién lo aprobó. Si más adelante hay un reclamo, el registro es la defensa.
4. **Evaluar salvaguardas.** Decidir medidas de protección: restringir qué puede cargarse, exigir revisión antes de publicar, pactar cláusulas con proveedores.

EJEMPLO

Una lista de verificación mínima inspirada en esa guía (adaptación nuestra, no un texto de la OMPI) para una empresa de alimentos que quiere usar IA generativa en comunicaciones: (a) ¿listamos los activos que podrían entrar (recetas, fichas, imágenes de marca, listas de clientes)? (b) ¿cuáles son estrictamente confidenciales y quedan fuera de la herramienta? (c) ¿leímos los términos de la plataforma sobre uso de datos y titularidad de lo generado? (d) ¿guardamos el prompt, la versión y el aprobador de cada pieza publicada? (e) ¿quién decide en los casos dudosos y con qué asesoría?

Note la conexión: tres de las cuatro prácticas (identificar activos, trazabilidad, salvaguardas) coinciden con controles de la tabla de riesgos para privacidad, deepfakes y propiedad intelectual. No es casual: casi todos los riesgos de esta unidad se controlan con el mismo conjunto de hábitos (inventariar, registrar, restringir, revisar).

Crterios para una prueba piloto

Una **prueba piloto** (*pilot*) es una prueba acotada, en condiciones reales pero con alcance limitado, que permite decidir si una solución merece escalarse. El curso lo resume en una frase de examen: **un piloto útil produce evidencia para decidir**. No es una demostración para impresionar ni un experimento para «ver qué pasa»; es un instrumento de decisión. Debe comenzar con tres elementos: **un problema acotado, una línea base y un responsable de negocio**.

La **línea base** (*baseline*) es la medición de cómo funciona hoy el proceso (tiempo, costo, calidad o riesgo), contra la cual se comparará el resultado del piloto. Sin ella, cualquier cifra posterior es inútil: «redujimos el tiempo a 20 minutos» no dice nada si no se sabe que antes eran 25 o 90. El **responsable de negocio** (*business owner*) es la persona del área usuaria, no de tecnología, que responde por el resultado y decide si se continúa. La razón de exigirlo es que un piloto sin dueño de negocio suele terminar como un proyecto técnico sin destino.

El curso llama **piloto demostrativo** (*showcase pilot*) al que impresiona en una presentación pero carece de continuidad: no tenía línea base, ni responsable, ni plan para operar después. Las siete preguntas del curso existen para **evitar pilotos demostrativos sin continuidad**. Reproducimos la lista literal y a continuación desarrollamos cada una con un ejemplo.

1. ¿Qué decisión, tarea o resultado se busca mejorar?
2. ¿Cómo se realiza hoy y cuál es su línea base de tiempo, costo, calidad o riesgo?
3. ¿Qué datos o contenidos están disponibles y con qué permisos?
4. ¿Qué error es tolerable y qué error sería inaceptable?
5. ¿Quién revisará los resultados y quién responde por la decisión final?
6. ¿Cómo se medirá valor, desempeño técnico y experiencia de las personas usuarias?
7. ¿Qué ocurrirá si la solución falla, cambia el contexto o deja de estar disponible?

1. ¿Qué decisión, tarea o resultado se busca mejorar? Obliga a formular el problema antes de la herramienta, en línea con la «pregunta de negocio» (un verbo y un resultado observable) del Artículo 1.

«Usar IA en marketing» no es un objetivo; «reducir el tiempo de redacción de las fichas de producto» sí lo es, porque se puede observar y medir.

2. ¿Cómo se realiza hoy y cuál es su línea base? Antes de cambiar nada, se mide el presente. Ejemplo: si hoy redactar una ficha toma en promedio 45 minutos (supuesto ilustrativo) y exige dos revisiones, esos son los números contra los que se evaluará el piloto, y también contra los que se compara la calidad: cuántos errores se detectaban antes.

3. ¿Qué datos o contenidos están disponibles y con qué permisos? Reúne dos requisitos que suelen separarse por error: que los datos existan y que se pueda usarlos. Una empresa puede tener miles de fotografías o documentos y no tener autorización para cargarlos en una herramienta externa. En el caso SurAndes, los permisos aparecen como una brecha: no hay política para cargar documentos internos ni inventario de información personal.

4. ¿Qué error es tolerable y qué error sería inaceptable? Es la pregunta de la proporcionalidad. Un error tolerable en un borrador es una frase poco elegante que el revisor corrige; uno inaceptable es un alérgeno mal declarado. Se fija *antes*, para que el resultado se juzgue con un criterio acordado y no según el entusiasmo del momento.

5. ¿Quién revisará los resultados y quién responde por la decisión final? Son dos roles distintos que el curso pide nombrar: el que revisa (calidad de la salida) y el que responde (consecuencias de la decisión). Es el control contra la sobreconfianza. En SurAndes, la persona de Marketing que ya aprueba cada publicación cumple ambos papeles para la Propuesta C.

6. ¿Cómo se medirá valor, desempeño técnico y experiencia de las personas usuarias? Son tres familias de medida y las tres importan. El valor es el beneficio de negocio (tiempo ahorrado, costo, ventas). El desempeño técnico es qué tan bien funciona el modelo (errores, cobertura). La experiencia de las personas usuarias dice si el sistema será usado realmente: un modelo preciso que los operarios ignoran no genera valor. Recuerde la distinción del Artículo 1 entre desempeño estadístico y utilidad empresarial; esta pregunta la formaliza.

7. ¿Qué ocurrirá si la solución falla, cambia el contexto o deja de estar disponible? Es el plan de contingencia y salida. Una herramienta externa puede cambiar sus condiciones, subir su precio o desaparecer. El caso lo expresa como requisito: la solución debe poder **detenerse sin interrumpir la operación**. Esa propiedad se llama **reversibilidad** (*reversibility*): poder deshacer el piloto sin dejar consecuencias.

Esto conecta con la Unidad 6 del Módulo 1, «Del prototipo a producción», donde distinguimos prueba de concepto, MVP y piloto, y vimos que muchas iniciativas se quedan atrapadas entre el prototipo y la operación. Las siete preguntas son, en esencia, la lista de cosas que impiden quedar atrapado: el piloto nace con un destino, una línea base, un dueño y una salida.

En resumen (recuadro del curso)

En resumen: «Avanzar de la teoría a la práctica en inteligencia artificial exige pasar del entusiasmo por la tecnología a la disciplina en la ejecución. Ya sea generando contenido, entrenando modelos de visión

o implementando pruebas piloto, el verdadero impacto radica en entender los límites de cada enfoque, gestionar los riesgos de forma responsable y garantizar que la supervisión humana mantenga el control sobre las decisiones críticas.»

El recuadro condensa el artículo en tres movimientos. El primero, *del entusiasmo a la disciplina*, resume por qué el curso insiste en formular el problema antes de elegir tecnología. El segundo, *entender los límites de cada enfoque*, apunta a las condiciones críticas de la tabla de necesidades (etiquetas representativas, interpretación experta, simulador, fuentes y derechos). El tercero, *supervisión humana sobre decisiones críticas*, es el hilo que une la proporcionalidad, el control de la sobreconfianza y el caso SurAndes. Note que el recuadro nombra tres actividades concretas (generar contenido, entrenar modelos de visión, implementar pilotos) que corresponden a Propuesta C, Propuesta A y a la lógica del piloto, es decir, al caso que sigue.

Video resumen

El curso incluye un video titulado **«Tecnologías clave para la IA generativa y la gestión empresarial»**. **Solo está disponible en la versión online de la clase** (o escaneando un código QR), y los recursos de enlaces y códigos QR podrían no estar disponibles a partir del 30 de noviembre de 2026. Lo que el PDF sí trae, en la página 19, es un texto de apoyo que resume el contenido del video. Buena parte repite lo ya visto; estas son las ideas que aportan algo **nuevo** respecto del resto de la unidad:

- **Reglas más eficientes, económicas y transparentes.** El texto dice que, si una necesidad operativa se resuelve mediante políticas estables y explícitas, la automatización convencional por reglas resulta *más eficiente, económica y transparente* que el machine learning. Es la primera vez que la unidad pone los tres adjetivos juntos: eficiencia (hace lo mismo con menos), economía (cuesta menos construir y mantener) y transparencia (se puede auditar regla por regla). Retoma la idea de que tres reglas claras y auditables pueden ser mejores que un modelo opaco.
- **El no supervisado requiere validación experta.** Los grupos que el modelo encuentra no se interpretan solos: hace falta que personas que conocen el negocio den sentido a los hallazgos.
- **El refuerzo opera en entornos dinámicos.** El texto lo describe como el enfoque que optimiza secuencias de decisiones mediante recompensas y penalizaciones *en entornos dinámicos*, es decir, entornos que cambian con las acciones y con el tiempo. Eso explica por qué exige simulador y definición cuidadosa de la recompensa.
- **Atajos correlacionales.** El texto nombra, entre los riesgos a controlar, los «atajos correlacionales del aprendizaje», con lo cual conecta el hallazgo de Teachable Machine (el modelo que aprende el fondo y no el objeto) con la lista de riesgos de esta sección. Es una forma de sesgo técnico que no figura como fila de la tabla pero sí en el resumen.
- **Trazabilidad del contenido sintético.** Entre lo que las organizaciones deben resguardar, junto con privacidad y propiedad intelectual, el texto agrega la trazabilidad del contenido sintético: poder saber qué se generó con IA, cómo y quién lo aprobó. Reúne los controles de deepfakes y propiedad intelectual en una sola exigencia.
- **Métricas orientadas al riesgo empresarial.** El texto cierra pidiendo pilotos acotados con línea base clara, datos representativos y **métricas orientadas al riesgo empresarial**. Una **métrica orientada al**

riesgo es la que se elige según el costo del error en esa operación (por ejemplo, errores de alérgenos publicados) y no según el promedio más favorable. Es la respuesta práctica a la advertencia del Artículo 1.

Además, el texto recuerda dos ideas ya vistas: la multimodalidad permite procesar, combinar y transformar *simultáneamente* diversas fuentes, y los modelos de lenguaje infieren la respuesta *más probable* según el contexto entregado en un prompt. Como este video no está en el PDF, la discrepancia 11 al final de la sección advierte que conviene revisarlo en la versión online antes de rendir la unidad.

Caso: Priorización de piloto de IA en SurAndes Alimentos

El curso cierra la unidad con un caso narrativo. **SurAndes Alimentos y su gerente general, Marcela Riquelme, son ficticios**: es un caso didáctico, no una empresa real. Su propósito es que usted practique lo aprendido: formular problemas, reconocer qué tecnología es cada propuesta, detectar la condición que falla y decidir con criterio con recursos limitados. Recomendamos leer primero el caso sin mirar la resolución del comité y tratar de decidir por su cuenta.

Contexto del caso

SurAndes Alimentos es una **empresa chilena mediana** que fabrica y distribuye **productos envasados** para supermercados, almacenes y clientes institucionales. Opera **una planta, dos centros de distribución y un equipo comercial de 45 personas**. Durante los últimos **tres años** incorporó tres sistemas: un **sistema de gestión empresarial** (un ERP), **cámaras en la línea de envasado** y un **canal digital de atención**. Con eso generó datos de procesos, de imágenes y de interacciones con clientes. Pero la información, dice el caso, **existe, pero se encuentra dispersa y tiene niveles variables de calidad**. Esa frase es la clave de todo: tener datos no es tener datos *utilizables*, y de ahí vendrán los descartes.

La gerencia general creó un **comité** para priorizar iniciativas de IA. El **presupuesto permite realizar un solo piloto durante doce semanas**. El comité recibió **cinco propuestas** y debe recomendar cuál probar primero. Observe la estructura: una restricción de recursos (un solo piloto), un horizonte corto (doce semanas) y cinco opciones que, a propósito, corresponden a cinco tecnologías distintas de las que la unidad acaba de presentar. Es la matriz de necesidades del Artículo 3 puesta a prueba en una empresa.

Propuesta A. Inspección visual de envases

Descripción literal del curso: «La planta registra cerca de 18.000 fotografías de envases. Un equipo de calidad etiquetó 6.000 como correctos, sello incompleto, etiqueta desplazada o abolladura. La propuesta consiste en entrenar un clasificador que alerte a un operario cuando detecte una anomalía. Las fotografías etiquetadas provienen principalmente del turno diurno y de dos productos.»

Qué tipo de aprendizaje es. Es **aprendizaje supervisado** y, dentro de él, **clasificación** de imágenes: cada fotografía debe asignarse a una de **cuatro clases** (correcto, sello incompleto, etiqueta desplazada, abolladura). En la tabla de seis necesidades del Artículo 3 corresponde a «predecir un número o una categoría conocida», cuya condición crítica son los ejemplos históricos *etiquetados y representativos*. También reaparece la fila del Artículo 2: «identificar defectos visuales, con imágenes etiquetadas por

tipo de defecto, salida categoría del producto, clasificación». Es el mismo tipo de problema que usted resolvería con Teachable Machine, pero a escala industrial.

Fortalezas. Hay un problema claro y medible (detectar envases defectuosos), una línea base posible (cuántos defectos detecta hoy el equipo de calidad), datos ya existentes (18.000 fotos), un subconjunto ya etiquetado (6.000) y un diseño prudente: el sistema *alerta a un operario*, no decide solo. Esa persona en el circuito de decisión es un control de sobreconfianza y mantiene el error controlable. Además, genera aprendizaje técnico y una mejora operativa directa en planta, como reconocerá luego el comité.

Su problema crítico: los datos etiquetados no son representativos. Las 6.000 imágenes etiquetadas son solo un tercio del total (6.000 de 18.000 son el 33 %), y además **proviene principalmente del turno diurno y de dos productos**. Esto activa dos alarmas del Artículo 1. La primera es la **falta de diversidad**: el modelo verá pocas condiciones de iluminación, pocos formatos de envase y pocos productos, y no sabrá generalizar al turno nocturno ni a los demás productos. La segunda es el riesgo de **atajos**: si, por ejemplo, la mayoría de los envases defectuosos de las fotos se tomaron en cierta hora, con cierta luz o de cierto producto, el modelo podría aprender esa condición en lugar del defecto, igual que en Teachable Machine aprende el fondo y no el objeto. Y todo eso se agrava porque se trata de cuatro clases: los defectos (sello incompleto, etiqueta desplazada, abolladura) son minoritarios frente a «correcto», de modo que, si las 6.000 imágenes se repartieran por igual serían 1.500 por clase (supuesto ilustrativo), pero en la práctica la clase «correcto» domina y las clases de defecto quedan con muy pocos ejemplos, justo las que más importan. Es la distinción entre desempeño estadístico y utilidad empresarial: un modelo puede tener alta exactitud simplemente por acertar «correcto» casi siempre y fallar en el defecto relevante.

Cómo se remedia. Ampliar y diversificar el conjunto de datos (más turnos, más productos, más defectos) y mantener al operario en el circuito. Pero ampliar requiere horas de etiquetado del equipo de calidad, y el caso informa luego que solo dispone de cuatro horas semanales. Esa tensión será decisiva.

Propuesta B. Segmentación de clientes

Descripción literal del curso: «El área comercial quiere agrupar clientes según frecuencia, volumen, estacionalidad, forma de pago y mezcla de productos. Hoy utiliza tres segmentos definidos solo por facturación. Existen cuatro años de transacciones, aunque los identificadores de algunos clientes cambiaron después de una migración de sistema.»

Qué tipo de aprendizaje es. Es **aprendizaje no supervisado**, concretamente **agrupamiento (clustering)**: no hay una etiqueta de «segmento correcto», se buscan grupos de clientes parecidos. En la tabla de necesidades corresponde a «explorar patrones o grupos desconocidos», con condición crítica: *variables pertinentes e interpretación experta*.

Fortalezas. Reemplaza una segmentación pobre (tres segmentos definidos solo por facturación) por una más rica en cinco variables (frecuencia, volumen, estacionalidad, forma de pago, mezcla de productos), y dispone de un historial largo (cuatro años) que da profundidad temporal para captar estacionalidad. El valor potencial para el área comercial, con 45 personas, es alto. El riesgo operativo es bajo: una segmentación no detiene la planta.

Su problema crítico: los identificadores de clientes quedaron inconsistentes tras la migración. Si un mismo cliente figura con dos identificadores, el modelo lo verá como dos clientes distintos, cada uno con la mitad de su historia; si dos clientes distintos comparten un identificador, mezclará sus comportamientos. En ambos casos, las variables de frecuencia, volumen y estacionalidad estarían mal calculadas y los grupos resultantes serían artefactos de los datos, no de los clientes. Como recordó el Artículo 2, los segmentos no son verdades naturales: dependen de la calidad de los datos. Esto exige un **saneamiento de datos** (*data cleansing*): reconciliar identificadores, eliminar duplicados y validar la historia, antes de hacer cualquier agrupamiento. Ese trabajo previo no cabe en un piloto de doce semanas con un solo equipo y sin comité de datos.

Propuesta C. Generación de fichas y contenidos

Descripción literal del curso: «Marketing propone utilizar IA generativa para producir borradores de fichas de producto, publicaciones y respuestas a consultas frecuentes. La información de ingredientes, alérgenos y conservación está en fichas técnicas aprobadas. El equipo estima que podrá reducir tiempos de redacción, pero todavía no define un flujo de revisión ni una política para cargar documentos internos.»

Qué tecnología es. Es **IA generativa** (modelo de lenguaje, basado en Transformer), que en la tabla de necesidades corresponde a «crear, transformar o sintetizar contenido», con condiciones críticas: *instrucciones, fuentes, validación y derechos de uso*. Fíjese en que las cuatro condiciones se relacionan con el caso: las instrucciones serán los prompts, las fuentes son las fichas técnicas aprobadas, la validación es la persona de Marketing y los derechos de uso conectan con la política de carga de documentos.

Fortalezas. Hay un problema acotado (redactar borradores), un beneficio estimado y medible (tiempo de redacción), una **fuentes de verdad ya aprobada** (las fichas técnicas con ingredientes, alérgenos y conservación) que permite anclar el contenido en información confiable y así reducir la confabulación, y un **revisor** ya disponible (la persona de Marketing que aprueba cada publicación, según la información adicional). El error es controlable porque es un borrador que una persona aprueba antes de publicar. Y el piloto es rápido, de bajo costo y **reversible**: si no funciona, Marketing vuelve a redactar a mano.

Su problema crítico: faltan el flujo de revisión y la política de carga. Las fichas están aprobadas, pero la propuesta *todavía no define un flujo de revisión ni una política para cargar documentos internos*. Sin flujo de revisión, existe un revisor «disponible» pero no un procedimiento: ¿qué se revisa?, ¿contra qué fuente?, ¿qué ocurre con un error de alérgenos?, ¿quién firma? Y sin política de carga, nadie sabe qué documentos internos pueden entregarse al modelo, con lo que reaparecen los riesgos de privacidad y propiedad intelectual de la tabla. Como el contenido toca **alérgenos**, el error inaceptable (pregunta 4 del piloto) está claro: publicar un dato de alérgenos falso. Por lo tanto, la Propuesta C es viable *con la condición pendiente* de definir ambos elementos antes de partir. Es una condición de gobernanza, no de datos ni de técnica, y por eso se puede cerrar en pocos días.

Propuesta D. Optimización dinámica del despacho

Descripción literal del curso: «Operaciones propone un sistema que aprenda decisiones de asignación de rutas mediante recompensas asociadas con puntualidad, costo de combustible y ocupación de

vehículos. La empresa no dispone de un simulador y los datos históricos de tráfico están incompletos. Un error podría afectar entregas comprometidas con clientes estratégicos.»

Qué tipo de aprendizaje es. Es **aprendizaje por refuerzo**: un agente (el sistema de asignación) toma acciones (asignar rutas) en un entorno (la operación de despacho) y recibe recompensas (puntualidad, costo de combustible, ocupación). Es «optimizar decisiones sucesivas con retroalimentación», cuya condición crítica, según la tabla, es *entorno seguro, recompensa bien definida y capacidad de simular*.

Fortalezas. El problema es real y valioso: asignar rutas con múltiples criterios es justo el tipo de optimización secuencial para el que sirve el refuerzo, y el ahorro en combustible y puntualidad podría ser significativo.

Su problema crítico: no hay simulador y el entorno no es seguro. Un agente de refuerzo aprende por ensayo y error, y no puede ensayar en la operación real si un error afecta a clientes estratégicos. Sin simulador no hay un lugar seguro donde equivocarse. Además, los datos históricos de tráfico están incompletos, de modo que ni siquiera podría construirse un simulador fiel. Se suma el riesgo de la **recompensa incompleta** que advirtió el Artículo 2: un sistema que maximice puntualidad, combustible y ocupación sin considerar otros factores podría, por ejemplo, sacrificar a los clientes pequeños para favorecer una métrica. Se cumple lo que el curso dice: por complejidad y costo de experimentación, el refuerzo **suele quedar fuera de los primeros pilotos**. Veredicto: se descarta.

Propuesta E. Detector de ánimo del personal

Descripción literal del curso: «Recursos Humanos propone analizar imágenes de las cámaras internas para inferir el estado emocional de los trabajadores y anticipar conflictos. No existe consentimiento específico para este uso, no se ha definido una relación clara entre expresión facial y desempeño, y la iniciativa podría afectar derechos y confianza interna.»

Qué tecnología es. Es visión computacional aplicada a la clasificación de imágenes (supervisado), con una salida que no es un objeto físico sino un **estado emocional inferido**. Técnicamente se parecería a la Propuesta A (clasificar imágenes), pero su objeto y su contexto son radicalmente distintos.

Fortalezas. Ninguna sustancial para el piloto. La intención declarada (anticipar conflictos) es legítima, pero el medio es desproporcionado.

Sus problemas críticos son tres, y los tres son de fondo. Primero, **no hay consentimiento específico**: se usarían imágenes de personas, datos personales, para una finalidad distinta de aquella para la que se instalaron las cámaras, lo que choca con la privacidad y con los principios de licitud y finalidad de la Ley 21.719. Segundo, **no hay una relación clara entre expresión facial y desempeño**: nadie ha demostrado que lo que el modelo infiere (una emoción) esté vinculado con lo que la empresa quiere anticipar (un conflicto); sin esa relación, el sistema produciría etiquetas sin validez. Tercero, **afecta derechos y confianza interna**: es una vigilancia de trabajadores con consecuencias en el clima laboral y en la dignidad de las personas, y encaja con el uso laboral de alto impacto del que el curso pide el máximo control. Veredicto: se descarta de inmediato, por razones éticas y de derechos, sin siquiera entrar en la discusión técnica.

⚠ Nota (discrepancia 12): en el video del profesor Rodrigo Pereira, Teachable Machine se usa para clasificar **expresiones faciales** como ejercicio didáctico, y en el caso SurAndes la Propuesta E (inferir el ánimo por la expresión facial de los trabajadores) se descarta. No es una contradicción: lo que cambia es el **uso**. Un ejercicio personal, voluntario y consentido con el propio rostro, sin consecuencias, es muy distinto de analizar a trabajadores sin consentimiento para tomar decisiones sobre ellos. Además, inferir emociones a partir de rostros es científicamente discutido, y el Reglamento de IA de la Unión Europea (2024/1689, art. 5) prohíbe el reconocimiento de emociones en el lugar de trabajo (dato de entrenamiento, no del curso). **Regla de examen:** el criterio es el del caso. Sin consentimiento y sin una relación válida entre expresión y desempeño, se descarta.

Información adicional del caso

Antes de la resolución, el caso entrega cinco restricciones que condicionan todo el análisis. Cada una pesa sobre una o más propuestas:

1. **No hay comité formal de datos ni inventario completo de información personal.** Es una carencia de gobernanza de datos. Afecta a la Propuesta E (no se sabe qué datos personales hay ni quién autoriza su uso), pero también a C (sin política de carga) y, en general, a cualquier propuesta que use datos de personas.
2. **Calidad puede dedicar cuatro horas semanales al piloto.** En doce semanas son 48 horas en total. Es el límite de la Propuesta A: si se quisiera, por ejemplo, etiquetar 6.000 imágenes adicionales (supuesto ilustrativo), habría que etiquetar 125 por hora, es decir, una cada 29 segundos aproximadamente, durante todas las horas disponibles y sin tiempo para otra cosa. La ampliación de datos que A necesita no cabe con ese recurso.
3. **Marketing cuenta con una persona responsable de aprobar cada publicación.** Es el revisor de la Propuesta C: ya existe, ya tiene autoridad y ya revisa. Es la respuesta a la pregunta 5 del piloto.
4. **La gerencia exige demostrar un resultado medible al término de las doce semanas.** Pide línea base y métrica desde el primer día. Favorece propuestas donde el resultado es fácil de medir, como el tiempo de redacción.
5. **La solución debe poder detenerse sin interrumpir la operación.** Es el requisito de reversibilidad. Descarta a D (si falla, interrumpe despachos) y favorece a C (si falla, se vuelve a redactar a mano).

Resolución del comité

Según el curso, durante la sesión de análisis el **Comité de IA descartó de inmediato** tres propuestas: **E**, por vulnerar derechos de privacidad e integridad laboral; **D**, por no contar con un simulador y poner en riesgo la operación real de entregas; y **B**, porque la migración de sistemas dejó inconsistencias en los identificadores de clientes que exigen un saneamiento previo de datos. Observe que son tres razones de naturaleza distinta, que corresponden a los tres criterios que el foro pregunta más adelante: *ético* (E), *operativo* (D) y *de calidad de datos* (B).

Con ello el análisis se concentró en las dos únicas alternativas viables. La **Propuesta A** (inspección visual) resultaba conveniente *si se buscaba aprendizaje técnico y mejora operativa directa en planta, siempre que se ampliara el conjunto de datos y se mantuviera al operario en el circuito de decisión.*

La **Propuesta C** (generación de contenidos) resultaba conveniente *si se necesitaba un piloto de ejecución rápida, bajo costo y 100 % reversible*. Note que ambas tienen un «si»: el comité no las compara en abstracto, sino según el objetivo que la empresa persiga.

La decisión final de Marcela Riquelme

Ese «si» lo resuelve la gerente general. Marcela Riquelme **determinó la línea base y el valor que la gerencia necesitaba demostrar**: para este primer piloto de doce semanas, la **prioridad absoluta** era obtener **un resultado medible con riesgo operativo nulo y sin exigir tiempo extra al equipo de calidad**, que solo disponía de 4 horas semanales para ampliar los datos de imágenes. Bajo ese criterio, la Propuesta A queda en desventaja: requiere ampliar datos con horas que el equipo de calidad no tiene, y opera en la línea de envasado, por lo que no tiene riesgo operativo nulo. La gerencia general aprobó oficialmente ejecutar **únicamente la Propuesta C**, apoyándose en **la persona ya disponible en Marketing para la revisión humana** y en **la existencia de fichas técnicas oficiales aprobadas**.

La lección es que la decisión no se tomó porque C sea «mejor» que A en términos absolutos, sino porque era la mejor *dada la prioridad definida*. Si la gerencia hubiese priorizado el impacto operativo de largo plazo y hubiese liberado horas de calidad, A podría haber sido la elegida. Por eso la decisión empieza fijando la línea base y el valor: la elección de tecnología es la consecuencia de ese acuerdo, no su punto de partida.

Tabla síntesis de las cinco propuestas

La siguiente tabla es un resumen nuestro (no del curso) que reúne lo anterior en una sola vista.

Propuesta	Tecnología	Condición crítica que falla o cumple	Veredicto
A. Inspección visual de envases	Aprendizaje supervisado (clasificación de imágenes, 4 clases)	Etiquetas representativas: solo 6.000 de 18.000 (33 %), principalmente del turno diurno y de dos productos; ampliar exige horas que calidad no tiene	Viable con condiciones (ampliar datos y operario en el circuito); no elegida por la prioridad de la gerente
B. Segmentación de clientes	Aprendizaje no supervisado (agrupamiento)	Variables pertinentes: identificadores inconsistentes tras la migración; falta saneamiento previo	Descartada por el comité
C. Generación de fichas y contenidos	IA generativa (modelo de lenguaje)	Fuentes aprobadas y revisor disponibles (cumple); falta definir flujo de revisión y política de carga	Viable, reversible; aprobada, con la condición pendiente de gobernanza
D. Optimización dinámica del despacho	Aprendizaje por refuerzo	Entorno seguro y simulador: no hay; datos de tráfico incompletos; riesgo para clientes estratégicos	Descartada por el comité
E. Detector de ánimo del personal	Visión computacional (clasificación de expresiones)	Consentimiento, relación válida expresión-desempeño y respeto de derechos: no cumple ninguno	Descartada de inmediato por el comité

Resolución guiada con la matriz y el semáforo (análisis propio, no del curso)

Aviso: lo que sigue es **análisis propio, no del curso**. Aplica la matriz de ocho dimensiones y el semáforo de factibilidad (que se explican en detalle más adelante, en la sección de la herramienta práctica) a cada propuesta, para que usted vea cómo se llega a la misma decisión por un camino sistemático. El curso no entrega esta tabla.

Propuesta	Semáforo	Razón principal
A. Inspección visual	Amarillo	Problema acotado y error controlable por el operario, pero hay brechas de diversidad de datos y de horas del equipo de calidad; resolverlas antes de probar
B. Segmentación	Amarillo	Datos existentes pero con identificadores inconsistentes; saneamiento previo; bajo riesgo operativo
C. Fichas y contenidos	Verde, con una condición pendiente	Fichas aprobadas como fuente, revisor definido, reversible, error controlable; antes de partir, definir el flujo de revisión y la política de carga de documentos
D. Despacho	Rojo	Sin simulador, alto impacto sobre clientes estratégicos, sin mecanismo seguro de prueba
E. Detector de ánimo	Rojo	Afecta derechos, sin consentimiento, sin relación válida entre expresión y desempeño; detener y reformular

La lectura del semáforo coincide con la decisión del curso. Los rojos (D y E) se detienen: la matriz pide «detener y reformular» cuando hay un uso de alto impacto sin base, controles ni mecanismos de revisión. Los amarillos (A y B) tienen brechas que resolver antes de probar. Solo C está en verde, y aun así con una condición: un verde honesto no significa «sin tareas», sino «sin brechas que impidan diseñar el piloto». La condición de C (flujo de revisión y política de carga) debe resolverse en la primera semana, no al final.

Métricas sugeridas para C (también análisis propio). Como el curso pide métricas orientadas al riesgo empresarial y línea base desde el inicio, proponemos tres:

- **Tiempo de redacción por ficha, antes y después.** La línea base se mide en las primeras semanas con redacción manual; luego se compara con el tiempo con asistencia más revisión. Mide el valor.
- **Tasa de borradores aprobados sin cambios.** Indica qué tan útil es el borrador. Si casi siempre hay que rehacerlo, el ahorro es ilusorio. Mide el desempeño técnico y la experiencia de la revisora.
- **Errores de alérgenos detectados en revisión, con meta cero publicados.** Es la métrica orientada al riesgo: no importa el promedio de calidad si un solo error de alérgenos llega a un consumidor. Interesan los detectados (muestran que la revisión funciona) y se exige que los publicados sean cero.

Preguntas de «Participa con tu comentario»: guía de respuesta

El caso termina con tres preguntas de foro. No tienen una respuesta única; a continuación ofrecemos un esquema de razonamiento para cada una, que usted puede adaptar a su propia experiencia profesional.

1. ¿Qué condiciones deben cumplirse en su entorno laboral o profesional para que una solución técnica atractiva no termine descartada por falta de datos, tiempos o gobernanza? Una respuesta sólida recorre los tres obstáculos que menciona la pregunta, apoyada en las siete preguntas del piloto. Sobre los *datos*: que existan, que sean representativos y que haya permiso para usarlos (pregunta 3). Sobre los *tiempos*: que las personas que deben aportar (etiquetar, revisar) tengan horas asignadas,

como las cuatro semanales de calidad; que el horizonte sea compatible con el trabajo previo (saneamiento) y que se comprometa un resultado medible. Sobre la *gobernanza*: que haya un responsable de negocio, un revisor con nombre, una política de uso de datos y una forma de detener la solución. Conviene cerrar con un ejemplo propio: un proyecto en que alguna de esas tres condiciones faltó y qué se habría hecho distinto. La idea central: las soluciones no se descartan por ser malas, sino porque no se verificó antes si las condiciones estaban dadas, y para eso sirve la matriz.

2. Al comparar las Propuestas A y C, ¿cuándo conviene priorizar un impacto operativo interno frente a una solución de rápida implementación y bajo riesgo? El curso da la pista: A conviene si se busca aprendizaje técnico y mejora operativa directa en planta, siempre que se amplíe el conjunto de datos y se mantenga al operario; C conviene si se necesita ejecución rápida, bajo costo y reversibilidad total. Entonces, *se prioriza A* cuando la organización puede liberar tiempo y datos para diversificar el conjunto, cuando el retorno operativo es grande y sostenido (por ejemplo, defectos costosos o reclamos frecuentes), cuando se tiene tolerancia a una fase más larga y cuando se quiere construir capacidad técnica propia. *Se prioriza C* cuando es el primer piloto, los recursos son escasos, se necesita demostrar un resultado medible en poco tiempo con riesgo operativo nulo y se quiere ganar confianza interna. Una buena respuesta puede proponer una secuencia: C primero como aprendizaje de gobernanza (flujo de revisión, política de carga) y luego A, con los datos y las horas necesarias, aprovechando lo aprendido.

3. De los criterios de descarte aplicados (éticos, operativos y de calidad de datos), ¿cuál suele ser el más ignorado al iniciar proyectos de tecnología y cómo se puede prevenir? No hay una respuesta correcta única, pero hay buenos argumentos. Una candidata fuerte es la **calidad de datos**: es la menos visible, porque los datos «existen» y se asume que sirven; el caso lo ilustra con la Propuesta B, donde el problema es un detalle de identificadores tras una migración. Se previene con una auditoría de datos al inicio, un responsable de datos y un saneamiento incluido en el plan. Otra candidata es el criterio **ético**: se ignora porque aparece como «un tema de después», pero la Propuesta E muestra que puede invalidar una idea desde el comienzo; se previene con una revisión de privacidad y derechos antes de diseñar, con consentimiento y con asesoría jurídica. La tercera, el **operativo** (como la ausencia de simulador de la Propuesta D), se previene preguntando siempre «¿dónde nos podemos equivocar sin consecuencias reales?». Elija una, argumente con experiencias concretas y proponga un mecanismo preventivo verificable (una lista de verificación, un comité, la matriz).

Video: Teachable Machine

La siguiente pieza del PDF es un video titulado «**Video: Teachable Machine**». Según el curso, **el profesor Rodrigo Pereira enseña cómo usar Teachable Machine para entrenar modelos de Machine Learning sin programar, clasificando imágenes y expresiones faciales**. Como en el caso del video resumen, el video y su PDF descargable («Video Unidad 2: Teachable Machine») están **solo en la versión online** de la clase y no vienen en este PDF. Lo que sí podemos hacer es conectarlo con lo ya aprendido: en esa actividad usted pasa por los siete pasos que describió el Artículo 3 (definir clases, reunir ejemplos variados, entrenar, probar con casos nuevos, registrar errores, reentrenar y anticipar qué podría salir mal), y la clasificación de expresiones faciales es, técnicamente, un problema

supervisado de clasificación de imágenes, igual que la Propuesta A, solo que con otra clase de etiquetas.

⚠ Nota (discrepancia 11): faltan en el PDF el **video resumen**, el **video del profesor Rodrigo Pereira sobre Teachable Machine** (que incluye clasificar expresiones faciales) y su **PDF descargable**. Lo que esta explicación dice sobre esas piezas está reconstruido a partir del texto de apoyo del curso y del artículo científico de Teachable Machine, no de los videos. **Regla de examen:** antes de rendir, revise esos recursos en la versión online; recuerde que los enlaces y códigos QR podrían no estar disponibles desde el 30 de noviembre de 2026.

Un último punto de coherencia, que ya anticipamos en la discrepancia 12: usar Teachable Machine con expresiones faciales en una actividad de clase es legítimo porque es un ejercicio voluntario, con el propio rostro y sin consecuencias sobre nadie. Esa misma técnica, aplicada a trabajadores sin consentimiento para decidir sobre ellos, es la Propuesta E. La tecnología no cambió; cambiaron el consentimiento, la finalidad y el impacto, y con ellos, el nivel de control que se exige.

Herramienta práctica: Matriz para evaluar una oportunidad de IA

Las páginas 25 y 26 del curso cambian de registro: dejan de explicar y te entregan un instrumento de trabajo. La **matriz para evaluar una oportunidad de IA** (*AI opportunity assessment matrix*) sirve para **evaluar y diagnosticar** una idea mediante **ocho dimensiones** y un **semáforo de factibilidad** (*feasibility traffic light*). El curso la presenta con tres propósitos precisos: **estructurar casos reales, identificar brechas de información y decidir antes de seleccionar tecnología o solicitar un piloto**.

Conviene leer esos tres propósitos como una sola idea. Todo lo que viste en las secciones anteriores (la pregunta de negocio con un verbo y un resultado observable, la tabla de necesidades y enfoques, los cinco componentes del aprendizaje, los seis riesgos, las siete preguntas del piloto) son piezas sueltas de criterio. La matriz las ordena en un único formulario de ocho filas que fuerza a recorrerlas todas, en una secuencia deliberada, antes de comprometer dinero, tiempo o reputación. Es, en lo práctico, la versión portátil de la Unidad: si mañana solo pudieras llevarte una hoja a una reunión con un equipo técnico, sería esta. Y encaja con el objetivo declarado desde la primera página: formular mejor los problemas **antes** de seleccionar una herramienta y conversar con equipos técnicos con un lenguaje común.

Instrucciones: los dos pasos

El curso define el uso en dos pasos, y ambos son evaluables.

- Paso 1.** Identifica una **tarea candidata**. Descríbela con cuatro elementos: el **resultado esperado**, el **tipo de información disponible**, un **enfoque inicial** y un **riesgo a controlar**. Nota que se te pide un enfoque «inicial», no una decisión: sigue la lógica de la tabla de necesidades del Artículo 3, que el propio curso llama «orientación inicial» y que no reemplaza una evaluación técnica ni jurídica.
- Paso 2.** Completa la matriz **antes de escoger herramienta**. Y la instrucción más valiosa: **si no puedes responder una fila, registra el supuesto o la información que falta**. Es decir, una celda vacía no es un fracaso ni se rellena con optimismo: se convierte en un dato (un supuesto explícito o una

tarea pendiente de conseguir información). Esa disciplina es la que transforma la matriz en un detector de brechas.

ANALOGÍA

La matriz funciona como la lista de verificación previa al despegue de un avión. El piloto más experimentado igual la recorre completa, y no porque dude de su pericia, sino porque los accidentes ocurren en el ítem que «se daba por sabido». Aquí, el ítem que se da por sabido suele ser la línea base («seguro que hoy es lento») o quién responde por el resultado («el área de TI, supongo»).

La matriz de 8 dimensiones

La imagen del PDF trae tres columnas: dimensión, pregunta guía y una columna de respuesta que viene en blanco para que la completes. Reproduzco las dos primeras, que son el contenido fijo del instrumento.

N.º	Dimensión	Pregunta guía
1	Problema	¿Qué tarea, decisión o resultado se busca mejorar?
2	Línea base	¿Cómo funciona hoy y cómo se mide tiempo, costo, calidad o riesgo?
3	Tipo de salida	¿Se necesita una regla, número, categoría, agrupación, acción secuencial o contenido?
4	Evidencia	¿Qué datos, etiquetas, documentos o ejemplos están disponibles?
5	Personas	¿Quién usa, revisa, corrige y responde por el resultado?
6	Riesgo	¿Qué impacto tendría un error sobre personas, operación, reputación o cumplimiento?
7	Piloto	¿Cuál es la prueba mínima, reversible y acotada?
8	Decisión	¿Qué indicadores permitirán escalar, ajustar o detener?

Por qué el orden de las ocho filas importa

Las dimensiones no están en orden alfabético ni de importancia: siguen el orden en que se toman decisiones sin engañarse. Primero se fija el **qué** (filas 1 y 2: problema y línea base), luego el **con qué se resolvería** (filas 3 y 4: salida y evidencia), después el **quién y el cuánto cuesta equivocarse** (filas 5 y 6: personas y riesgo), y por último el **cómo se prueba y cómo se decide** (filas 7 y 8: piloto y decisión). La tecnología concreta, que es lo que la gente quiere discutir primero, no aparece en ninguna fila: es lo que se elige **después** de la matriz. Esa ausencia es la tesis del Artículo 1 hecha formulario: «la tecnología se escoge después de formular el problema».

Cada dimensión, en detalle

1. Problema

Qué pregunta realmente. Pide la tarea, decisión o resultado que se quiere mejorar. No pregunta qué tecnología queremos probar. Es el recuadro «Pregunta de negocio» del Artículo 1: definir la tarea con **un verbo y un resultado observable** (predecir, clasificar, agrupar, recomendar, generar, detectar). **Por qué va primera:** sin ella, las otras siete filas no tienen contra qué medirse. **Respuesta mala:** «implementar IA en atención al cliente», que no tiene verbo observable ni resultado. **Respuesta buena:** «clasificar cada reclamo entrante en una de tres categorías de prioridad, en menos de un minuto desde su ingreso, para que el equipo atienda primero lo urgente».

2. Línea base

Qué pregunta realmente. Cómo se hace hoy la tarea y cómo se mide en tiempo, costo, calidad o riesgo. Es el concepto de **línea base** (*baseline*) del criterio de piloto: la segunda de las siete preguntas del piloto («¿cómo se realiza hoy y cuál es su línea base?») y la segunda de las cinco comprobaciones de «una solución de IA también puede ser innecesaria». **Por qué va segunda:** porque sin línea base cualquier mejora es una opinión. Es también lo que permite medir el «impacto real en la operación» y no solo la precisión estadística, y lo que la gerencia de SurAndes exigía al pedir un resultado medible al término de las doce semanas. **Respuesta mala:** «hoy es lento y se equivocan mucho». **Respuesta buena:** «hoy dos personas leen los reclamos cada mañana; tardan un tiempo medido por una muestra de una semana y, según una revisión posterior de otra muestra, un porcentaje identificado de los urgentes se detecta con retraso». Fíjate en que lo bueno no es la cifra, sino que exista un método para obtenerla; si la cifra falta, se registra como información pendiente, tal como pide el Paso 2.

3. Tipo de salida

Qué pregunta realmente. Qué forma tiene el resultado: **una regla, un número, una categoría, una agrupación, una acción secuencial o contenido**. Esta fila **es** la tabla de las seis necesidades del Artículo 3 (aplicar una política estable, predecir un número o categoría, explorar grupos desconocidos, optimizar decisiones sucesivas, crear o transformar contenido, resolver una tarea combinada) comprimida en una pregunta. Las seis respuestas posibles de la fila se corresponden con los enfoques así: regla con reglas o automatización convencional; número con regresión; categoría con clasificación (ambas, aprendizaje supervisado); agrupación con aprendizaje no supervisado; acción secuencial con aprendizaje por refuerzo; contenido con IA generativa. Cuando la respuesta honesta es «varias a la vez», aparece la **arquitectura híbrida**. **Por qué va tercera:** el tipo de salida es lo que, junto con la evidencia, determina el enfoque; y solo tiene sentido preguntarlo cuando el problema y la línea base están claros. **Respuesta mala:** «una solución inteligente». **Respuesta buena:** «una categoría entre tres, es decir, clasificación», lo que de inmediato abre la pregunta de la fila siguiente: ¿hay etiquetas?

4. Evidencia

Qué pregunta realmente. Qué datos, etiquetas, documentos o ejemplos existen. Aquí entran en juego los cinco componentes de cómo aprende un modelo: datos, representación, entrenamiento, evaluación e inferencia. Si el enfoque es supervisado, se necesitan **etiquetas confiables**; si es no supervisado,

variables pertinentes; si es generativo, **fuentes** aprobadas y derechos de uso. Recuerda dos advertencias del curso: un conjunto numeroso puede seguir siendo insuficiente si repite las mismas condiciones (el caso de las 6.000 fotos de SurAndes, tomadas sobre todo en el turno diurno y de solo dos productos), y los permisos sobre los datos importan tanto como su cantidad (tercera pregunta del piloto: «¿qué datos o contenidos están disponibles y con qué permisos?»). **Respuesta mala:** «tenemos muchos datos». **Respuesta buena:** «tenemos una cantidad definida de reclamos históricos, con un campo de prioridad asignado por quien los atendió; falta verificar si ese campo se asignó con un criterio consistente entre personas y turnos».

5. Personas

Qué pregunta realmente. Quién **usa, revisa, corrige y responde** por el resultado: cuatro verbos, no uno. Es la quinta pregunta del piloto («¿quién revisará los resultados y quién responde por la decisión final?») y la materialización de la **supervisión humana** que el curso reclama en el resumen. Recuerda el módulo 2, unidad 5, donde vimos el **human-in-the-loop**: aquí se baja a nombres y cargos. **Por qué está después de la evidencia:** porque el diseño de la revisión depende de qué tan confiable sea el insumo. **Respuesta mala:** «el sistema lo hace solo» o «el área de TI». **Respuesta buena:** «lo usa el equipo de atención; el supervisor del turno revisa una muestra y todo reclamo marcado como urgente; la jefatura de servicio responde por el resultado».

6. Riesgo

Qué pregunta realmente. Qué impacto tendría un error sobre **personas, operación, reputación o cumplimiento**. Es la aplicación directa del principio de **proporcionalidad**: la gestión del riesgo debe ser proporcional al impacto (el borrador publicitario admite corrección; una recomendación clínica, crediticia o laboral exige controles mucho más rigurosos). Aquí conviene repasar la tabla de los seis riesgos (sesgo, confabulación, privacidad, propiedad intelectual, deepfakes e integridad, sobreconfianza) y marcar cuáles aplican; el enunciado del Paso 1 pide justamente «un riesgo a controlar». También es la fila donde se decide qué tipo de error importa más, vínculo con la idea de que la métrica debe representar el riesgo y la decisión que se quiere apoyar. **Respuesta mala:** «riesgo bajo» sin justificación, o «ninguno». **Respuesta buena:** «el error grave es que un reclamo urgente se clasifique como normal y espere; el error leve es el inverso, que cuesta tiempo de revisión; el riesgo de privacidad existe porque los reclamos contienen datos de clientes».

7. Piloto

Qué pregunta realmente.Cuál es la prueba **mínima, reversible y acotada**. Son tres adjetivos con un criterio cada uno: mínima (la menor prueba que produce evidencia para decidir), reversible (puede detenerse sin interrumpir la operación, como exigía la gerencia de SurAndes) y acotada (un problema delimitado, un responsable de negocio, un plazo). Remite a los criterios de piloto del Artículo 3: «un piloto útil produce evidencia para decidir» y evita los «pilotos demostrativos sin continuidad». Recuerda también la distinción de la Unidad 6 del Módulo 1 entre prueba de concepto, piloto y producto mínimo viable: aquí hablamos de la prueba pequeña que informa la decisión de seguir, no del sistema final. **Respuesta mala:** «desplegar en todas las sucursales». **Respuesta buena:** «seis semanas, una sola sucursal, el sistema sugiere la prioridad y la persona decide; se puede apagar volviendo al procedimiento manual el mismo día».

8. Decisión

Qué pregunta realmente. Qué indicadores permitirán **escalar, ajustar o detener**. Observa que el curso nombra tres salidas posibles, no dos: la decisión no es solo «seguir o no seguir». **Por qué va al final:** porque cierra el círculo con la línea base (fila 2): los indicadores de decisión son la misma métrica, medida de nuevo, más los umbrales acordados de antemano. Es la sexta pregunta del piloto («¿cómo se medirá valor, desempeño técnico y experiencia de las personas usuarias?») y la séptima («¿qué ocurrirá si la solución falla?»). **Respuesta mala:** «veremos cómo nos va». **Respuesta buena:** «escalar si se cumple el umbral de detección de urgentes y baja el tiempo de primera respuesta; ajustar si hay brechas solo en un tipo de reclamo; detener si un reclamo urgente se pierde más de lo tolerado»; los umbrales exactos se fijan antes de empezar, no después de ver los resultados.

CÓMO SE CONECTAN LAS FILAS

Si cambias una respuesta, se mueven las demás. Si en la fila 3 la salida pasa de «categoría» a «contenido» (por ejemplo, redactar la respuesta al cliente), la fila 4 ahora pide fuentes y derechos de uso en vez de etiquetas, la fila 6 suma confabulación y propiedad intelectual, y la fila 5 exige un revisor antes de enviar. La matriz no son ocho casillas independientes, sino un sistema pequeño de restricciones.

El semáforo de factibilidad

Una vez completadas las filas, el curso propone leerlas en conjunto con un semáforo de tres estados. No es una fórmula ni un puntaje: es una lectura de criterio sobre el conjunto.

Estado	Interpretación	Acción
Verde	Problema acotado, datos disponibles, error controlable y responsable definido	Diseñar piloto y línea base
Amarillo	Existen brechas de datos, permisos, métricas o capacidades	Resolver brechas antes de probar
Rojo	Uso de alto impacto sin base, controles ni mecanismos de revisión	Detener y reformular

Léelo con cuidado, porque cada color corresponde a una acción distinta y no a un juicio de valor. **Verde** no significa «aprobado para producción»: significa que se puede **diseñar el piloto y su línea base**, es decir, pasar a las filas 7 y 8 en serio. Sus cuatro condiciones coinciden con cuatro filas de la matriz: problema acotado (fila 1), datos disponibles (fila 4), error controlable (fila 6) y responsable definido (fila 5). **Amarillo** es el estado más frecuente y más útil: hay una idea razonable con brechas de datos, permisos, métricas o capacidades; la acción es **resolver las brechas antes de probar**, y por eso el Paso 2 insiste en registrar qué información falta: esa lista es el plan de trabajo del amarillo. **Rojo** es el único que ordena parar: aparece cuando hay **alto impacto sin base, controles ni mecanismos de revisión**; la acción es **detener y reformular**, no «intentarlo con más cuidado». Reformular puede significar cambiar el problema (usar la tecnología en una tarea de menor impacto), o añadir lo que falta (consentimiento, simulador, revisor) y reevaluar.

ANALOGÍA

Piensa en el semáforo de un cruce. El verde no te dice que vayas rápido, solo que puedes avanzar con atención; el amarillo te pide resolver algo antes de cruzar (frenar, mirar); el rojo te detiene aunque tengas prisa. Un proyecto en rojo con presión de la gerencia sigue en rojo: eso fue lo que ocurrió con las propuestas D y E del caso SurAndes que se explicó en la sección anterior.

Ejemplo completo resuelto (ilustrativo): clasificar reclamos de clientes

Para ver la matriz funcionando con un caso distinto al de SurAndes (que se resolvió entero en la sección del caso), usaré un **ejemplo ilustrativo construido por mí, no tomado del curso**. Supongamos una empresa de distribución mayorista de insumos que recibe reclamos de clientes por correo y por un formulario web. Alguien propone «usar IA para clasificar automáticamente los reclamos en **urgente**, **normal** y **consulta**». Esto es lo que quedaría en el Paso 1 y en cada fila. Todas las cifras son hipotéticas y se señalan como tales; donde no las inventé, se registra el supuesto o la información que falta, que es lo que pide el curso.

Paso 1 (tarea candidata). Resultado esperado: que cada reclamo entrante quede con una de tres prioridades antes de que lo lea una persona. Información disponible: el texto del reclamo, el cliente, el tipo de producto y un campo de «prioridad» que el equipo completa hoy a mano. Enfoque inicial: clasificación supervisada de texto. Riesgo a controlar: que un reclamo urgente quede clasificado como normal.

N. °	Dimensión	Respuesta del ejemplo
1	Problema	Clasificar cada reclamo entrante en urgente, normal o consulta, para que el equipo atienda primero lo que afecta entregas ya comprometidas o seguridad del producto.
2	Línea base	Dos personas leen y priorizan los reclamos cada mañana. Se medirá, con una muestra de una semana, el tiempo desde que llega el reclamo hasta su primera respuesta y cuántos urgentes se detectaron tarde. <i>Información que falta:</i> hoy no existe ninguna de esas dos mediciones (se registra como tarea previa).
3	Tipo de salida	Una categoría entre tres: clasificación, aprendizaje supervisado. No se necesita generar texto en esta etapa.
4	Evidencia	Existen reclamos históricos de dos años con el campo «prioridad». <i>Supuesto a verificar:</i> que el campo se llenó con criterio consistente entre personas y turnos. <i>Información que falta:</i> si los textos contienen datos personales y bajo qué permisos pueden usarse para entrenar o evaluar.
5	Personas	Usa el equipo de atención. Revisa el supervisor del turno: todo lo marcado «urgente» y una muestra del resto. Responde por el resultado la jefatura de servicio al cliente. Hay un responsable de negocio nombrado.
6	Riesgo	Error grave: urgente clasificado como normal (reclamo que espera y daña la relación con un cliente importante, o un tema de seguridad del producto). Error leve: normal clasificado como urgente (cuesta tiempo de revisión). Riesgos de la tabla de seis: sesgo (si las etiquetas históricas reflejan un trato desigual a ciertos clientes), privacidad (datos de clientes en los textos) y sobreconfianza (que el equipo deje de leer lo marcado «normal»). Impacto: moderado y controlable con revisión humana.
7	Piloto	Ocho semanas, una sola sucursal. El sistema sugiere la prioridad; la persona decide. Reversible: se apaga y se vuelve al procedimiento manual el mismo día, sin cambiar el flujo de otras sucursales.
8	Decisión	Se fijan los umbrales antes de empezar. Escalar si baja el tiempo de primera respuesta y la detección de urgentes mejora respecto a la línea base. Ajustar si el fallo se concentra en un tipo de reclamo (agregar ejemplos de ese tipo y reentrenar). Detener si se pierde un urgente por encima del límite acordado o si aparece un problema de privacidad sin resolver.

Lectura del semáforo: amarillo. Justificación, apoyada en la tabla del curso: el problema está acotado (fila 1) y hay un responsable definido (fila 5), el error es controlable porque una persona revisa (filas 6 y 7), y la tecnología es razonable (una clasificación con datos históricos). Pero faltan cosas: no hay línea base medida (fila 2), no se ha verificado la consistencia de las etiquetas ni los permisos sobre los textos (fila 4). Eso encaja con la definición literal de amarillo: «existen brechas de datos, permisos, métricas o capacidades». La acción que el curso asigna es **resolver las brechas antes de probar**: medir una semana de línea base, auditar una muestra de etiquetas históricas con dos revisores, y confirmar con asesoría jurídica el uso de los textos con datos personales. Si esas tres tareas salen bien, el caso pasa a verde y se diseña el piloto formal.

No es rojo porque el error no tiene impacto alto sin controles: hay revisión humana y una salida reversible. Y habría sido rojo si la propuesta fuera, por ejemplo, **responder automáticamente a los clientes sin que nadie revise** temas de seguridad del producto: eso sería «alto impacto sin base, controles ni mecanismos de revisión», con acción «detener y reformular». Esa comparación ilustra por qué el color no depende de la tecnología sino del conjunto de respuestas.

Recordatorio de método: el ejemplo es mío, con fines pedagógicos. Los porcentajes y tiempos reales de una empresa deberían medirse, no estimarse; por eso en las filas 2 y 4 aparecen como información pendiente. Hacer visible esa carencia es parte del instrumento y no un defecto del ejemplo.

Listado de links relevantes: IA generativas

Las páginas 27 a 29 del curso entregan un panorama de herramientas de IA generativa «organizadas en cuatro áreas clave: texto, imágenes, sonido y voz, y video», con la invitación a descubrir «cuáles se adaptan mejor a tus necesidades». El texto introductorio plantea que la IA generativa «ha transformado la creación de contenidos, ofreciendo herramientas especializadas capaces de potenciar la productividad y la creatividad en múltiples formatos», y propone usar el panorama para identificar las soluciones que mejor se adapten a tus proyectos, con la opción de descargar la guía completa desde el botón «Descargar PDF» de la versión online.

Son **26 herramientas**: 9 de texto, 6 de imágenes, 5 de sonido, voz y música, y 6 de video. Un detalle de lectura importante: este listado es una **selección**, no una clasificación técnica ni una recomendación comercial; varias herramientas cruzan áreas (Gemini genera texto y también imágenes y música; Grok y Leonardo.Ai aparecen en una sola área aunque hacen más). Y es la parte de la Unidad que más rápido envejece, tema de la discrepancia 9 al final de esta sección. Las cuatro tablas siguientes recogen, para cada herramienta, lo que dice el curso y un rasgo distintivo para recordar, que es lo que realmente conviene memorizar.

1. Generación y trabajo con texto (9 herramientas)

Herramienta	Empresa / origen (según el curso)	Para qué sirve según el curso	Rasgo distintivo para recordar
Gemini	Google	Asistente multimodal: genera y analiza texto, documentos, imágenes, código y otros contenidos; se integra con servicios del ecosistema Google.	Multimodal y pegado al ecosistema Google.
DeepSeek	Desarrollado en China	Familia de modelos y asistente destacado por razonamiento, programación y modelos abiertos o de acceso relativamente económico.	Razonamiento y programación a bajo costo o con modelos abiertos.
Manus	El curso no indica empresa	Agente de IA que ejecuta tareas de varios pasos con mayor autonomía: investigar, analizar información, producir documentos o desarrollar entregables.	Es un agente (ejecuta pasos), no solo un chat.
Claude	Anthropic	Particularmente fuerte en análisis y producción de textos extensos, razonamiento, documentos y programación.	Textos largos y análisis de documentos.
ChatGPT	OpenAI	Asistente multimodal: texto, imágenes, archivos, investigación, programación y ejecución de tareas mediante herramientas.	Generalista multimodal con herramientas.
Microsoft Copilot	Microsoft	Asistente basado en IA generativa, integrado progresivamente con Microsoft 365 y otras herramientas de productividad.	Vive dentro de Microsoft 365.
Perplexity	El curso no indica empresa	Motor de búsqueda y asistente de investigación: responde con información de la web, incorporando citas y enlaces a las fuentes; útil para búsqueda, investigación y verificación.	Responde con citas y enlaces a fuentes: el de la verificación.
Meta AI	Meta	Asistente integrado con sus modelos Llama y con WhatsApp, Instagram y Facebook; también genera y edita imágenes.	Dentro de las apps sociales de Meta; modelos Llama.
Blackbox AI	El curso no indica empresa	Plataforma vinculada al desarrollo de software, agentes de programación y acceso a múltiples modelos; funciona también como infraestructura para usar cientos de modelos desde una misma plataforma.	Código, y una sola puerta para cientos de modelos.

2. Generación de imágenes (6 herramientas)

Herramienta	Empresa / origen (según el curso)	Para qué sirve según el curso	Rasgo distintivo para recordar
Nano Banana (generación de imágenes de Gemini)	Google	Nombre popular de la familia de modelos de generación y edición de imágenes de Google integrada en Gemini: crea imágenes desde texto y modifica imágenes existentes mediante instrucciones.	Apodo de la generación de imágenes dentro de Gemini.
GPT Image 2 / ChatGPT Images 2.0	OpenAI	Generación y edición de imágenes integrada en ChatGPT; sirve tanto para crear desde cero como para modificaciones precisas de imágenes existentes.	Edición precisa, dentro de ChatGPT.
Leonardo.Ai	El curso no indica empresa	Plataforma especializada en generación visual: crear, editar y transformar imágenes, además de funciones de animación y video.	Especializada en lo visual, con animación y video.
Grok	xAI	Asistente multimodal general que incorpora generación y edición de imágenes además de conversación, búsqueda y razonamiento.	Un asistente general que también hace imágenes.
FLUX / Black Forest Labs	Black Forest Labs	Familia de modelos generativos especializada en imágenes; destaca por calidad visual, seguimiento de prompts y variantes para generación y edición.	Calidad visual y obediencia al prompt.
Adobe Firefly	Adobe	Suite de IA generativa para creación y edición de imágenes, video, audio y gráficos, fuertemente integrada con el ecosistema creativo de Adobe.	Dentro del ecosistema creativo de Adobe.

3. Sonido, voz y música (5 herramientas)

Herramienta	Empresa / origen (según el curso)	Para qué sirve según el curso	Rasgo distintivo para recordar
Suno	El curso no indica empresa	Generador de música: produce canciones completas a partir de una descripción, con instrumentación, letra y voces.	Canción completa desde una descripción.
Udio	El curso no indica empresa	Generación musical con IA; permite crear y transformar música mediante prompts y herramientas de composición y experimentación sonora.	Crear y transformar música por prompts.
Lyria 3	Google DeepMind	Modelo de generación musical integrado en Gemini; convierte instrucciones e incluso referencias visuales en piezas musicales.	Música desde texto o imágenes, dentro de Gemini.
TurboScribe	El curso no indica empresa	Transcripción automática: convierte audio y video en texto y reconoce distintos hablantes; útil para entrevistas y reuniones.	Transcribe e identifica hablantes.
FakeYou	El curso no indica empresa	Generación y transformación de voz: texto a voz, conversión y clonación de voces.	Clonación de voces (riesgo de deepfake).

4. Generación y edición de video (6 herramientas)

Herramienta	Empresa / origen (según el curso)	Para qué sirve según el curso	Rasgo distintivo para recordar
Google Veo	Google DeepMind	Familia de modelos para generar video desde texto o imágenes; sus versiones recientes pueden generar audio, ambientes y diálogos de manera nativa.	Video con audio y diálogos nativos.
VEED	El curso no indica empresa	Plataforma online de creación y edición de video con IA: genera videos, subtítulos, voces, avatares y automatiza tareas de edición.	Edición online con subtítulos, voces y avatares.
Kling AI	Kuaishou	Generación de video e imágenes: texto a video, imagen a video y edición generativa, entre otras funciones.	Texto o imagen a video.
Runway	El curso no indica empresa	Una de las plataformas especializadas en video generativo más conocidas: texto a video, imagen a video y herramientas avanzadas de edición audiovisual.	Video generativo y edición avanzada.
HeyGen	El curso no indica empresa	Videos con avatares y presentadores virtuales: genera videos desde guiones, clona voces y traduce videos manteniendo la sincronización labial.	Avatares que hablan por ti, con voz clonada (riesgo de deepfake).
Wan AI	Ecosistema de Alibaba	Familia de modelos generativos de video orientada a creación desde texto e imágenes.	Video desde texto e imágenes, del ecosistema Alibaba.

Cómo elegir entre ellas para un uso empresarial

El Artículo 1 repetía que la tecnología se elige después de formular el problema. Esto vale también para las herramientas: el listado no responde «¿cuál es la mejor?», sino «¿cuál encaja con lo que formulé en la matriz?». Hay seis criterios que conviene aplicar, y todos se conectan con lo ya visto.

1. Modalidad de entrada y de salida. Parte por la fila 3 de la matriz (tipo de salida). Si necesitas texto, mira el primer grupo; si necesitas una pieza visual, el segundo; si necesitas transcribir una reunión, TurboScribe; si necesitas un video con presentador, HeyGen o VEED. Las herramientas multimodales (Gemini, ChatGPT, Meta AI, Grok) cubren varias a la vez, y el curso recordó en el Artículo 3 que el control debe considerar cada modalidad: una imagen convincente puede esconder un error que una revisión rápida no ve.

2. Qué datos cargas y qué privacidad ofrece. Es el riesgo de **privacidad** de la tabla de seis: «carga, inferencia o exposición de datos personales y sensibles», cuyo control inicial es minimizar datos, anonimizar y utilizar **entornos autorizados**. El listado del curso no dice qué política de datos tiene cada

herramienta, así que esa información debe pedirse al proveedor y revisarse con asesoría jurídica, más aún con la Ley 21.719 en el horizonte (vimos en la sección de Chile el calendario y la discrepancia 7). Regla práctica: ningún dato personal o secreto comercial se carga en una herramienta que no esté autorizada formalmente por la organización. Recuerda el caso SurAndes, donde la propuesta C no tenía definida una «política para cargar documentos internos»: era la condición pendiente.

3. Licencias y propiedad intelectual. El segundo riesgo de la tabla: «uso o generación de material protegido, marcas o secretos comerciales», con control inicial «revisar licencias, procedencia, contratos y uso previsto». La OMPI recomienda identificar los activos involucrados, revisar condiciones de uso, mantener trazabilidad y evaluar salvaguardas. En las herramientas de imágenes, música y video esto pesa más: de qué se alimentó el modelo y qué uso comercial permiten sus términos no se deducen del listado. De ahí que la discrepancia 9 recomiende revisar términos de uso y licencias antes de usar una herramienta en la empresa.

4. Verificación de fuentes: el caso Perplexity. Los modelos generativos infieren lo más probable y no consultan automáticamente una fuente verdadera; de ahí la **confabulación**. El curso destaca que Perplexity responde con **citas y enlaces a las fuentes**, lo que la hace útil para verificación. Cuidado con la lectura exagerada: contar con enlaces facilita comprobar una afirmación, pero no la comprueba por sí mismo; hay que abrir la fuente y confirmar que dice lo que se le atribuye. Es exactamente el matiz de la discrepancia 6: conectar fuentes reduce, pero no elimina, la confabulación.

5. Riesgo de deepfake y clonación de voz. Tres herramientas del listado hacen explícita la capacidad de generar voz o imagen de personas: **FakeYou** (clonación de voces), **HeyGen** (clonar voces, avatares, sincronización labial) y, en menor medida, **VEED** (avatares y voces). Corresponden al riesgo «deepfakes e integridad» de la tabla: «audio, imagen o video sintético capaz de inducir a error», con controles de **etiquetar contenido, preservar trazabilidad y verificar procedencia**. Usarlas con la voz o la imagen de una persona real sin su consentimiento expreso es un problema ético y legal, no una cuestión de «qué tan bien salió»; con consentimiento, por ejemplo, para traducir un video institucional propio, sigue requiriendo etiquetado como contenido sintético.

6. Integración con el ecosistema. Dos herramientas del listado se definen por dónde viven: **Microsoft Copilot**, integrado a Microsoft 365, y **Gemini**, integrado a los servicios de Google (y a Nano Banana, Lyria 3 y, vía Google, Veo). Si la organización ya trabaja en uno de esos ecosistemas, la integración reduce fricción (los datos ya están en un entorno bajo contrato), pero también concentra dependencia. Esto conecta con la última pregunta de piloto: «¿qué ocurrirá si la solución falla, cambia el contexto o deja de estar disponible?». Es el riesgo de la cadena de valor: una herramienta cambia de dueño, de condiciones o de precio, y tu proceso depende de ella (la discrepancia 9 muestra varios ejemplos).

EJEMPLO ILUSTRATIVO

Una empresa necesita transcribir las reuniones semanales y generar tareas. La matriz da: tipo de salida «contenido» (resumen y lista de tareas); evidencia, audios de reuniones con datos de clientes; riesgo, privacidad moderada. Criterios: modalidad (audio a texto: TurboScribe o un asistente multimodal), datos (hay datos de clientes: se requiere un entorno autorizado y revisión de las condiciones del proveedor) y ecosistema (si ya se usa Microsoft 365, evaluar primero Copilot). La elección final no sale del listado

sino de ese cruce, y queda condicionada al semáforo de la matriz, que probablemente sea amarillo hasta aclarar los permisos.

Conexión con los riesgos de la unidad

Mira cómo cada riesgo de la tabla de seis riesgos aparece asociado a un tipo de herramienta: **sesgo** en cualquiera que clasifique o genere imágenes de personas; **confabulación** en todo asistente de texto; **privacidad** en cualquiera donde cargues archivos; **propiedad intelectual** sobre todo en imagen, música y video; **deepfakes e integridad** en voz y avatares; **sobreconfianza** en agentes como Manus, que ejecutan varios pasos con autonomía y por tanto reducen los puntos en que alguien revisa. En el mapa conceptual de esta Unidad esa relación se dibuja como dos enlaces cruzados: herramientas con propiedad intelectual («licencias y derechos») y herramientas con deepfakes («clonación de voz»).

 **Nota (discrepancia 9):** el curso describe 26 herramientas como están a la fecha de su redacción, pero este tipo de listados envejece rápido. A octubre de 2026 la evidencia señala lo siguiente. **Manus** no pertenece a Meta: la compra anunciada en diciembre de 2025 se revirtió y desde agosto de 2026 opera de forma independiente. **Blackbox AI** hoy se presenta sobre todo como plataforma de acceso a más de 300 modelos (el curso ya dice «cientos»). **Nano Banana** ya tiene una segunda versión. **Leonardo.Ai** fue adquirida por Canva. **xAI**, la empresa de Grok, pasó a manos de SpaceX. **Suno y Udio** firmaron acuerdos con discográficas y cambiaron sus condiciones de descarga. **Regla de examen:** memoriza la categoría de cada herramienta (texto, imagen, sonido y voz, video) y su rasgo distintivo, tal como se resume en las tablas de arriba; y, en la práctica, revisa términos de uso y licencias antes de usar cualquiera en la empresa.

Bibliografía comentada

La página 30 reúne siete materiales «utilizados en el desarrollo de la unidad». Una bibliografía no es un adorno: te dice en qué se apoya cada afirmación y, por tanto, cuánto peso darle. Conviene saber de qué fuente viene cada idea, porque así distingues lo que el curso toma de un documento normativo, de una guía institucional o de la documentación de una empresa. A continuación, las siete entradas en el orden del PDF, con lo que cada una aporta. Las URL se transcriben tal como aparecen en el documento del curso, en texto plano.

Entrada	Qué es	Qué aporta a la Unidad
Biblioteca del Congreso Nacional de Chile. <i>Ley 21.719</i> . https://www.bcn.cl/leychile/navegar?idNorma=1209272	Texto de la ley chilena de protección de datos personales, publicada en diciembre de 2024 (13-dic-2024).	El recuadro de Chile: modernización de la Ley 19.628, vigencia el 1 de diciembre de 2026, principios de licitud, finalidad, seguridad y responsabilidad, y creación de la Agencia de Protección de Datos Personales.
Carney, M. et al. (2020). <i>Teachable Machine: Approachable Web-Based Tool for Exploring Machine Learning Classification</i> . https://doi.org/10.1145/3334480.3382839	Artículo del congreso CHI Extended Abstracts 2020 que presenta la herramienta.	La base de la sección de experimentación: herramienta web para clasificar imágenes, sonidos y poses sin código; usa transfer learning sobre MobileNet, entrena en el navegador y retiene el 15 % de las muestras como validación (discrepancia 5).
Google Cloud. <i>Multimodal AI</i> . https://cloud.google.com/use-cases/multimodal-ai	Página de casos de uso de Google Cloud.	La definición de multimodalidad: procesar modalidades como imágenes, videos y texto y combinar entradas y salidas diversas. Es la fuente citada como «Google Cloud, s. f.-b».
Google for Developers. <i>What is Machine Learning?</i> https://developers.google.com/machine-learning/intro-to-ml/what-is-ml?hl=es-419	Material introductorio de aprendizaje automático.	La definición de modelo («una relación matemática derivada de datos»), el rol del tamaño y la diversidad del conjunto, las definiciones de supervisado, no supervisado y refuerzo, y la descripción de lo generativo. Es la fuente más citada (2025, 2026a). De aquí sale además la clasificación en cuatro categorías de la discrepancia 1.
NIST (2024). <i>Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile</i> (NIST.AI.600-1). https://doi.org/10.6028/NIST.AI.600-1	Perfil de IA generativa del marco de gestión de riesgos de IA del NIST, publicado en julio de 2024.	La definición de confabulación y la idea de gestionar riesgos a lo largo de diseño, desarrollo, uso y evaluación. El documento enumera 12 riesgos (discrepancia 10).

OMPI (2024). <i>Generative AI: Navigating Intellectual Property</i> . https://www.wipo.int/publications/en/details.jsp?id=4713	Guía de la Organización Mundial de la Propiedad Intelectual, con principios rectores y una lista de verificación (<i>checklist</i>).	El respaldo de las recomendaciones de propiedad intelectual: identificar los activos involucrados, revisar condiciones de uso, mantener trazabilidad y evaluar salvaguardas. Es una guía, no una norma.
UNESCO. <i>Ética de la inteligencia artificial</i> . https://www.unesco.org/es/artificial-intelligence/recommendation-ethics	Recomendación sobre la Ética de la IA, adoptada en noviembre de 2021 por 193 Estados.	El marco de principios del uso responsable (proporcionalidad, seguridad, privacidad, responsabilidad, transparencia, supervisión humana, sostenibilidad, equidad). La Recomendación tiene 4 valores y 10 principios (discrepancia 3).

Una nota sobre cómo leer el conjunto: de las siete fuentes, tres son **normativas o institucionales** (BCN, OMPI, UNESCO), una es un **marco técnico de gestión de riesgos** (NIST), una es **investigación académica** (Carney et al.) y dos son **documentación de empresa** (las dos de Google). Esa mezcla explica el tono de la Unidad: definiciones técnicas tomadas de la documentación del proveedor, principios éticos tomados de organismos internacionales y obligaciones legales tomadas de la ley local. Por eso el curso insiste en que las organizaciones deben revisar sus obligaciones con asesoría jurídica: ninguna de estas fuentes sustituye ese paso.


Nota (discrepancia 8): la bibliografía lista siete entradas, pero el texto del curso cita más fuentes de las que ahí aparecen. Falta **Vaswani et al. (2017)** («Attention Is All You Need», presentado en NIPS 2017), referencia del Transformer. Además, el texto cita fuentes con marcas que la lista no distingue: «Google for Developers 2026a», «2025», «Google Cloud s. f.-b» y «Google s. f.» (no hay «2026b» ni «s. f.-a»). Por último, el paper de Vaswani se presentó para **traducción automática**, no en general «para producir lenguaje humano». **Regla de examen:** si piden la referencia del Transformer, es Vaswani et al., 2017.

Resumen de la Unidad 2

La página 31 cierra con diez puntos. Los repaso uno por uno, aterrizándolos con dos a cuatro frases y diciendo en qué parte de la explicación se desarrollaron, para que puedas volver al lugar exacto si alguno no te resulta claro.

- Definir la tarea y el resultado antes de la herramienta.** Es la tesis de toda la Unidad. El orden correcto es problema, luego tipo de salida y evidencia, y al final tecnología; invertirlo produce pilotos que buscan un problema. Se desarrolló en el Artículo 1 (recuadro «Pregunta de negocio») y se instrumentó en las filas 1 y 3 de la matriz.

2. **Reglas cuando los procesos son simples, conocidos y estables; ML cuando las relaciones son complejas y hay datos suficientes.** Si una política cabe en tres reglas claras y auditables, un modelo agrega costo y opacidad. El machine learning aporta valor cuando las relaciones son numerosas, variables o difíciles de programar a mano y existen datos pertinentes. Se desarrolló en la sección «De las reglas a los modelos».
3. **Ciclo de vida del aprendizaje: datos, representación, entrenamiento, evaluación con muestras independientes e inferencia.** Son los cinco componentes. La palabra clave es «independientes»: evaluar con los mismos ejemplos del entrenamiento no mide la capacidad de generalizar. Se desarrolló en «¿Cómo aprende un modelo?» y se refleja en las filas de evidencia y piloto.
4. **Aprendizaje supervisado: regresión para números, clasificación para categorías, con datos etiquetados.** La calidad de las etiquetas es el requisito principal: etiquetas sesgadas o inconsistentes producen un modelo que aprende esos problemas. Se desarrolló en el Artículo 2 con la tabla de cuatro problemas.
5. **Aprendizaje no supervisado: estructuras en datos sin etiquetas, que requieren validación e interpretación.** El modelo encuentra grupos, pero nombrarlos y decidir si son útiles exige conocimiento del negocio; los segmentos no son verdades naturales. Se desarrolló en el Artículo 2 (clustering) y reapareció en la propuesta B del caso.
6. **Aprendizaje por refuerzo: secuencias de decisiones con recompensas y penalizaciones, que exigen simulaciones precisas.** Necesita un entorno seguro, una recompensa bien definida y capacidad de simular; sin simulador, el error ocurre en la operación real. Se desarrolló en el Artículo 2 y se aplicó a la propuesta D, descartada. Ver discrepancia 2.
7. **Modelos generativos: respuestas probabilísticas a partir del contexto, sin verificar de forma autónoma la veracidad.** Generan secuencias a partir de patrones estadísticos y contexto, infiriendo lo más probable (el ejemplo de la corona y el príncipe). De ahí nace la confabulación. Se desarrolló en «De predecir a generar» y en el Transformer; ver discrepancia 6.
8. **Multimodalidad: integra entradas y salidas de texto, imagen, audio y video.** Permite analizar una fotografía junto con su ficha técnica, convertir una reunión en transcripción y tareas, o generar piezas adaptadas a distintos canales, siempre con control por modalidad. Se desarrolló en la sección de multimodalidad y se ve en las herramientas del listado.
9. **Uso responsable: mitigar sesgos, alucinaciones, brechas de privacidad y riesgos legales con supervisión humana proporcional al impacto.** La palabra decisiva es «proporcional»: el control se gradúa según lo que cueste el error. Se desarrolló en «Riesgos y uso responsable» (tabla de seis riesgos, NIST, UNESCO, Chile, propiedad intelectual) y es la fila 6 de la matriz.
10. **Pilotos: línea base clara, datos autorizados, límites de error definidos y responsables asignados.** Un piloto útil produce evidencia para decidir; sin línea base no hay mejora medible, sin autorización no hay datos legítimos, sin límites de error no hay criterio de éxito y sin responsables nadie decide. Se desarrolló en los criterios de piloto, en el caso SurAndes (donde se aprobó solo la propuesta C) y en las filas 2, 4, 5, 7 y 8 de la matriz.

Índice de discrepancias ⚠

Doce puntos donde el curso y la evidencia disponible no coinciden del todo, o donde falta información. En todos los casos la versión del curso es la que se evalúa; la columna final indica qué responder.

N. °	Tema	Qué dice el curso	Qué dice la evidencia	Regla de examen
1	¿Tres o cuatro tipos de aprendizaje?	Tres enfoques (supervisado, no supervisado, refuerzo); lo generativo se trata aparte.	La fuente que cita (Google for Developers) clasifica en cuatro categorías, sumando IA generativa, y dice que un sistema puede pertenecer a una o más.	Según el curso, tres; según Google, cuatro. Las categorías no son excluyentes.
2	Refuerzo «cobra protagonismo en producción»	Suele quedar fuera de los primeros pilotos, pero cobra protagonismo una vez en producción.	La fuente citada no lo respalda; se ilustra con juegos y robótica y es frágil ante recompensas mal especificadas (CoastRunners, OpenAI, 2016). Exige entorno, simulador y recompensa definida.	Rara vez es el primer piloto por complejidad y costo; necesita entorno seguro o simulador. No argumentar que «en producción domina».
3	UNESCO: 8 principios vs 10	Nombra ocho: proporcionalidad, seguridad, privacidad, responsabilidad, transparencia, supervisión humana, sostenibilidad y equidad.	La Recomendación (nov-2021, 193 Estados) tiene 10 principios; faltan sensibilización y educación, y gobernanza y colaboración adaptativas; los nombres completos son más amplios.	«Según el curso», 8; «cuántos tiene la Recomendación», 10.
4	«Precisión promedio» no es precision	Un modelo puede tener buena precisión promedio y fallar en el segmento más relevante.	En términos técnicos eso es accuracy (exactitud); precision es otra métrica: de lo marcado positivo, cuánto lo era.	La idea es correcta; en ejercicios técnicos distinguir accuracy, precision y recall.
5	Teachable Machine: «entrenamiento y prueba»	Revisar la distribución de muestras para entrenamiento y prueba.	La herramienta retiene automáticamente el 15 % de cada clase como validación (no una prueba independiente); usa transfer learning sobre MobileNet y entrena en el navegador.	En el examen, las palabras del curso; en un proyecto real, separar entrenamiento, validación y prueba.
6	«No consultan una fuente verdadera»	Los generativos generan lo más probable y no verifican de forma autónoma la veracidad.	Cierto para el modelo base; muchos productos actuales lo combinan con búsqueda o documentos, lo que reduce pero no elimina la confabulación. El ejemplo del príncipe es asociación	Responder lo del curso; si preguntan por mitigación, mencionar conectar fuentes y verificar.

			estadística, no razonamiento garantizado.	
7	Ley 21.719: fecha en disputa	Entra en vigor el 1 de diciembre de 2026.	Es la fecha legal vigente, pero el 1-sep-2026 el Gobierno ingresó un proyecto para postergarla al 1-dic-2027, en trámite a fines de septiembre de 2026. El proyecto de ley de IA sigue en el Senado.	Responder 1-dic-2026 y agregar que hay un proyecto de postergación en trámite.
8	Bibliografía incompleta	Siete entradas.	Se cita además Vaswani et al. (2017) y fuentes con marcas (2026a, 2025, s. f.-b, Google s. f.) que la lista no separa. Vaswani se presentó para traducción automática.	Referencia del Transformer: Vaswani et al., 2017.
9	El listado de herramientas envejece rápido	Describe 26 herramientas.	A octubre de 2026: Manus es independiente; Blackbox AI es hoy plataforma de más de 300 modelos; Nano Banana tiene segunda versión; Leonardo.Ai es de Canva; xAI pasó a SpaceX; Suno y Udio firmaron acuerdos con discográficas.	Memorizar categoría y rasgo distintivo; revisar términos de uso y licencias antes de usar una herramienta.
10	NIST: más riesgos y otra estructura	Gestionar riesgos desde el diseño, desarrollo, uso y evaluación; nombra confabulación, privacidad, sesgo, integridad, propiedad intelectual y relación persona-sistema.	El perfil AI 600-1 enumera 12 riesgos (incluye además QBRN, contenido violento u obsceno, impacto ambiental, seguridad de la información y cadena de valor); el marco base (AI RMF 1.0, 2023) tiene cuatro funciones: Gobernar, Mapear, Medir, Gestionar.	La definición de confabulación es fiel a NIST; si piden la estructura del marco, las cuatro funciones.
11	Partes que solo están online	Video resumen, video de Teachable Machine (profesor Rodrigo Pereira, con expresiones faciales) y su PDF descargable, solo en la versión online.	Esas piezas no vienen en el PDF; la explicación se reconstruye desde el texto del curso y el paper de Teachable Machine.	Antes del examen, revisar esos recursos online (disponibles hasta el 30-nov-2026).
12	Teachable Machine con	El video usa expresiones faciales como ejercicio	No hay contradicción: cambia el uso (ejercicio	El criterio es el del caso: sin

	rostros vs Propuesta E	didáctico; el caso descarta inferir el ánimo del personal por expresión facial.	personal y consentido vs vigilancia de trabajadores). Inferir emociones de rostros es científicamente discutido y la Ley de IA de la UE prohíbe el reconocimiento de emociones en el lugar de trabajo.	consentimiento ni relación válida, se descarta.
--	---------------------------	--	---	---

Glosario

Los 123 términos técnicos de la unidad, agrupados por categoría. Cada uno es también una flashcard del archivo interactivo.

Fundamentos

Término	Inglés	Definición
Inteligencia artificial (IA)	<i>Artificial Intelligence (AI)</i>	Campo que reúne tecnologías capaces de realizar tareas asociadas con percepción, lenguaje, aprendizaje, razonamiento o decisión.
Aprendizaje automático	<i>Machine Learning (ML)</i>	Enfoque que entrena modelos con datos para producir predicciones, clasificaciones o contenido sin programar una regla para cada caso.
Aprendizaje profundo	<i>Deep Learning</i>	Subcampo del machine learning que usa redes neuronales con múltiples capas para aprender patrones complejos.
Red neuronal de múltiples capas	<i>Multilayer neural network</i>	Modelo formado por capas de unidades conectadas; cada capa transforma la salida de la anterior en rasgos más abstractos.
Familia de tecnologías de IA	<i>AI technology family</i>	La IA incluye reglas, búsqueda y optimización, ML, procesamiento de lenguaje, visión computacional y sistemas generativos.
Sistema basado en reglas	<i>Rule-based system</i>	Software que sigue instrucciones explícitas escritas por personas: si ocurre A, ejecute B.
Automatización convencional	<i>Conventional automation</i>	Automatizar con reglas fijas; es más eficiente, barata y transparente que el ML cuando la política es estable.
Búsqueda y optimización	<i>Search and optimization</i>	Técnicas de IA que exploran alternativas para encontrar la mejor solución según un criterio.
Procesamiento de lenguaje natural (PLN)	<i>Natural Language Processing (NLP)</i>	Área de la IA que permite a las máquinas comprender y producir lenguaje humano.
Visión computacional	<i>Computer vision</i>	Área de la IA que permite a las máquinas interpretar imágenes y video.
Superposición de categorías	<i>Overlapping categories</i>	Una solución real combina varias tecnologías, por ejemplo un modelo de lenguaje, un clasificador, búsqueda y reglas.
Pregunta de negocio	<i>Business question</i>	Definir la tarea con un verbo y un resultado observable antes de hablar de modelos o herramientas.
Resultado observable	<i>Observable outcome</i>	Efecto concreto y medible que se quiere producir: predecir, clasificar, agrupar, recomendar, generar o detectar.

Opacidad	<i>Opacity</i>	Dificultad para entender por qué un sistema decide lo que decide; es un costo que agrega un modelo frente a reglas claras.
Auditable	<i>Auditable</i>	Que una persona puede revisar y verificar cómo se tomó una decisión.

Cómo aprende un modelo

Término	Inglés	Definición
Modelo	<i>Model</i>	Representación matemática aprendida de los datos que transforma una entrada en una predicción, clasificación o contenido.
Datos de entrenamiento	<i>Training data</i>	Ejemplos usados para ajustar el modelo y que aprenda patrones.
Representación	<i>Representation</i>	Decisión de qué elementos funcionarán como entradas del modelo: columnas de una tabla, píxeles o palabras.
Característica	<i>Feature</i>	Variable o atributo de entrada, como antigüedad, frecuencia de compra, píxeles o palabras.
Datos tabulares	<i>Tabular data</i>	Datos organizados en filas y columnas, como una planilla o una tabla de base de datos.
Píxel	<i>Pixel</i>	Punto mínimo de una imagen digital; sus valores numéricos son la entrada de un modelo de visión.
Entrenamiento	<i>Training</i>	Proceso en que el algoritmo ajusta los parámetros del modelo para reducir la diferencia entre sus resultados y los esperados.
Parámetros	<i>Parameters</i>	Números internos del modelo que se ajustan durante el entrenamiento.
Hiperparámetros	<i>Hyperparameters</i>	Configuraciones que se fijan antes de entrenar, como épocas, tamaño de lote o tasa de aprendizaje.
Función de pérdida	<i>Loss function</i>	Fórmula que mide cuánto se equivoca el modelo; entrenar es hacerla lo más pequeña posible.
Evaluación	<i>Evaluation</i>	Medición del desempeño del modelo con datos distintos de los que usó para entrenar.
Conjunto de validación	<i>Validation set</i>	Parte de los datos reservada para revisar el modelo mientras se ajusta; Teachable Machine aparta el 15 %.
Conjunto de prueba	<i>Test set</i>	Datos que el modelo nunca vio, usados al final para estimar su desempeño real.
Inferencia	<i>Inference</i>	Uso del modelo ya entrenado para producir un resultado frente a una entrada nueva.
Generalización	<i>Generalization</i>	Capacidad del modelo de acertar en casos nuevos, no solo en los que vio al entrenar.

Sobreajuste	<i>Overfitting</i>	Cuando el modelo memoriza el entrenamiento y falla con datos nuevos.
Diversidad de los datos	<i>Data diversity</i>	Variedad de condiciones en los ejemplos (ángulos, luz, fondos); pesa tanto como la cantidad.
Representatividad	<i>Representativeness</i>	Grado en que los datos reflejan las condiciones reales donde operará el modelo.
Desempeño estadístico	<i>Statistical performance</i>	Qué tan bien acierta el modelo según una métrica técnica.
Utilidad empresarial	<i>Business utility</i>	Valor real que el modelo aporta a la decisión, considerando el costo de cada tipo de error.
Exactitud	<i>Accuracy</i>	Proporción de todas las predicciones que fueron correctas; es la «precisión promedio» del curso.
Precisión (métrica)	<i>Precision</i>	De todo lo que el modelo marcó como positivo, qué proporción lo era de verdad.
Sensibilidad	<i>Recall</i>	De todos los positivos reales, qué proporción detectó el modelo.
Falso positivo (alerta falsa)	<i>False positive</i>	El modelo da una alerta y no había problema.
Falso negativo	<i>False negative</i>	El modelo no alerta y sí había problema.
Métrica orientada al riesgo	<i>Risk-oriented metric</i>	Indicador elegido según la decisión y el costo de equivocarse, no solo según el acierto promedio.

Tipos de aprendizaje

Término	Inglés	Definición
Aprendizaje supervisado	<i>Supervised learning</i>	Aprendizaje con ejemplos etiquetados; se usa principalmente para regresión y clasificación.
Etiqueta	<i>Label</i>	Resultado conocido que acompaña un ejemplo, como fraude, defecto o nivel de demanda.
Etiquetas confiables	<i>Reliable labels</i>	Respuestas históricas sin sesgos, criterios inconsistentes ni errores de registro; requisito principal del supervisado.
Regresión	<i>Regression</i>	Tarea supervisada que estima un valor numérico, como demanda semanal o minutos de despacho.
Clasificación	<i>Classification</i>	Tarea supervisada que estima una categoría, como spam o legítimo, defectuoso o correcto.
Clasificador	<i>Classifier</i>	Modelo que asigna cada entrada a una de varias clases.
Aprendizaje no supervisado	<i>Unsupervised learning</i>	Aprendizaje con datos sin etiquetas, orientado a encontrar patrones, similitudes o agrupaciones.
Agrupamiento	<i>Clustering</i>	Técnica no supervisada que reúne casos parecidos en grupos que no estaban definidos.
Segmento	<i>Segment</i>	Grupo de clientes o casos con comportamiento parecido; su nombre y sentido los pone el negocio.
Caso atípico	<i>Outlier / anomaly</i>	Dato que se aleja claramente del comportamiento habitual del resto.
Aprendizaje por refuerzo	<i>Reinforcement learning</i>	Un agente aprende por acciones, recompensas y penalizaciones dentro de un entorno.
Agente	<i>Agent</i>	Quien toma las acciones en el aprendizaje por refuerzo.
Entorno	<i>Environment</i>	El mundo, real o simulado, donde actúa el agente y que responde a sus acciones.
Recompensa	<i>Reward</i>	Señal numérica que premia o castiga cada acción del agente.
Política	<i>Policy</i>	Regla aprendida que indica qué acción tomar en cada situación para maximizar la recompensa acumulada.
Recompensa acumulada	<i>Cumulative reward</i>	Suma de recompensas a lo largo de una secuencia de decisiones; es lo que el agente maximiza.

Recompensa incompleta	<i>Misspecified reward</i>	Recompensa mal diseñada que incentiva conductas inconvenientes no previstas.
Optimización secuencial	<i>Sequential optimization</i>	Mejorar una cadena de decisiones donde cada una afecta a las siguientes.
Simulador	<i>Simulator</i>	Entorno artificial donde el agente puede equivocarse sin dañar la operación real.

IA generativa y multimodal

Término	Inglés	Definición
Modelo predictivo	<i>Predictive model</i>	Modelo que estima un valor o una categoría.
Modelo generativo	<i>Generative model</i>	Modelo que aprende regularidades de grandes colecciones de datos para producir contenido nuevo.
IA generativa	<i>Generative AI</i>	IA que crea o transforma texto, código, imágenes, audio y video a partir de una entrada.
Transformer	<i>Transformer</i>	Arquitectura de red neuronal presentada en 2017 basada en el mecanismo de atención; base de los modelos de lenguaje actuales.
Mecanismo de atención	<i>Attention mechanism</i>	Pondera cuánto se relaciona cada elemento del contexto con los demás para decidir qué importa.
Contexto	<i>Context</i>	Información de entrada que el modelo considera para producir su respuesta.
Token	<i>Token</i>	Fragmento de texto (palabra o parte de palabra) con el que trabaja un modelo de lenguaje.
Predicción del siguiente token	<i>Next-token prediction</i>	Mecanismo por el que un modelo de lenguaje genera texto eligiendo, paso a paso, la continuación más probable.
Modelo de lenguaje	<i>Language model</i>	Modelo que estima la probabilidad de secuencias de texto y genera continuaciones.
Instrucción (prompt)	<i>Prompt</i>	Texto que entrega al modelo una tarea, información y condiciones de salida.
Multimodalidad	<i>Multimodality</i>	Capacidad de procesar y combinar distintos tipos de datos (texto, imagen, audio, video) en entradas y salidas.
Modalidad	<i>Modality</i>	Tipo de dato: texto, imagen, audio, video o código.
Arquitectura híbrida	<i>Hybrid architecture</i>	Solución que combina reglas, modelos predictivos y generativos con un flujo, controles y responsables.
Búsqueda documental	<i>Document retrieval</i>	Componente que recupera documentos relevantes para que el modelo responda con fuentes.

Riesgos y regulación

Término	Inglés	Definición
Teachable Machine	<i>Teachable Machine</i>	Herramienta web de Google para crear clasificadores de imágenes, sonidos y poses sin escribir código.
Aprendizaje por transferencia	<i>Transfer learning</i>	Reutilizar un modelo ya entrenado y ajustarlo con pocos ejemplos nuevos; es lo que hace Teachable Machine.
Correlación espuria (atajo)	<i>Shortcut / spurious correlation</i>	Patrón accidental que el modelo aprende en lugar del objeto real, como el fondo de la foto.
Confianza del modelo	<i>Model confidence</i>	Probabilidad que el modelo asigna a su respuesta; no garantiza que sea correcta.
Ciclo de vida de la IA	<i>AI lifecycle</i>	Etapas de diseño, desarrollo, uso y evaluación en las que deben gestionarse los riesgos.
Principios UNESCO	<i>UNESCO AI ethics principles</i>	Recomendación de 2021: proporcionalidad, seguridad, privacidad, responsabilidad, transparencia, supervisión humana, sostenibilidad y equidad, entre otros.
Marco de gestión de riesgos de NIST	<i>NIST AI Risk Management Framework</i>	Guía estadounidense para gestionar riesgos de IA; su perfil generativo es el NIST AI 600-1 (2024).
Sesgo	<i>Bias</i>	Error sistemático por datos poco representativos, etiquetas históricas o desempeño desigual entre grupos.
Confabulación (alucinación)	<i>Confabulation / hallucination</i>	Contenido falso o erróneo presentado con falsa certeza de veracidad.
Privacidad	<i>Privacy</i>	Riesgo de cargar, inferir o exponer datos personales y sensibles.
Anonimización	<i>Anonymization</i>	Quitar o transformar datos para que no se pueda identificar a las personas.
Minimización de datos	<i>Data minimization</i>	Usar solo los datos personales estrictamente necesarios para el fin declarado.
Propiedad intelectual	<i>Intellectual property</i>	Derechos sobre obras, marcas y secretos comerciales que pueden infringirse al usar o generar contenido.
Deepfake	<i>Deepfake</i>	Audio, imagen o video sintético capaz de inducir a error sobre lo que alguien dijo o hizo.
Integridad de la información	<i>Information integrity</i>	Que el contenido sea verificable y no engañe sobre su origen o veracidad.

Trazabilidad	<i>Traceability</i>	Poder rastrear el origen, la procedencia y los cambios de un contenido o una decisión.
Contenido sintético	<i>Synthetic content</i>	Contenido producido por IA; debe etiquetarse y rastrearse.
Sobreconfianza	<i>Overreliance</i>	Delegar en exceso o aceptar resultados del sistema sin revisión.
Supervisión humana	<i>Human oversight</i>	Personas que revisan, corrigen y responden por lo que produce el sistema.
Umbral de escalamiento	<i>Escalation threshold</i>	Nivel de riesgo o duda a partir del cual el caso pasa a revisión humana.
Proporcionalidad	<i>Proportionality</i>	Los controles deben crecer con el impacto de la decisión: un borrador publicitario no es una recomendación clínica.
Ley 19.628	<i>Chilean Law 19,628</i>	Ley chilena de protección de la vida privada que rige hoy el tratamiento de datos personales.
Ley 21.719	<i>Chilean Law 21,719</i>	Ley chilena que moderniza la protección de datos personales; publicada en dic-2024, vigencia legal 1-dic-2026.
Agencia de Protección de Datos Personales	<i>Personal Data Protection Agency</i>	Organismo chileno creado por la Ley 21.719 para fiscalizar el tratamiento de datos.
Consentimiento	<i>Consent</i>	Autorización específica de la persona para un uso determinado de sus datos.
OMPI	<i>WIPO</i>	Organización Mundial de la Propiedad Intelectual; recomienda identificar activos, revisar condiciones de uso, mantener trazabilidad y evaluar salvaguardas.

Piloto y decisión

Término	Inglés	Definición
Prueba piloto	<i>Pilot</i>	Prueba acotada que produce evidencia para decidir si escalar, ajustar o detener una solución.
Línea base	<i>Baseline</i>	Medición de cómo funciona hoy el proceso (tiempo, costo, calidad o riesgo) para comparar después.
Piloto demostrativo	<i>Showcase pilot</i>	Prueba que impresiona pero no tiene continuidad ni sirve para decidir.
Error tolerable	<i>Tolerable error</i>	Equivocación que el negocio puede absorber y corregir sin daño serio.
Responsable de negocio	<i>Business owner</i>	Persona que responde por la decisión final y por los resultados del piloto.
Reversibilidad	<i>Reversibility</i>	Que la solución pueda detenerse o deshacerse sin interrumpir la operación.
Operario en el circuito	<i>Human in the loop</i>	Una persona revisa y decide sobre lo que el sistema sugiere.
Saneamiento de datos	<i>Data cleansing</i>	Corregir, unificar y depurar datos antes de usarlos en un modelo.
Gobernanza de datos	<i>Data governance</i>	Reglas, roles y responsables sobre cómo se gestionan y usan los datos de una organización.
Matriz de evaluación de oportunidad de IA	<i>AI opportunity assessment matrix</i>	Herramienta del curso con 8 dimensiones: problema, línea base, tipo de salida, evidencia, personas, riesgo, piloto y decisión.
Semáforo de factibilidad	<i>Feasibility traffic light</i>	Verde: diseñar piloto; amarillo: resolver brechas antes de probar; rojo: detener y reformular.
Brecha de información	<i>Information gap</i>	Dato o supuesto que falta para decidir; se registra en la matriz.

Herramientas generativas

Término	Inglés	Definición
Asistente generativo de texto	Text generation assistant	Herramienta conversacional que genera y analiza texto, como Gemini, Claude, ChatGPT, Copilot o Meta AI.
Agente de IA	AI agent	Sistema que ejecuta tareas de varios pasos con mayor autonomía, como Manus.
Buscador con IA y citas	AI answer engine	Asistente que responde con información de la web y enlaces a sus fuentes, como Perplexity.
Modelo abierto	Open-weight model	Modelo cuyos pesos se publican para descargarlo y usarlo, como algunos de DeepSeek o FLUX.
Generador de imágenes	Image generator	Herramienta que crea o edita imágenes desde texto, como Nano Banana, GPT Image, FLUX o Firefly.
Generador de música	Music generator	Herramienta que compone canciones desde una descripción, como Suno, Udio o Lyria 3.
Transcripción automática	Automatic transcription	Conversión de audio o video a texto distinguiendo hablantes, como TurboScribe.
Clonación de voz	Voice cloning	Imitar la voz de una persona con IA; útil y riesgosa (deepfakes y derechos de imagen).
Texto a video	Text-to-video	Generación de video a partir de una descripción escrita, como Veo, Kling, Runway o Wan.
Avatar virtual	Virtual avatar	Presentador sintético que habla un guion, como en HeyGen o VEED.
Sincronización labial	Lip sync	Ajustar el movimiento de los labios de un video a un audio nuevo, por ejemplo al traducirlo.

Mapa conceptual

El árbol siguiente reúne todos los conceptos de la Unidad, con la relación verbal que une cada rama a la raíz. Úsalo como índice mental: si recuerdas las siete ramas, puedes reconstruir la Unidad.

Tecnologías clave para la IA generativa

└─[parte de] Conceptos y familia (azul)

| └─ Familia de tecnologías: reglas · búsqueda y optimización · machine learning · procesamiento de lenguaje · visión · generativos

| | └─ Deep learning (subcampo del ML, redes de múltiples capas)

- | └ Las categorías se superponen: un asistente = LLM + clasificador + búsqueda + reglas
- | └ Pregunta de negocio: un verbo y un resultado observable (predecir, clasificar, agrupar, recomendar, generar, detectar)
- | └ Reglas vs modelos: si A entonces B · cuándo el ML aporta valor · tres reglas auditables
- | ─[se construye con] Cómo aprende un modelo (verde)
- | └ Datos · Representación (características, píxeles) · Entrenamiento (parámetros, reducir la diferencia)
- | └ Evaluación (datos no vistos, generalizar) · Inferencia
- | └ Datos y contexto: la cantidad no basta, la diversidad sí (bodega: ángulos, luz, fondos)
- | └ Desempeño estadístico ≠ utilidad empresarial (precisión promedio, alertas falsas, error costoso)
- | ─[se elige entre] Tipos de aprendizaje (ámbar)
- | └ Supervisado → regresión · clasificación · tabla de cuatro problemas · etiquetas confiables
- | └ No supervisado → clustering · usos · los segmentos no son verdades naturales
- | └ Por refuerzo → agente, entorno, acciones, recompensa, política · recompensa incompleta · fuera de los primeros pilotos
- | ─[evoluciona a] IA generativa (violeta)
- | └ De predecir a generar (texto, código, imagen, audio, video; transformar entre modalidades)
- | └ Transformer y atención (2017)
- | └ Secuencias probables, no fuente verdadera → ejemplo del rey
- | └ Prompt (tarea, información, condiciones de salida)
- | └ Multimodalidad → usos · control por modalidad
- | └ Matriz necesidad → enfoque → condición crítica → arquitectura híbrida · IA innecesaria (cinco comprobaciones)
- | ─[exige] Riesgos y uso responsable (coral)
- | └ Teachable Machine → siete pasos · observación clave: atajos, aprende el fondo
- | └ Marcos: UNESCO (principios) · NIST (ciclo de vida)
- | └ Tabla de seis riesgos → sesgo · confabulación · privacidad · propiedad intelectual · deepfakes e integridad · sobreconfianza
- | └ Proporcionalidad al impacto (borrador publicitario vs recomendación clínica, crediticia o laboral)
- | └ Chile: Ley 19.628 → Ley 21.719 · Agencia de Protección de Datos Personales · OMPI
- | ─[se decide con] Piloto, caso y matriz (cian)
- | └ Criterios de piloto: siete preguntas · línea base
- | └ Caso SurAndes → A visión · B segmentación · C generativa (elegida) · D refuerzo · E detector de ánimo · decisión de Marcela Riquelme
- | └ Matriz de 8 dimensiones → semáforo verde, amarillo, rojo
- | ─[se apoya en] Herramientas generativas (gris)
 - | └ Texto (9): Gemini · DeepSeek · Manus · Claude · ChatGPT · Microsoft Copilot · Perplexity · Meta AI · Blackbox AI

└─ Imágenes (6): Nano Banana · GPT Image 2 / ChatGPT Images 2.0 · Leonardo.Ai · Grok
· FLUX · Adobe Firefly
└─ Sonido, voz y música (5): Suno · Udio · Lyria 3 · TurboScribe · FakeYou
└─ Video (6): Google Veo · VEED · Kling AI · Runway · HeyGen · Wan AI

Enlaces cruzados entre ramas

Además de la jerarquía, hay relaciones que cruzan ramas y que conviene tener presentes porque son frecuentes en las preguntas de aplicación:

- Machine learning → deep learning, «subcampo».
- Etiquetas confiables → sesgo, «etiquetas sesgadas producen un modelo sesgado».
- Diversidad de datos → atajos, «poca diversidad lleva a atajos».
- Teachable Machine → aprendizaje supervisado, «es clasificación supervisada».
- Desempeño estadístico vs utilidad → línea base, «se mide contra la línea base».
- Secuencias probables → confabulación, «origen de la confabulación».
- Propuesta A (inspección visual) → aprendizaje supervisado, «clasificador»; y → diversidad de datos, «turno diurno, dos productos».
- Propuesta B (segmentación) → aprendizaje no supervisado, «clustering».
- Propuesta D (despacho dinámico) → aprendizaje por refuerzo, «recompensas, sin simulador».
- Propuesta E (detector de ánimo) → privacidad, «sin consentimiento».
- Propuesta C (fichas y contenidos) → IA generativa; y → sobreconfianza, «revisor humano».
- Tabla de necesidades → matriz de 8 dimensiones, «se profundiza en».
- Herramientas generativas → propiedad intelectual, «licencias y derechos»; y → deepfakes, «clonación de voz».

Conexiones con unidades previas

La Unidad 2 no parte de cero; reutiliza y profundiza cuatro bloques de conocimiento previo.

- **Módulo 3, Unidad 1:** Transformer, modelos de lenguaje, preentrenamiento y ajuste fino, IA generativa, sesgo algorítmico (COMPAS), Ley 21.719 y los casos AutoTech, ShopSmart y FinAI. Esta Unidad profundiza en cómo aprende un modelo y en cómo elegir la tecnología.
- **Módulo 1, Unidad 3:** aprendizaje supervisado, característica, etiqueta, regresión, clasificación y métricas; es la base de la distinción entre accuracy, precision y recall de la discrepancia 4.
- **Módulo 1, Unidad 6:** del prototipo a producción, con piloto, prueba de concepto y producto mínimo viable; sostiene los criterios de piloto y las filas 7 y 8 de la matriz.
- **Módulo 2, Unidad 5:** ética, sesgo, transparencia, *human-in-the-loop* y gobernanza; sostiene la fila 5 de la matriz (personas) y el principio de supervisión humana proporcional al impacto.