

Unidad 5 · **Responsabilidad social y ética profunda**

La Unidad 4 te dejó parado en el terreno de la **gestión del cambio**: cómo una organización mueve personas, procesos y cultura para que una implementación de IA no muera en el escritorio del gerente que la aprobó. Esta unidad da el paso siguiente y, con él, cierra el arco del curso. Ya no se trata de cómo se instala la tecnología ni de cómo se vence la resistencia organizacional a usarla; se trata de con qué criterios esa tecnología se sostiene en el tiempo sin destruir lo que se supone que debía proteger. El eje ya no es la adopción, es la **confianza**, y el material que la sostiene ya no es un plan de gestión del cambio, es un marco de **ética y gobernanza**. Todo lo técnico que viste en unidades anteriores —modelos, prototipos, ciclos de proyecto— sigue siendo condición necesaria, pero esta unidad argumenta, con datos y con un caso completo, que deja de ser condición suficiente en el momento en que la IA empieza a decidir sobre personas.

Los objetivos de la unidad

El curso organiza la apertura de cada unidad en tres preguntas —para qué estamos aquí, qué haremos, para qué nos servirá— y en esta unidad esas tres preguntas no son un formalismo: son la explicación de por qué el diplomado decide terminar exactamente aquí. La primera pregunta, *¿para qué estamos aquí?*, plantea algo que suena obvio dicho así pero que es fácil de olvidar en la práctica: el éxito de un proyecto de IA no se mide solo por su complejidad técnica —qué tan sofisticado es el modelo, qué tan alta es su exactitud— sino por si la organización logra sostenerlo con criterios éticos, con responsabilidad frente a sus efectos y, sobre todo, con la confianza de quienes lo usan y de quienes son afectados por él. Es la misma lógica que vertebra toda la unidad: un sistema técnicamente excelente que nadie entiende, que nadie supervisa y en el que nadie confía, es un sistema que fracasa, por más preciso que sea.

La segunda pregunta, *¿qué haremos?*, es en realidad el índice de la unidad disfrazado de pregunta: vas a entender por qué la confianza se volvió decisiva en esta etapa del recorrido, qué riesgos concretos aparecen cuando la IA pasa de sugerir a intervenir en decisiones, qué aportan la **ética profunda** y la **responsabilidad social** como marcos de pensamiento —no como eslóganes corporativos—, qué función cumple la **gobernanza de la IA** como mecanismo operativo de esos principios, qué dicen los principales marcos internacionales al respecto, y qué distingue en la práctica a las organizaciones que ya incorporaron estos criterios de las que no. Nota que el orden no es casual: primero el problema (confianza), después el diagnóstico (riesgos y sesgo), después la respuesta a

nivel de principios (ética), después la respuesta a nivel de estructura (gobernanza), y por último la evidencia de que esto ya está estandarizado externamente (marcos internacionales). Es exactamente el orden en que vas a leer el resto del documento.

La tercera pregunta, *¿para qué nos servirá?*, es la más importante para tu rol como profesional que ya sabe de IA y se está especializando: no se trata de que memorices definiciones para un control —aunque el control existe y las definiciones se evalúan literalmente— sino de que salgas de esta unidad con cuatro capacidades que no dependen del framework de moda: poder analizar una implementación de IA desde una perspectiva organizacional amplia y no solo desde la métrica del modelo; poder reconocer, en un caso real, las tensiones éticas y sociales que un sistema introduce aunque nadie las haya puesto en el documento de requerimientos; poder identificar qué acciones concretas fortalecen la confianza de clientes, colaboradores y reguladores; y poder explicar —a un directorio, a un cliente, a un regulador— por qué la gobernanza no es burocracia sino la condición para que la IA no se convierta en un pasivo. El curso decide cerrar con esto, después de la técnica y después del cambio organizacional, porque sin este último nivel, todo lo anterior es frágil: puedes tener el mejor modelo del mercado y el mejor plan de adopción, y perderlo todo en la primera decisión que nadie puede explicar.

 **Nota:** el PDF original advierte que los recursos entregados como enlaces y códigos QR podrían dejar de estar disponibles a partir del 5 de octubre de 2026. Es una nota administrativa del curso, no un contenido técnico, pero se incluye aquí porque forma parte literal de la apertura de la unidad.

Los diez conceptos clave, explicados de verdad

El curso abre con diez definiciones, una detrás de otra, en el formato típico de diapositiva de diccionario. Ese formato es eficiente para memorizar y pésimo para entender, porque presenta los conceptos como diez cajas separadas cuando en realidad son diez piezas de un mismo mecanismo: una organización que usa IA para decidir sobre personas necesita, al mismo tiempo, que esas decisiones sean rastreables, que alguien las entienda, que alguien las supervise, que los datos que las alimentan sean legítimos, y que exista una estructura que haga cumplir todo lo anterior. Vas a ver los diez conceptos en el orden del curso, pero leyéndolos como una cadena, no como una lista.

Confianza organizacional (*organizational trust*) es, según el curso, la valoración que construyen clientes, colaboradores y grupos de interés sobre cómo la organización emplea la IA, protege la información y respalda sus decisiones con criterios transparentes y responsables. El problema que resuelve es simple de nombrar y difícil de lograr: sin esta valoración positiva, ningún otro logro técnico se traduce en uso real. El mecanismo es acumulativo, no puntual —se construye interacción por interacción, no con un anuncio

corporativo— y es el concepto paraguas de toda la unidad: los otros nueve son, en distintos grados, condiciones para que la confianza organizacional exista o mecanismos para reconstruirla cuando se pierde.

Ética profunda (*deep ethics* o *ethics by design*) es la perspectiva que incorpora consideraciones éticas desde el diseño hasta el uso de la IA, buscando crear valor sin daños injustificados a personas ni a la sociedad. El problema que resuelve es el de la ética reactiva: la organización que solo piensa en consecuencias éticas cuando estalla un escándalo llega siempre tarde, porque para entonces el daño ya ocurrió y el modelo ya está en producción con esos defectos incorporados. El mecanismo es temporal: mover la pregunta ética del final del proyecto —"¿esto que construimos está bien?"— al principio —"¿qué necesitamos que sea cierto para que esto esté bien, antes de construirlo?". Se conecta directamente con la responsabilidad social (es su aplicación al terreno de la IA), con el sesgo algorítmico (es lo primero que la ética profunda busca prevenir) y con la gobernanza (es la estructura que hace operativa esta perspectiva en el día a día, no solo en el discurso).

ANALOGÍA

Pensarlo como la diferencia entre construir un edificio con normas sísmicas desde los planos y construirlo primero y después, cuando ya se agrietó con el primer temblor, salir a preguntar si convenía reforzarlo. La ética profunda es la norma sísmica: se diseña con ella incorporada, no se le añade encima cuando ya pasó lo que se quería evitar.

Responsabilidad social (*social responsibility*) es el compromiso de la organización con los efectos de sus decisiones sobre las personas, la comunidad y el entorno, lo que incluye la obligación de usar la IA de manera responsable. Resuelve el problema de la externalidad no contabilizada: una organización puede optimizar todos sus indicadores internos —costos, velocidad, satisfacción del accionista— mientras genera daños que no aparecen en ningún balance porque caen fuera de sus muros, en clientes rechazados injustamente o en comunidades afectadas por un sesgo. El mecanismo es extender el círculo de consecuencias que la organización se hace cargo de gestionar más allá de sus resultados financieros directos. Se conecta con la ética profunda como su expresión más amplia (la ética profunda mira el diseño del sistema; la responsabilidad social mira el efecto del sistema en el mundo) y, como vas a ver en la última sección de esta unidad, termina siendo una ventaja competitiva y no solo una obligación moral.

Sesgo algorítmico (*algorithmic bias*) son los resultados de un sistema que favorecen o perjudican injustificadamente a determinados grupos, con origen en los datos de entrenamiento o en decisiones tomadas al construir el modelo. Este es, junto con la distinción entre transparencia y explicabilidad, uno de los cuatro conceptos de esta lista que cuesta más intuir bien, porque el sentido común tiende a asumir que un algoritmo, al

ser matemática, es neutral por definición —y esa suposición es exactamente el error que el curso quiere que dejes atrás. El problema que resuelve reconocerlo (no el sesgo en sí, que es un problema, sino el acto de nombrarlo y buscarlo activamente) es que un sistema puede tener una exactitud global excelente y, al mismo tiempo, estar sistemáticamente equivocado con un subgrupo específico de personas, sin que ese error se note en ningún reporte que solo mire el promedio. El mecanismo tiene dos fuentes distintas que conviene no mezclar: puede venir de los datos de entrenamiento —si el pasado que el modelo aprendió ya contenía una desigualdad, el modelo la hereda— o puede venir de decisiones de construcción del modelo —qué variables se incluyen, cómo se define la etiqueta que se quiere predecir, qué umbral de decisión se elige—. Vas a ver el mecanismo del sesgo algorítmico desarrollado en detalle, con el caso Amazon como ejemplo, más adelante en el documento; aquí basta con fijar que no requiere intención discriminatoria de nadie: un sistema puede aprender a discriminar exactamente igual que aprende cualquier otro patrón, porque para el algoritmo no hay diferencia entre un patrón legítimo y uno que reproduce una desigualdad histórica.

ANALOGÍA

Es como un espejo que refleja con precisión perfecta una habitación torcida: el espejo no está roto ni miente, simplemente devuelve, sin corregirla, la distorsión que ya estaba en lo que tenía delante. El algoritmo no inventa el sesgo; refleja, con exactitud matemática, el sesgo que ya existía en los datos que le diste para aprender.

Transparencia (*transparency*) es comunicar con claridad cuándo se usa IA, para qué se usa y cómo influye en las decisiones. **Explicabilidad** (*explainability*) es la posibilidad de entender y justificar las recomendaciones o decisiones del sistema, especialmente cuando afectan directamente a una persona. El curso las presenta como conceptos separados y aquí conviene ser muy preciso, porque es fácil tratarlas como sinónimos y no lo son: la transparencia responde a la pregunta "¿me estás usando IA, y para qué?"; es información sobre la existencia y el propósito del sistema, y se puede tener transparencia total sin entender absolutamente nada de cómo el sistema llega a sus conclusiones —un banco puede decirte con toda claridad "usamos un modelo de IA para evaluar tu crédito" sin que eso te explique por qué te lo rechazó—. La explicabilidad responde a la pregunta siguiente, la que de verdad le importa a la persona afectada: "¿por qué, en mi caso particular, decidiste esto?"; es información sobre el razonamiento detrás de una decisión puntual. Puedes tener transparencia sin explicabilidad (te avisan que usan IA, pero nadie puede justificarte el resultado) y, con más dificultad, cierto grado de explicabilidad sin transparencia plena (te dan una justificación razonable sin que hayas sabido de entrada que había un algoritmo de por medio, lo cual además sería, en sí mismo, un problema de transparencia). Ninguna de las dos exige revelar cada detalle técnico del algoritmo —eso sería otra cosa, que el curso no pide y que en la práctica suele ser imposible incluso para

quienes construyeron el modelo—; exigen que la persona afectada entienda qué pasó y por qué, en un lenguaje que le sirva.

⚠ Nota: el curso trabaja únicamente con transparencia y explicabilidad, pero en la literatura técnica hay un tercer término, prerequisite mínimo indispensable para entender bien el segundo, que conviene fijar aquí aunque el curso no lo desarrolle: la **interpretabilidad** (*interpretability*). La interpretabilidad es una propiedad del modelo mismo: qué tan directamente un ser humano puede seguir, paso a paso, el mecanismo interno que produjo un resultado, sin necesitar una herramienta externa que lo traduzca. Un árbol de decisión pequeño es interpretable porque puedes leer sus reglas una por una; una red neuronal profunda casi nunca lo es, porque su "razonamiento" está distribuido en millones de parámetros sin una regla legible. La explicabilidad, en cambio, no exige que el modelo sea interpretable: existen técnicas (por ejemplo, las que generan explicaciones aproximadas post-hoc sobre qué variables pesaron más en una predicción concreta) que producen una justificación comprensible para una persona incluso cuando el modelo subyacente sigue siendo, en sí mismo, una caja opaca. En resumen: la interpretabilidad es una cualidad del modelo ("¿puedo leer su mecanismo?"); la explicabilidad es una cualidad de la comunicación hacia el afectado ("¿puedo justificarle el resultado, entienda o no el mecanismo completo?"); y la transparencia es una cualidad de la relación con el usuario ("¿sabe siquiera que hay IA de por medio?"). Los tres términos suelen confundirse en el habla cotidiana; para el examen, la distinción que el curso evalúa es solo transparencia versus explicabilidad, tal como se definió arriba.

Privacidad de los datos (*data privacy*) es el resguardo de la información personal en su obtención, almacenamiento y tratamiento, respetando los derechos de las personas y la normativa vigente. Resuelve el problema de que la necesidad legítima de datos para entrenar y operar un sistema no es, por sí sola, una autorización ilimitada para recolectar y usar cualquier dato: la utilidad de un dato para el modelo no lo vuelve automáticamente legítimo de usar. El mecanismo combina obligaciones legales (normativa de protección de datos) con decisiones de diseño (qué se recolecta, cuánto tiempo se guarda, quién accede). Se conecta con la transparencia —parte de ser transparente es decir qué datos se usan— y con la ética profunda, porque las decisiones de privacidad se toman mejor cuando se piensan desde el diseño y no como un parche legal posterior.

Supervisión humana (*human oversight*) es la intervención activa de personas que revisan, interpretan y validan las decisiones apoyadas por IA, sobre todo en los casos donde el juicio profesional no es sustituible. Resuelve un problema que la velocidad del sistema por sí sola no resuelve: que un modelo procese millones de registros en segundos no significa que capte todo el contexto relevante de cada caso individual; hay circunstancias, matices y excepciones que un modelo entrenado con datos históricos simplemente no vio nunca. El mecanismo es mantener a una persona con autoridad real —no solo simbólica— para revisar, cuestionar y, cuando corresponda, revertir una recomendación del sistema. Se

conecta con la explicabilidad (es difícil supervisar bien algo que no puedes entender) y es, junto con la transparencia, uno de los pilares que sostienen la confianza organizacional cuando la IA empieza a decidir sobre personas, tal como vas a ver con detalle en la siguiente sección de este documento.

Gobernanza de la IA (*AI governance*) es el marco de normas, responsables, procedimientos y controles para conducir y vigilar el desarrollo, la puesta en marcha y el uso de la IA. Es, con el sesgo algorítmico y la pareja transparencia/explicabilidad, uno de los conceptos que más se presta a malentendido, porque suena a burocracia y el curso es explícito en que no lo es: la gobernanza no es un trámite adicional que retrasa los proyectos, es la estructura organizativa que hace que los otros nueve conceptos de esta lista dejen de ser buenas intenciones y se conviertan en prácticas exigibles con nombre y apellido de responsable. El problema que resuelve es el de los principios sin dueño: una organización puede declarar que valora la transparencia, la equidad y la supervisión humana, y aun así no tener a nadie que responda por ellas en la práctica diaria, con lo cual esos valores no sobreviven la primera presión de negocio que los contradiga. El mecanismo, como vas a ver desarrollado en la Sección 3 de esta unidad, distribuye roles (quién aprueba, quién audita, quién monitorea), procedimientos (cómo se revisa un modelo antes de lanzarlo, cómo se responde a un resultado inesperado) y ciclos (revisión periódica, no solo al lanzamiento). Se conecta con absolutamente todos los conceptos anteriores porque es, en un sentido preciso, el mecanismo operativo de todos ellos: sin gobernanza, la ética profunda es una declaración de valores, la supervisión humana depende de la buena voluntad individual, y la privacidad de los datos depende de que a nadie se le olvide.

ANALOGÍA

Si la ética profunda es el conjunto de valores que una organización dice sostener —"vamos a ser justos, vamos a ser transparentes"—, la gobernanza es el reglamento interno, el organigrama y el calendario de auditorías que hacen que esos valores se cumplan aunque cambie el gerente que los proclamó. Sin gobernanza, la ética profunda es una declaración enmarcada en la pared de la oficina; con gobernanza, es un proceso que alguien audita cada trimestre.

IA responsable (*responsible AI*) es, según el curso, la creación y utilización de sistemas seguros, justos y transparentes, alineados con los valores y objetivos de la organización. Es, de los diez, el concepto más integrador: no añade un mecanismo nuevo a los nueve anteriores, sino que los nombra en conjunto, como resultado. Una organización practica IA responsable cuando la confianza organizacional que genera está respaldada por ética profunda incorporada desde el diseño, por responsabilidad frente a sus efectos sociales, por vigilancia activa contra el sesgo algorítmico, por transparencia y explicabilidad hacia los afectados, por resguardo de la privacidad, por supervisión humana efectiva y por una gobernanza que hace todo esto exigible. Es, en ese sentido, el concepto de llegada de esta

primera sección y el título que vas a volver a encontrar como nombre de la última sección de la unidad, donde se conecta explícitamente con qué hace confiable a una organización.

Concepto	Pregunta que responde	Qué falla cuando está ausente
Confianza organizacional	¿Los grupos de interés creen en cómo usamos la IA?	La adopción se estanca o se revierte, aunque el sistema funcione bien técnicamente.
Ética profunda	¿Pensamos en el daño posible desde el diseño, o solo al final?	Los problemas se detectan tarde, cuando ya están en producción y ya causaron daño.
Responsabilidad social	¿Nos hacemos cargo de los efectos fuera de la organización?	Se optimizan indicadores internos mientras se generan daños externos invisibles al balance.
Sesgo algorítmico	¿El sistema perjudica sistemáticamente a algún grupo?	Se discrimina sin intención ni conciencia, escondido detrás de una métrica global saludable.
Transparencia	¿La persona sabe que hay IA de por medio y para qué se usa?	El afectado se entera del sistema solo cuando algo le sale mal, y desconfía de todo lo demás.
Explicabilidad	¿Podemos justificar esta decisión particular a la persona afectada?	El rechazo o la recomendación se percibe como arbitrario, aunque tenga una lógica interna.
Privacidad de los datos	¿Usamos solo los datos que corresponde, como corresponde?	Se erosiona la confianza y se incurre en incumplimiento normativo.
Supervisión humana	¿Alguien con criterio revisa lo que el sistema no puede captar?	Errores de contexto que un humano habría detectado pasan directo a producción.
Gobernanza de la IA	¿Quién es responsable de qué, en qué momento del ciclo de vida?	Los principios quedan sin dueño y se diluyen ante la primera presión de negocio.
IA responsable	¿El sistema, en su conjunto, es seguro, justo, transparente y alineado con los valores de la organización?	La organización trata la IA como un riesgo aislado en lugar de un activo estratégico gestionado.

La confianza: el siguiente desafío de la transformación organizacional

La Unidad 4 dejó establecido algo que esta sección retoma directamente: la transformación con IA no se consolida solo por adquirir la tecnología. Puedes tener el presupuesto aprobado, el proveedor contratado y el modelo entrenado, y aun así no tener una transformación real si la organización no logra sostener el cambio en el tiempo. La Unidad 4 abordó ese sostenimiento desde el ángulo de la **resistencia organizacional**: las personas se resisten al cambio, y ese cambio requiere gestión deliberada. Esta sección da el paso siguiente en la misma línea argumental: incluso superada la resistencia inicial, incluso con la organización dispuesta a adoptar la tecnología, aparece un desafío distinto y más persistente, que no se resuelve con un plan de comunicación de seis semanas. Ese desafío es la confianza, y por eso el curso lo llama explícitamente "el desafío siguiente" de la transformación organizacional: no reemplaza a la gestión del cambio, viene después de ella, en el terreno donde la gestión del cambio ya no alcanza.

Para entender por qué la confianza se volvió un desafío en sí mismo, conviene mirar qué está haciendo la IA hoy dentro de las organizaciones, porque cada una de estas capacidades sube la exigencia de confianza un escalón más:

- **Atiende consultas:** cuando un asistente virtual responde en nombre de la organización, la persona ya no está hablando con un humano identificable a quien pedirle cuentas directamente, y eso exige confiar en que la respuesta automatizada es correcta y adecuada sin esa garantía personal.
- **Analiza grandes cantidades de información:** cuando el volumen de datos procesados excede lo que cualquier persona podría revisar manualmente, la organización le está pidiendo a los grupos de interés que confíen en un análisis que, por su propia escala, nadie puede auditar línea por línea.
- **Detecta patrones y sugiere acciones:** cuando el sistema no solo describe sino que recomienda qué hacer, exige confiar no solo en su capacidad de observación sino en su criterio, lo cual es un salto de exigencia mayor que confiar en que un reporte esté bien calculado.
- **Apoya decisiones de contrataciones, créditos y fraudes:** cuando el sistema participa en decisiones con consecuencias directas y a veces irreversibles sobre la vida de una persona —quién es contratado, a quién se le presta dinero, a quién se acusa de fraude— exige el nivel más alto de confianza, porque el costo de una decisión mal fundada ya no es un error de reporte, es un daño concreto a alguien.

Estas cuatro capacidades no son hipotéticas ni futuras: son lo que la IA hace hoy, de forma rutinaria, en organizaciones de todo tipo. Y es precisamente por eso que la confianza marca la diferencia entre adopción y fracaso: una plataforma técnicamente sofisticada puede ser

rechazada, evitada o subutilizada si quienes deben interactuar con ella no entienden cómo opera ni por qué llega a sus resultados. La sofisticación técnica no compra automáticamente aceptación; la aceptación se gana por otra vía, y esa vía es la confianza.

Esto tiene una consecuencia directa sobre cómo se debe evaluar un proyecto de IA, y es aquí donde el curso hace un giro importante: evaluar un sistema solo con **indicadores técnicos** —exactitud, tiempo de procesamiento— ya no basta. Hace falta observar, además, la aceptación real, la comprensión que tienen los usuarios de lo que el sistema hace y la confianza percibida por quienes conviven con sus decisiones. Esto no es una preferencia estética por lo "humano" frente a lo "técnico"; es una necesidad práctica, porque un indicador técnico excelente puede convivir, sin ninguna contradicción matemática, con un daño real y localizado que el indicador global no muestra.

EJEMPLO

Imagina un modelo de evaluación crediticia con una **exactitud** (*accuracy*) global del 94%: de cada 100 decisiones que toma sobre solicitudes de crédito, 94 coinciden con lo que un analista experto habría decidido. Es, en cualquier reporte gerencial, un número excelente. Ahora supón que ese mismo banco tiene una cartera de 50.000 clientes, y que un subgrupo específico —digamos, solicitantes de una zona geográfica con menor historial crediticio formal— representa el 8% de esa cartera: 4.000 personas. Si dentro de ese subgrupo la exactitud del modelo cae a 61%, eso significa que de esas 4.000 personas, el modelo acierta en 2.440 casos y se equivoca en 1.560. Mil quinientas sesenta personas reciben una decisión de crédito —un rechazo indebido, o una aprobación que no correspondía— que no coincide con lo que un evaluador experto habría resuelto, concentradas todas en el mismo grupo. La razón por la que esto no se ve en el 94% global es puramente aritmética: ese subgrupo es solo el 8% de la cartera, así que sus errores, por muy graves y concentrados que sean, pesan poco en el promedio total. El 92% restante de la cartera puede tener una exactitud cercana al 98% y arrastrar el promedio general hacia arriba, escondiendo por completo el problema. El KPI en el tablero de control dice 94% y se ve saludable; mientras tanto, hay 1.560 personas de un mismo grupo que reciben decisiones equivocadas de forma sistemática, no aleatoria. Ese es exactamente el mecanismo por el cual un indicador técnico impecable destruye la confianza sin que ningún número en el reporte gerencial lo anticipe: el promedio esconde el daño porque el daño está concentrado donde el promedio no mira.

Este ejemplo es la razón profunda por la que el curso insiste en que la confianza no aparece de forma automática como consecuencia de un buen resultado técnico. La confianza no es un premio que se gana solo con exactitud; es un **requisito** aparte, que hay que perseguir de forma deliberada, con sus propios mecanismos —transparencia, explicabilidad, supervisión humana, los mismos conceptos que ya definiste arriba—, precisamente porque el resultado técnico puede ser excelente en promedio y, al mismo tiempo, no ser confiable para una parte específica de las personas a las que afecta.

Sobre este mismo punto, el curso cita a **Davenport y Ronanki (2018)**: "*Los proyectos con mejores resultados combinan la tecnología con las capacidades humanas y con los procesos de la organización, avanzando de forma gradual y con foco en la creación de valor. Desde esa mirada, la confianza depende tanto del algoritmo como de la manera concreta en que la IA se incorpora al trabajo cotidiano*".

Vale la pena conocer el contexto real de esta cita, porque el artículo original —"Artificial Intelligence for the Real World", publicado en Harvard Business Review, volumen 96, número 1, páginas 108 a 116— es más rico de lo que la frase aislada deja ver. Davenport y Ronanki construyeron su tesis a partir de una encuesta a 250 ejecutivos y del análisis de 152 proyectos reales de IA en distintas organizaciones. Su hallazgo central fue que los proyectos con mejores resultados no eran los más ambiciosos ni los más vistosos, sino los que avanzaban de forma incremental, ampliando capacidades humanas en procesos acotados, en lugar de apostar por transformaciones radicales de una sola vez —lo que ellos llaman, con cierta ironía, "moon shots"—. El ejemplo que usan para ilustrar el fracaso de la apuesta grande es el proyecto de Watson en el MD Anderson Cancer Center, una inversión de USD 62 millones que no llegó a producir los resultados clínicos esperados, en contraste con iniciativas mucho más pequeñas y acotadas que sí funcionaron. Además, los autores proponen una taxonomía de tres tipos de aplicación de IA en las organizaciones que ayuda a entender por qué "la manera concreta en que la IA se incorpora al trabajo cotidiano" es tan determinante para la confianza: la **automatización de procesos** (*process automation*), enfocada en tareas administrativas y financieras de back-office; el **insight cognitivo** (*cognitive insight*), que usa análisis de datos para informar decisiones humanas sin reemplazarlas; y el **compromiso cognitivo** (*cognitive engagement*), que interactúa directamente con clientes o empleados, por ejemplo mediante chatbots o sistemas de recomendación. Cada uno de estos tres tipos exige un nivel distinto de confianza precisamente porque exige un nivel distinto de cercanía con la persona afectada: automatizar un proceso interno de conciliación contable pide mucha menos confianza pública que un chatbot que interactúa en vivo con un cliente.

Los tres efectos de la confianza a nivel organizacional

El curso presenta este contenido como un carrusel interactivo de tres láminas bajo la pregunta "¿Cuáles son los efectos de la confianza a nivel organizacional?". Del texto que declara el propio material se identifica el primer efecto, textualmente:

Mejor desempeño: cuando clientes, trabajadores y otros grupos de interés perciben transparencia y responsabilidad en el uso de la IA, se relacionan con mayor seguridad, comparten información con mayor disposición y participan activamente en nuevas iniciativas de innovación. Es un efecto que se retroalimenta: la confianza genera comportamientos —compartir información, involucrarse— que a su vez generan mejores insumos y más participación, lo que mejora el desempeño del sistema y de la organización que lo opera.

⚠ Nota: las láminas 2 y 3 de este carrusel no quedaron visibles en el PDF descargable del curso —solo se conserva la primera lámina, "Mejor desempeño", con su texto completo—. Las dos siguientes son una **reconstrucción** coherente con el resto de la unidad, no el texto original del curso, y se presentan así, marcadas, para que quede claro qué es literal y qué es inferencia razonada a partir del resto del material.

Menor fricción en la adopción (reconstrucción): cuando la confianza está presente, los procesos de adopción avanzan con menos fricción operativa: se reduce el retrabajo generado por decisiones cuestionadas y revertidas, disminuyen los escalamientos hacia supervisores o comités cuando una recomendación del sistema genera dudas, y baja la tentación de "volver a los métodos antiguos" en paralelo al sistema nuevo, una práctica que, cuando ocurre, indica que la organización adoptó la herramienta en el papel pero no en la práctica. Este efecto conecta directamente con la Unidad 4: es, en el fondo, la resistencia organizacional operando a la inversa —la confianza reduce exactamente el tipo de fricción que la gestión del cambio busca gestionar.

Mejor reputación ante terceros (reconstrucción): la confianza generada internamente se proyecta hacia afuera, hacia clientes que valoran trabajar con una organización que explica cómo usa la IA, hacia reguladores que encuentran menos motivos de escrutinio cuando la transparencia ya es una práctica establecida, y hacia inversionistas que ven en la gestión responsable de la IA una señal de menor riesgo reputacional y legal a futuro. Este tercer efecto anticipa un tema que la unidad desarrolla más adelante, cuando aborda la responsabilidad social como ventaja estratégica y los beneficios competitivos de ser una organización confiable.

El espejo de estos tres efectos es igual de importante que ellos: cuando predomina la **desconfianza**, una solución técnicamente adecuada —recuerda el ejemplo del 94% de exactitud— queda en desuso. Los usuarios la evitan cuando pueden, cuestionan cada uno de sus resultados incluso cuando son correctos, o simplemente vuelven a los métodos que ya conocían, aunque sean más lentos o menos precisos, porque al menos los entienden y confían en ellos. El cierre de esta idea, tal como lo plantea el curso, es contundente y conviene retenerlo tal cual: sin confianza, la IA queda reducida a una herramienta aislada. No una herramienta mala, no una herramienta rota: una herramienta que existe pero que la organización no logra integrar a su forma real de operar, porque nadie construyó, alrededor de ella, la relación de confianza que la haría parte del trabajo cotidiano.

Que este no es un problema retórico sino un problema medido lo confirma el **Stanford AI Index Report 2026**, del Stanford Institute for Human-Centered Artificial Intelligence, en su capítulo sobre opinión pública: en Estados Unidos, el 73% de los expertos en IA percibe positivamente el impacto de la tecnología en el empleo, frente a solo el 23% del público general, una brecha de 50 puntos porcentuales entre quienes construyen estos sistemas y quienes conviven con sus efectos. El mismo informe registra que la confianza de la

población estadounidense en la capacidad de su propio gobierno para supervisar la IA es de apenas 31%. Estas dos cifras no describen un problema de percepción menor ni pasajero: describen, con datos, la misma brecha de confianza que esta sección viene argumentando de forma conceptual, y sirven como evidencia de que "la confianza es el siguiente desafío" no es una frase inspiracional del curso, sino una descripción precisa del estado actual de la relación entre las personas y los sistemas de IA que las afectan.

El curso cierra esta sección con dos preguntas que invita a comentar, y que conviene tener presentes porque resumen exactamente la tensión que acabas de recorrer: qué tan preparada está tu propia organización para sostener, no solo instalar, un sistema de IA que decide sobre personas; y qué señales —más allá de los indicadores técnicos— usarías para saber si la confianza en un sistema de IA se está construyendo o se está erosionando.

Cuando la IA comienza a tomar decisiones

La sección anterior dejó establecido que la confianza no es una consecuencia automática de un buen resultado técnico, sino una condición que hay que construir. Esa exigencia se vuelve mucho más concreta en el momento en que la inteligencia artificial deja de cumplir un papel auxiliar —responder consultas, ordenar información— y empieza a intervenir en decisiones que afectan a personas, a procesos internos o al rumbo estratégico de la organización. El curso enumera cinco usos que marcan ese salto:

- Sugerir acciones concretas a quien toma la decisión final.
- Ordenar antecedentes y priorizar qué información revisar primero.
- Detectar riesgos que un análisis manual difícilmente encontraría a tiempo.
- Anticipar comportamientos futuros de clientes, procesos o mercados.
- Respaldar decisiones que hasta hace poco dependían únicamente del juicio profesional.

El punto en común de estos cinco usos es que la IA deja de describir la realidad para empezar a influir sobre ella. Mientras el sistema solo resumía información, un error se corregía revisando el resumen. Cuando el sistema participa en la decisión —aunque sea sugiriendo, no resolviendo—, el error ya tiene un efecto sobre una persona concreta: un crédito que no se otorga, un postulante que no avanza, un tratamiento que no se ofrece. Por eso, cuando la inteligencia artificial interviene en una decisión, es razonable que la persona afectada quiera conocer las razones. El curso desarrolla tres escenarios donde esa exigencia se vuelve explícita.

Quién pregunta	Qué puede exigir razonablemente	Qué no se le puede (ni se le debe) entregar
Cliente al que se le rechaza un crédito	Los factores principales que pesaron en el rechazo (por ejemplo, nivel de endeudamiento, historial de pago, ingresos declarados) y una vía para pedir revisión humana.	El valor exacto de cada coeficiente del modelo o el código fuente: no aportan comprensión y, en la mayoría de los casos, son secreto comercial del proveedor del sistema.
Postulante evaluado para un cargo o un cupo	Los criterios generales que se usaron para evaluar (competencias, experiencia, resultados de pruebas) y confirmación de que existió, en algún punto, revisión humana.	Una comparación punto por punto contra otros postulantes: expondría datos personales de terceros y no es lo que la persona necesita para entender su propio resultado.
Médico que recibe una recomendación de tratamiento	Qué variables clínicas del paciente motivaron la sugerencia y con qué nivel de certeza la respalda el sistema, para poder contrastarla con su propio criterio.	Una explicación que sustituya su juicio profesional: el sistema respalda la decisión, no la reemplaza, y la responsabilidad clínica sigue siendo suya.

Los tres casos comparten una misma estructura: la organización debe poder explicar cuál fue la participación del sistema y cómo se llegó a la decisión final, sin que eso implique convertir la explicación en un manual técnico del algoritmo. Y los tres confirman algo que conviene dejar explícito porque suele pasarse por alto: la tecnología, por sí sola, no garantiza una buena decisión. El resultado que entrega un modelo está condicionado por tres factores que actúan en conjunto y que conviene distinguir con precisión, porque cada uno se corrige de una manera distinta:

- **Información disponible:** un modelo no puede usar datos que nunca recibió; si faltan variables relevantes, el resultado será incompleto por más sofisticado que sea el algoritmo.
- **Elecciones realizadas al construir el modelo:** qué variables se incluyen, cómo se etiquetan los casos de entrenamiento, qué umbral se define como aceptable; todas son decisiones humanas, no hechos objetivos que el modelo "descubre".
- **Contexto en que se usa:** el mismo modelo puede rendir de forma distinta según el mercado, la población o el momento en que se aplique.

Adoptar inteligencia artificial supone, entonces, revisar su desempeño de manera constante y comprobar que sus recomendaciones sigan siendo compatibles con los objetivos y los valores institucionales. Esa idea de revisión constante es la puerta de entrada al problema más estudiado —y más malentendido— de esta sección: el sesgo algorítmico.

Cuando los datos no representan toda la realidad

Existe una intuición extendida y equivocada: que una decisión basada en datos es, por definición, objetiva. Los datos, se piensa, no tienen opiniones. El problema con esa intuición es que confunde el origen de los datos con su contenido. Los algoritmos no aprenden de la realidad directamente: aprenden de *registros* de la realidad, producidos por personas y organizaciones en un momento y un contexto determinados. Y esos registros pueden absorber errores, ausencias y patrones problemáticos que ya estaban presentes antes de que el modelo existiera.

El mecanismo es más simple de lo que parece y vale la pena hacerlo explícito, porque es la clave para entender por qué esto ocurre sin que nadie lo busque. Un modelo predictivo, en su función más básica, hace una sola cosa: encuentra el patrón estadístico que mejor explica los resultados pasados y lo proyecta hacia adelante. Si en el pasado un grupo fue sistemáticamente favorecido o perjudicado —no necesariamente por decisión consciente de nadie, sino por la acumulación de prácticas, accesos desiguales u omisiones históricas—, ese patrón queda registrado en los datos como si fuera una regularidad legítima del mundo. El modelo no distingue entre "esto ocurre porque hay una causa real" y "esto ocurre porque en el pasado hubo una desigualdad que nadie corrigió": ambas se ven, estadísticamente, igual de consistentes. El algoritmo, entonces, optimiza para reproducir el patrón, y una desigualdad que pertenecía al pasado se convierte en una regla de decisión para el presente. A este fenómeno se le llama **sesgo algorítmico** *algorithmic bias*, y hoy es una de las principales preocupaciones de cualquier organización que use IA para decisiones sobre personas.

 **Nota (prerrequisito mínimo):** conviene distinguir dos fuentes de sesgo que suelen mencionarse juntas pero que son mecanismos distintos. El **sesgo histórico** *historical bias* aparece cuando los datos reflejan con precisión una desigualdad que existió en el mundo real (por ejemplo, que históricamente contrataron más hombres para un cargo técnico): el dato es "correcto" en el sentido de que describe lo que pasó, pero perpetuar ese patrón perpetúa también la desigualdad. El **sesgo de muestreo** *sampling bias* es distinto: ocurre cuando el conjunto de entrenamiento no representa proporcionalmente a la población sobre la que el modelo va a operar (por ejemplo, entrenar un sistema de diagnóstico con datos de una sola clínica, de un solo rango etario o de un solo país y luego aplicarlo a una población mucho más diversa). El primero es un problema de qué pasó; el segundo, de a quién se muestreó. Un modelo puede sufrir uno, el otro, o ambos a la vez, y las dos categorías vuelven a aparecer en el módulo cada vez que se habla de calidad y representatividad de los datos.

Es importante subrayar algo que el curso plantea con claridad y que conviene no perder de vista: en la inmensa mayoría de los casos no existe una intención consciente de discriminar. Nadie programa al modelo para perjudicar a un grupo. Lo que ocurre es que el modelo

aprende a partir de ejemplos anteriores, y cuando esos ejemplos son poco representativos o contienen decisiones desequilibradas, el modelo produce conclusiones que ya no son adecuadas para la situación presente, incluso mientras cumple perfectamente con su objetivo matemático de minimizar el error sobre los datos con los que fue entrenado.

ANALOGÍA

Piensa en un modelo entrenado con datos históricos como un conductor que solo puede mirar por el espejo retrovisor mientras avanza. El espejo no miente: muestra con exactitud el camino que ya se recorrió. El problema es que ese camino tenía curvas, baches y desvíos que existieron por razones del pasado —obras viales, decisiones urbanas, restricciones que ya no aplican—, y si el conductor solo se guía por lo que ve en el espejo, va a seguir esquivando baches que hace tiempo fueron reparados. El modelo hace exactamente eso con los datos: proyecta hacia el futuro los patrones del pasado sin capacidad propia para preguntarse si esos patrones deberían seguir vigentes.

EJEMPLO

El caso más citado de sesgo algorítmico en reclutamiento aparece en la bibliografía de esta unidad (Dastin, 2018, Reuters) pero el cuerpo del material no lo desarrolla, así que vale la pena reconstruirlo completo porque es el ejemplo más claro del mecanismo recién descrito. Amazon comenzó a construir, desde 2014, una herramienta interna de inteligencia artificial para automatizar la revisión de currículums de postulantes técnicos: el sistema debía asignar a cada candidatura un puntaje de una a cinco estrellas, igual que Amazon puntúa productos. El modelo se entrenó con los currículums que la empresa había recibido durante los diez años anteriores, un periodo en el que la mayoría de los postulantes —y de los contratados— en cargos técnicos eran hombres, reflejo de un desequilibrio de género que existía en toda la industria tecnológica, no una particularidad de Amazon. El modelo hizo exactamente lo que un modelo predictivo hace: buscó los patrones que mejor explicaban quién había sido considerado "buen candidato" en el pasado, y como en el conjunto de entrenamiento ese patrón estaba dominado por hombres, el sistema aprendió, por su cuenta, que ser hombre correlacionaba con ser un buen candidato. Hacia 2015, los equipos de reclutamiento de Amazon notaron que el sistema no evaluaba de forma neutral las candidaturas relacionadas con mujeres: penalizaba currículums que contenían literalmente la palabra "women's" (por ejemplo, "capitana del club de ajedrez femenino") y degradaba sistemáticamente a egresadas de dos universidades exclusivamente femeninas, aunque nadie le había indicado al modelo que el género fuera una variable a considerar. Amazon intentó corregir el sesgo editando el sistema para que esos términos específicos dejaran de penalizarse, pero la empresa no tuvo garantías de que el modelo no encontrara otras formas, más sutiles, de discriminar por el mismo motivo, y terminó disolviendo el equipo que desarrollaba la herramienta a inicios de 2017. La herramienta nunca fue el único criterio de contratación de la empresa. El detalle técnico que hace de este caso una lección permanente es este: a nadie se le ocurrió incluir "género" como variable de entrada, y aun

así el sesgo apareció, porque el modelo encontró **variables proxy** —el nombre de un club, el nombre de una universidad, ciertos verbos o construcciones más frecuentes en un tipo de currículum que en otro— que funcionaban como sustitutos estadísticos del género sin decir "género" en ningún lugar. Por eso "quitar el campo género" del conjunto de datos, la solución más intuitiva y la primera que se le ocurre a casi cualquiera, no resuelve el problema: el sesgo no vivía en un campo, vivía en la correlación entre decenas de otras variables y un patrón histórico de contratación desigual.

El propio material cita a Russell y Norvig para resumir la raíz del fenómeno: "*Los sistemas de inteligencia artificial construyen sus aprendizajes a partir de la información disponible*" (Russell y Norvig, 2021). La frase parece casi trivial, pero encierra la implicación completa de todo lo anterior: si la información disponible es parcial, desactualizada o desequilibrada, el aprendizaje también lo será, sin que el algoritmo tenga ninguna forma interna de saberlo. De ahí que la calidad, la diversidad y la vigencia de los datos de entrenamiento influyan directamente en la conducta del modelo, y que revisar esos datos no sea una tarea que termina al poner el sistema en marcha, sino una responsabilidad que se mantiene durante toda su operación.

La solución responsable que propone el curso se apoya en tres frentes que funcionan solo si actúan juntos, porque cada uno cubre una falla distinta: revisar la calidad de los datos (para no entrenar con un espejo retrovisor sucio o incompleto), controlar periódicamente el comportamiento del modelo (porque el patrón que era válido al momento del entrenamiento puede dejar de serlo) y combinar el análisis automatizado con la experiencia de las personas (porque hay señales de que algo no cuadra que un ser humano detecta antes que una métrica agregada). El segundo frente introduce un concepto técnico que conviene nombrar con precisión porque explica por qué el control tiene que ser periódico y no un evento único: la **deriva del modelo** *model drift*. Un modelo se entrena en un momento dado, sobre una fotografía de la realidad; pero el mundo sigue moviéndose — cambian los hábitos de consumo, cambia la composición demográfica de los clientes, cambia el contexto económico— y la relación entre las variables que el modelo aprendió a asociar puede volverse cada vez menos representativa del presente, aunque el modelo en sí no haya cambiado ni una línea de código. Es el mismo mecanismo de fondo que produjo el sesgo en el caso Amazon, pero visto en el tiempo: incluso un modelo bien construido hoy puede empezar a fallar mañana simplemente porque la realidad que describe se movió y él se quedó fijo en el momento en que fue entrenado. Por eso "revisar la calidad de los datos" no es una casilla que se marca una vez: es una vigilancia continua.

Comprender las decisiones fortalece la confianza

Que un sistema responda con rapidez o alcance un buen nivel de acierto no es suficiente. Las personas que participan del proceso —o que son afectadas por él— necesitan entender qué función cumplió la tecnología en el momento de decidir. Aquí es donde la transparencia

y la explicabilidad, ya definidas como conceptos clave del módulo, se aplican de manera concreta: si el sistema sugiere una acción, es razonable preguntar qué antecedentes consideró y cuáles tuvieron mayor influencia en la recomendación.

El punto fino que hace el curso, y que conviene subrayar porque suele generar una expectativa equivocada, es este: ni la transparencia ni la explicabilidad exigen revelar cada detalle técnico del algoritmo. No se trata de publicar el código fuente, los pesos del modelo o la arquitectura exacta. Lo esencial —lo que efectivamente construye confianza— es que las personas afectadas puedan comprender por qué la organización tomó una determinada decisión y qué criterios la respaldan. Una explicación clara en ese sentido reduce las dudas mucho más que una descripción técnica incomprensible, aunque esta última sea, en apariencia, "más transparente".

El cuidado de los datos personales sigue la misma lógica de límite razonable, pero en la dirección opuesta: la necesidad de información que tiene un sistema de IA para aprender y mejorar no justifica usar cualquier dato sin restricciones. El curso lo plantea en tres verbos que conviene separar porque cada uno implica una responsabilidad distinta y un punto de falla distinto:

- **Obtener:** cómo se recolecta el dato y con qué base legal o consentimiento; la falla típica aquí es recopilar información "por si sirve después", sin un propósito definido.
- **Guardar:** cuánto tiempo se conserva, con qué nivel de seguridad y quién tiene acceso; la falla típica es retener datos indefinidamente, mucho después de que cumplieron su función.
- **Tratar:** para qué se usa efectivamente el dato una vez recolectado; la falla típica es usarlo para un fin distinto del que la persona autorizó.

 **Nota (prerrequisito mínimo):** tres principios operativos, no desarrollados en el cuerpo del PDF pero indispensables para entender "obtener, guardar y tratar" con el rigor que exige la práctica profesional: la **minimización de datos** *data minimization* (recolectar solo lo estrictamente necesario para el propósito declarado, no todo lo que sea técnicamente posible de capturar); la **anonimización** *anonymization* (procesar los datos de forma que ya no puedan asociarse a una persona identificable, reduciendo el daño posible ante una filtración); y el **consentimiento informado** *informed consent* (que la persona sepa, en términos comprensibles, qué dato entrega, para qué se usará y por cuánto tiempo, antes de autorizarlo). Los tres son la base técnica y legal sobre la que se sostiene cualquier política de privacidad de datos aplicada a IA.

Aunque un sistema pueda revisar millones de registros en segundos, la responsabilidad final continúa siendo humana. La **supervisión humana** permite tres cosas que ningún modelo, por sofisticado que sea, puede hacer por sí mismo: reconocer errores que el propio sistema no tiene forma de detectar sobre sí mismo (un modelo no sabe que se equivocó

salvo que alguien se lo diga), interpretar circunstancias particulares que el modelo no capta porque no forman parte de las variables con las que fue entrenado, y decidir cuándo el contexto exige considerar elementos que sencillamente no aparecen en los datos disponibles. Por esta razón, la inteligencia artificial suele aportar más cuando complementa el trabajo de las personas que cuando pretende sustituirlo: la combinación de capacidad analítica, experiencia profesional y revisión permanente conduce a decisiones más sólidas que cualquiera de los dos componentes por separado, y es exactamente el argumento que vuelve a aparecer, con otro nombre, en la subsección de gobernanza que sigue.

Las preguntas de comentario que propone el curso para cerrar esta sección son:

1. ¿Qué condiciones debería cumplir una organización antes de utilizar inteligencia artificial para apoyar decisiones que afectan a personas?
2. ¿Por qué la transparencia, la explicabilidad y la supervisión humana son necesarias cuando una decisión incorpora recomendaciones generadas por IA?

Ética y gobernanza de la IA: de los principios a la práctica

La inteligencia artificial dejó de ser un desafío exclusivamente técnico para convertirse en un asunto de gestión estratégica. Esto no es una frase de efecto: tiene una consecuencia práctica directa. Una solución de IA no puede evaluarse únicamente por su rendimiento algorítmico —qué tan bien predice, qué tan rápido responde—; su verdadero valor reside en su capacidad de operar de forma justa, comprensible y alineada con los valores de la organización y de la sociedad en la que opera. Cuando la IA interviene en decisiones que afectan a clientes, colaboradores o comunidades, la pregunta relevante deja de ser solo "¿funciona?" para pasar a ser "¿sus resultados son responsables?".

Vale la pena explicar por qué actuar con ética y establecer una gobernanza sólida no es, como suele suponerse, un freno a la innovación, sino justamente lo contrario: un habilitador de confianza y de continuidad del negocio. El mecanismo es el mismo que ya apareció en el caso Amazon, visto ahora desde el lado de la prevención: cuando un problema ético o de sesgo se detecta después del lanzamiento —con el sistema ya operando, ya tomando decisiones sobre personas reales—, corregirlo implica rehacer trabajo que ya se dio por terminado, y en los casos más graves, implica retirar de producción un sistema en el que la organización ya invirtió años y millones. Amazon no ajustó su herramienta de reclutamiento: la disolvió. Detectar el mismo problema en la fase de diseño, mediante una evaluación de impacto ético que hoy es estándar en cualquier marco de gobernanza serio, cuesta una fracción de ese retrabajo. La ética y la gobernanza, entendidas así, no compiten con la velocidad de innovar: evitan pagar el costo de innovar dos veces.

Esa lógica preventiva es también lo que distingue a la **ética profunda** del mero **cumplimiento normativo** *regulatory compliance*. El cumplimiento normativo responde a

una pregunta distinta: "¿qué exige la ley hoy?". Y la ley, por su propia naturaleza, llega tarde: se redacta y se aprueba después de que los problemas ya fueron documentados, litigados o denunciados públicamente —el propio recorrido del AI Act europeo, con sus plazos que se han ido postergando a medida que la industria y los reguladores negocian los detalles, es un buen ejemplo de cuánto tiempo toma ese proceso—. La ética profunda, en cambio, se integra desde el diseño del sistema, no cuando surge una controversia: convierte la reflexión ética en una guía proactiva durante toda la vida del proyecto, en lugar de una revisión reactiva al final. Los nombres operativos que ha adoptado esta idea en la práctica profesional son **ética por diseño** *ethics by design* y **privacidad por diseño** *privacy by design*: en ambos casos, el principio es incorporar la consideración ética o de privacidad en la primera línea de código y en la primera decisión de qué datos recolectar, no como un parche posterior a cargo del equipo legal.

El curso plantea seis principios que actúan como brújula para orientar el desarrollo de sistemas de IA. Conviene desarrollarlos uno por uno, porque cada uno resuelve una falla distinta y cada uno se reconoce por lo que ocurre cuando falta:

Equidad y justicia *fairness*: el modelo no debe perpetuar sesgos ni discriminar a ningún grupo por razón de género, origen u otra condición. El mecanismo detrás de este principio es exactamente el que se explicó al analizar el sesgo algorítmico: sin una revisión activa, el modelo tiende a reproducir las desigualdades del pasado. Cuando este principio falta, el resultado observable es el caso Amazon: un sistema estadísticamente exitoso que discrimina sin que nadie lo haya programado para hacerlo.

Transparencia y explicabilidad: las decisiones de la IA deben poder ser comprendidas y explicadas por personas, especialmente cuando afectan derechos individuales. Cuando este principio falta, aparece exactamente la situación descrita en los tres escenarios de la sección anterior: un cliente, un postulante o un médico que reciben una decisión sin ninguna razón comprensible detrás.

Privacidad y seguridad: los datos personales deben protegerse, y la infraestructura del sistema debe resguardarse frente a amenazas externas. Es la aplicación directa de los tres verbos —obtener, guardar, tratar— ya explicados, sumada a la **seguridad de la información** *information security* propiamente técnica: control de accesos, cifrado, protección ante filtraciones. Cuando falta, el resultado es una filtración de datos personales o un uso de la información para un fin distinto del autorizado.

Confiabilidad y robustez *reliability and robustness*: el sistema debe mantener un rendimiento aceptable incluso ante datos inesperados o cambios en el entorno. Este principio es, en esencia, la respuesta organizacional a la deriva del modelo explicada más arriba: un modelo "confiable" no es el que nunca se equivoca, sino el que sigue funcionando razonablemente bien cuando la realidad se mueve, o que al menos avisa cuando dejó de hacerlo. Cuando falta, el síntoma es un modelo que rendía bien en las

pruebas iniciales y se degrada silenciosamente en producción, sin que nadie lo note hasta que el daño ya ocurrió.

Inclusión y no discriminación *inclusiveness and non-discrimination*: es necesario involucrar a equipos diversos durante el desarrollo para evitar puntos ciegos culturales o sesgos no evidentes. Este principio actúa antes que el modelo exista: un equipo homogéneo tiene más probabilidades de no notar, durante el diseño, que una variable o un caso de uso afecta de forma distinta a un grupo que no está representado en la sala. Cuando falta, el síntoma típico es un sistema que "nadie vio venir" que iba a fallar para cierto grupo, precisamente porque nadie de ese grupo participó en revisarlo.

Rendición de cuentas *accountability*: siempre debe existir una persona o un equipo responsable que responda por el comportamiento del sistema y sus consecuencias. Es el principio que cierra el círculo de los cinco anteriores: de nada sirve identificar un sesgo, una falla de privacidad o un problema de robustez si, al preguntar "¿quién responde por esto?", la respuesta institucional es el silencio. Cuando falta, la organización entera queda expuesta, porque no hay una persona con la autoridad y la obligación de actuar.

 **Nota:** el curso atribuye estos seis principios a "diversos expertos y empresas líderes (como Floridi & Cows, o Microsoft)", como si fuera una lista compartida por ambas fuentes. No lo es. Floridi y Cows (2019) proponen, en su artículo de referencia sobre ética de la IA, **cinco** principios —no seis—: beneficencia, no maleficencia, autonomía y justicia (los cuatro clásicos de la bioética de Beauchamp y Childress, trasladados al campo de la IA) más explicabilidad, que es el aporte original de los autores a ese marco de cuatro principios. Microsoft, por su parte, sí tiene una lista de seis principios en su Responsible AI Standard v2, pero esa lista tampoco coincide, principio por principio, con la del curso: la de Microsoft es fairness, reliability and safety, privacy and security, inclusiveness, transparency y accountability (transparencia y explicabilidad aparecen separadas en dos principios distintos, no fusionadas en uno). La lista de seis principios que usa el curso es, en la práctica, una síntesis propia, más cercana en número y contenido a la de Microsoft que a la de Floridi y Cows, pero no idéntica a ninguna de las dos. **Regla para el examen:** si la pregunta es por "los seis principios de esta unidad" o por "los principios que actúan como brújula", la respuesta son los seis de la lista del curso (equidad y justicia; transparencia y explicabilidad; privacidad y seguridad; confiabilidad y robustez; inclusión y no discriminación; rendición de cuentas). Si la pregunta es específicamente por "los principios de Floridi y Cows", la respuesta son los cinco de la bioética aplicada (beneficencia, no maleficencia, autonomía, justicia, explicabilidad). No mezclar ambas listas al responder.

Principio del curso	Equivalente en Floridi y Cows (2019)	Equivalente en Microsoft Responsible AI Standard v2
Equidad y justicia	Justicia	Fairness
Transparencia y explicabilidad	Explicabilidad	Transparency (separado de Accountability)
Privacidad y seguridad	No maleficencia (protege privacidad y seguridad, entre otros daños)	Privacy and Security
Confiabilidad y robustez	Sin equivalente directo; parcialmente cubierto por no maleficencia	Reliability and Safety
Inclusión y no discriminación	Justicia (acceso igualitario)	Inclusiveness
Rendición de cuentas	Explicabilidad (incluye el componente de accountability)	Accountability
Sin equivalente en el curso	Beneficencia; autonomía	—

La incorporación de estos seis principios desde el inicio no frena la innovación, sino que la orienta: permite detectar a tiempo problemas de discriminación, uso indebido de información o pérdida de confianza, fortaleciendo la relación con los grupos de interés que ya se identificaron en la sección anterior del módulo.

Gobernanza de la IA: el cómo y el quién

Si la ética define el qué y el por qué —qué principios respetar y por qué importan—, la **gobernanza de la IA** define el cómo y el quién: es el marco de normas, responsables, procedimientos y controles que permite conducir y vigilar el desarrollo, la puesta en marcha y el uso de la inteligencia artificial. Gobernar la IA es gestionar un proceso integral que coordina personas, procesos y decisiones a lo largo de todo el ciclo de vida del sistema. Y conviene ser preciso con algo que el curso subraya y que suele malinterpretarse: la finalidad de la gobernanza no es burocratizar, es decir, no es agregar trámites por agregarlos. Es organizar la complejidad para evitar contradicciones, duplicidades o riesgos invisibles que aparecen inevitablemente cuando distintas áreas de una organización trabajan con IA sin coordinarse entre sí.

El curso alinea esta idea con el marco **NIST AI RMF** *NIST AI Risk Management Framework* (2023), que propone gestionar los riesgos de la IA "considerando el liderazgo, los procesos internos, la supervisión y la mejora continua".

⚠ **Nota:** esa formulación es una paráfrasis del curso, no la nomenclatura oficial del marco. El NIST AI RMF 1.0 (publicado el 26 de enero de 2023 por el Instituto Nacional de Estándares y Tecnología de Estados Unidos) organiza la gestión de riesgo en **cuatro funciones** *Govern, Map, Measure, Manage* con contenido específico cada una: **GOVERN** es la función transversal, la base sobre la que se apoyan las otras tres —instala la cultura de gestión de riesgos, las políticas, los roles y la rendición de cuentas dentro de la organización—; **MAP** contextualiza el riesgo antes de medir nada: identifica el sistema, su propósito, sus impactos posibles y las partes interesadas afectadas; **MEASURE** aplica métodos cuantitativos y cualitativos para analizar, evaluar y monitorear los riesgos identificados y las capacidades de confiabilidad del sistema; y **MANAGE** asigna recursos para tratar esos riesgos —mitigarlos, transferirlos, evitarlos o aceptarlos— y define cómo responder ante incidentes. El marco añade además siete características que debe tener un sistema de IA confiable: válido y confiable, seguro (*safe*), seguro y resiliente frente a ataques (*secure and resilient*), responsable y transparente, explicable e interpretable, con privacidad reforzada, y justo, con el sesgo dañino gestionado activamente. **Regla para el examen:** la paráfrasis del curso ("liderazgo, procesos internos, supervisión y mejora continua") y las cuatro funciones oficiales (Govern, Map, Measure, Manage) describen lo mismo, a distinto nivel de detalle; si la pregunta pide "las funciones del NIST AI RMF" hay que nombrar las cuatro por su nombre en inglés, no la paráfrasis en español.

Una buena gobernanza, en la práctica, es la que logra responder con claridad a cinco preguntas. Cada una tiene, idealmente, un responsable identificable, y no una respuesta difusa repartida entre "el área técnica" en general:

Pregunta clave	Quién la responde en la práctica
¿Quién aprueba un modelo antes de su lanzamiento?	El comité de IA o ética, como instancia formal de autorización para proyectos de alto riesgo.
¿Quién verifica la calidad y el origen de los datos?	El custodio de datos, en coordinación con el equipo técnico que construyó el modelo.
¿Cómo se monitoriza el comportamiento del modelo en producción?	El propietario del modelo, con métricas de desempeño y alertas de deriva definidas junto al comité.
¿Quién interviene cuando se producen resultados inesperados?	El usuario de negocio que ejerce la supervisión humana en primera línea, escalando al comité si el caso es grave o recurrente.
¿Cada cuánto se revisa y actualiza el sistema?	La frecuencia la define el comité de gobernanza; la ejecuta el propietario del modelo, con revisión independiente de auditoría interna.

Roles que intervienen en la gobernanza

Cuando una organización multiplica sus proyectos de IA, las decisiones dejan de pertenecer solo al equipo técnico. Intervienen múltiples áreas, y si cada una actúa por separado, sin criterios compartidos, aparecen contradicciones o riesgos que nadie detecta a tiempo. Para evitarlo, la gobernanza asigna responsabilidades concretas a distintos roles. El PDF original presenta esta idea como un carrusel de seis láminas, de las cuales solo queda visible la primera:

 **Nota:** las láminas 2 a 6 del carrusel "Roles que intervienen en la gobernanza" no quedaron visibles en la versión descargable del PDF; solo se conserva el rol número uno, tal como lo redactó el curso. Lo que sigue es una reconstrucción coherente de los cinco roles faltantes, elaborada a partir de las cinco preguntas clave de gobernanza que el propio curso plantea en la subsección anterior y del comité de seis áreas —Riesgos, Tecnología, Cumplimiento, Auditoría, RR. HH. y Atención al Cliente— que aparece más adelante en el caso Banco Futuro. No es el texto original del PDF.

1. **Comité de IA o ética** (rol 1, textual del curso): equipo multidisciplinar de directivos, juristas y tecnólogos que revisa y autoriza proyectos de alto riesgo. Responde a la pregunta de quién aprueba un modelo antes de su lanzamiento.
2. **Propietario del modelo** *model owner*: la persona o el equipo que responde por el desempeño del modelo una vez en producción; define las métricas que se van a monitorear, recibe las alertas de deriva del modelo y decide cuándo escalar un problema al comité. Responde a cómo se monitoriza el comportamiento del modelo en producción.
3. **Custodio de datos** *data steward*: responsable de verificar la calidad, el origen y la representatividad de los datos usados para entrenar y para operar el modelo; es quien puede detectar, antes de que el modelo se entrene, si un conjunto de datos arrastra sesgo histórico o sesgo de muestreo. Responde a quién verifica la calidad y el origen de los datos.
4. **Cumplimiento y asesoría jurídica**: evalúa que el sistema cumpla la normativa vigente (protección de datos, regulación sectorial, obligaciones del AI Act cuando corresponda) y participa en la autorización de proyectos junto al comité. Responde, en conjunto con el comité, a quién aprueba un modelo, y además a cada cuánto exige la normativa una revisión.
5. **Auditoría interna**: realiza la **auditoría de algoritmos** *algorithm audit* periódica e independiente de los modelos ya en producción, verificando que los controles de gobernanza definidos realmente se estén aplicando y no solo estén documentados en una política. Responde a cada cuánto se revisa y actualiza el sistema, desde una mirada independiente del equipo que lo opera.
6. **Usuario de negocio** que ejerce la supervisión humana: la persona que usa el sistema en el día a día —el ejecutivo comercial, el analista de crédito, el médico— y que está en

la mejor posición para notar cuándo una recomendación no calza con su criterio profesional. Responde a quién interviene cuando se producen resultados inesperados, siendo la primera línea de defensa antes de que el problema escale.

Cuando estas funciones están claramente asignadas, la organización puede avanzar con mayor seguridad y menos ambigüedad: cada una de las cinco preguntas clave de gobernanza tiene un responsable identificable, en lugar de una responsabilidad difusa que, en la práctica, nadie termina asumiendo.

El ciclo de vida de la IA: un proceso continuo

La gobernanza y la ética no son acciones puntuales que se ejecutan una vez y quedan resueltas; acompañan al sistema durante todo su recorrido. Reducir la gobernanza al momento del lanzamiento es un error concreto y bien identificable, no una imprecisión menor, porque ya se explicó por qué el rendimiento de un modelo puede cambiar cuando cambian los datos, el entorno o las condiciones del negocio: es exactamente el fenómeno de la deriva del modelo descrito más arriba. Un sistema que se gobierna solo hasta el día de su lanzamiento queda, a partir de ese día, sin nadie vigilando si la realidad que lo sostiene sigue siendo la misma. El **ciclo de vida de la IA** *AI lifecycle* organiza esa vigilancia continua en cuatro fases:

Diseño y estrategia (fase 1 de 4): se define el problema que se busca resolver, el beneficio esperado y los riesgos potenciales. En esta fase se realiza la **evaluación de impacto ético** *ethical impact assessment* —el mecanismo concreto de la ética por diseño explicada más arriba: preguntarse, antes de escribir una línea de código, a quién puede afectar el sistema y de qué manera— y se verifica la calidad y la representatividad de los datos disponibles, es decir, se revisa por adelantado si existe riesgo de sesgo histórico o de muestreo.

Desarrollo y pruebas (fase 2 de 4): el equipo técnico construye el modelo, pero antes de que pueda autorizarse su uso, el comité de IA revisa su finalidad, los sesgos detectados durante las pruebas, la seguridad del sistema y los efectos posibles sobre clientes y trabajadores. Esta es la fase donde el comité ejerce, en la práctica, la función de aprobación descrita en la primera pregunta clave de gobernanza.

Implementación y lanzamiento (fase 3 de 4): se establecen mecanismos de **human-in-the-loop** —literalmente, "humano en el circuito": arreglos donde una persona interviene en el proceso de decisión antes de que el resultado del modelo se ejecute, en lugar de que el sistema actúe de forma completamente autónoma—, se documentan las limitaciones conocidas del modelo en lo que la práctica profesional llama una **documentación del modelo** *model card* —una ficha técnica y de uso responsable que resume para qué fue entrenado el modelo, con qué datos, qué limitaciones tiene y en qué condiciones no debería usarse—, y se inicia el **monitoreo en producción** *production monitoring* de sus resultados.

Operación y seguimiento continuo (fase 4 de 4): la supervisión no termina con el lanzamiento. Es necesario revisar periódicamente que el modelo sigue siendo confiable, ajustarlo ante nuevas circunstancias y, sobre todo, aprender de cada proyecto para fortalecer la capacidad de la organización en las iniciativas futuras. Esta fase es, en términos prácticos, donde se detecta y se corrige la deriva del modelo antes de que produzca un daño equivalente al del caso Amazon.

El cierre de esta idea conecta con todo lo anterior: si la gobernanza se limitara al lanzamiento, la organización estaría vigilando exactamente el momento en que el sistema es menos probable que falle —acaba de ser probado y aprobado— y dejando de vigilar el momento en que la deriva del modelo empieza a acumularse silenciosamente. Por eso el ciclo de vida se presenta como un proceso continuo y no como una secuencia de cuatro pasos que termina en el tercero.

La responsabilidad social como ventaja estratégica

La responsabilidad social aplicada a la IA supone reconocer que sus efectos trascienden a la organización que la usa. Una recomendación errónea, un modelo que nadie logra explicar o un uso descuidado de los datos personales pueden deteriorar la confianza de clientes, trabajadores y otros grupos de interés; son, en esencia, las tres formas concretas en que puede fallar todo lo explicado hasta aquí: falla el modelo (equidad y confiabilidad), falla la explicación (transparencia y explicabilidad), o falla el manejo de los datos (privacidad y seguridad). Por eso muchas organizaciones han incorporado la responsabilidad social a sus procesos de innovación, buscando que el avance tecnológico contribuya al bienestar sin dejar de fortalecer su competitividad.

Esta forma de entender la responsabilidad también mejora la relación con el entorno, y lo hace por una vía directa: una organización gana credibilidad cuando explica el uso que hace de la IA, establece controles verificables y demuestra que asume las consecuencias de sus decisiones, en lugar de limitarse a declarar principios en un documento que nadie más que el equipo legal lee. Así, la ética y la responsabilidad social dejan de ser asuntos paralelos a la gestión del negocio y se convierten en palancas concretas para construir vínculos más sólidos con las personas y las instituciones con las que la organización se relaciona.

Gobernar la inteligencia artificial, en definitiva, no consiste solo en vigilar algoritmos: consiste en crear las condiciones para que la tecnología evolucione con seguridad, transparencia y coherencia organizacional. Al integrar la ética profunda desde el diseño y establecer una gobernanza clara —con roles definidos, un ciclo de vida vigilado de principio a fin y principios que se aplican, no solo se declaran—, las organizaciones transforman la IA de un riesgo potencial en un activo estratégico: uno que protege la confianza ya construida, impulsa el aprendizaje continuo de la propia organización y asegura que la innovación

contribuya al bienestar general sin perder de vista la competitividad que la justificó en primer lugar.

Las preguntas de comentario que propone el curso para cerrar esta sección son:

1. ¿Qué cambios concretos requeriría tu organización para pasar de declarar principios éticos de IA a incorporarlos efectivamente en el ciclo de vida de sus proyectos?
2. ¿Cómo equilibrar la necesidad de innovación rápida con los tiempos y procesos que exige una gobernanza rigurosa de la IA?

IA responsable y organizaciones confiables

El curso cierra el círculo con una idea que funciona como bisagra entre todo lo visto hasta aquí y lo que sigue: **una organización confiable no es la que elimina todos los riesgos, sino la que los reconoce, los gestiona y construye día a día relaciones basadas en transparencia**. Esta frase merece que la desarmemos, porque contradice una expectativa muy extendida entre equipos técnicos: la de que "hacerlo bien" significa reducir el riesgo a cero antes de lanzar. Eso no es solo poco realista con sistemas de aprendizaje automático que cambian de comportamiento cuando cambian los datos —lo que ya viste como **deriva del modelo** *model drift* en el bloque de gobernanza—; es además la actitud que, paradójicamente, produce menos confianza. Una organización que promete cero riesgo y luego falla (porque todo sistema falla alguna vez) pierde credibilidad de golpe. Una organización que reconoce desde el inicio que va a haber errores, publica cómo los detecta y cómo responde, y demuestra con hechos sostenidos en el tiempo que ese proceso funciona, construye algo más resistente: una reputación de manejo responsable, no de infalibilidad. Por eso el título habla de organizaciones "confiables" y no "perfectas". El cambio significativo, dice el curso, aparece cuando la tecnología se incorpora de forma responsable y esa confianza se construye con cuatro palancas que ya conoces por su nombre pero que aquí se ensamblan en un sistema: liderazgo, personas, procesos y decisiones. Las cinco características que siguen en esta sección son, precisamente, el desglose de esas cuatro palancas en prácticas concretas.

Referentes internacionales

Para sostener esas prácticas, ninguna organización parte de cero: existe todo un ecosistema de organismos internacionales, instituciones de normalización y gobiernos que ya se hicieron la pregunta de cómo gobernar la IA y publicaron su respuesta. El curso es explícito en un punto que conviene subrayar porque cambia la actitud con la que se lee un marco internacional: estos referentes **no son solo obligaciones externas** que hay que cumplir a regañadientes. Son herramientas para mejorar procesos internos, anticipar dificultades antes de que se conviertan en crisis (como la que vivió Banco Futuro, que verás más adelante) y fortalecer la confianza de cuatro audiencias distintas: clientes,

colaboradores, inversionistas y reguladores. Cada una de esas audiencias lee estos marcos de forma distinta —un regulador busca cumplimiento, un inversionista busca gestión de riesgo, un cliente busca garantías—, y por eso a una organización le conviene conocer varios marcos, no uno solo.

Lo interesante es que estos referentes no dicen todos lo mismo ni de la misma manera: plantean respuestas distintas al mismo desafío de fondo, que es cómo aprovechar el potencial de la IA sin desconocer sus riesgos. Algunos enfatizan **principios éticos** (declaraciones de valores que orientan el comportamiento deseable); otros enfatizan la **gestión de riesgos** (procesos sistemáticos para identificar, medir y tratar amenazas); otros la **gobernanza** (estructuras de roles y decisión); y otros el **cumplimiento normativo** *regulatory compliance*, es decir, obligaciones legales con consecuencias jurídicas si se incumplen. Distinguir estos cuatro énfasis es la clave para no tratar todos los marcos como si fueran intercambiables: un principio ético no obliga legalmente a nadie, pero orienta la cultura; una ley vinculante sí obliga, con sanciones. Vas a ver los cinco marcos concretos organizados exactamente según este eje, de lo más orientativo a lo más vinculante.

 **Nota:** el carrusel de marcos internacionales del PDF original quedó con solo la primera lámina visible —los Principios de la OCDE (2019)— y además mal renderizada, letra por letra. Las láminas correspondientes a UNESCO, NIST, ISO/IEC 42001 y AI Act no quedaron legibles en el documento descargable. Lo que sigue está reconstruido íntegramente desde las fuentes oficiales de cada marco, verificadas a septiembre de 2026, precisamente para que el vacío del carrusel no se convierta en un vacío de tu formación.

1. Principios de la OCDE sobre IA (2019), el más antiguo de los cinco y el único que el curso presenta con cierto detalle. La *OECD* (Organización para la Cooperación y el Desarrollo Económicos) publicó en 2019 cinco principios basados en valores, pensados como una guía de alto nivel más que como una norma operativa: (1) crecimiento inclusivo, desarrollo sostenible y bienestar; (2) valores centrados en el ser humano y equidad, que incluye derechos humanos, valores democráticos y privacidad; (3) transparencia y explicabilidad; (4) robustez, seguridad y protección; y (5) rendición de cuentas. A estos se suman cinco recomendaciones dirigidas a los gobiernos, no a las empresas: invertir en investigación y desarrollo; construir un ecosistema digital inclusivo; crear un entorno de políticas públicas interoperable entre países; desarrollar capacidades humanas y gestionar la transición laboral; y cooperar internacionalmente. Es, en el eje que acabas de ver, el marco más cercano al polo de "principio ético": no certifica nada, no obliga a nada, pero fija el vocabulario común que después usan casi todos los marcos posteriores —de hecho, la frase del curso que citamos más abajo sobre transparencia, rendición de cuentas, supervisión humana y gestión de riesgos es, en buena medida, un eco directo de estos cinco principios.

 **Nota:** el curso cita únicamente la versión 2019 de los Principios de la OCDE. En mayo de 2024 la OCDE los actualizó, sin reemplazarlos: amplió la definición de "sistema de IA" para cubrir explícitamente la **IA generativa** y los modelos de propósito general, e incorporó riesgos que en 2019 no eran centrales —desinformación e integridad de la información, propiedad intelectual y sostenibilidad ambiental—. A septiembre de 2026, la versión actualizada está respaldada por 47 jurisdicciones. Regla para el examen: si la pregunta pide los Principios de la OCDE, la respuesta correcta son los cinco de 2019 (siguen vigentes tal cual); si la pregunta pide qué cambió o qué cubre la versión actual, la respuesta es la actualización de 2024, que amplía el alcance sin sustituir los cinco principios originales.

2. Recomendación de la UNESCO sobre la Ética de la IA (noviembre de 2021). Este es un salto de categoría respecto de la OCDE: no es un documento de una organización económica dirigido a gobiernos miembros, sino el primer instrumento normativo global sobre ética de la IA, adoptado por aclamación por los 193 Estados Miembros de la UNESCO. "Por aclamación" significa que no hubo votación dividida: hubo consenso explícito de todos los países, lo que le da un peso simbólico que ningún otro marco de esta lista tiene. Su estructura se organiza en dos niveles. Primero, cuatro **valores** de fondo: dignidad humana y derechos humanos; sociedades justas, pacíficas e interconectadas; diversidad e inclusión; y florecimiento del medioambiente y los ecosistemas —este último valor es distintivo de la UNESCO: ningún otro marco de la lista pone la sostenibilidad ambiental al mismo nivel jerárquico que los derechos humanos—. Segundo, diez **principios** operativos que bajan esos valores a criterios de acción: proporcionalidad y no causar daño; seguridad y protección; privacidad y protección de datos; gobernanza adaptativa y multiactor; responsabilidad y rendición de cuentas; transparencia y explicabilidad; supervisión y determinación humanas; sostenibilidad; conciencia y alfabetización; y equidad y no discriminación. Para que esto no se quede en declaración de intenciones, la UNESCO desarrolló dos herramientas de implementación concretas: la **RAM** *Readiness Assessment Methodology*, un instrumento para que un país evalúe qué tan preparado está institucionalmente para gobernar la IA, y la **EIA** *Ethical Impact Assessment*, una evaluación de impacto ético aplicable a proyectos concretos —el mismo tipo de instrumento que el curso menciona, sin nombrarlo con esta sigla, en la fase de Diseño y estrategia del ciclo de vida—. La UNESCO reporta que apoya a más de 50 países en la implementación de esta Recomendación.

 **Nota:** el cuerpo del curso fecha la Recomendación de la UNESCO en 2021, pero la bibliografía del mismo documento la fecha en 2022. Ambas fechas son correctas según a qué se refieran: el texto se adoptó formalmente en noviembre de 2021; la edición publicada del documento —la versión con formato final que suele citarse bibliográficamente y es la que se usa en la lectura obligatoria de esta unidad— es de 2022.

Regla para el examen: si preguntan cuándo se adoptó, la respuesta es 2021; si preguntan por la edición o publicación citada en bibliografía, es 2022.

3. NIST AI RMF 1.0 (enero de 2023). El bloque anterior de esta explicación ya presentó en detalle sus cuatro funciones —**GOVERN, MAP, MEASURE y MANAGE**— y sus siete características de IA confiable, así que aquí no las repetimos; si necesitas refrescarlas, están en la sección de gobernanza. Lo que agregamos aquí es el encuadre que le falta a esa presentación para entenderlo como referente internacional: primero, que el *NIST* (Instituto Nacional de Estándares y Tecnología, la agencia de normalización técnica de Estados Unidos) lo publicó como **marco voluntario** de gestión de riesgos, no como ley —a diferencia del AI Act europeo que verás más abajo, ninguna organización está legalmente obligada a adoptar el NIST AI RMF, y eso es justamente lo que lo vuelve atractivo como estándar de facto: cualquier empresa, en cualquier país, puede adoptarlo sin que eso implique quedar sujeta a jurisdicción estadounidense—. Segundo, que el marco tuvo una extensión relevante después de su publicación original: en julio de 2024 el NIST publicó el **Generative AI Profile** (identificado como NIST AI 600-1), un perfil específico que aplica las mismas cuatro funciones al caso particular de los modelos generativos, con riesgos propios de esa tecnología —alucinaciones, contenido sintético, fuga de datos de entrenamiento— que el marco original de 2023 no cubría con ese nivel de detalle. Para una organización fuera de Estados Unidos, el valor del NIST AI RMF está en que ofrece el vocabulario de gestión de riesgos más citado internacionalmente y es compatible como insumo metodológico dentro de un sistema de gestión certificable como ISO/IEC 42001, que es el siguiente marco.

4. ISO/IEC 42001:2023, publicada en diciembre de 2023. Este es el primer estándar internacional de **sistema de gestión de IA** *AI Management System, AIMS*, y aquí conviene detenerse porque el tipo de instrumento que es cambia completamente su utilidad frente a los tres anteriores. Los marcos previos —OCDE, UNESCO, NIST— son principios o metodologías: los adoptas, los sigues, pero nadie externo certifica que los cumples. ISO/IEC 42001 es distinto: sigue la estructura **Annex SL**, el esqueleto común que comparten los estándares ISO de sistemas de gestión (el mismo que usan ISO 27001 de seguridad de la información e ISO 9001 de calidad), lo que en la práctica significa que una organización que ya tiene certificación ISO 27001 puede integrar su sistema de gestión de IA sobre la misma base documental y de auditoría, sin partir de cero. Funciona con el clásico ciclo **PDCA** *Plan-Do-Check-Act*: planificar, ejecutar, verificar y actuar sobre el sistema de gestión de forma continua —el mismo patrón de mejora continua que ya viste en la fase 4 del ciclo de vida de la IA—. Y lo más importante: ISO/IEC 42001 **es certificable**. Una organización puede pasar una auditoría externa realizada por un organismo acreditado y obtener un certificado que demuestra, ante clientes, inversionistas y reguladores, que su forma de gestionar la IA cumple el estándar. Esto la distingue con precisión de otro documento de la misma familia ISO que suele confundirse con ella: **ISO/IEC 23894**, que es una guía de gestión del riesgo

de IA —aplica el marco general de gestión de riesgo ISO 31000 al contexto específico de la IA—, es puramente orientativa, no certificable, y puede usarse como metodología dentro de los controles de un sistema de gestión ISO/IEC 42001; no lo reemplaza ni compite con él.

 **Nota:** el curso no menciona la novedad de 2025: se publicó **ISO/IEC 42006:2025**, que fija los requisitos que deben cumplir los propios organismos de auditoría y certificación de sistemas de gestión de IA. Dicho de otro modo, si ISO/IEC 42001 es la norma que certifica a las organizaciones, ISO/IEC 42006:2025 es la norma que certifica a quienes certifican —asegura que el certificador sea competente e imparcial—. Es una pieza de infraestructura de confianza de segundo orden, relevante para quien evalúe qué tan sólida es una certificación 42001 concreta.

5. Al Act de la Unión Europea — Reglamento (UE) 2024/1689, publicado en el Diario Oficial de la Unión Europea el 12 de julio de 2024 y en vigor desde el 1 de agosto de 2024. Este es, de los cinco marcos, el único **vinculante**: no es un principio orientativo, no es un marco voluntario de gestión de riesgo, no es una norma que se adopta si se quiere certificar algo —es una ley que aplica con fuerza jurídica a cualquier organización que ofrezca o use sistemas de IA en el mercado de la Unión Europea, sin importar dónde tenga su sede—. Su arquitectura central es una clasificación por **categorías de riesgo**: cuatro niveles que determinan qué obligaciones aplican a un sistema según cuánto daño potencial representa. La categoría de riesgo inaceptable cubre **prácticas prohibidas** *prohibited practices* —por ejemplo, sistemas de puntuación social del estilo del "social scoring" gubernamental, o técnicas de manipulación subliminal que distorsionan el comportamiento de una persona de forma que le cause daño—: quedan directamente vetadas, sin excepción de uso. La categoría de **sistema de alto riesgo** *high-risk AI system* incluye, entre otros, los sistemas usados para evaluación crediticia, selección de personal, admisión educativa o aplicación de la ley: no están prohibidos, pero quedan sujetos a una regulación estricta —evaluación de conformidad, documentación técnica, supervisión humana obligatoria, registro en una base de datos pública— antes de poder comercializarse. Dentro de esta categoría, el Reglamento distingue dos anexos: el Anexo III cubre sistemas de alto riesgo independientes (por ejemplo, un software de screening de créditos vendido como producto autónomo) y el Anexo I cubre IA embebida como componente de seguridad dentro de productos ya regulados por otra normativa (por ejemplo, el software de un dispositivo médico). La categoría de riesgo limitado impone solo obligaciones de transparencia —avisar que se está interactuando con una IA, por ejemplo un chatbot—, y la categoría de riesgo mínimo no trae obligaciones específicas. El Reglamento introduce además la figura de **IA de propósito general** *general-purpose AI, GPAI*, que cubre a los modelos base tipo los grandes modelos de lenguaje, con obligaciones propias de transparencia técnica y gestión de riesgo sistémico, independientes de en qué aplicación final se use el modelo.

 **Nota — la discrepancia más importante de la unidad:** el curso presenta el AI Act como un marco de 2024, sin calendario de aplicación. A septiembre de 2026 ese calendario cambió de forma sustancial y es indispensable conocerlo tal como está hoy. Lo que ya está vigente: las prohibiciones del artículo 5 y las obligaciones de alfabetización en IA del artículo 4, desde el 2 de febrero de 2025; las obligaciones para los modelos de IA de propósito general (GPAI), desde el 2 de agosto de 2025; y las obligaciones de transparencia del artículo 50 (por ejemplo, avisar que se interactúa con una IA), desde el 2 de agosto de 2026. Lo que cambió: las obligaciones sustantivas para los sistemas de alto riesgo fueron **aplazadas** por el llamado **Digital Omnibus** —el Reglamento (UE) 2026/1744, publicado en el Diario Oficial el 24 de julio de 2026 y en vigor desde el 27 de julio de 2026—: las del Anexo III (sistemas independientes) se movieron del 2 de agosto de 2026 al **2 de diciembre de 2027**, y las del Anexo I (IA embebida en productos regulados) se movieron del 2 de agosto de 2027 al **2 de agosto de 2028**. Es importante entender que el Digital Omnibus es ley vigente en vigor, no una propuesta en discusión, y que afecta solamente al capítulo de alto riesgo: no toca las prohibiciones, ni las obligaciones GPAI, ni la transparencia del artículo 50, que siguen su calendario original sin cambios. Regla para el examen: si la pregunta es sobre el contenido del AI Act —qué categorías de riesgo existen, qué es un sistema de alto riesgo, qué es una práctica prohibida—, la respuesta correcta usa las cuatro categorías tal como las presenta el curso, sin necesidad de mencionar fechas. Si la pregunta es sobre plazos o sobre el estado actual de aplicación del Reglamento, la respuesta correcta es el calendario aplazado por el Digital Omnibus, no el calendario original de 2024.

Marco	Emisor y año	Tipo de instrumento	Qué exige, en una frase	¿Es vinculante?
Principios de la OCDE sobre IA	OCDE, 2019 (actualizado 2024)	Principios éticos orientativos	Cinco valores guía y cinco recomendaciones a gobiernos	No
Recomendación sobre la Ética de la IA	UNESCO, nov. 2021	Instrumento normativo global (no ley)	Cuatro valores y diez principios, con herramientas RAM y EIA	No
AI RMF 1.0	NIST (EE. UU.), ene. 2023	Marco voluntario de gestión de riesgos	Cuatro funciones (Govern, Map, Measure, Manage) para gestionar riesgo de IA	No
ISO/IEC 42001	ISO/IEC, dic. 2023	Norma de sistema de gestión, certificable	Sistema de gestión de IA (AIMS) auditable con ciclo PDCA	No es ley, pero es certificable y auditable por terceros
AI Act de la Unión Europea	Unión Europea, Reg. (UE) 2024/1689, jul. 2024	Ley (reglamento)	Cuatro categorías de riesgo con obligaciones legales escalonadas	Sí

El propio curso resume el aporte conjunto de los dos marcos más citados en una frase que conviene retener textual: *"La OCDE (2019) y la UNESCO (2021) destacan especialmente la transparencia, la rendición de cuentas, la supervisión humana y la gestión de riesgos"*. Nota que estos cuatro elementos no son una lista nueva: son, casi palabra por palabra, los mismos conceptos que ya trabajaste como **transparencia**, **rendición de cuentas**, **supervisión humana** y las funciones de gestión de riesgo del NIST AI RMF en el bloque anterior. Esa coincidencia no es casual: es la evidencia de que, más allá de las diferencias de énfasis entre principios, riesgo, gobernanza y cumplimiento, los cinco marcos convergen en un núcleo común de exigencias, y ese núcleo es exactamente el que el curso viene enseñando desde el bloque B.

Cómo se construye una organización confiable

Los cinco marcos anteriores dicen qué se espera desde afuera. Esta subsección responde la pregunta complementaria: qué tiene que pasar adentro de una organización para que esa

expectativa se cumpla en la práctica y no se quede en una política redactada que nadie sigue. El curso identifica cinco características, y vale la pena leerlas no como una lista de buenas intenciones sino como cinco puntos de falla distintos: cada una describe un mecanismo concreto, y cada una tiene una forma reconocible de fallar cuando no está presente.

La primera es el **liderazgo comprometido**. El mecanismo es que la confianza no se puede delegar únicamente al equipo técnico: son los directivos quienes impulsan la cultura organizacional, asignan los recursos —presupuesto, tiempo, personas— necesarios para implementar controles, y marcan el ejemplo con su propio comportamiento frente a la tecnología. Cuando este liderazgo falta, lo que se observa es un patrón muy reconocible: la organización tiene una política de IA responsable en un documento, pero ningún directivo la menciona en una decisión real, y el equipo técnico percibe que "responsable" es una palabra de relaciones públicas, no un criterio que afecte su trabajo diario. La segunda es **personas formadas y conscientes**: no basta con que existan principios escritos si nadie en la organización entiende su rol específico dentro de la cadena de valor de la IA ni sabe identificar un riesgo cuando lo tiene enfrente. Cuando falta, el síntoma es el que viste en el caso Banco Futuro más abajo: un ejecutivo comercial que no puede explicarle a un cliente por qué se rechazó su crédito, no porque no quiera, sino porque nunca fue entrenado para traducir la salida de un modelo en un lenguaje comprensible. La tercera es **procesos claros y documentados**: desde la selección de los datos hasta el monitoreo posterior al lanzamiento, cada etapa necesita procedimientos definidos y responsables asignados por nombre, no por intención genérica. Sin esto, lo que ocurre es exactamente lo que el comité de Banco Futuro diagnosticó como "procedimientos": ausencia de criterios compartidos, cada sucursal improvisando su propia manera de usar el sistema. La cuarta es **decisiones con criterio crítico**: usar la herramienta con juicio profesional, sin confiar en ella de forma ciega, manteniendo la intervención humana activa cuando el criterio profesional es indispensable —esta característica es la puerta de entrada a los conceptos de sesgo de automatización y aversión al algoritmo que vas a ver en el caso—. Y la quinta es **supervisión y mejora continua**: la IA cambia rápido, aparecen regulaciones nuevas (como el Digital Omnibus que acabas de leer) y las expectativas sociales evolucionan, así que una organización que se declaró "confiable" una vez y no revisa esa condición periódicamente deja de serlo sin darse cuenta.

EJEMPLO

Piensa en dos bancos que lanzan el mismo modelo de evaluación crediticia el mismo día, con la misma exactitud estadística. El Banco A tiene un directorio que revisa trimestralmente los indicadores de sesgo del modelo (liderazgo comprometido), analistas capacitados para explicar un rechazo en términos no técnicos (personas formadas), un procedimiento escrito que dice quién aprueba una excepción (procesos claros), instrucciones explícitas de que el analista puede anular la recomendación del sistema justificando el porqué (criterio crítico), y una auditoría semestral del comportamiento

del modelo (mejora continua). El Banco B tiene el mismo modelo, pero ninguna de las cinco características. Estadísticamente, ambos bancos son igual de "precisos". Organizacionalmente, solo uno de los dos es confiable, y eso se va a notar exactamente en el momento en que el modelo cometa un error —que tarde o temprano va a cometer.

La confianza como proceso continuo

El curso resume esta idea con una cita que conviene tomar en serio porque condensa buena parte de la unidad. Es de Microsoft (2022): "*Una inteligencia artificial responsable exige incorporar principios éticos, gobernanza y supervisión desde las primeras decisiones de diseño*". La fuente de esa cita es el **Microsoft Responsible AI Standard**, en su versión 2, publicado en junio de 2022, uno de los documentos más citados en la práctica corporativa de gobernanza de IA y que el curso recomienda como material complementario (lo verás en la sección de recursos). Ese documento no se queda en la declaración de principios: construye una arquitectura de tres capas que va de lo abstracto a lo verificable. En la capa superior están los **principios** —seis, en el caso de Microsoft: equidad *fairness*, confiabilidad y seguridad *reliability and safety*, privacidad y seguridad *privacy and security*, inclusión *inclusiveness*, transparencia *transparency* y rendición de cuentas *accountability*—. Cada principio se traduce en una o más metas concretas, **goals**, como por ejemplo "realizar evaluaciones de impacto" o "mantener supervisión humana activa". Y cada meta se traduce, a su vez, en **requirements**: requisitos verificables y auditables, es decir, criterios que se pueden comprobar objetivamente en una revisión, no aspiraciones vagas. Esta arquitectura de tres capas —Principio, Meta, Requisito— es la respuesta operativa a la pregunta que la unidad viene planteando desde el inicio: cómo pasar de "queremos ser éticos" a "podemos demostrar que lo somos".

El PDF del curso ilustra esta idea con un carrusel de cinco láminas del que solo quedó visible la primera: "Diseño con propósito — desde el inicio, definir qué problema se resuelve, qué beneficios se esperan y qué riesgos pueden aparecer; incorporar principios éticos como guía". Esa primera lámina coincide, sin sorpresa, con la fase de Diseño y estrategia del ciclo de vida de la IA que ya estudiaste. Las cuatro láminas faltantes se pueden reconstruir siguiendo la misma lógica del ciclo de vida de cuatro fases más el elemento de aprendizaje organizacional que el curso menciona en el cierre de la sección de gobernanza:

1. **Diseño con propósito** (visible en el PDF): definir desde el inicio qué problema se resuelve, qué beneficios se esperan y qué riesgos pueden aparecer; incorporar principios éticos como guía desde la primera decisión, no como parche posterior.
2. **Desarrollo con controles y revisión de sesgos**: durante la construcción del modelo, aplicar pruebas sistemáticas de sesgo sobre distintos subgrupos, documentar las decisiones de diseño que afectan la equidad del sistema, y someter el modelo a la

revisión del Comité de IA antes de autorizarlo —exactamente lo que el curso describió en la fase 2 del ciclo de vida.

3. **Implementación con supervisión humana declarada:** al lanzar el sistema, establecer explícitamente los mecanismos de **human-in-the-loop** —quién interviene, en qué casos, con qué margen de decisión— y documentar por escrito las limitaciones conocidas del modelo, para que nadie lo use más allá de lo que fue diseñado a hacer.
4. **Operación con monitoreo y trazabilidad:** una vez en producción, sostener el monitoreo continuo del comportamiento del modelo, registrar cada decisión relevante de forma que sea posible reconstruir después por qué el sistema hizo lo que hizo —esto es la **trazabilidad** *traceability*, condición indispensable para poder auditar o explicar una decisión meses después de tomada—.
5. **Aprendizaje continuo:** cerrar el ciclo capturando lo aprendido de cada proyecto —qué funcionó, qué falló, qué habría que hacer distinto— y alimentar con eso el diseño del siguiente proyecto, de forma que la organización no repita los mismos errores. Este último paso es el que convierte una secuencia de proyectos aislados en una capacidad organizacional que mejora con el tiempo.

 **Nota:** los pasos 2 a 5 de este carrusel no aparecen en el PDF original —el carrusel quedó truncado en la primera lámina—. Se reconstruyeron aquí en coherencia directa con el ciclo de vida de cuatro fases que el propio curso presentó en la sección de gobernanza y con la idea de aprendizaje organizacional mencionada en su cierre, para que la secuencia quede completa y utilizable como checklist.

La confianza como ventaja competitiva

Hasta aquí la confianza se presentó como una condición necesaria para que un proyecto de IA no fracase. Esta subsección da un paso más: la confianza no es solo defensiva, es una ventaja competitiva activa, y el curso identifica cuatro beneficios concretos que obtiene una organización que la construye bien.

El primero es **credibilidad y reputación:** una organización gana credibilidad exactamente cuando explica el uso que hace de la IA, establece controles verificables y asume las consecuencias cuando algo sale mal, en lugar de minimizarlo o esconderlo. El segundo es **relaciones más sólidas:** los cuatro grupos de interés que mencionamos antes —clientes, colaboradores, inversionistas y reguladores— valoran la transparencia de forma consistente, y eso se traduce en vínculos más duraderos: un cliente que entiende por qué el sistema tomó una decisión es un cliente que se queda, incluso si esa decisión no le fue favorable. El tercero es **menos riesgos legales y operativos:** anticipar discriminación, sesgos o uso indebido de datos personales antes de que se materialicen reduce sanciones regulatorias (piensa en las obligaciones del AI Act) y reduce lo que el curso llama, sin nombrarlo con este término exacto, el **riesgo reputacional** *reputational risk* —el daño a la

reputación de una organización que se produce cuando un fallo de IA se hace público, incluso si el fallo técnico en sí fue menor: el daño reputacional casi nunca es proporcional al error técnico, sino a qué tan mal gestionada se percibe la respuesta de la organización—. El cuarto beneficio es la **innovación sostenible** *sustainable innovation*: la idea de que la IA genera valor real y duradero solo cuando ese valor no descuida la responsabilidad hacia las personas afectadas; una innovación que produce resultados a corto plazo a costa de daño no compensado no es sostenible, porque tarde o temprano ese daño se convierte en el tipo de crisis de confianza que vas a ver en el caso Banco Futuro.

Los nueve puntos del video resumen

El material de la unidad cierra esta sección con un video resumen de nueve puntos que funciona como mapa completo de todo lo recorrido hasta aquí, y que conviene repasar como tal —no como contenido nuevo, sino como el esqueleto que conecta todo lo anterior—. Primero, el valor real de un sistema de IA no depende solo de su rendimiento técnico: depende de si genera confianza en quienes lo usan y en quienes son afectados por él. Segundo, la confianza funciona como un activo estratégico, no como un efecto colateral agradable de tener. Tercero, cuando la IA interviene en decisiones que afectan personas aparecen exigencias adicionales que no existen cuando la IA solo asiste: transparencia, explicabilidad, privacidad y supervisión humana. Cuarto, los datos no son neutrales: reflejan el mundo del que provienen, con sus desigualdades incluidas, y de ahí nace el sesgo algorítmico. Quinto, la ética profunda se incorpora desde el diseño, no cuando surge la controversia. Sexto, la responsabilidad social es parte de la estrategia de la organización, no una función aislada de relaciones públicas o cumplimiento. Séptimo, la gobernanza es lo que hace operativos los principios éticos: sin gobernanza, un principio queda en el papel. Octavo, existen marcos internacionales de referencia —OCDE, UNESCO, NIST, ISO/IEC 42001 y AI Act— que ofrecen respuestas complementarias, no competidoras, al mismo desafío. Y noveno, una organización confiable se construye con decisiones consistentes sostenidas en el tiempo, no con declaraciones puntuales: es exactamente la idea con la que abrió esta sección y con la que se cierra el caso que sigue a continuación.

El caso Banco Futuro

El punto de partida y la apuesta tecnológica

Carlos Rojas, Director de Transformación Digital, narra el caso de Banco Futuro, una entidad chilena con más de treinta años de historia que se vio forzada a modernizarse por la presión de dos frentes nuevos: los bancos digitales y las fintech ágiles, competidores sin la carga de infraestructura legada de un banco tradicional pero con capacidad de iterar mucho más rápido. Frente a esa presión, el directorio tomó una decisión de fondo: apostar fuerte por la tecnología, incorporando soluciones de inteligencia artificial en cuatro

procesos clave —evaluación de créditos, detección de fraudes, personalización de ofertas y atención al cliente mediante asistentes virtuales—. Es importante notar, antes de seguir, que esta decisión en sí misma no era irresponsable ni estaba mal planteada: cuatro procesos bien elegidos, todos con potencial real de mejora mediante IA. El problema del caso, como vas a ver, no está en qué decidió hacer el banco sino en cómo lo hizo.

Los resultados iniciales que parecían un éxito

Al principio, los resultados fueron, en palabras del propio relato, "de lo más alentadores": los procesos se volvieron más ágiles, los tiempos de respuesta se acortaron drásticamente, y los modelos predictivos empezaron a identificar patrones que antes pasaban desapercibidos para los analistas humanos. Los informes internos mostraban mejoras medibles en productividad y control de costos, y Banco Futuro llegó a ser reconocido como un referente de innovación tecnológica dentro del sector financiero chileno. Si el caso terminara aquí, sería una historia de éxito técnico sin matices. No termina aquí, y esa es exactamente la lección: el éxito medido con **indicadores técnicos** —precisión, velocidad, costo— puede coexistir con un fracaso que esos mismos indicadores no detectan.

Las tres señales de alerta

La primera señal llegó desde afuera del banco: clientes frustrados que no entendían por qué se les había rechazado una solicitud de crédito. Los ejecutivos comerciales intentaban explicarles los criterios del sistema, pero sus respuestas resultaban demasiado técnicas y poco comprensibles para quien las recibía —el banco tenía un problema de **explicabilidad**, no de precisión: el modelo probablemente estaba tomando decisiones correctas en términos estadísticos, pero nadie sabía traducir esas decisiones a un lenguaje que un cliente pudiera entender—. La segunda señal fue interna: analistas con años de experiencia observaban con escepticismo que ciertas recomendaciones del sistema no se alineaban con su juicio profesional. El sistema mantenía una alta **exactitud** estadística en el agregado, pero en casos particulares el criterio humano apuntaba en una dirección distinta, y esa discrepancia instaló un clima de incertidumbre entre los equipos. La tercera señal fue la consecuencia de no resolver la segunda: con el tiempo, la división de opiniones generó **prácticas dispares entre sucursales** —cada sucursal, sin una política común, terminó desarrollando su propia forma informal de usar o ignorar las recomendaciones del sistema—, diluyendo la coherencia operativa del banco. Nota la progresión: una señal externa (clientes) y dos señales internas (analistas, sucursales) que, sin gobernanza que las conectara, se fueron acumulando en paralelo sin que nadie las leyera como síntomas del mismo problema de fondo.

El momento crítico del informe de consumidores

El punto de quiebre llegó desde un lugar inesperado: un informe de consumidores que cuestionó la transparencia de varias financieras que usaban IA. Banco Futuro no fue

mencionado en ese informe. Pero encendió las alarmas de todos modos, porque Carlos Rojas y su equipo entendieron algo crucial: el riesgo no era que el banco hubiera hecho algo mal específico y reportable, sino que el desafío que ese informe exponía —falta de transparencia en el uso de IA en el sector financiero— era exactamente el mismo tipo de riesgo que las tres señales de alerta ya venían anunciando puertas adentro. El desafío, concluyeron, era de confianza, no técnico. Este es un punto de método que vale la pena retener: a veces la señal que activa la acción correctiva no es un incidente propio, sino reconocer el propio riesgo reflejado en el incidente de otro.

El comité y el diagnóstico en tres partes

El directorio respondió creando un comité con seis áreas representadas —Riesgos, Tecnología, Cumplimiento, Auditoría, Recursos Humanos y Atención al Cliente—, liderado por Carlos Rojas. El comité conversó con ejecutivos, analistas y sucursales, y revisó reclamos y procedimientos existentes. El diagnóstico que produjo se organizó en tres partes, y cada una corresponde a una de las tres señales de alerta que viste antes.

Sobre los **modelos**: técnicamente impecables, superiores a los métodos tradicionales que reemplazaron —es decir, el problema nunca fue de calidad del modelo predictivo—, pero faltaba gobernanza alrededor de ellos. Sobre los **procedimientos**: no había criterios compartidos ni procedimientos claros que dijeran cómo debía usarse el sistema en la práctica diaria, lo que explica directamente las prácticas dispares entre sucursales. Sobre los **colaboradores**: estaban divididos entre quienes creían que la IA reemplazaba el juicio profesional y quienes la veían solo como una referencia opcional, lo que generaba decisiones dispares y difuminaba las responsabilidades —nadie sabía con certeza quién debía responder cuando algo salía mal—. La conclusión del comité fue directa: el banco había invertido en modelos, pero había descuidado los principios éticos y la supervisión humana. Carlos Rojas lo resumió en una frase que el curso cita textualmente: *"La confianza se construye con personas que entiendan y supervisen la IA"*.

ANALOGÍA

Piensa en un avión con el mejor sistema de piloto automático disponible en el mercado —el equivalente al modelo "técnicamente impecable" de Banco Futuro— pero sin protocolo de cabina que diga cuándo el piloto humano debe tomar el control, sin entrenamiento del piloto en cuándo confiar en el sistema y cuándo no, y sin manual compartido entre distintas tripulaciones sobre cómo operar juntos con el automatismo. El avión vuela bien la mayor parte del tiempo. El problema aparece exactamente en los casos límite, que son los que más importan, y ahí no hay ni criterio compartido ni responsabilidad clara sobre quién decide.

Sesgo de automatización, aversión al algoritmo y confianza calibrada

Las dos posturas irreconciliables que dividieron a los colaboradores de Banco Futuro tienen nombre técnico, aunque el curso no las nombre así explícitamente: son un prerequisite mínimo indispensable para entender el caso con precisión, así que los introducimos aquí. Si vienes de la Unidad 4, ya te los cruzaste: son exactamente los dos extremos que rompían la colaboración persona-IA en el caso Seguros del Pacífico. Aquí reaparecen con otro ropaje, y esa reaparición es en sí misma un dato: no son una curiosidad de un caso, son el modo por defecto en que una organización se relaciona con un sistema que no entiende. Quienes aceptaban ciegamente las recomendaciones de la IA, sin cuestionarlas incluso cuando su propio juicio profesional apuntaba en otra dirección, incurrían en **sesgo de**

automatización *automation bias*: la tendencia humana a sobreconfiar en la salida de un sistema automatizado precisamente porque es automatizado, tratando la recomendación de una máquina como si tuviera más autoridad que el propio criterio, incluso sin evidencia de que la merezca en ese caso particular. Quienes, en el extremo opuesto, rechazaban sistemáticamente las recomendaciones del sistema y preferían revisar cada caso personalmente sin importar cuán buena fuera la evidencia estadística del modelo, incurrían en **aversión al algoritmo** *algorithm aversion*: la tendencia opuesta, a desconfiar de una recomendación algorítmica más de lo que la evidencia justifica, simplemente porque proviene de un algoritmo y no de una persona.

El objetivo de la gobernanza de IA no es eliminar ninguna de estas dos posturas empujando a todo el mundo hacia el extremo contrario —no se trata de conseguir que todos confíen ciegamente, ni de conseguir que todos desconfíen sistemáticamente—. El objetivo es producir lo que se conoce como **confianza calibrada** *calibrated trust*: confiar en el sistema exactamente en la medida en que el sistema es confiable, caso a caso, ni más ni menos. Un analista con confianza calibrada no acepta ni rechaza la recomendación del sistema por default: evalúa, para el caso concreto que tiene enfrente, si las condiciones bajo las cuales el modelo fue entrenado y validado se cumplen razonablemente, y ajusta su nivel de confianza en consecuencia.

EJEMPLO

Un modelo de evaluación crediticia de Banco Futuro fue entrenado y validado sobre solicitantes con historial crediticio formal en Chile. Llega una solicitud de un trabajador independiente con ingresos informales variables, un perfil poco representado en los datos de entrenamiento. Un analista con sesgo de automatización acepta la recomendación del modelo sin más, aunque el caso está fuera del rango donde el modelo fue validado. Un analista con aversión al algoritmo ignora la recomendación incluso en los casos rutinarios donde el modelo tiene un historial excelente, generando trabajo redundante y decisiones más lentas sin mejorar la calidad. Un analista con confianza calibrada reconoce que este caso particular —ingresos informales, perfil poco representado— es precisamente uno de los que exige revisión humana reforzada, y trata con más autonomía los casos que sí caen dentro de lo que el modelo domina bien. Esa es la diferencia práctica entre las tres

posturas, y es exactamente el tipo de criterio que Banco Futuro tuvo que instalar mediante formación después de la crisis.

Las cuatro medidas

El comité tradujo su diagnóstico en cuatro medidas concretas. La tabla siguiente las mapea contra los seis principios éticos que estudiaste en el bloque anterior y contra las cuatro fases del ciclo de vida de la IA, para que quede visible cómo cada medida corrige un déficit específico identificado en el diagnóstico.

Medida de Banco Futuro	Principios éticos que activa	Fase del ciclo de vida que refuerza
1. Política clara con criterios de transparencia, cuidado de datos personales, equidad, revisión humana y responsabilidad	Transparencia y explicabilidad · Privacidad y seguridad · Equidad y justicia · Rendición de cuentas	Diseño y estrategia (define reglas antes de que se necesiten en la operación)
2. Comité de Gobernanza de IA con perfiles diversos para revisar modelos nuevos y hacer seguimiento de los operativos	Rendición de cuentas · Inclusión y no discriminación (perfiles diversos evitan puntos ciegos)	Desarrollo y pruebas (revisión antes de autorizar) + Operación y seguimiento continuo
3. Formación reforzada: talleres de ética, interpretación, sesgos y responsabilidad	Equidad y justicia · Confiabilidad y robustez (personas capaces de detectar comportamiento anómalo)	Transversal a las cuatro fases, con más peso en Implementación (prepara a quien va a supervisar)
4. Mejor comunicación con clientes: explicaciones sencillas y posibilidad de revisión humana	Transparencia y explicabilidad · Rendición de cuentas	Implementación y lanzamiento (mecanismos de human-in-the-loop declarados) + Operación (sostiene el canal en el tiempo)

El resultado a un año

Un año después de implementadas las cuatro medidas, el banco reportó mejoras en varios frentes a la vez: creció la confianza de los propios colaboradores en el sistema, bajaron tanto las diferencias de práctica entre sucursales como los reclamos de clientes por decisiones automatizadas, y —el cambio más significativo desde el punto de vista cultural— la IA pasó de ser percibida como un sustituto del juicio profesional a ser percibida como un

respaldo de ese juicio. Se afianzó, en palabras del relato, una cultura de innovación con transparencia y ética.

La lección

La lección final, narrada por el propio Carlos Rojas, es que no basta con que la IA funcione bien: hace falta explicar sus resultados, mantener revisión humana activa y definir con claridad las responsabilidades de cada quien. La ética y la responsabilidad social no son un anexo de la estrategia tecnológica: son parte de la gestión cotidiana. Una IA responsable integra tecnología, personas, procesos y liderazgo en una sola estrategia común, y la innovación sostenible —el cuarto beneficio de la organización confiable que viste más arriba— se construye precisamente sobre esa base de confianza, no al margen de ella.

El curso propone cinco preguntas de comentario sobre este caso, pensadas para trabajarlas en el foro de la unidad: (1) qué dificultades principales aparecieron en Banco Futuro después de implementar la IA, y por qué no eran solamente técnicas; (2) de qué manera la transparencia, la supervisión humana y la gobernanza impulsadas por Carlos Rojas y el comité ayudaron a recuperar la confianza de clientes y colaboradores; (3) qué principios de ética profunda y responsabilidad social estuvieron presentes en la estrategia de recuperación, a partir de las cuatro medidas adoptadas; (4) qué otras políticas, mecanismos o indicadores propondrías si formarás parte del Comité de Gobernanza de IA de Banco Futuro; y (5) qué aprendizajes del caso podrían aplicarse a otra organización de tu elección —empresa, institución pública, universidad o centro de salud.

Los recursos y la evaluación de la unidad

La unidad cierra con un conjunto de recursos complementarios y una actividad evaluada que conviene mapear con precisión, porque una de ellas entra directamente en el control.

El primer recurso es un video de la profesora del curso, Elizabeth Chicata, titulado "*¿Cómo asegurar un uso ético, confiable y responsable de la IA?*", donde se retoma la idea de que el éxito de un proyecto de IA depende de factores que van más allá del desempeño técnico del modelo —el mismo argumento que atraviesa toda la unidad—.

El segundo es un podcast titulado "*La confianza en una institución según su utilización de IA*", organizado alrededor de una pregunta guía que conviene responder con argumentos propios, no solo repetirla: ¿qué genera más confianza, contar con una IA muy precisa o la utilización confiable de esta? La respuesta que se desprende de todo lo visto en esta unidad es que la precisión y la confianza no son la misma variable, y que optimizar solo la primera puede dejar la segunda intacta o incluso dañarla —es exactamente lo que le pasó a Banco Futuro, cuyo modelo era, en palabras del propio comité, "técnicamente impecable" y aun así generó una crisis de confianza—. Una IA extremadamente precisa pero opaca, sin mecanismos de supervisión humana ni canales de explicación, puede producir el mismo

tipo de rechazo que produjo el sistema de crédito del banco: decisiones correctas en el agregado que nadie puede justificar caso a caso. En cambio, una IA con precisión buena pero no perfecta, usada de forma transparente, con supervisión humana activa y explicaciones comprensibles, genera el tipo de confianza calibrada que sostiene la adopción en el tiempo. La respuesta más defendible, entonces, no es "la precisión no importa" —sí importa, es la base técnica sin la cual no hay nada que gobernar— sino que la precisión es condición necesaria y no suficiente: la utilización confiable es la que convierte esa precisión en valor sostenido.

El tercer recurso es un ejercicio práctico completo, estructurado como caso corto para desarrollar por escrito. El planteamiento: una empresa del sector financiero incorpora un sistema de IA para apoyar el análisis de solicitudes de crédito, con el objetivo de acortar tiempos de respuesta, procesar información con mayor agilidad y dar a los analistas antecedentes que faciliten decisiones más oportunas. Los ensayos técnicos resultan satisfactorios: en la mayoría de los casos, las recomendaciones del sistema coinciden con las que antes formulaban los especialistas humanos. Desde el punto de vista tecnológico, el proyecto cumple sus objetivos. La dificultad aparece cuando el sistema empieza a usarse de manera cotidiana y surgen tres problemas que el diseño no había anticipado: primero, algunos clientes piden una explicación sobre el rechazo de sus solicitudes; segundo, ciertos analistas no logran justificar por qué el sistema sugiere una opción distinta de la que ellos consideran más apropiada; tercero, empieza a discutirse quién debe responder cuando una decisión respaldada por IA produce efectos no esperados. Frente a esto, la empresa toma cuatro medidas: establece políticas de uso, distribuye funciones entre las distintas áreas, incorpora instancias de revisión humana, y mejora la comunicación con clientes y colaboradores sobre el papel real de la herramienta en la toma de decisiones. El punto que el ejercicio subraya explícitamente, y que conviene retener como la observación clave de todo el caso: **la solución tecnológica no fue reemplazada**. El cambio estuvo en la forma en que la organización se hizo cargo de su utilización, no en el modelo mismo —el mismo patrón exacto que viste en Banco Futuro, donde el modelo también era "técnicamente impecable" y el problema estaba en todo lo que lo rodeaba—.

La pregunta central que el ejercicio plantea para desarrollar es: ¿basta con que una inteligencia artificial entregue buenos resultados, o es igualmente necesario asegurar que las decisiones en las que participa sean explicables, responsables y dignas de confianza? Y propone cinco preguntas de desarrollo, cada una con un ángulo de respuesta y el concepto de la unidad que la sostiene:

1. ¿Por qué no sería adecuado evaluar un proyecto de IA considerando solamente sus resultados técnicos? — Respóndela apoyándote en la distinción entre indicadores técnicos y confianza percibida de la sección 1 de la unidad: la exactitud es una condición necesaria, no suficiente, para que un sistema se adopte y se sostenga en el tiempo.

2. ¿Qué dificultades podrían surgir si las personas no comprenden cómo intervino la IA en una decisión o no está claro quién responde por sus consecuencias? — Apóyate en transparencia, explicabilidad y rendición de cuentas: sin ellas aparece exactamente el tipo de confusión de responsabilidades que diluyó la coherencia operativa de Banco Futuro.
3. Si formarás parte del equipo directivo, ¿qué cambios concretos impulsarías para que clientes y colaboradores se sintieran más seguros? — Apóyate en las cinco características de la organización confiable, en particular liderazgo comprometido y procesos claros y documentados: la pregunta pide acción directiva, no solo diagnóstico técnico.
4. ¿De qué manera la ética, la responsabilidad social y una adecuada gobernanza ayudan a prevenir usos inadecuados de la IA? — Apóyate en la distinción entre ética (el qué y el porqué) y gobernanza (el cómo y el quién) de la sección de gobernanza: la pregunta pide mostrar cómo esas dos piezas se complementan, no tratarlas como sinónimos.
5. Desde tu experiencia laboral, ¿qué obstáculo consideras más difícil de resolver al implementar IA de manera responsable y sostenerla en el tiempo? — Esta es la única pregunta genuinamente abierta; el concepto que mejor la sostiene es supervisión y mejora continua, porque la dificultad más citada en la práctica no es lanzar bien, sino mantener la calidad de la gobernanza cuando cambian los datos, el entorno o las personas involucradas.

El material complementario formal de la unidad es el **Microsoft Responsible AI Standard**, versión 2, publicado en junio de 2022 —el mismo documento del que sale la cita de Microsoft que viste más arriba—. El curso lo recomienda porque es, de todos los marcos de esta unidad, el que ofrece el ejemplo más desarrollado de cómo pasar de principios éticos declarados a requisitos operativos verificables mediante su arquitectura de tres capas (Principio, Meta, Requisito), lo que lo vuelve especialmente útil como plantilla práctica para cualquier organización que quiera construir su propia política de IA responsable. Existe traducción no oficial al español, lo que facilita su lectura para quien prefiera no trabajar directamente con el original en inglés.

Por último, la unidad fija una **lectura obligatoria que se evalúa en el control** — conviene marcar esto con claridad porque no es un material optativo—: dos documentos, con rangos de páginas específicos. El primero es OECD/CAF (2022), *"Uso estratégico y responsable de la inteligencia artificial en el sector público de América Latina y el Caribe"*, páginas 64 a 73, que cubre ética de los datos, IA fiable, los Principios de la OCDE sobre IA que ya estudiaste en esta sección, ejemplos de aplicación, gobernanza, confianza y responsabilidad. El segundo es UNESCO (2022), la edición publicada de la *"Recomendación sobre la Ética de la IA"* que también estudiaste arriba, páginas 13 a 22, que cubre los fines y objetivos del documento, sus cuatro valores y sus diez principios. Si vas a estudiar para el

control, estas veinte páginas —diez de cada documento— son material de examen directo, no contexto opcional.

Discrepancias entre el curso y la práctica actual

⚠ Discrepancia 1 — la más relevante de la unidad. Qué dice el curso: presenta el AI Act de la Unión Europea como un marco de 2024, sin calendario de aplicación. Qué dice el estado actual (sep-2026): el Digital Omnibus — Reglamento (UE) 2026/1744, en vigor desde el 27 de julio de 2026 — aplazó las obligaciones de alto riesgo del Anexo III al 2 de diciembre de 2027 y las del Anexo I al 2 de agosto de 2028, mientras que prohibiciones (feb-2025), obligaciones GPAI (ago-2025) y transparencia del artículo 50 (ago-2026) siguen vigentes en su calendario original. Regla para el examen: si la pregunta es sobre el contenido del AI Act (categorías de riesgo, qué es alto riesgo, qué es práctica prohibida), responde con las cuatro categorías tal como las presenta el curso; si la pregunta es sobre plazos o el estado de aplicación, el calendario vigente es el aplazado por el Digital Omnibus.

⚠ Discrepancia 2. Qué dice el curso: cita únicamente los Principios de la OCDE sobre IA de 2019. Qué dice la fuente actual: en mayo de 2024 la OCDE actualizó los principios, ampliando la definición de sistema de IA para cubrir IA generativa y de propósito general, e incorporando desinformación, propiedad intelectual y sostenibilidad ambiental; hoy los respaldan 47 jurisdicciones. Regla para el examen: si preguntan por los Principios de la OCDE, van los cinco de 2019, que siguen vigentes; si preguntan qué cambió o cubre hoy, es la actualización de 2024, que amplía sin reemplazar.

⚠ Discrepancia 3. Qué dice el curso: atribuye "seis principios" éticos a "Floridi & Cowls, o Microsoft", presentándolos como si fueran una misma lista de ambas fuentes. Qué dice la fuente actual: Floridi y Cowls (2019) proponen cinco principios —beneficencia, no maleficencia, autonomía, justicia y explicabilidad—, no seis; Microsoft sí tiene seis principios en su Responsible AI Standard, pero no coinciden uno a uno con la lista del curso (Microsoft: fairness, reliability & safety, privacy & security, inclusiveness, transparency, accountability). La lista de seis principios del curso es una síntesis propia, más cercana a una combinación de Microsoft y la OCDE que a una cita textual de cualquiera de las dos fuentes. Regla para el examen: si preguntan por los seis principios "del curso", usa la lista tal como la presenta el material (equidad y justicia, transparencia y explicabilidad, privacidad y seguridad, confiabilidad y robustez, inclusión y no discriminación, rendición de cuentas); si preguntan específicamente por Floridi y Cowls, son cinco, no seis.

⚠ Discrepancia 4. Qué dice el curso: describe el NIST AI RMF de forma parafraseada, como "liderazgo, procesos internos, supervisión y mejora continua". Qué dice la fuente actual: la nomenclatura oficial del marco son cuatro funciones con nombre propio — GOVERN, MAP, MEASURE y MANAGE— más siete características de IA confiable (válida y confiable, segura, segura y resiliente, responsable y transparente, explicable e interpretable, con privacidad reforzada, y justa con el sesgo dañino gestionado). Regla para el examen: si preguntan por el NIST AI RMF con nombre propio, usa GOVERN, MAP, MEASURE, MANAGE; la paráfrasis del curso es una descripción informal válida del espíritu del marco, no la nomenclatura que se evalúa si la pregunta pide precisión técnica.

⚠ Discrepancia 5. Qué dice el curso: cuatro carruseles interactivos del PDF quedaron con solo su primera lámina visible —efectos de la confianza organizacional (1 de 3), roles que intervienen en la gobernanza (1 de 6), marcos internacionales (1 de 5) y confianza como proceso continuo (1 de 5)—. Qué se hizo: todo el contenido faltante de estos cuatro carruseles se reconstruyó en esta explicación a partir del propio material de la unidad y de fuentes oficiales de cada marco, y quedó marcado explícitamente como reconstrucción en cada caso. Regla para el examen: el contenido reconstruido es coherente con la lógica del curso, pero si un examen pide "textualmente lo que dice el material", límitate a la primera lámina que sí es literal del PDF; si pide comprensión del concepto completo, usa la reconstrucción.

⚠ Discrepancia 6. Qué dice el curso: el cuerpo del texto fecha la Recomendación de la UNESCO en 2021 y la bibliografía la fecha en 2022. Qué dice la fuente actual: la Recomendación se adoptó por aclamación en noviembre de 2021; 2022 corresponde a la edición publicada del documento, la misma que se usa en la lectura obligatoria de la unidad. Regla para el examen: si preguntan cuándo se adoptó, es 2021; si preguntan por la edición citada en bibliografía o en la lectura obligatoria, es 2022. Ambas fechas son correctas según el contexto de la pregunta.

⚠ Discrepancia 7. Qué dice el curso: menciona ISO/IEC 42001 (2023) sin fecha precisa ni novedades posteriores. Qué dice la fuente actual: se publicó en diciembre de 2023, y en 2025 se sumó ISO/IEC 42006:2025, que fija los requisitos que deben cumplir los organismos que auditan y certifican sistemas de gestión de IA conforme a 42001. Regla para el examen: si preguntan por ISO/IEC 42001, es el estándar certificable de diciembre de 2023; si preguntan qué garantiza la calidad de una certificación 42001, la respuesta es ISO/IEC 42006:2025, la norma que certifica a los certificadores.

Glosario

Término	Inglés	Definición
Confianza organizacional	<i>Organizational trust</i>	Valoración que construyen clientes, colaboradores y grupos de interés sobre cómo la organización emplea la IA, protege la información y respalda sus decisiones con criterios transparentes y responsables.
Ética profunda	<i>Deep ethics / ethics by design</i>	Perspectiva que incorpora consideraciones éticas desde el diseño hasta el uso de la IA, buscando crear valor sin daños injustificados a personas ni sociedad.
Responsabilidad social	<i>Social responsibility</i>	Compromiso de una organización con los efectos de sus decisiones sobre personas, comunidad y entorno, incluida la obligación de usar la IA de forma responsable.
Sesgo algorítmico	<i>Algorithmic bias</i>	Resultados de un sistema que favorecen o perjudican injustificadamente a determinados grupos, originados en los datos de entrenamiento o en decisiones de construcción del modelo.
Transparencia	<i>Transparency</i>	Comunicar con claridad cuándo se usa IA, para qué se usa y cómo influye en las decisiones que produce.
Explicabilidad	<i>Explainability</i>	Posibilidad de entender y justificar las recomendaciones o decisiones de un sistema de IA, especialmente cuando afectan directamente a una persona.
Interpretabilidad	<i>Interpretability</i>	Grado en que el funcionamiento interno de un modelo puede comprenderse directamente, sin recurrir a explicaciones generadas a posteriori.
Privacidad de los datos	<i>Data privacy</i>	Resguardo de la información personal en su obtención, almacenamiento y tratamiento, respetando derechos y normativa vigente.

Término	Inglés	Definición
Supervisión humana	<i>Human oversight</i>	Intervención activa de personas que revisan, interpretan y validan decisiones apoyadas por IA, sobre todo donde el juicio profesional no es sustituible.
Gobernanza de la IA	<i>AI governance</i>	Marco de normas, responsables, procedimientos y controles para conducir y vigilar el desarrollo, la puesta en marcha y el uso de la IA.
Inteligencia artificial responsable	<i>Responsible AI</i>	Creación y utilización de sistemas de IA seguros, justos y transparentes, alineados con los valores y objetivos de la organización.
Adopción tecnológica	<i>Technology adoption</i>	Proceso por el cual una organización o sus usuarios incorporan efectivamente una tecnología nueva a su trabajo cotidiano, más allá de haberla instalado.
Grupos de interés	<i>Stakeholders</i>	Personas o entidades —clientes, colaboradores, inversionistas, reguladores— cuya confianza y valoración se ven afectadas por el uso que una organización hace de la IA.
Indicadores técnicos	<i>Technical metrics</i>	Métricas de desempeño de un sistema, como precisión o tiempo de procesamiento, que por sí solas no bastan para evaluar su éxito organizacional.
Exactitud	<i>Accuracy</i>	Proporción de predicciones correctas de un modelo sobre el total de casos evaluados; una exactitud alta puede convivir con daño concentrado en subgrupos específicos.
Datos de entrenamiento	<i>Training data</i>	Conjunto de información histórica a partir del cual un modelo aprende los patrones que luego aplica a casos nuevos.
Calidad de los datos	<i>Data quality</i>	Grado en que los datos usados por un sistema son correctos, completos y consistentes, condición base para que el modelo se comporte de forma confiable.
Representatividad de los datos	<i>Data representativeness</i>	Grado en que un conjunto de datos refleja proporcionalmente la diversidad real de la

Término	Inglés	Definición
		población o los casos a los que el modelo se aplicará.
Vigencia de los datos	<i>Data recency</i>	Grado en que los datos usados por un modelo siguen reflejando las condiciones actuales, y no un contexto que ya cambió.
Sesgo histórico	<i>Historical bias</i>	Desigualdades o patrones discriminatorios ya presentes en el mundo real que quedan registrados en los datos y que el modelo aprende y repite.
Sesgo de muestreo	<i>Sampling bias</i>	Distorsión que ocurre cuando el proceso de recolección de datos sobrerrepresenta o subrepresenta a ciertos grupos respecto de la población real.
Discriminación algorítmica	<i>Algorithmic discrimination</i>	Trato desigual e injustificado hacia un grupo de personas que resulta de las decisiones o predicciones de un sistema de IA.
Derecho a explicación	<i>Right to explanation</i>	Facultad de una persona afectada por una decisión automatizada de recibir una justificación comprensible de por qué el sistema decidió lo que decidió.
Modelo predictivo	<i>Predictive model</i>	Sistema entrenado con datos históricos para estimar resultados futuros o desconocidos, como el riesgo de incumplimiento de un crédito.
Rendición de cuentas	<i>Accountability</i>	Principio según el cual siempre debe existir una persona o equipo identificable responsable del comportamiento de un sistema de IA y de sus consecuencias.
Equidad y justicia	<i>Fairness</i>	Principio ético que exige no perpetuar sesgos ni discriminar por género, origen u otra condición en las decisiones de un sistema de IA.
Confiabilidad y robustez	<i>Reliability and robustness</i>	Principio ético que exige que un sistema mantenga un rendimiento aceptable incluso ante datos inesperados o cambios en su entorno de operación.
Inclusión y no discriminación	<i>Inclusiveness and non-discrimination</i>	Principio ético que promueve equipos diversos durante el desarrollo de un sistema, para evitar

Término	Inglés	Definición
		puntos ciegos culturales o sesgos no evidentes.
Seguridad de la información	<i>Information security</i>	Conjunto de prácticas orientadas a resguardar la infraestructura y los datos de un sistema frente a amenazas externas.
Ética por diseño	<i>Ethics by design</i>	Práctica de incorporar criterios éticos desde las primeras decisiones de un proyecto de IA, en lugar de agregarlos una vez que surge una controversia.
Privacidad por diseño	<i>Privacy by design</i>	Práctica de incorporar protecciones de privacidad desde la etapa inicial de diseño de un sistema, en vez de añadirlas después como parche.
Minimización de datos	<i>Data minimization</i>	Principio que exige recolectar y conservar únicamente los datos personales estrictamente necesarios para el propósito declarado del sistema.
Anonimización	<i>Anonymization</i>	Proceso de eliminar o transformar identificadores personales de un conjunto de datos de modo que una persona ya no pueda ser identificada a partir de él.
Consentimiento informado	<i>Informed consent</i>	Autorización que una persona otorga para el uso de sus datos personales después de haber sido informada con claridad sobre ese uso.
Cumplimiento normativo	<i>Regulatory compliance</i>	Grado en que las prácticas de una organización se ajustan a las leyes y regulaciones vigentes aplicables al uso de IA.
Human-in-the-loop	<i>Human-in-the-loop</i>	Mecanismo de diseño que mantiene a una persona activamente involucrada en la revisión o validación de las decisiones de un sistema de IA.
Ciclo de vida de la IA	<i>AI lifecycle</i>	Secuencia continua de fases —diseño, desarrollo, implementación y operación— que atraviesa un sistema de IA desde su concepción hasta su uso sostenido.
Evaluación de impacto ético	<i>Ethical impact assessment</i>	Análisis formal realizado antes de implementar un sistema de IA para anticipar sus riesgos éticos y sociales potenciales.

Término	Inglés	Definición
Comité de gobernanza de IA	<i>AI governance board</i>	Equipo multidisciplinario que revisa, autoriza y hace seguimiento de los proyectos de IA de una organización, especialmente los de mayor riesgo.
Propietario del modelo	<i>Model owner</i>	Persona o rol formalmente responsable del desempeño, mantenimiento y consecuencias de un modelo de IA específico dentro de la organización.
Custodio de datos	<i>Data steward</i>	Persona o rol responsable de la calidad, el origen y el uso apropiado de los datos utilizados por un sistema de IA.
Auditoría de algoritmos	<i>Algorithm audit</i>	Revisión sistemática del comportamiento de un modelo para detectar sesgos, errores o desviaciones respecto de lo esperado.
Monitoreo en producción	<i>Production monitoring</i>	Observación continua del comportamiento de un modelo una vez que está en uso real, para detectar cambios o fallas a tiempo.
Deriva del modelo	<i>Model drift</i>	Deterioro del desempeño de un modelo con el tiempo, causado por cambios en los datos, el entorno o el comportamiento de las personas que representa.
Documentación del modelo	<i>Model card</i>	Registro formal que describe el propósito, las limitaciones, los datos de entrenamiento y el desempeño conocido de un modelo de IA.
Trazabilidad	<i>Traceability</i>	Capacidad de reconstruir, después de tomada, por qué un sistema llegó a una decisión determinada.
Plan de contingencia	<i>Fallback plan</i>	Procedimiento alternativo previsto para actuar cuando un sistema de IA falla, se comporta de forma inesperada o debe desactivarse.
Sesgo de automatización	<i>Automation bias</i>	Tendencia a sobreconfiar en la recomendación de un sistema automatizado y aceptarla sin cuestionarla, incluso cuando el criterio propio indica lo contrario.
Aversión al algoritmo	<i>Algorithm aversion</i>	Tendencia a rechazar sistemáticamente las recomendaciones de un sistema algorítmico,

Término	Inglés	Definición
		incluso cuando la evidencia estadística las respalda.
Confianza calibrada	<i>Calibrated trust</i>	Nivel de confianza en un sistema ajustado, caso a caso, a qué tan confiable es realmente ese sistema en esa situación particular.
Principios de la OCDE sobre IA	<i>OECD AI Principles</i>	Marco de cinco principios éticos y cinco recomendaciones a gobiernos, publicado en 2019 y actualizado en 2024, orientado a un uso de la IA centrado en las personas.
Recomendación de la UNESCO sobre la Ética de la IA	<i>UNESCO Recommendation on the Ethics of AI</i>	Primer instrumento normativo global sobre ética de la IA, adoptado por los 193 Estados Miembros de la UNESCO en noviembre de 2021, con cuatro valores y diez principios.
NIST AI RMF	<i>NIST AI Risk Management Framework</i>	Marco voluntario de gestión de riesgos de IA publicado por el NIST de Estados Unidos en enero de 2023, organizado en cuatro funciones.
Funciones del NIST AI RMF	<i>Govern, Map, Measure, Manage</i>	Las cuatro funciones centrales del NIST AI RMF: gobernar la cultura de riesgo, mapear el contexto, medir el riesgo y gestionar la respuesta a ese riesgo.
ISO/IEC 42001	<i>ISO/IEC 42001</i>	Norma internacional publicada en diciembre de 2023 que define un sistema de gestión de IA certificable, con estructura Annex SL y ciclo PDCA.
Sistema de gestión de IA	<i>AI Management System (AIMS)</i>	Conjunto estructurado de políticas, procesos y controles con los que una organización gestiona la IA de forma sistemática y auditable, según define ISO/IEC 42001.
AI Act de la Unión Europea	<i>EU AI Act</i>	Reglamento (UE) 2024/1689, único marco vinculante de esta unidad, que clasifica los sistemas de IA en cuatro categorías de riesgo con obligaciones legales escalonadas.
Categorías de riesgo	<i>Risk tiers</i>	Los cuatro niveles del AI Act —inaceptable, alto, limitado y mínimo— que determinan qué obligaciones legales aplican a un sistema de IA.

Término	Inglés	Definición
Sistema de alto riesgo	<i>High-risk AI system</i>	Sistema de IA que, por su ámbito de aplicación (por ejemplo crédito, empleo o educación), queda sujeto a regulación estricta bajo el AI Act antes de poder comercializarse.
Práctica prohibida	<i>Prohibited practice</i>	Uso de IA considerado de riesgo inaceptable bajo el AI Act y vetado sin excepción, como la manipulación subliminal dañina o el puntaje social gubernamental.
IA de propósito general	<i>General-purpose AI (GPAI)</i>	Modelo de IA base, como un gran modelo de lenguaje, con obligaciones propias de transparencia y gestión de riesgo bajo el AI Act, independientes de su aplicación final.
Microsoft Responsible AI Standard	<i>Microsoft Responsible AI Standard</i>	Documento de Microsoft de junio de 2022 que traduce seis principios éticos en metas y requisitos verificables mediante una arquitectura de tres capas.
Los cinco principios de Floridi y Cows	<i>Floridi and Cows five principles</i>	Marco académico de 2019 que propone cinco principios éticos para la IA en sociedad: beneficencia, no maleficencia, autonomía, justicia y explicabilidad.
Automatización de procesos	<i>Process automation</i>	Tipo de aplicación de IA que reemplaza tareas administrativas o de back-office previamente realizadas por personas, sin involucrar decisiones complejas.
Insight cognitivo	<i>Cognitive insight</i>	Tipo de aplicación de IA que analiza grandes volúmenes de datos para generar hallazgos que informan decisiones humanas.
Compromiso cognitivo	<i>Cognitive engagement</i>	Tipo de aplicación de IA que interactúa directamente con clientes o empleados, como chatbots, agentes virtuales o sistemas de recomendación.
Riesgo reputacional	<i>Reputational risk</i>	Daño potencial a la reputación de una organización derivado de un uso de IA que se percibe como poco transparente, sesgado o mal gestionado.

Término	Inglés	Definición
Innovación sostenible	<i>Sustainable innovation</i>	Generación de valor mediante IA que no descuida la responsabilidad hacia las personas afectadas, y que por eso puede mantenerse en el tiempo sin generar crisis de confianza.

Mapa conceptual

RESPONSABILIDAD SOCIAL Y ÉTICA PROFUNDA EN IA

- |
- | — CONFIANZA ORGANIZACIONAL
 - | | — Por qué importa
 - | | | — Requisito para sostener la transformación (se conecta con la resistencia organizacional de la Unidad 4)
 - | | | | — No aparece automáticamente tras un buen resultado técnico
 - | | — Efectos cuando existe
 - | | | — Mejor desempeño: mayor seguridad, más información compartida
 - | | | — Adopción tecnológica sostenida
 - | | — Qué la destruye
 - | | | — Desconfianza → herramienta técnicamente buena cae en desuso
 - | | | — Grupos de interés que no perciben transparencia
 - | | | — Riesgo reputacional cuando un fallo se hace público mal gestionado
- |
- | — RIESGOS CUANDO LA IA DECIDE
 - | | — Sesgo algorítmico
 - | | | — Sesgo histórico (desigualdades ya presentes en los datos de entrenamiento)
 - | | | | — Sesgo de muestreo (grupos sobre o subrepresentados)
 - | | | | — Discriminación algorítmica (el resultado dañino que produce el sesgo no corregido)
 - | | | — Los datos no son neutrales
 - | | | | — Calidad, representatividad y vigencia de los datos
 - | | | | — Solución: revisar datos + monitorear el modelo + combinar con juicio humano
 - | | — Derecho a explicación
 - | | | — Transparencia (qué se usa y para qué)
 - | | | — Explicabilidad / interpretabilidad (por qué decidió así)
 - | | | — Privacidad de los datos + supervisión humana (responsabilidad final siempre humana)

- |
- | — LOS SEIS PRINCIPIOS ÉTICOS
 - | | — Equidad y justicia
 - | | — Transparencia y explicabilidad
 - | | — Privacidad y seguridad
 - | | — Confiabilidad y robustez
 - | | — Inclusión y no discriminación
 - | | — Rendición de cuentas
 - | | — nota: síntesis propia del curso, distinta de los 5 de Floridi y Cowls y de los 6 de Microsoft

- |
- | — GOBERNANZA
 - | | — El cómo y el quién (la ética define el qué y el porqué)
 - | | — Roles
 - | | | — Comité de IA o ética
 - | | | — Propietario del modelo
 - | | | — Custodio de datos
 - | | — Cinco preguntas clave
 - | | | — quién aprueba, quién verifica datos, cómo se monitorea, quién interviene, cada cuánto se revisa
 - | | — Ciclo de vida de 4 fases
 - | | | — 1. Diseño y estrategia – evaluación de impacto ético, calidad de datos
 - | | | — 2. Desarrollo y pruebas – Comité revisa sesgos antes de autorizar
 - | | | — 3. Implementación y lanzamiento – human-in-the-loop, model card, plan de contingencia
 - | | | — 4. Operación y seguimiento – monitoreo en producción, deriva del modelo, auditoría, trazabilidad

- |
- | — MARCOS INTERNACIONALES
 - | | — Principios de la OCDE (2019, actualizado 2024) – principios éticos orientativos
 - | | — Recomendación UNESCO (nov. 2021) – 4 valores, 10 principios, herramientas RAM y EIA
 - | | — NIST AI RMF (ene. 2023) – Govern, Map, Measure, Manage; voluntario
 - | | — ISO/IEC 42001 (dic. 2023) – sistema de gestión de IA (AIMS), certificable
 - | | — AI Act de la UE (jul. 2024) – único vinculante; categorías de riesgo, alto riesgo, práctica prohibida, GPAI
 - | | — calendario aplazado por el Digital Omnibus (2026) – discrepancia 1

- |
- | — LA ORGANIZACIÓN CONFIABLE
 - | | — 5 características
 - | | — Liderazgo comprometido

- | | — Personas formadas y conscientes
- | | — Procesos claros y documentados
- | | — Decisiones con criterio crítico
- | | — Supervisión y mejora continua
- | — 4 beneficios (confianza como ventaja competitiva)
- | | — Credibilidad y reputación
- | | — Relaciones más sólidas
- | | — Menos riesgos legales y operativos
- | | — Innovación sostenible
- | — Caso Banco Futuro
 - | — Modelos impecables + gobernanza ausente = crisis de confianza
 - | — Sesgo de automatización vs. aversión al algoritmo → confianza calibrada
 - | — 4 medidas: política clara, comité de gobernanza, formación, comunicación con clientes
 - | — Lección: la IA no sustituye el criterio humano, lo potencia
(se conecta con la Unidad 4: gestión del cambio y resistencia organizacional –
las 4 medidas de Banco Futuro son, en esencia, una gestión del cambio aplicada a IA)