

Unidad 1 · Crear valor empresarial con la IA

Diplomado UDD «Toma de decisiones basadas en datos con IA» · Etapa 1

*Esta unidad es la puerta de entrada del diplomado. No enseña todavía a programar un modelo ni a escribir una consulta: enseña a **pensar** dónde y por qué la inteligencia artificial genera valor dentro de una organización. Su tesis central: la Inteligencia de Negocios clásica —que respondía «¿qué pasó?» mirando el retrovisor— está mutando, gracias a la IA, hacia una Inteligencia de Decisión que además anticipa y recomienda. Toda la unidad gira alrededor de un mapa mental de dos ejes (valor vs. dificultad) y de cuatro tipos de análisis (descriptivo, diagnóstico, predictivo, prescriptivo).*

1. Orientación: ¿para qué estamos aquí?

El objetivo del curso es entender cómo la evolución de la **Inteligencia de Negocios (Business Intelligence o BI)** hacia la **Inteligencia de Decisión** —vía la integración de la **Inteligencia Artificial (IA)**— transforma la toma de decisiones en las organizaciones. La meta para el alumno es doble: (a) identificar cómo estas tecnologías mejoran la **cultura de datos**, y (b) reconocer cómo el **aprendizaje automático** puede generar valor real para el negocio.

Se exploran cuatro bloques, en orden: cómo la IA transforma el panorama del BI, con foco en la **democratización del conocimiento** y la **necesidad de respuestas rápidas**; los casos de uso comunes; una intuición precisa de qué son la IA y el ML sin exageraciones; y un marco práctico de **mapeo de historias de IA** para priorizar proyectos según su **impacto en el negocio**.

La frase clave: este conocimiento permite **dejar de basar decisiones en el instinto y empezar a fundamentarlas en datos precisos y predicciones probabilísticas sobre el futuro**. Una **predicción probabilística** no dice «va a pasar X»; dice «hay un 78% de probabilidad de que pase X»: pasar de la certeza fingida a la incertidumbre cuantificada es la esencia del cambio cultural. Además, el mapeo de casos de uso permite comunicar el valor de la IA a las **partes interesadas (stakeholders)**, facilitando la adopción.

NOTA

Nota de continuidad. Al ser la Unidad 1, no hay módulos previos sobre los cuales construir; esta unidad es el cimiento conceptual. Los cuatro tipos de análisis, la distinción algoritmo/modelo y el marco Setup–Acciones–Resultados–Impacto reaparecerán en las unidades siguientes, al pasar «de la comprensión teórica a la evaluación y el diseño de soluciones aplicadas».

2. Conceptos clave (glosario inicial del PDF)

El PDF abre con definiciones cortas. No las resumimos: las desplegamos, en el mismo orden en que aparecen, conectándolas entre sí.

2.1 Inteligencia de Negocios (BI)

Qué es. El PDF: **sistemas diseñados para procesar datos y obtener información que permita tomar decisiones seguras en escenarios complejos**. Definición estándar: conjunto de **prácticas, arquitecturas y herramientas** que convierten **datos** en **información útil** para decidir.

Por qué existe. El BI nació para **reemplazar decisiones basadas solo en intuiciones por decisiones fundamentadas en evidencia histórica**, integrando **información dispersa** y convirtiéndola en **métricas**

comprensibles.

Cómo funciona (BI clásico). Consolida datos de diversas fuentes y los presenta con **reportes, indicadores (KPIs) y paneles de control (dashboards)**. Su énfasis es **descriptivo**. Dos limitaciones estructurales: es **esencialmente retrospectivo y depende de la intervención humana**.

ANALOGÍA

El BI clásico es el **espejo retrovisor** de un auto: muestra con nitidez el camino ya recorrido, indispensable para no chocar con lo que dejaste atrás, pero no dice nada de la curva que viene. La IA agrega el parabrisas y el GPS.

EJEMPLO

Un gerente abre su dashboard el lunes y ve: «las ventas de la región sur cayeron 12% en junio». Eso es BI descriptivo puro: sabe *qué* pasó, pero no *por qué*, ni *qué pasará*, ni *qué hacer*.

2.2 Inteligencia Artificial (IA)

Qué es. El PDF: **herramienta para construir entidades capaces de resolver tareas específicas, principalmente mediante el aprendizaje automático**. Definición sobria: IA no es «una máquina que piensa como un humano», sino una herramienta para fabricar sistemas que resuelven tareas concretas.

Por qué importa la sobriedad. El curso insiste en **evitar interpretaciones exageradas**. La mayoría de las aplicaciones actuales no son inteligencias generales: son sistemas estrechos y especializados.

ANALOGÍA

La IA empresarial es menos como el robot de las películas y más como una **calculadora muy especializada**: extraordinaria en su tarea, e inútil fuera de ella. Una calculadora de raíces no sabe hacer café.

NOTA

Nota. El curso define la IA como algo que resuelve tareas «principalmente mediante el aprendizaje automático». En la literatura, el ML es la rama *dominante hoy*, pero la IA es un campo más amplio que incluye sistemas simbólicos, basados en reglas, búsqueda, planificación y optimización. La definición del curso describe la práctica empresarial actual, no la totalidad del campo. (Ver Discrepancias.)

2.3 Aprendizaje automático (ML)

Qué es. El PDF: **paradigma de programación donde el algoritmo encuentra patrones en los datos históricos para resolver tareas sin reglas codificadas manualmente**. En inglés, **Machine Learning (ML)**.

Qué problema resuelve. Hay tareas para las que es imposible escribir reglas a mano (distinguir spam, anticipar quién abandona). El ML invierte la lógica: en vez de que un humano escriba las reglas, el sistema **infiere las reglas a partir de ejemplos**.

Cómo funciona. Recibe **datos históricos junto con resultados conocidos e identifica patrones estadísticos** que le permiten **generalizar a nuevos casos**. La clave es *generalizar*: aprender de casos vistos para acertar en casos nunca vistos.

ANALOGÍA

Programación tradicional = enseñar a cocinar dando una **receta exacta** paso por paso. ML = mostrar **200 platos ya cocinados** con su resultado (rico/malo) y dejar que la persona **deduzca sola** qué combinaciones funcionan. La receta es explícita; la deducción es aprendida.

EJEMPLO

Para estimar el riesgo de abandono, el modelo analiza 50.000 clientes pasados de los que se sabe quién se fue. Detecta que quienes hicieron 3 o más reclamos en 60 días y no usaron la app en 30 días abandonaron el 68% de las veces. Nadie se lo dijo; lo dedujo de los datos.

NOTA

Nota. Llamar al ML «paradigma de programación» es didáctico pero impreciso. Formalmente, el ML es un **subcampo de la IA**, no un estilo de programación paralelo. La idea correcta que el curso transmite: en ML el comportamiento se aprende en vez de codificarse. (Ver Discrepancias.)

2.4 Inteligencia de Decisión

Qué es. El PDF: **la fórmula resultante de sumar Inteligencia Artificial e Inteligencia de Negocio para optimizar la toma de decisiones humana y automatizada.** En inglés, **Decision Intelligence**. Se plantea como una suma conceptual:

$$\text{Inteligencia de Decisión} = \text{Inteligencia de Negocios (BI)} + \text{Inteligencia Artificial (IA)}$$

Desglose. El **BI** aporta el «qué pasó» y la infraestructura de datos; la **IA** aporta el «qué pasará» y el «qué hacer»; la **suma** apunta a **optimizar la toma de decisiones**, tanto la **humana** (un gerente mejor informado) como la **automatizada** (el sistema decide solo, a escala).

ANALOGÍA

Si el BI es el retrovisor y la IA el GPS predictivo, la Inteligencia de Decisión es **el conductor experto** que usa ambos instrumentos a la vez para llegar mejor y más rápido.

2.5 IA estrecha (Narrow AI)

Qué es. El PDF: **tecnología capaz de resolver un problema único y bien definido para el que ha sido entrenada, a diferencia de la IA General.** En inglés, **Narrow AI** (*Weak AI*).

El contraste. La **IA General** (**Artificial General Intelligence, AGI**) abordaría cualquier tipo de problema, como un humano; no existe comercialmente hoy. Casi todo lo empresarial es Narrow AI: un modelo de churn no traduce; un traductor no detecta fraude.

Por qué importa. Es la vacuna contra la exageración. Quien promete «una IA que resolverá todos tus problemas» promete AGI, que no existe. Lo valioso es una batería de sistemas estrechos, cada uno excelente en su tarea.

2.6 Algoritmo de ML

Qué es. El PDF: **proceso computacional que analiza un conjunto de datos para encontrar el mejor modelo posible.** Matiz clave: el **algoritmo es el método**; el **modelo es el resultado**.

ANALOGÍA

El algoritmo es la **técnica de un escultor** (el método de cincelado); el modelo es la **estatua terminada**. La misma técnica, aplicada a distintos bloques de mármol (distintos datos), produce estatuas distintas.

2.7 Mapeo de historias de IA

Qué es. El PDF: **técnica ágil para contrastar procesos actuales con implementaciones futuras habilitadas por IA, estructurando el impacto y los resultados**. En inglés, **AI use-case story mapping** (*storyboarding*). Existe porque el error más común es empezar por la tecnología antes de definir el problema. Se desarrolla en la sección 5.

2.8 Churn

Qué es. El PDF: la **tasa de abandono de clientes**, el **porcentaje de clientes que dejan de usar un servicio o producto en un período**. En inglés, **churn / churn rate**. Conviene hacer explícita la fórmula:

$$\text{Churn rate} = \frac{\text{Clientes que se fueron en el período}}{\text{Clientes al inicio del período}} \times 100\%$$

Desglose. El **numerador** cuenta cuántos clientes abandonaron durante el período; el **denominador**, cuántos había al comenzar; el cociente por 100 es el porcentaje de fuga.

EJEMPLO

Si TelecomPlus empezó enero con 10.000 clientes y perdió 500, su churn mensual fue $(500 / 10.000) \times 100\% = 5\%$. Si el churn «aumentó un 15%», no llegó al 15%: creció un 15% relativo, de 5% a $5\% \times 1,15 = 5,75\%$. Una «reducción del 10%» lo devolvería a $5,75\% \times 0,90 \approx 5,18\%$. El PDF da los porcentajes de cambio; el nivel base es ilustrativo.

Por qué es el hilo conductor. El churn aparece en la Figura 3, en el caso TelecomPlus, en el ejercicio de retail y en el foro DataConnect. Es el caso perfecto: muestra el salto de «describir quién se fue» (BI clásico) a «predecir quién se irá y qué ofrecerle» (IA).

3. ¿Cómo la IA está cambiando el panorama del BI?

Idea rectora: la incorporación de la IA en el BI responde a **tres transformaciones simultáneas**: (1) **necesidad de acceso inmediato** a información relevante; (2) **democratización del análisis**, con herramientas accesibles para **perfiles no técnicos**; (3) **eliminación de barreras tecnológicas**, vía plataformas automatizadas.

El contexto que lo detona. Con el aumento exponencial del **volumen**, la **velocidad** y la **variedad de los datos** —las **tres V** del Big Data (volumen = cuántos; velocidad = qué tan rápido llegan; variedad = de cuántos tipos)—, impulsado por sistemas digitales, plataformas en línea y **dispositivos conectados**, la **capacidad de análisis manual resultó insuficiente**. A esto se suma la **falta de perfiles especializados** capaces de extraer valor en tiempos compatibles con la operación. Hay océanos de datos y pocos especialistas: la IA llena ese vacío.

3.1 Figura 1 — Evolución del BI: de hindsight a foresight

Qué muestra. Organiza la analítica en un plano de **dos dimensiones**: eje **vertical** = **valor generado**; eje **horizontal** = **complejidad/dificultad**. Es, en esencia, el **modelo de madurez analítica** de Gartner. Cuatro

tipos de análisis y su pregunta:

Tipo de análisis	Pregunta	Visión temporal	Inglés
Descriptivo	¿Qué ocurrió?	Retrospectiva (hindsight)	Descriptive
Diagnóstico	¿Por qué ocurrió?	Retrospectiva / interpretativa	Diagnostic
Predictivo	¿Qué es probable que ocurra?	De la perspectiva (insight)	Predictive
Prescriptivo	¿Qué acción tomar?	Anticipatoria (foresight)	Prescriptive

Desglose. El **descriptivo** («¿qué ocurrió?») está en la base (bajo valor, baja complejidad), en la **capa de ingestión** (*ingestion layer*), asociado al **hindsight**. El **diagnóstico** («¿por qué ocurrió?») agrega una **capa interpretativa**. El **predictivo** («¿qué es probable que ocurra?») es el **salto cualitativo** que trae la IA, hacia el **insight**. El **prescriptivo** es la cima —mayor valor y complejidad, el **foresight**—: no solo anticipa, **recomienda acciones concretas**.

Las dos capas horizontales. La **capa de aplicación** (*application layer*) se enfoca en **automatización y facilidad de uso** y refleja la **democratización** (abajo). La **capa analítica** (*analytical layer*) concentra **predicción y optimización**, donde se **captura el mayor valor** (arriba). En la base aparece el rótulo **datos no estructurados**. Conclusión: la transición **no es solo tecnológica, sino conceptual**: de reportar el pasado a anticipar y guiar decisiones en tiempo casi real.

ANALOGÍA

Piensa en un médico. *Descriptivo*: «tienes fiebre de 39°» (mide). *Diagnóstico*: «es una infección bacteriana» (explica). *Predictivo*: «sin tratamiento, en 3 días empeorarás» (anticipa). *Prescriptivo*: «toma este antibiótico cada 8 horas» (recomienda). El valor sube en cada escalón, y también la dificultad.

3.2 Casos comunes de uso: los tres mecanismos

La IA aporta valor **ampliando la capacidad analítica sin aumentar proporcionalmente la complejidad para el usuario final**: más potente y a la vez más fácil de usar. Tres mecanismos.

Mecanismo 1 — Automatización y facilidad de uso. Tareas que antes requerían intervención técnica —**explorar variables, identificar patrones, generar reportes**— se ejecutan automáticamente. Permite **preguntas en lenguaje natural, explicaciones automáticas y alertas** sin consultas complejas. Impacto doble: más **eficiencia** y **reducción estructural de la dependencia de especialistas**. La *Figura 2* enfatiza la parte baja (descriptivo/diagnóstico) en la capa de aplicación: el aporte es hacer el análisis accesible; valor acotado, orientado al pasado (hindsight).

Mecanismo 2 — Capacidad predictiva. La IA **identifica patrones complejos y estima comportamientos futuros**: predicción de demanda, churn, riesgo financiero. La **diferencia clave es la granularidad**: el análisis **deja de ser agregado y pasa a nivel individual**, habilitando **decisiones accionables**. La *Figura 3* ubica predictivo/prescriptivo en la capa analítica, donde se captura el mayor valor; el predictivo es el **punto de inflexión entre insight y foresight**.

EJEMPLO

El BI clásico dice: «proyectamos vender 3% menos el próximo trimestre» (número global). La IA predictiva dice: «este cliente, Juan Pérez, tiene 82% de probabilidad de irse el mes que viene». No puedes «intervenir un 3%», pero sí llamar a Juan y ofrecerle algo. Del promedio a la persona: eso vuelve accionable la decisión.

Mecanismo 3 — Integración de datos no estructurados. El BI se centró en **datos estructurados** (tabulares). Pero mucha información vive en **datos no estructurados**: correos, documentos, imágenes, conversaciones, audio. La IA los **transforma en datos analizables**: un **texto** en **variables de sentimiento** o **clasificaciones temáticas**; una **imagen** en **etiquetas o patrones visuales**; un **audio** se **transcribe y analiza**. Esto **amplía el alcance del BI** y actúa como **habilitador clave**, incorporando señales que antes quedaban fuera de la decisión formal.

Cómo se relacionan las figuras. La **Figura 2** enfatiza automatización y democratización (parte baja); la **Figura 3** muestra cómo el valor se desplaza a la analítica avanzada (parte alta). Misma historia, dos ángulos.

NOTA

Democratización del análisis. Poner las capacidades de análisis al alcance de perfiles **no técnicos**. La pregunta de reflexión del PDF: ¿mejora la democratización mediante IA la toma de decisiones organizacional? Respuesta del curso: sí, con matices —más gente decidiendo con datos, pero con riesgo de decidir mal si no entiende las limitaciones del modelo.

4. Intuir la IA y el ML (sin exageraciones)

Afina las definiciones y agrega el concepto más importante para el resto del diplomado: la tríada **algoritmo – entrenamiento – modelo**.

Nada de ciencia ficción. La mayoría de las aplicaciones son **IA estrecha (narrow AI)**: tareas específicas con **alto nivel de precisión**, no inteligencia general.

El núcleo es el ML. A diferencia de la **programación tradicional** —donde las **reglas las define explícitamente un programador**—, en ML el sistema **infiere relaciones a partir de datos**: el comportamiento **no se codifica, se aprende de ejemplos**. Recibe **datos históricos con resultados conocidos** e **identifica patrones que le permiten generalizar**.

EJEMPLO

Para estimar el **riesgo de abandono**, el modelo **analiza observaciones pasadas y detecta configuraciones de variables que suelen preceder ese evento**. No le programaron «si hace 3 reclamos, se irá»; lo dedujo de miles de historias.

4.1 Los tres componentes: algoritmo, entrenamiento, modelo

Componente	Qué es	Analogía	Inglés
Algoritmo	El procedimiento de aprendizaje: define cómo se aprende. Es el método.	La técnica de cincelado del escultor	Algorithm
Entrenamiento	El proceso que ajusta los parámetros del algoritmo usando datos.	El acto de esculpir el mármol concreto	Training
Modelo	El resultado entrenado, capaz de generar predicciones. La instancia aprendida.	La estatua terminada	Model

Frase con olor a examen: «el algoritmo es el método, mientras que el modelo es la instancia aprendida a partir de ese método». El mismo algoritmo (p. ej., un árbol de decisión), entrenado con los datos de TelecomPlus, produce un modelo distinto que con los de un banco. Método idéntico, resultado distinto, porque los datos difieren.

NOTA

Qué son los «parámetros». Los **parámetros** son los números internos que el modelo afina durante el entrenamiento para encajar con los datos (los «pesos» que da a cada variable). Entrenar = buscar los parámetros que mejor reproducen los resultados conocidos.

4.2 «Garbage in, garbage out»: la calidad de los datos manda

La efectividad del ML depende directamente de la calidad de los datos. El modelo **no adquiere conocimiento abstracto**, sino que **captura las regularidades presentes en la información disponible**. Por eso **sesgos, errores o falta de representatividad se reflejan en el comportamiento del modelo**. Los **sesgos** (*bias*): si los datos reflejan una realidad injusta, el modelo la perpetúa. Los **errores**: datos mal registrados dan predicciones malas. La **falta de representatividad**: si solo vio clientes urbanos, fallará con los rurales.

ANALOGÍA

El modelo es un **espejo del pasado**: refleja fielmente lo que había en los datos, defectos incluidos. Si le enseñas con un espejo torcido, aprenderá a ver torcido. De ahí: **«basura entra, basura sale»** (*garbage in, garbage out*).

5. Mapeo de ideas de casos de uso de IA

El error que evita. Uno de los **principales errores en proyectos de IA es comenzar por la tecnología antes de definir el problema de negocio** («tengo un martillo, busquemos un clavo»). El mapeo invierte el orden: primero el problema, después la herramienta.

La técnica: el storyboard. Estructurar cada idea mediante un **guion gráfico o storyboard** que permita **visualizar cómo cambiaría un proceso real al incorporar IA**. Técnica **ágil**: describe primero la **situación inicial/configuración** (punto de partida, recursos, condiciones actuales) y luego las **acciones**, lo que **efectivamente cambia** con la IA: alertas automáticas, priorización de clientes, clasificación de documentos, recomendaciones.

5.1 Figura 4 — Matriz: implementación actual vs. futura

Qué muestra. Una **matriz** que contrasta el **estado actual** con la **implementación futura habilitada por IA**. Columnas = las **cuatro dimensiones** de todo caso de uso:

Dimensión	Inglés	Qué describe
Configuración	Setup	El inicio del proceso: recursos y supuestos iniciales, el punto de partida.
Acciones	Actions	Qué se genera o modifica en el flujo de trabajo.
Resultados inmediatos	Outcomes	Los productos inmediatos del proceso (p. ej., una lista de clientes priorizados o una predicción diaria).
Impacto	Results	La consecuencia empresarial observable (p. ej., reducción de pérdidas o aumento de ingresos).

Resultados vs. Impacto. No son lo mismo. Un **Resultado inmediato** (*outcome*) es lo que el sistema *produce*: «una lista de 200 clientes en riesgo». El **Impacto** (*result*) es lo que eso *logra para el negocio*: «reducción de pérdidas por fuga». Salida técnica vs. valor de negocio. La matriz obliga a conectarlos.

Ejemplo (retail, del PDF). La matriz aplicada al churn en retail:

	Configuración (Setup)	Acciones	Resultados (Outcomes)	Impacto (Results)
Actual	Equipos de tienda y servicio recogen feedback disperso entre ventas, e-commerce y postventa.	Identifican problemas de forma manual (precios, quiebres de stock, tiempos de despacho).	Gestión de reclamos caso a caso; reportes manuales de satisfacción.	El cliente migra a la competencia; pérdida de ventas recurrentes sin detección temprana.
Futura (IA)	Integración de datos históricos (compras, frecuencia, devoluciones, reclamos, navegación); trabajo conjunto comercial-marketing-analítica.	Análisis de patrones de abandono; modelo predictivo que estima probabilidad de fuga por cliente; explicaciones de factores.	Cada cliente recibe un puntaje de riesgo de abandono; visualización en sistemas comerciales y CRM; segmentos críticos.	Campañas personalizadas (descuentos, contacto proactivo); intervención antes de la fuga; menor churn y mayor valor del cliente.

Utilidad. Doble: (a) **comunica el valor esperado** a las partes interesadas; (b) **evalúa tempranamente la viabilidad**, identificando limitaciones de datos o bajo impacto antes de invertir. Conecta cambios operativos con resultados de negocio.

5.2 Figura 5 — Modelo de madurez analítica

Qué muestra. Ubica los casos de uso dentro del modelo de madurez analítica, cerrando el círculo con la Figura 1: descriptivo (¿qué ocurrió?, hindsight), diagnóstico (¿por qué ocurrió?), predictivo (¿qué ocurrirá?, insight), prescriptivo (¿cómo hacer que ocurra?, foresight). Mensaje: **no todos los casos de uso generan el mismo valor**; los que **anticipan y recomiendan** están en los niveles más altos. El material complementario confirma que es el **modelo de Gartner**. Conclusión: la evolución hacia **inteligencia de decisión** impulsada por IA **no es solo un cambio tecnológico, sino una transformación profunda** en cómo las organizaciones comprenden y usan la información.

6. Síntesis conceptual de la unidad

1. El valor del análisis se desplaza de describir el pasado a **anticipar y recomendar acciones**, habilitado por **automatización, analítica avanzada y datos no estructurados**.
2. La IA en los negocios no es una **inteligencia general**, sino un **conjunto de herramientas especializadas** (narrow AI) basadas en ML, cuyo desempeño **depende críticamente de los datos y del problema específico**.
3. Por eso la **identificación y estructuración de casos de uso** (el mapeo) es un **paso esencial**: conecta capacidades tecnológicas con **impacto empresarial tangible**.
4. La unidad conceptualiza la IA **no como un fin en sí misma, sino como un medio para mejorar la toma de decisiones** —hilo que sostiene las unidades siguientes.

7. Caso aplicado: TelecomPlus — reducir el churn con IA

Escenario. Laura Martínez, analista de inteligencia de negocios en TelecomPlus (telefonía móvil e internet en varias regiones), nota que la **tasa de rotación** —especialmente en el **segmento joven (18-29 años)**— aumenta, afectando **rentabilidad y crecimiento futuro**.

Problema (tradicional, descriptivo/diagnóstico). En reuniones mensuales, Laura presenta **informes tradicionales** con tablas y gráficos que muestran un **aumento del 15% en la tasa de abandono**. Los jóvenes son los más propensos, **pero el análisis no ofrece recomendaciones claras**. Las soluciones —**nuevos planes o descuentos generales**— no resultan efectivas. El análisis **se detiene en lo descriptivo**, sin enfoque proactivo ni personalizado, dejando a los gerentes decidiendo con su experiencia. Es el techo del BI descriptivo (Figura 1).

Solución (potenciada por IA, predictivo/prescriptivo). TelecomPlus implementa un **modelo de IA**. Laura colabora con tecnología para **entrenar un modelo de ML con datos históricos de comportamiento de compra, uso de productos e interacción con el servicio**. Ahora el sistema **predice la probabilidad de abandono de cada cliente de manera individual** (la **granularidad**) y **sugiere una «próxima mejor acción» (next best action)**: un descuento específico a los de mayor riesgo y valor, o un cambio de plan. La IA **optimiza miles de decisiones diarias** antes imposibles de gestionar manualmente.

NOTA

Próxima mejor acción (Next Best Action). Recomendación del modelo sobre **cuál es la mejor acción a tomar con cada cliente en este momento**. Es el paso prescriptivo: no basta con saber *quién* se irá (predictivo); el sistema dice *qué hacer* con cada uno (prescriptivo).

Resultado. Tras la implementación, **la tasa de rotación disminuye un 10% en el primer trimestre**. Reduce la fuga, **mejora los ingresos** (retiene clientes valiosos) y permite un **uso más eficiente de los recursos**, porque la IA **maneja de manera autónoma las intervenciones personalizadas**. El caso recorre el eje de madurez de hindsight (informes de Laura) a foresight (next best action), usando implícitamente la matriz Setup–Acciones–Resultados–Impacto.

8. Ejercicio práctico y foro

El PDF pide **seleccionar un proceso concreto del entorno** (ventas, atención, logística, RR.HH.) y responder: (1) ¿qué decisiones se toman hoy y con qué información?; (2) ¿qué problema podría abordarse con datos?; (3) ¿cómo cambiaría con IA —qué datos, qué tipo de análisis, qué resultado? Sugiere el esquema **Configuración – Acciones – Resultados – Impacto**. El objetivo no es diseñar una solución técnica, sino **identificar dónde la IA generaría valor real**. El ejemplo de retail (sección 5.1) es la respuesta modelo. El **foro** replica con la empresa ficticia **DataConnect** (internet, churn 18-29), discutiendo recomendaciones y **retos** (calidad de datos, adopción, interpretación). El video complementario, «**Disrupción digital**», propone tres ejercicios para pensar la transformación digital.

9. Bibliografía de la unidad

- **Zwingmann, T. (2024).** *Inteligencia empresarial basada en IA (AI-Powered Business Intelligence)*. O'Reilly Media. (Fuente principal del marco BI + IA.)
- **Calvo, J., & Escapa, C. (2025).** *The AI Driven Business: Leading, Competing, and Thriving in the Age of Artificial Intelligence*. Libros de Cabecera.
- **Digital.ai (s.f.).** *IT decision-making through the lens of Gartner's analytics maturity model*. (Fuente del modelo de madurez analítica, Figuras 1 y 5.)

Glosario

Término	Inglés	Definición en una línea
Inteligencia de Negocios (BI)	<i>Business Intelligence</i>	Prácticas, arquitecturas y herramientas que convierten datos dispersos en información útil para decidir.
Inteligencia Artificial (IA)	<i>Artificial Intelligence</i>	Herramienta para construir sistemas que resuelven tareas específicas, hoy principalmente mediante ML.
Aprendizaje automático (ML)	<i>Machine Learning</i>	Enfoque donde el sistema infiere patrones y reglas a partir de datos históricos, no de reglas codificadas a mano.
Inteligencia de Decisión	<i>Decision Intelligence</i>	Disciplina que suma BI + IA para optimizar la toma de decisiones humana y automatizada.
IA estrecha	<i>Narrow AI</i>	Sistema que resuelve un único problema bien definido para el que fue entrenado, sin capacidad general.
IA general	<i>Artificial General Intelligence (AGI)</i>	Inteligencia hipotética capaz de abordar cualquier problema, como un humano; no existe comercialmente hoy.
Algoritmo de ML	<i>Algorithm</i>	Procedimiento computacional (el método) que analiza datos para encontrar el mejor modelo posible.
Entrenamiento	<i>Training</i>	Proceso que ajusta los parámetros del algoritmo usando datos para producir el modelo.
Modelo	<i>Model</i>	Resultado entrenado, capaz de generar predicciones; la instancia aprendida a partir del algoritmo.
Parámetros	<i>Parameters</i>	Números internos que el modelo afina durante el entrenamiento para encajar con los datos.
Mapeo de historias de IA	<i>AI use-case story mapping</i>	Técnica ágil que contrasta el proceso actual con su versión futura con IA para ver dónde se genera valor.
Storyboard	<i>Storyboard</i>	Guion gráfico que ilustra paso a paso cómo cambiaría un proceso al incorporar IA.
Churn	<i>Churn / Churn rate</i>	Tasa de abandono: porcentaje de clientes que dejan de usar un servicio en un período.
Análisis descriptivo	<i>Descriptive analytics</i>	Análisis que responde «¿qué ocurrió?» describiendo datos históricos.
Análisis diagnóstico	<i>Diagnostic analytics</i>	Análisis que responde «¿por qué ocurrió?» agregando una capa interpretativa.
Análisis predictivo	<i>Predictive analytics</i>	Análisis que estima «¿qué es probable que ocurra?» a partir de patrones en los datos.
Análisis prescriptivo	<i>Prescriptive analytics</i>	Análisis que responde «¿qué acción tomar?» recomendando decisiones concretas.
Visión retrospectiva	<i>Hindsight</i>	Mirada al pasado; asociada a los análisis descriptivo y diagnóstico.
Visión de la perspectiva	<i>Insight</i>	Comprensión de patrones que permite estimar lo probable; asociada al análisis predictivo.
Visión anticipatoria	<i>Foresight</i>	Capacidad de anticipar y guiar acciones futuras; asociada al análisis prescriptivo.
Modelo de madurez analítica	<i>Analytics maturity model</i>	Marco (de Gartner) que ordena la analítica en niveles crecientes de valor y dificultad, de descriptivo a prescriptivo.
Capa de ingestión	<i>Ingestion layer</i>	Nivel base donde se captan y describen los datos (análisis descriptivo).

Término	Inglés	Definición en una línea
Capa de aplicación	<i>Application layer</i>	Franja centrada en automatización y facilidad de uso; refleja la democratización del análisis.
Capa analítica	<i>Analytical layer</i>	Franja de capacidades avanzadas de predicción y optimización, donde se captura el mayor valor.
Datos estructurados	<i>Structured data</i>	Información organizada en filas y columnas (ventas, inventarios, registros financieros).
Datos no estructurados	<i>Unstructured data</i>	Información sin formato tabular: textos, imágenes, audio, correos, conversaciones.
Análisis de sentimiento	<i>Sentiment analysis</i>	Conversión de texto en variables que miden la actitud o emoción expresada.
Democratización del análisis	<i>Data democratization</i>	Poner las capacidades de análisis de datos al alcance de perfiles no técnicos.
Automatización	<i>Automation</i>	Ejecución automática de tareas analíticas (explorar variables, generar reportes, emitir alertas).
Granularidad	<i>Granularity</i>	Nivel de detalle del análisis; la IA lo lleva de lo agregado a lo individual.
Decisiones accionables	<i>Actionable decisions</i>	Decisiones concretas y ejecutables que se habilitan al analizar a nivel individual.
Próxima mejor acción	<i>Next Best Action</i>	Recomendación del modelo sobre la mejor acción a tomar con cada cliente en el momento.
Predicción de demanda	<i>Demand forecasting</i>	Estimación de la demanda futura mediante modelos predictivos.
Sesgo	<i>Bias</i>	Distorsión aprendida por el modelo cuando los datos históricos reflejan una realidad parcial o injusta.
Tres V del dato	<i>Three V's (Volume, Velocity, Variety)</i>	Volumen, velocidad y variedad crecientes de los datos que hicieron insuficiente el análisis manual.
Programación tradicional	<i>Rule-based programming</i>	Enfoque donde un programador define explícitamente todas las reglas del comportamiento.
Generalización	<i>Generalization</i>	Capacidad del modelo de acertar en casos nuevos a partir de patrones aprendidos de casos vistos.
Configuración (Setup)	<i>Setup</i>	Dimensión del mapeo: punto de partida, recursos y supuestos iniciales del proceso.
Acciones	<i>Actions</i>	Dimensión del mapeo: qué se genera o modifica en el flujo de trabajo con IA.
Resultados inmediatos	<i>Outcomes</i>	Dimensión del mapeo: los productos directos del proceso (p. ej., una lista priorizada).
Impacto	<i>Results</i>	Dimensión del mapeo: la consecuencia empresarial observable (p. ej., menos pérdidas, más ingresos).
CRM	<i>Customer Relationship Management</i>	Sistema de gestión de la relación con clientes donde se visualizan puntajes e indicadores.
Disrupción digital	<i>Digital disruption</i>	Transformación profunda de procesos y modelos de negocio impulsada por tecnologías digitales e IA.

Total de términos del glosario: 43.

Mapa conceptual

```
Crear valor empresarial con la IA (Unidad 1)
|
+-- 1. De la Inteligencia de Negocios (BI) a la Inteligencia de Decision
|   +-- BI clasico
|   |   +-- es -> analisis descriptivo (retrospectivo, hindsight)
|   |   +-- depende de -> intervencion humana
|   |   +-- limitado por -> volumen/velocidad/variedad (3 V) + falta de especialistas
|   +-- se transforma por -> integracion de IA
|   |   +-- responde a -> 3 transformaciones: acceso inmediato . democratizacion . eliminar barreras
|   +-- resultado -> Inteligencia de Decision = BI + IA (decision humana y automatizada)
|
+-- 2. Modelo de madurez analitica (Gartner) - eje VALOR vs DIFICULTAD [Figs 1 y 5]
|   +-- Analisis descriptivo -> "que ocurrio?" -> hindsight -> capa de ingestion
|   +-- Analisis diagnostico -> "por que ocurrio?" -> capa interpretativa
|   +-- Analisis predictivo -> "que ocurrira?" -> insight <- punto de inflexion (IA)
|   +-- Analisis prescriptivo -> "como hacer que ocurra?" -> foresight -> mayor valor
|   +-- capa de aplicacion -> automatizacion + facilidad de uso (parte baja) [Fig 2]
|   +-- capa analitica -> prediccion + optimizacion (parte alta, mayor valor) [Fig 3]
|
+-- 3. Tres mecanismos de valor de la IA en el BI
|   +-- Automatizacion -> lenguaje natural . alertas . reportes -> menos dependencia de expertos
|   +-- Prediccion -> patrones complejos + granularidad individual -> decisiones accionables
|   |   +-- ejemplos -> churn . prediccion de demanda . riesgo financiero
|   +-- Integracion de datos no estructurados -> texto(sentimiento) . imagen(etiquetas) . audio(transcripcion)
|   +-- contrapunto -> datos estructurados (tabulares)
|
+-- 4. Que es la IA y el ML (sin exageraciones)
|   +-- IA estrecha (narrow AI) <-contrasta con-> IA general (AGI, no existe hoy)
|   +-- ML -> infiere reglas de los datos <-contrasta con-> programacion tradicional (reglas explicitas)
|   |   +-- objetivo -> generalizar a nuevos casos
|   +-- triada: Algoritmo (metodo) -> Entrenamiento (ajusta parametros) -> Modelo (instancia aprendida)
|   +-- calidad de datos manda -> sesgos/errores/falta de representatividad -> "garbage in, garbage out"
|
+-- 5. Mapeo de historias de IA (storyboard) - herramienta practica
|   +-- evita el error -> empezar por la tecnologia antes que por el problema
|   +-- matriz: Implementacion actual vs. futura [Fig 4]
|   +-- 4 dimensiones -> Configuracion (Setup) . Acciones . Resultados (Outcomes) . Impacto (Results)
|   +-- utilidad doble -> comunicar valor esperado + evaluar viabilidad temprano
|
+-- 6. Caso aplicado: TelecomPlus (hilo conductor churn)
|   +-- problema -> churn juvenil (18-29) +15%, analisis solo descriptivo
|   +-- solucion -> modelo ML predice abandono individual + "proxima mejor accion" (next best action)
|   +-- resultado -> churn -10% en el primer trimestre + mas ingresos + eficiencia
|   +-- replica en -> ejercicio retail (CRM, puntaje de riesgo) . foro DataConnect . video Disrupcion digital
```

Discrepancias detectadas

DISCREPANCIA 1

Discrepancia 1 — Definición de IA como «principalmente aprendizaje automático».

Qué dice el curso: la IA resuelve tareas específicas *principalmente mediante el aprendizaje automático*.

Qué dice la literatura: el ML es la rama dominante hoy, pero la IA como campo es más amplia (sistemas simbólicos, reglas, búsqueda, planificación, optimización, lógica). IA $\approx$ ML describe la práctica empresarial actual, no la disciplina completa.

Regla para el examen: si preguntan por *la IA en los negocios hoy*, responde con la visión del curso (IA $\approx$ ML en tareas estrechas). Si piden *definir la IA como campo*, aclara que el ML es su subcampo más usado, no su totalidad.

DISCREPANCIA 2

Discrepancia 2 — El ML como «paradigma de programación».

Qué dice el curso: el ML es un «paradigma de programación donde el algoritmo encuentra patrones en los datos».

Qué dice la literatura: formalmente el ML es un **subcampo de la IA**, no un paradigma paralelo a la programación tradicional. La contraposición del curso (reglas explícitas vs. aprendidas) es correcta y didáctica, pero la etiqueta es imprecisa.

Regla para el examen: conserva la idea central —en ML el comportamiento se *aprende* de ejemplos en vez de *codificarse*—, que es lo evaluable. Solo matiza («ML es un subcampo de la IA») si la pregunta apunta a la taxonomía.