

UNIDAD 5

Análisis **predictivo** y **prescriptivo** potenciado por IA

El recorrido completo de la analítica: de **describir el pasado** a **recomendar la próxima acción**. Qué ocurrió, por qué ocurrió, qué podría ocurrir y qué deberíamos hacer — y las herramientas de IA que responden cada pregunta.

4 niveles de analítica

Lenguaje natural & narrativa

Clasificación · Regresión · Anomalías

Fuga del objetivo

Siguiente mejor acción · Refuerzo

Explicación completa del módulo — **no un resumen**. Ancla de continuidad: **Fibromin** (mantención predictiva industrial).

Cómo **leer** este documento

Esta es la Unidad 5 explicada al 100%: cada concepto, término y ejemplo del PDF del curso está aquí, desarrollado con su mecanismo, una analogía y un caso concreto. Sigue el orden del material original. Antes de empezar, tres convenciones que vas a ver repetidas.

EN FIBROMIN

Cajas azules. Aterrizan cada concepto abstracto en tu app de mantención predictiva. La Unidad 5 tiene una particularidad afortunada: **Fibromin es, literalmente, un sistema de analítica predictiva y prescriptiva**. Casi todo lo que dice el curso, tú ya lo estás haciendo o lo vas a hacer. El ancla no fuerza nada esta vez.

ANALOGÍA

Cajas verdes. Un puente desde algo cotidiano hacia el concepto técnico, para fijar la intuición antes de la definición formal.

OJO, EXAMEN

Cajas ámbar. Definiciones y distinciones con olor a pregunta. Lo que conviene poder responder de memoria, con las palabras exactas del curso.

MÁS ALLÁ DEL CURSO

Cajas grises. Enriquecimiento que **no está en el PDF**: el nombre real de la herramienta que el curso describe sin nombrar, la mecánica interna de un algoritmo, una fórmula. Útil para dominar de verdad el tema, pero **no es material evaluable** — sepáralo mentalmente de lo que sí entra.

⚠ DISCREPANCIA

Cajas coral. Donde el curso dice una cosa y la práctica actual dice otra. Explico primero la versión del curso (es la que te evalúan) y luego la corrección, para que sepas ambas. En esta unidad hay **tres**, y dos son jugosas: el curso enseña dos servicios de Microsoft que se apagan en octubre de 2026.

1 Los **cuatro niveles** de la analítica

Toda organización genera datos: ventas, clientes, procesos, sensores. Pero tener datos no es lo mismo que tomar buenas decisiones. **El valor aparece cuando el dato se transforma en algo que ayuda a decidir** — cuando permite comprender una situación, encontrar sus causas, anticipar lo que viene y elegir un curso de acción. La Unidad 5 organiza ese salto en una escalera de cuatro peldaños.

El curso presenta la analítica empresarial como una **progresión de capacidades**: cada nivel responde una pregunta distinta y aporta una perspectiva que el anterior no tenía. No son cuatro herramientas sueltas, sino cuatro etapas de madurez que se apoyan una en otra. Vale la pena memorizarlas por su pregunta, porque así es como el curso las examina.

LOS CUATRO NIVELES Y SU PREGUNTA RECTORA

Nivel	Pregunta	Qué hace	Ejemplo en un negocio
Descriptivo	¿Qué ocurrió?	Resume y visualiza información histórica para comprender el comportamiento pasado.	El volumen de ventas del trimestre; los productos más vendidos.
Diagnóstico	¿Por qué ocurrió?	Identifica los factores que explican un resultado y las relaciones entre variables.	Qué segmento de clientes explica la caída de ingresos.
Predictivo	¿Qué podría ocurrir?	Usa el histórico para estimar comportamientos futuros y reducir la incertidumbre.	Qué clientes tienen alta probabilidad de abandonar.
Prescriptivo	¿Qué deberíamos hacer?	Evalúa alternativas y recomienda la acción con mayor probabilidad de un buen resultado.	Qué oferta concreta hacerle a ese cliente para retenerlo.

El movimiento clave entre los dos primeros niveles y los dos últimos es un **cambio de foco**. Descriptivo y diagnóstico miran hacia atrás: describen y explican lo que ya pasó. El predictivo gira la cabeza hacia adelante — y, con cuidado, el curso aclara que su propósito *no* es adivinar el futuro con certeza absoluta, sino **reducir la incertidumbre** de la decisión. El prescriptivo da el último paso: deja de mirar el escenario y empieza a recomendar qué hacer frente a él, combinando modelos predictivos con mecanismos que evalúan alternativas y estiman sus efectos.

OJO, EXAMEN — LA CADENA ANALÍTICA

Los cuatro niveles **no son categorías independientes**: forman una misma cadena, y cada eslabón depende de la calidad del anterior. Las recomendaciones prescriptivas dependen de predicciones confiables; las predicciones dependen de una buena comprensión de los factores explicativos (diagnóstico); y el diagnóstico requiere información descriptiva consistente y de calidad. **Si el dato de base es malo, todo lo que se construya encima hereda el error**. Esta idea reaparece en el nivel predictivo con la frase "un modelo solo puede ser tan bueno como los datos con que se entrena".

El PDF ilustra esta progresión con una pirámide de cuatro cajas (la Figura 1): DATOS → INFORMACIÓN → CONOCIMIENTO → DECISIÓN. Los datos crudos se convierten en información cuando se organizan en reportes, métricas y visualizaciones; la información se vuelve conocimiento cuando revela patrones, tendencias y hallazgos; y el conocimiento se transforma en decisión, es decir, en acción empresarial. Cada nivel de analítica empuja el dato un peldaño más arriba en esa pirámide.

MÁS ALLÁ DEL CURSO — EL NOMBRE DE ESA PIRÁMIDE

La secuencia Datos → Información → Conocimiento → Decisión es una versión de la clásica **jerarquía DIKW** (Data, Information, Knowledge, Wisdom), un modelo estándar en gestión del conocimiento. El curso reemplaza "sabiduría" (Wisdom) por "decisión", que es más operativo y encaja mejor con el objetivo del módulo: no acumular saber, sino **actuar**. No necesitas el nombre para el examen, pero si alguna vez lo ves escrito, es esto.

EN FIBROMIN — LOS CUATRO NIVELES EN UN MOTOR

Toma un motor crítico monitoreado por Fibromin y recorre la escalera completa:

Descriptivo — El dashboard muestra la vibración y la temperatura del rodamiento en los últimos seis meses. *¿Qué ocurrió?* La vibración subió de a poco.

Diagnóstico — ¿Qué explica esa subida? ¿El turno de noche, una planta específica, un tipo de rodamiento? *¿Por qué ocurrió?*

Predictivo — Con ese histórico, Fibromin estima: este motor tiene alta probabilidad de falla en las próximas 200 horas. *¿Qué podría ocurrir?*

Prescriptivo — La app no se detiene en la alerta: recomienda la acción óptima — inspeccionar ahora, reprogramar la parada, cambiar el rodamiento antes del fin de semana. *¿Qué deberíamos hacer?*

Toda la propuesta de valor de Fibromin es subir a sus clientes por esta escalera: la mayoría de las plantas todavía viven en el peldaño descriptivo (un tablero que dice qué pasó) y Fibromin las lleva hasta el prescriptivo.

ANALOGÍA — EL MÉDICO

Piensa en una consulta médica. **Descriptivo**: el termómetro marca 39°C (el hecho). **Diagnóstico**: el médico identifica una infección bacteriana (la causa). **Predictivo**: sin tratamiento, esto escalará a neumonía en 48 horas (el pronóstico). **Prescriptivo**: toma este antibiótico cada 8 horas (la acción recomendada). El termómetro por sí solo nunca te curó; hizo falta subir los cuatro peldaños.

Conexión con módulos previos: esta escalera es la contracara de **CRISP-DM** (Unidad 3). La "comprensión del negocio" y la "comprensión de los datos" de CRISP-DM viven en los niveles descriptivo y diagnóstico; el "modelado" es el predictivo; y el "despliegue" que convierte el modelo en decisión operativa es el prescriptivo. También recupera la **incertidumbre** de la Unidad 4 (esa imprevisibilidad en requisitos, aceptación y calidad de datos): el nivel predictivo existe precisamente para reducirla, no para eliminarla.

2 Análisis **descriptivo** potenciado por IA

El análisis descriptivo es el punto de partida de cualquier iniciativa analítica. Su trabajo es **organizar, resumir y presentar información histórica** para entender cómo se comportó la organización. Durante años se apoyó en indicadores, informes periódicos y visualizaciones. La pregunta que responde es simple: **¿qué ocurrió?**

Con esa mirada se conoce el volumen de ventas de un período, cuáles fueron los productos más vendidos, cómo evolucionaron los costos o si se cumplieron las metas. Sigue siendo esencial — pero tiene un problema práctico que la IA vino a resolver.

El cuello de botella de lo descriptivo tradicional

En muchas organizaciones, acceder a la información depende de **especialistas** que saben construir consultas, diseñar reportes o interpretar modelos de datos complejos. El usuario de negocio no pregunta directamente: le pide un reporte a un equipo técnico y *espera*. Ese modelo genera **cuellos de botella** — se vuelve insostenible cuando las decisiones deben tomarse rápido y la cantidad de preguntas posibles supera de lejos la capacidad de respuesta del equipo analítico. La IA ataca esto por dos frentes: la consulta en lenguaje natural y la narrativa inteligente.

Consulta de Lenguaje Natural (NLQ · Natural Language Query)

La **Consulta de Lenguaje Natural (NLQ)** es una tecnología que permite a los usuarios interactuar con los datos **mediante preguntas sencillas en lenguaje humano**, obteniendo visualizaciones automáticas. En lugar de escribir código o navegar por veinte reportes, alguien de comercial escribe:

- ¿Cuáles fueron las ventas del último trimestre?
- ¿Qué región presentó el mayor crecimiento?
- ¿Qué categoría de productos generó más ingresos durante el año?
- ¿Cómo evolucionaron los costos operacionales en los últimos seis meses?

El sistema interpreta la intención de la pregunta, identifica las métricas relevantes y determina qué información recuperar. Parece magia, pero por debajo hay varias tareas simultáneas y difíciles: **reconocer entidades** relevantes, **interpretar el contexto temporal** ("último trimestre", "durante el año"), **identificar medidas y dimensiones**, **resolver ambigüedades lingüísticas** y construir una **representación estructurada** de la consulta original — que en el fondo es una consulta formal a la base de datos.

El punto más delicado son las **equivalencias semánticas**. Una empresa puede usar indistintamente "ventas", "facturación", "ingresos" o "recaudación" para referirse a la misma métrica. Para responder bien, el sistema debe entender que todas apuntan al mismo campo del modelo de datos. Esa configuración tiene nombre propio en el curso.

OJO, EXAMEN — SINÓNIMOS DE CAMPO

La clave técnica que hace funcionar el NLQ es la configuración de **sinónimos de campo** (`field synonyms`): decirle al sistema que "ingresos", "facturación" y "ventas" apuntan al mismo campo del modelo de datos. Sin sinónimos, el sistema no entiende la pregunta del vendedor; con ellos, cualquiera interactúa de forma fluida con grandes volúmenes de datos sin saber cómo está estructurada la base por debajo.

La gran ventaja del NLQ es que **reduce la dependencia de conocimientos técnicos especializados**: gente de comercial, finanzas u operaciones accede a la información sin entender la estructura de las bases de datos. Pero el curso pone un límite honesto y correcto: **la calidad de las respuestas sigue dependiendo de la calidad del modelo de datos**. La IA facilita la interacción, pero no compensa datos incompletos, inconsistentes o mal definidos. Si el campo "ventas" mezcla pesos con dólares, ninguna pregunta en lenguaje natural lo va a arreglar.

MÁS ALLÁ DEL CURSO — CÓMO SE LLAMA DE VERDAD Y CÓMO CAMBIÓ

Lo que el curso describe como "consulta en lenguaje natural con sinónimos de campo" es, casi textual, el **visual Q&A de Power BI** de Microsoft, donde configuras un `linguistic schema` con sinónimos. La generación de estos apuntes se apoya en toda la suite de IA de Power BI, que iremos identificando caso por caso.

Además, un matiz de actualidad: el enfoque "clásico" que describe el curso (mapear la frase a una consulta estructurada usando un diccionario de sinónimos) fue la norma hasta hace poco. Hoy los **modelos de lenguaje grandes (LLM)** hacen esto de forma mucho más flexible con `text-to-SQL` / `text-to-DAX`: generan la consulta directamente desde la pregunta, sin depender tanto de sinónimos pre-configurados. El concepto del curso sigue vigente y es el correcto para entender el mecanismo; solo cambió la tecnología que lo implementa.

Narrativa inteligente (Smart Narrative)

El segundo avance ataca el otro extremo del proceso: una vez que tienes el dato, hay que **interpretarlo y comunicarlo**. Tradicionalmente, un analista revisa tablas y gráficos y escribe conclusiones para gerentes — tarea lenta, sobre todo si los informes se actualizan seguido. La **narrativa inteligente** es la capacidad de la IA de **generar automáticamente resúmenes textuales de gráficos y tablas**, facilitando la lectura de tendencias.

Estos sistemas analizan indicadores, comparaciones y tendencias para producir descripciones en texto de los hallazgos principales: detectan un incremento sostenido y lo destacan, o señalan caídas relevantes, cambios abruptos, diferencias entre segmentos, resultados que se apartan de lo habitual. Su utilidad no es solo ahorrar tiempo: también **estandarizan** la comunicación de resultados y la hacen comprensible para quien no tiene formación analítica. Y son **dinámicas** — si el usuario filtra por año o región, el texto se reescribe al instante para reflejar la nueva realidad de los datos.

El PDF muestra esto con un gráfico de ventas (la Figura 2, "Ventas hasta la fecha", que compara ventas reales, meta y año previo) y con una tabla generada por IA a partir de él. Conviene mirarla con atención porque ilustra un puente importante: cómo lo *descriptivo* ya empieza a insinuar lo *diagnóstico*.

TABLA 1 — RAZONADO HECHO CON IA SOBRE EL GRÁFICO DE VENTAS (FIGURA 2 DEL CURSO)

Hallazgos clave (lo que la narrativa detecta — descriptivo)	Preguntas de diagnóstico (lo que abre — hacia el "por qué")
Las ventas crecieron ~ 400% respecto al inicio del período.	¿Qué factores impulsaron el fuerte crecimiento entre junio y septiembre?
El desempeño supera al año anterior en todos los meses observados.	¿Qué cambió después de septiembre que provocó una desaceleración relativa?
Entre junio y septiembre se registra la fase de crecimiento más acelerada.	¿La brecha respecto a la meta se concentra en ciertos productos, regiones o segmentos?
Desde septiembre la meta crece más rápido que las ventas reales.	¿Existen restricciones operativas o comerciales que estén limitando el crecimiento reciente?
Hay riesgo de incumplir objetivos si la desaceleración continúa.	—

OJO, EXAMEN — LA NARRATIVA NO REEMPLAZA AL HUMANO

El curso es enfático: estas narrativas **no sustituyen el análisis humano**. Su función es destacar patrones potencialmente relevantes y acelerar la interpretación inicial. La validación de conclusiones y la contextualización siguen requiriendo conocimiento del negocio y criterio profesional. Es un tema recurrente de toda la unidad — reaparece idéntico en el nivel prescriptivo — y suele venir como pregunta de reflexión.

Democratización del acceso a la información

Juntar consulta en lenguaje natural y generación automática de narrativas refleja una tendencia mayor: la **democratización del acceso a los datos**. Históricamente, solo un grupo reducido de especialistas podía explorar información de forma autónoma; el resto pedía y esperaba. Las herramientas de IA **trasladan parte de la capacidad exploratoria directamente a los usuarios del negocio**.

Esto *no elimina* al especialista — lo cambia de rol. En vez de gastar su tiempo generando reportes a pedido, puede dedicarse a lo de mayor valor: diseñar modelos analíticos, validar resultados, identificar oportunidades estratégicas. El beneficio organizacional de fondo es reducir el tiempo entre **la aparición de una pregunta y la obtención de una respuesta**: cuando la información fluye, el análisis se vuelve ágil y las decisiones se apoyan en evidencia actualizada.

EN FIBROMIN — DESCRIPTIVO CON IA PARA EL JEFE DE PLANTA

NLQ: el jefe de mantención de una faena no sabe SQL ni quiere aprender. Con lenguaje natural pregunta "¿qué equipo tuvo más alarmas de vibración el mes pasado?" o "muéstrame la temperatura del molino SAG en el último turno de noche" y obtiene el gráfico al toque. Ahí tienes la democratización: el conocimiento del dato deja de estar preso en el equipo de datos de Fibromin y llega directo a quien opera el motor.

Narrativa inteligente: bajo el gráfico de vibración, un subtítulo automático — "la vibración del rodamiento subió 22% en las últimas tres semanas, concentrada en el turno de noche". Ese texto lo habría escrito un analista; ahora se genera solo y se reescribe si el jefe filtra por otra faena.

Y el límite del curso aplica en serio a Fibromin: si los sensores están mal calibrados o hay huecos en la serie de datos, ninguna pregunta bonita lo salva. **Basura entra, basura sale** — que es exactamente la regla de oro de la Unidad 4: "no te cases con datos que no son realistas".

Conexión con la Unidad 4: recordá las **tres capas** de un sistema de IA (datos, análisis, usuario). El NLQ y la narrativa inteligente viven en la **capa de usuario** — son la interfaz que acerca el resultado a quien decide. El "esqueleto que camina" atraviesa las tres; estas dos herramientas son la punta que toca al humano.

3 Análisis **diagnóstico** e información automatizada

Una vez que sabes *qué* ocurrió, surge la pregunta que de verdad orienta la acción: **¿por qué ocurrió?** El descriptivo detecta tendencias y variaciones, pero rara vez explica sus causas. El propósito del análisis diagnóstico es **descubrir los factores que explican un resultado** y comprender las relaciones entre las variables del negocio.

Fíjate que las cuatro "preguntas de diagnóstico" que abría la narrativa inteligente en la tabla anterior — ¿qué impulsó el crecimiento?, ¿qué cambió después de septiembre?, ¿la brecha se concentra en algún segmento? — son exactamente las que este nivel viene a contestar. El descriptivo *plantea* el misterio; el diagnóstico lo *resuelve*.

Tradicionalmente, esto dependía de analistas que exploraban grandes volúmenes a mano, formulaban hipótesis y las contrastaban con los datos. La IA automatiza parte del proceso, encontrando patrones y factores explicativos que pasarían inadvertidos en una revisión convencional. El curso destaca dos herramientas.

Influenciadores clave (Key Influencers)

Los **influenciadores clave** son la visualización que **identifica qué factores tienen el mayor impacto sobre una métrica específica de interés**. Si detectas una caída de ingresos, en vez de revisar variable por variable, esta herramienta analiza muchas a la vez y determina cuáles presentan una asociación significativa con el resultado: puede revelar que ciertos segmentos de clientes, regiones, productos o canales contribuyen de manera *desproporcionada* a la variación.

El valor es de foco: permite concentrar la investigación en los factores con mayor capacidad explicativa, en vez de que el equipo explore a mano cientos de causas posibles. Reduce el tiempo de "por qué" de días a minutos.

MÁS ALLÁ DEL CURSO — QUÉ HACE POR DENTRO KEY INFLUENCERS

"Influenciadores clave" es el visual **Key Influencers de Power BI**, y por dentro no es magia: corre modelos de **ML.NET** según el tipo de métrica que analizás.

- Si la métrica es **categorica** (ej. abandonó / no abandonó), usa una **regresión logística** (algoritmo L-BFGS): compara el grupo que dio "sí" contra el que dio "no" y mide cuánto mueve cada factor la probabilidad.
- Si la métrica es **numérica** (ej. precio, ventas), usa una **regresión lineal** (algoritmo SDCA): mide el efecto de cada factor sobre el valor.

Para no dejarse engañar por factores con pocos datos, aplica un **test de Wald** con un umbral de significancia de $p < 0.05$: si un factor parece influyente pero se apoya en un puñado de casos, no lo reporta. Y su función "Top Segments" usa un **árbol de decisión** (FastTree) para encontrar combinaciones de valores interesantes. Sabés todo esto de ingeniería; el punto es que la herramienta del curso es, literalmente, regresión logística/lineal con un vestido de "IA sin código".

Causa raíz y el árbol de descomposición (Decomposition Tree)

Complementariamente, el diagnóstico busca la **causa raíz**. En vez de quedarse en correlaciones superficiales, el objetivo es **profundizar progresivamente** hasta comprender el mecanismo que origina el resultado. Esto suele implicar recorrer distintas dimensiones del negocio — clientes, productos, ubicaciones, procesos — desde una visión general hacia niveles crecientes de detalle.

El ejemplo del curso es nítido: una caída de ventas aparece, al principio, concentrada en una región. Un análisis posterior muestra que se limita a ciertas ciudades; luego, que afecta sobre todo a un segmento de clientes; finalmente, a una línea específica de productos. Cada nivel de zoom acota el problema hasta encontrar una explicación lo bastante sólida para sustentar una decisión.

La herramienta que asiste esto es el **árbol de descomposición**: una herramienta de análisis de causa raíz que **usa IA para sugerir en qué dimensión de los datos conviene profundizar** para explicar un resultado. Tú eliges la métrica; la IA propone la siguiente rama de mayor contribución. Automatiza lo que antes era una revisión manual exhaustiva.

MÁS ALLÁ DEL CURSO — LAS "AI SPLITS" DEL ÁRBOL

El "árbol de descomposición" es el **Decomposition Tree de Power BI**. Cuando lo dejas en modo automático, ofrece dos tipos de corte inteligente (AI splits): **High Value**, que abre la dimensión que *más* aporta a la métrica, y **Low Value**, que abre la que *menos* aporta. En modo manual, tú eliges la dimensión. Eso es todo lo que hay detrás de "la IA sugiere en qué dimensión profundizar".

OJO, EXAMEN — DIAGNÓSTICO ≠ CAUSALIDAD

Distinción fina que el curso subraya y que es candidata a pregunta: el análisis diagnóstico **no busca demostrar causalidad absoluta**. En la mayoría de los casos identifica **patrones, asociaciones y factores explicativos** que requieren la interpretación de un experto del negocio. La experiencia de los responsables sigue siendo fundamental para validar hipótesis. En una línea: *correlación no es causación* — la IA te muestra qué está asociado, el humano decide qué causa qué.

EN FIBROMIN — DIAGNÓSTICO DE UNA FALLA

Un cliente reporta que sus rodamientos fallan más de lo esperado. **Influenciadores clave**: Fibromin corre el análisis sobre "¿falló el rodamiento? (sí/no)" y encuentra que la temperatura de operación y la carga son los dos factores que más suben la probabilidad de falla, muy por encima de la marca del rodamiento. Ya sabes por dónde mirar.

Árbol de descomposición: partes del total de fallas y la IA sugiere abrir por faena (una concentra el 60%), luego por equipo (los molinos), luego por turno (noche), luego por tipo de lubricación. En cuatro cortes pasaste de "fallan los rodamientos" a "los molinos de la faena norte, en turno de noche, con la lubricación X". Eso es una causa raíz accionable.

Y el límite del curso importa: Fibromin no *prueba* que el turno de noche cause la falla — muestra que están asociados. Quizás de noche opera personal menos experimentado, o baja la temperatura ambiente. Ahí entra el ingeniero de confiabilidad a interpretar. La IA acota; el humano concluye.

Conexión con la Unidad 3: cuando el árbol de descomposición sugiere una dimensión, está proponiendo una **hipótesis** a contrastar — el mismo espíritu del ciclo iterativo de CRISP-DM. Y ojo con el **ground truth** de la Unidad 3: para que el análisis de "¿falló? sí/no" tenga sentido, alguien tuvo que etiquetar correctamente qué eventos fueron fallas reales. Si esa etiqueta está mal, el diagnóstico apunta al lugar equivocado.

4 Analítica **predictiva** y sus requisitos

Comprendidos los patrones históricos y sus causas, se puede dar el salto hacia adelante. La **analítica predictiva** usa datos históricos para **identificar patrones que permitan estimar comportamientos futuros**. Su objetivo no es predecir el futuro con certeza absoluta, sino **reducir la incertidumbre** de la decisión: anticipar un evento relevante antes de que ocurra permite planificar recursos, reducir riesgos y reaccionar más rápido.

El requisito previo: rigor y calidad de datos

El curso marca un cambio de exigencia respecto de los niveles anteriores. Construir un modelo predictivo pide **más rigor**: antes de entrenar nada, hay que evaluar la calidad de los datos disponibles, verificar su consistencia y comprender bien las variables involucradas. La frase que resume todo — y que conviene tener grabada — es:

Un modelo predictivo **solo puede ser tan bueno**
como los datos con los que se entrena.

Esta es la misma idea de la cadena analítica (nivel 1), pero con dientes: en lo descriptivo, un dato malo produce un reporte impreciso; en lo predictivo, un dato mal preparado puede producir un modelo que *parece* excelente y en realidad es una trampa. Ahí entra el concepto más importante de toda la unidad.

Fuga del objetivo (Target Leakage) — el concepto estrella

La **fuga del objetivo** es un error en el aprendizaje automático donde **una característica del conjunto de datos incluye la información que el modelo intenta predecir**. Dicho de otro modo: una variable usada durante el entrenamiento contiene información que, en la práctica, **no estaría disponible al momento de hacer la predicción**. El foro del curso lo dice sin anestesia: el modelo "hace trampa".

La consecuencia es traicionera. El modelo aparenta una **precisión extraordinaria durante las pruebas** — porque está viendo, disfrazada, la respuesta — pero **fracasa cuando se implementa en condiciones reales**, donde esa variable delatora no existe todavía. Es el peor tipo de error: no se nota en el laboratorio, solo en producción, cuando ya confiaste en él.

OJO, EXAMEN — LOS DOS EJEMPLOS CANÓNICOS DEL CURSO

El curso ancla el concepto con dos ejemplos que conviene poder repetir:

1. Predecir abandono de clientes. Sería incorrecto usar variables que registran **acciones realizadas después** de que el cliente ya decidió irse. Mejoran artificialmente el modelo en el entrenamiento, pero no sirven para anticipar nada — el cliente ya se fue.

2. La "fecha de cancelación del contrato" (ejemplo del foro). Si un cliente tiene fecha de cancelación, *prácticamente ya sabemos que abandonó*. El modelo dará resultados espectaculares en el entrenamiento, pero porque usa información que en la realidad no existe cuando hay que tomar la decisión.

Variables **válidas** para predecir abandono, en cambio: antigüedad del cliente, número de reclamos, consumo mensual — todas existen *antes* del evento.

MÁS ALLÁ DEL CURSO — LA REGLA MENTAL Y CÓMO SE DETECTA

La prueba de una línea para cazar leakage: "**¿esta variable ya existiría en el instante exacto en que necesito hacer la predicción?**" Si la respuesta es no — porque es futura, o es un efecto del resultado en vez de una causa — es fuga. La "fecha de cancelación" no existe cuando el cliente todavía es cliente; por eso es leakage.

Cómo se detecta en la práctica: **(a)** una métrica de desempeño sospechosamente perfecta — un $AUC \approx 0.99$ o accuracy del 100% casi nunca es un buen modelo, casi siempre es leakage; **(b)** una sola variable con importancia dominante y difícil de justificar causalmente; **(c)** el modelo se derrumba al pasar a datos nuevos. Esto es exactamente la **regla de oro de la Unidad 4** — "no te cases con los datos", asegura que sean realistas — llevada al detalle: una variable puede ser real y aun así ser trampa si no estará disponible a tiempo.

Asegurada la calidad de los datos, la analítica predictiva aborda tres tipos de problema. El curso los presenta como los ejemplos más comunes: clasificación, regresión y detección de anomalías.

Clasificación (Classification)

Los modelos de **clasificación** buscan **determinar a qué categoría pertenecerá un evento futuro**.

La **variable objetivo** (*target*) representa una clase o etiqueta específica. Los ejemplos del curso:

- Determinar si un cliente **abandonará o permanecerá** en la empresa.
- Identificar si una transacción **podría ser fraudulenta**.
- Clasificar una solicitud de crédito como **aprobada o rechazada**.
- Estimar si un vuelo **llegará a tiempo o con retraso**.

En todos, el objetivo es asignar una observación a una categoría a partir del histórico. Y la utilidad está en el tiempo: permiten **actuar antes de que ocurra el evento** — identificar clientes con alta probabilidad de abandono y lanzar retención *antes* de perderlos.

Regresión (Regression)

En otros escenarios el objetivo no es una categoría sino un **valor numérico**. Los modelos de **regresión** estiman variables continuas: ventas futuras, demanda esperada, tiempo de entrega de pedidos, consumo energético, costos operacionales. La diferencia con la clasificación es directa: donde la clasificación elige entre un conjunto limitado de etiquetas, la regresión **estima una cantidad específica**.

Su gracia es transformar indicadores *descriptivos* en herramientas *prospectivas*: en vez de mirar solo cómo se comportó un indicador en el pasado, la organización proyecta su evolución futura y anticipa desviaciones respecto de sus objetivos.

CLASIFICACIÓN VS. REGRESIÓN — LA DISTINCIÓN DEL CURSO

	Clasificación	Regresión
Qué predice	Una categoría / etiqueta (conjunto limitado de opciones).	Un valor numérico continuo (una cantidad).
La pregunta	¿A qué grupo pertenece?	¿Cuánto / cuántos?
Ejemplos	Abandono sí/no · fraude sí/no · crédito aprobado/rechazado · vuelo a tiempo/con retraso.	Ventas del próximo mes · demanda esperada · tiempo de entrega · consumo energético.
En Fibromin	¿Este motor fallará en las próximas 200 h? (sí/no)	¿Cuántas horas de vida útil le quedan al rodamiento?

MÁS ALLÁ DEL CURSO — CÓMO SE MIDE CADA UNO (Y POR QUÉ IMPORTA PARA EL LEAKAGE)

Sabés esto de ingeniería, pero conviene conectarlo con la unidad. Un **clasificador** se evalúa con exactitud (*accuracy*), precisión, exhaustividad (*recall*), F1 y AUC. Una **regresión**, con el error medio — el más usado es la raíz del error cuadrático medio:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

donde y_i es el valor real, $\hat{y}_i$ el predicho por el modelo, y n el número de observaciones. Se elevan al cuadrado las diferencias (para que los errores no se cancelen y castigar más los grandes), se promedian, y se toma la raíz para volver a las unidades originales — en Fibromin, horas de vida útil.

La conexión con el leakage: esas métricas son el **detector de mentiras**. Un AUC de 0.99 o un RMSE ridículamente bajo casi nunca significan "gran modelo"; significan "revisá tus variables, hay fuga del objetivo".

Detección de anomalías (Anomaly Detection)

La tercera aplicación no predice una categoría ni un valor, sino que **identifica comportamientos que se apartan significativamente de lo esperado** en una serie temporal. Las **anomalías** pueden ser problemas operacionales, fallas técnicas, fraudes o eventos excepcionales que piden atención

inmediata: un salto inesperado en los tiempos de espera de un centro de atención, una caída abrupta de ventas en una sucursal, un consumo de recursos inusual.

La diferencia entre el enfoque tradicional y el moderno es el punto examinable:

UMBRALES FIJOS VS. MÉTODOS MODERNOS DE DETECCIÓN DE ANOMALÍAS

Enfoque tradicional	Métodos modernos (potenciados por IA)
Umbral fijo. Una regla rígida: "alerta si supera el percentil 90" o "si pasa de X". Igual para todo, todo el tiempo.	Consideran el comportamiento histórico de la serie. Distinguen entre variaciones <i>normales</i> (estacionales, tendencias) y desviaciones <i>realmente significativas</i> . Se adaptan al contexto de cada serie.
Problema: no considera tendencias temporales ni estacionalidad. Genera muchas falsas alarmas — o se pierde anomalías reales que caen bajo el umbral.	Beneficio: reducen las falsas alarmas y permiten concentrar la atención en los eventos con mayor probabilidad de impacto real.

MÁS ALLÁ DEL CURSO — QUÉ HAY BAJO "MÉTODOS MODERNOS"

La diferencia técnica: un umbral fijo ignora que una serie tiene **tendencia y estacionalidad**. Los métodos modernos primero descomponen la serie (tendencia + estacionalidad + residuo) y luego marcan como anómalo lo que se sale de una **banda dinámica** que se mueve con el patrón esperado — no de una línea recta. Así, un pico de ventas cada diciembre no dispara alarma (es esperable), pero uno en marzo sí. El servicio que el curso usa para esto tiene nombre, fecha de nacimiento y — atención — fecha de defunción: **ver Discrepancia 1** al final del documento.

EN FIBROMIN — EL NIVEL PREDICTIVO ES EL PRODUCTO

Fibromin vive en este peldaño. Los tres problemas son sus tres funciones centrales:

Clasificación — "¿este motor fallará en las próximas 200 horas? sí/no". Con eso, mantención actúa antes de la falla.

Regresión — la vida útil restante (RUL, *Remaining Useful Life*) en horas. En vez de una alarma binaria, un número: "te quedan ~180 horas". Eso permite programar la parada con precisión quirúrgica.

Detección de anomalías — la vibración del rodamiento se sale de su banda normal *antes* de cruzar cualquier umbral clásico. Un umbral fijo diría "todo bien, no llegó al límite"; el método moderno dice "esta subida no es normal *para este motor en este turno*".

Y el leakage acecha en Fibromin: si para predecir la falla usaras la variable "orden de trabajo de reparación emitida" o "repuesto de rodamiento solicitado", tendrías un AUC de 0.99 y un modelo inútil — porque esas variables solo se activan *cuando la falla ya fue detectada*. Son la "fecha de cancelación" de tu dominio. La clasificación real de Fibromin solo puede usar señales que existen *antes* de la falla: vibración, temperatura, horas de operación, carga.

En síntesis, la analítica predictiva cambia la forma de usar los datos: en vez de reaccionar a hechos consumados, anticipa escenarios. Pero incluso una predicción perfecta deja una pregunta sin responder — **¿qué acción ejecutar frente a ese escenario?** — y esa es la puerta al último nivel.

Conexión con la Unidad 3: la **degradación de los modelos** (recordá *data drift* y *concept drift*) es la razón de que el ejercicio del curso pida no solo diseñar y evaluar, sino **mantener** el modelo. Un clasificador de abandono entrenado hoy pierde puntería a medida que cambian los clientes y el mercado. Predecir no es un evento único; es un mantenimiento permanente — igual que los motores que monitorea Fibromin.

5 Analítica **prescriptiva** y la siguiente mejor acción

La **analítica prescriptiva** es el nivel más avanzado. El foco se desplaza de la predicción a la **decisión**: ya no basta con estimar qué podría pasar, hay que responder **¿qué deberíamos hacer?** Combina modelos predictivos con mecanismos capaces de **evaluar distintas alternativas y recomendar la que tiene mayor probabilidad de un buen resultado**.

El problema que resuelve es real: en muchas organizaciones la decisión sigue dependiendo de la experiencia, la intuición o reglas generales. Cuando hay múltiples alternativas posibles y grandes volúmenes de datos, es difícil determinar cuál es la mejor acción para cada situación. El ejemplo que arrastra toda la unidad: una empresa *predice* qué clientes tienen alto riesgo de abandono — pero esa predicción, por sí sola, no resuelve nada. Todavía hay que decidir **qué acción concreta ejecutar** para retenerlos.

Siguiente mejor acción (Next Best Action)

Aquí surge el concepto de **siguiente mejor acción**: identificar, **para cada situación específica, la intervención con mayor probabilidad de alcanzar el resultado deseado**. Según el contexto, esa acción puede ser una oferta comercial, una recomendación de producto, una intervención de servicio al cliente o una decisión operacional.

La diferencia con los enfoques tradicionales de **reglas fijas** es la personalización. Un sistema prescriptivo **adapta la recomendación a las características de cada caso**. El curso lo ilustra con precisión: dos clientes con una probabilidad *similar* de abandono pueden requerir estrategias de retención **completamente distintas**, según su historial, nivel de gasto, antigüedad o comportamiento reciente. La regla fija trata a todos igual; la siguiente mejor acción trata a cada uno según quién es.

Aprendizaje por refuerzo (Reinforcement Learning)

Una de las técnicas más usadas para esto es el **aprendizaje por refuerzo**. Su diferencia con los **modelos supervisados** vistos hasta ahora es de fondo: donde el modelo supervisado aprende de **ejemplos históricos etiquetados** (aquí está la respuesta correcta, aprende de ella), el aprendizaje por refuerzo se basa en la **interacción continua con un entorno**.

El mecanismo, en las palabras del curso: un **agente** toma decisiones, observa los resultados obtenidos y recibe una **recompensa** asociada a su desempeño. Con el tiempo, el sistema aprende qué acciones producen mejores resultados y ajusta su comportamiento para **maximizar la recompensa acumulada**. No le dices qué hacer; lo dejas probar y aprender de las consecuencias.

	Supervisado (niveles anteriores)	Por refuerzo (prescriptivo)
Aprende de	Ejemplos históricos etiquetados (la respuesta correcta ya está).	Interacción con un entorno: prueba, observa el resultado, recibe recompensa.
Señal	El error respecto de la etiqueta conocida.	La recompensa (a veces retardada) de cada acción.
Objetivo	Predecir bien la etiqueta / el valor.	Maximizar la recompensa acumulada en el tiempo.
Ejemplo	Clasificar riesgo de abandono.	Elegir qué oferta hacer para retener, y mejorar oferta a oferta.

El ejemplo del curso es el programa de retención. Una empresa tiene varias alternativas para retener a un cliente en riesgo: un descuento, beneficios adicionales, extender condiciones contractuales. Al principio el sistema prueba distintas alternativas sobre distintos perfiles; a medida que observa cuáles generan respuesta favorable y cuáles no, ajusta su estrategia. Las decisiones **evolucionan con la evidencia**, en vez de depender de reglas de expertos o de campañas estáticas diseñadas una vez al año.

MÁS ALLÁ DEL CURSO — EL DILEMA EXPLORACIÓN/EXPLOTACIÓN Y QUÉ ES "DE VERDAD"

Eso de "al principio prueba distintas alternativas y después ajusta" tiene nombre y es el corazón del aprendizaje por refuerzo: el dilema **exploración vs. explotación**. **Explotar** es usar la mejor oferta conocida hasta ahora (ir a lo seguro). **Explorar** es probar una oferta nueva de la que no estás seguro, arriesgando una peor recompensa hoy para *aprender* y quizás encontrar algo mejor mañana. Todo el arte está en balancear ambas: si solo explotas, nunca descubres una oferta superior; si solo exploras, nunca cobras lo que aprendiste.

Segundo punto, importante: en casos de "siguiente mejor acción" como este, lo que se usa casi siempre *no* es aprendizaje por refuerzo completo, sino un pariente más simple llamado **banditos contextuales** (contextual bandits) — RL de *un solo paso*, donde el sistema observa un contexto (el perfil del cliente), elige una acción (la oferta) y recibe una recompensa, sin que haya una cadena de estados que se transforman. Es exactamente lo que hace el "bucle de rango y recompensa" del caso del curso. Ver **Discrepancia 3** para el matiz completo.

OJO, EXAMEN — LA PRESCRIPTIVA NO REEMPLAZA AL HUMANO (OTRA VEZ)

El cierre de la unidad, y candidato seguro a pregunta: la analítica prescriptiva **no reemplaza el juicio humano ni elimina la supervisión**. Las recomendaciones deben evaluarse dentro del contexto estratégico de la organización, considerando **restricciones operativas, aspectos regulatorios y criterios éticos**. Proporciona una capacidad adicional para identificar oportunidades de acción que el análisis tradicional no vería — pero la decisión final, y su responsabilidad, siguen siendo humanas. Es el mismo mensaje del nivel descriptivo (la narrativa no reemplaza al analista): un hilo conductor de toda la unidad.

EN FIBROMIN — DE LA ALERTA A LA ACCIÓN ÓPTIMA

Aquí Fibromin cierra su promesa. El nivel predictivo dice "este motor fallará en ~180 horas". Pero eso, solo, no resuelve el problema del jefe de mantención — ¿qué hace con esa información?

Siguiente mejor acción: la app recomienda la intervención óptima *para ese equipo específico*. Dos motores con la misma probabilidad de falla pueden merecer acciones distintas: uno es crítico y no puede parar en horario productivo (recomendación: intervención en la ventana de mantención del domingo); el otro tiene redundancia (recomendación: dejar operar y monitorear). Igual que los dos clientes del curso con el mismo riesgo pero distinta estrategia.

Aprendizaje por refuerzo / bandidos contextuales: con el tiempo, Fibromin puede aprender qué *política* de intervención minimiza el costo total — el equilibrio entre el costo de una falla no prevista y el costo de mantenciones innecesarias. Explora (¿y si espero 20 horas más antes de intervenir?) y explota (la ventana que históricamente funcionó), ajustando su recomendación faena a faena.

Y el guardarraíl del curso aplica en serio: en una minera, una recomendación de "deja operar" que sale mal cuesta millones y puede ser un tema de seguridad. Por eso la acción de Fibromin la **valida un ingeniero de confiabilidad** antes de ejecutarse. La IA prescribe; el humano firma.

Con esto se completa el recorrido: los datos dejan de servir solo para describir el pasado y se convierten en apoyo activo para decidir. La organización no solo comprende lo que ocurrió y anticipa lo que viene, sino que dispone de mecanismos para **actuar de forma más informada**.

6 Casos de uso **prácticos** de IA en negocios

El curso baja los cuatro niveles a **casos reales** que abarcan gestión comercial, operación en aeropuertos y retención en telecomunicaciones. No hay conceptos nuevos aquí — salvo uno, AutoML — sino los mismos de antes, ahora en escenarios concretos. Los reúno en una tabla y me detengo en lo que aporta.

Una herramienta que atraviesa los casos predictivos merece definición propia, porque el PDF la introduce recién aquí: el **aprendizaje automático automatizado (AutoML)**. Es la tecnología que **automatiza la construcción de un modelo** — la preparación de datos, la selección del algoritmo, el ajuste de sus parámetros y la validación — para que un usuario sin ser científico de datos entrene un clasificador o una regresión. En los casos de vuelos, el modelo no lo programa un especialista línea por línea: lo entrena AutoML.

Nivel	Caso	Herramienta / técnica	Detalle clave
Descript.	Consulta de datos con lenguaje natural	Q&A basado en IA	El vendedor pregunta "¿ventas en Estados Unidos el año pasado?" y obtiene un gráfico. La clave es la config. de sinónimos de campo .
Descript.	Resumir datos con lenguaje natural	Narrativa inteligente	Genera subtítulos/anotaciones sobre gráficos, dinámicos : si filtras por año o región, el texto se reescribe solo.
Diagnóst.	Información automatizada para causa raíz	Influyentes clave + árbol de descomposición	Ventas se desplomaron: los influyentes hallan qué variable pesa más; el árbol sugiere en qué dimensión seguir bajando.
Predict.	Clasificar retrasos de vuelos	Clasificación con AutoML	¿Los vuelos en el aire aterrizarán con +15 min de retraso? Factores cruciales: el tiempo de rodaje (taxi-out) y la combinación origen-destino.
Predict.	Predecir el KPI de tiempo de vuelo	Regresión con AutoML	Predice el tiempo real vs. el programado (valor numérico). Identifica qué vuelos de larga distancia excederán su horario. Supera a la regresión lineal simple.
Predict.	Detección de anomalías operativas	Servicio de detección de anomalías	Picos inusuales en tiempos de salida. El percentil 90 (umbral fijo) es ineficaz por ignorar estacionalidad; se usan márgenes dinámicos .
Prescr.	Siguiente mejor acción para retención	Motor de personalización con aprendizaje por refuerzo	Un bucle de rango y recompensa prueba ofertas (descuentos, meses gratis) y aprende cuál funciona por perfil. Supera a las ofertas únicas y a las pruebas A/B .

OJO — UNA IMPRECISIÓN DEL PROPIO MATERIAL

El PDF anuncia "**seis** casos prácticos" pero en el desarrollo lista **siete** (dos descriptivos, uno de diagnóstico, tres predictivos y uno prescriptivo). Es un desliz de conteo del curso, no un error conceptual — probablemente agrupan los dos de vuelos-predictivos como uno. No cambia nada de fondo; lo apunto para que no te desconcierte si en el examen aparece el número "seis".

MÁS ALLÁ DEL CURSO — AUTOML POR DENTRO, Y LAS PRUEBAS A/B

AutoML: en Power BI vive en los `dataflows` y permite construir modelos de predicción binaria, clasificación multiclase y regresión sin código. Por dentro automatiza cuatro cosas que un científico de datos haría a mano: ingeniería de características, **selección del algoritmo** (árboles con *gradient boosting*, regresión logística, redes neuronales), ajuste de hiperparámetros y validación cruzada. Es la "capa de análisis" de la Unidad 4 puesta en piloto automático. Reaparece de la Unidad 4 — ahí ya lo vimos como herramienta de prototipado.

Prueba A/B (A/B *testing*): el método clásico que el caso prescriptivo dice superar. Consiste en dividir a los usuarios en dos grupos, mostrar la oferta A a uno y la B al otro, y quedarse con la que gane. Su límite frente al refuerzo: es *estático* (defines A y B de antemano) y trata a todos por igual dentro de cada grupo. El refuerzo, en cambio, personaliza por perfil y sigue aprendiendo — por eso logra tasas de aceptación más altas.

EN FIBROMIN — LOS AVIONES SON MOTORES VOLADORES

Fíjate en algo lindo: los tres casos de aeropuertos son **Fibromin con alas**. "¿Aterrizará con retraso?" es clasificación, igual que "¿fallará el motor?". "¿Cuánto durará el vuelo?" es regresión, igual que "¿cuántas horas de vida útil quedan?". Y la detección de anomalías en tiempos de salida es idéntica a la detección de vibración anómala.

No es coincidencia: el ejemplo oficial del servicio de anomalías que el curso enseña es, literalmente, **un motor de avión con 20 sensores** (rotación, presión de combustible, rodamiento) donde ninguna señal por separado dice mucho, pero juntas revelan la salud del equipo. Airbus lo usó para monitorear aeronaves y anticipar fallas. Cambia "avión" por "molino SAG" y tienes el pitch de Fibromin. Estás en muy buena compañía técnica.

7 Los desafíos del foro, **razonados**

El foro del curso plantea un caso que junta casi todo: una empresa de e-commerce con retrasos, donde el árbol de descomposición encontró que la causa raíz **no es el tráfico** sino un cuello de botella en el **etiquetado de la bodega en horas punta**. El equipo intentó un modelo predictivo de retrasos, pero falló por **fuga del objetivo** al incluir "reclamo ingresado por el cliente" — algo que solo pasa *cuando el paquete ya se atrasó*. No te doy respuestas para copiar; te doy el **método de razonamiento**, que es lo transferible al examen y a Fibromin.

Desafío 1 · Diseño de variables (caza de fuga)

La pregunta: de esta lista, cuáles son seguras para predecir el retraso **antes de que el paquete salga de la bodega**, y cuáles causarían otra fuga. El método es una sola pregunta, aplicada a cada variable: **"¿este dato ya existe en el instante en que hago la predicción — es decir, antes de que el paquete salga?"**

APLICANDO LA REGLA TEMPORAL DEL LEAKAGE

Variable	Veredicto	Por qué
Hora exacta de la compra	Segura	Se conoce en el momento de comprar, mucho antes del despacho. Además es útil: una compra en hora punta cae en el cuello de botella.
Comuna de destino	Segura	Se conoce al generar el pedido. Legítima para estimar tiempos de reparto.
Estado: "Devuelto por dirección incorrecta"	Fuga	Este estado solo puede existir <i>después</i> de que el paquete salió, viajó y falló la entrega. Usarlo es mirar el futuro: en el instante de la predicción, no existe.
Cantidad de artículos en el pedido	Segura	Se conoce al comprar. Y tiene sentido causal: más artículos, más tiempo de preparación y etiquetado.

La trampa está diseñada con inteligencia: tres variables inofensivas y una — el "estado" — que suena a dato del pedido pero es un **efecto posterior** del resultado que quieres predecir. Ese es el patrón universal de la fuga: una variable que solo se llena *después* de que pasó lo que intentas anticipar.

Desafío 2 · Programación de la recompensa

La pregunta: qué puntaje (positivo o negativo) dar a cada escenario para que el aprendizaje por refuerzo elija bien al transportista. El principio a entender — y es de los más profundos de la unidad — es: **el sistema optimiza exactamente lo que premias, ni más ni menos**. Si diseñas mal la recompensa, obtienes un sistema que cumple la métrica y arruina el negocio.

- **Entrega antes de la hora estimada** → recompensa **positiva**. Es el resultado deseado.
- **Entrega con retraso de más de 2 horas** → castigo **negativo fuerte**. Es justo lo que se quiere evitar.
- **Transportista más rápido pero que cobra el doble** → castigo **negativo** (o recompensa reducida). Aquí está la lección: si *solo* premias la velocidad y no penalizas el costo, el sistema aprenderá a elegir **siempre el más caro** y te fundirá el margen. La operación no es "entregar rápido" sino "entregar a tiempo al menor costo". La recompensa debe reflejar **ese balance**, no una sola dimensión.

OJO, EXAMEN — LA MORALEJA DEL DISEÑO DE RECOMPENSAS

Un sistema de refuerzo es un genio que cumple tus deseos *al pie de la letra*. Premia solo velocidad y tendrás velocidad a cualquier precio; premia solo "no reclamamos" y aprenderá a esconder problemas. La recompensa tiene que codificar el **objetivo real y completo** del negocio — con sus trade-offs — o el sistema optimizará una versión deformada de lo que querías.

Desafío 3 · Acción inmediata (sin gastar en software)

La pregunta cierra con un giro que te va a gustar: si la IA ya demostró que el problema es el etiquetado en bodega en horas punta, ¿qué medida **administrativa o logística** implementarías mañana, sin gastar un peso en software? El punto pedagógico es fuerte: **la IA diagnóstica, pero la solución no tiene por qué ser más tecnología**. Con la causa raíz identificada, la respuesta es de operaciones — tu terreno. Opciones razonables: reasignar personal al etiquetado durante las horas punta, escalonar los turnos para aplanar el pico, pre-etiquetar en las horas valle, priorizar la cola de despachos urgentes, o revisar el layout del flujo de la bodega. El valor de todo el aparato de IA fue **apuntar el dedo al lugar correcto**; resolverlo puede costar cero en licencias.

EN FIBROMIN — EL MISMO MÉTODO, TU DOMINIO

Los tres desafíos son plantillas directas para Fibromin. **Caza de fuga**: al armar el clasificador de fallas, pasa cada sensor por la pregunta "¿esto existe antes de la falla?" — la vibración sí; la "orden de reparación" no. **Diseño de recompensa**: si algún día optimizas la política de mantención con refuerzo, premia la falla evitada, pero castiga la parada innecesaria y la falla no prevista — o el sistema aprenderá a intervenir todo el tiempo (nunca falla nada, pero paras la planta cada semana) o a no intervenir nunca. **Acción inmediata**: cuando el diagnóstico apunte a "la lubricación del turno de noche", la solución quizás sea un cambio de procedimiento, no un modelo nuevo.

8 Discrepancias detectadas

Tres puntos donde el curso y la realidad de hoy no coinciden. La regla general: **en el examen responde según el curso** (es lo que te evalúan); las correcciones son para tu práctica en Fibromin y para que no te sorprendas. Dos de estas son del mismo tipo que la del Azure ML Studio Classic de la Unidad 4 — herramientas de Microsoft que el curso enseña y que ya tienen fecha de defunción.

DISCREPANCIA 1 — EL SERVICIO DE DETECCIÓN DE ANOMALÍAS SE APAGA EN 2026

Qué dice el curso: enseña detección de anomalías en series temporales con "servicios de IA univariantes", y el material complementario remite a la guía oficial de Microsoft Learn para configurarlos. El *concepto* — bandas dinámicas que consideran el histórico de la serie en lugar de umbrales fijos — es correcto y está plenamente vigente.

Qué dice la práctica actual: el servicio concreto que el curso enseña a configurar es **Azure AI Anomaly Detector**. Microsoft lo está **retirando el 1 de octubre de 2026**, y desde el 20 de septiembre de 2023 ya no se pueden crear nuevos recursos. La ruta recomendada es migrar a **Microsoft Fabric** (que integra el proyecto de código abierto `microsoft/anomaly-detector`) o usar ese proyecto open source directamente. [confirmado — documentación oficial de Microsoft, 2025–2026]

Regla para el examen: si preguntan por el **concepto** (qué es detección de anomalías, umbrales fijos vs. dinámicos), responde con el curso — sigue 100% vigente. Si preguntan por la **herramienta** para hacerlo hoy, el servicio dedicado de Azure se está retirando; hoy se hace con Fabric o bibliotecas open source. Para Fibromin: no construyas sobre el Anomaly Detector standalone.

⚠ **DISCREPANCIA 2 — EL MOTOR DE "SIGUIENTE MEJOR ACCIÓN" TAMBIÉN SE APAGA EN 2026**

Qué dice el curso: el caso prescriptivo describe un "motor de personalización basado en aprendizaje por refuerzo" que mediante un "bucle de rango y recompensa" aprende qué oferta hacer a cada perfil de cliente. El *concepto* es correcto.

Qué dice la práctica actual: esa descripción es, casi textual, **Azure AI Personalizer** — el servicio de Microsoft que procesaba *contextos* y *acciones* con aprendizaje por refuerzo para determinar la mejor decisión, y cuya API se llama justamente **Rank & Reward** ("rango y recompensa"). Microsoft lo está **retirando el 1 de octubre de 2026** — la misma fecha que Anomaly Detector — y ya no permite crear nuevos recursos. Hoy la "siguiente mejor acción" se implementa con bibliotecas de bandidos contextuales o plataformas de RL propias. [confirmado — anuncio oficial de Microsoft, oct. 2025]

Regla para el examen: el **concepto** (siguiente mejor acción, aprendizaje por refuerzo, bucle rango-recompensa) es lo evaluable y va tal cual. Solo ten presente que el **servicio llave en mano** que lo hacía se retira. Para Fibromin: si algún día implementas NBA de mantención, no dependas del Personalizer.

⚠ **DISCREPANCIA 3 — EL AGENTE INTERACTÚA CON UN ENTORNO, NO CON "EL USUARIO"**

Qué dice el curso: hay una **inconsistencia interna** en el propio PDF. En "Conceptos clave" define el aprendizaje por refuerzo como decisiones óptimas "mediante un sistema de recompensas basado en interacciones con **el usuario**". Pero más adelante, en el Nivel 4, lo define correctamente como "interacción continua con un **entorno**".

Qué dice la literatura: la definición canónica es la segunda. En aprendizaje por refuerzo, el agente interactúa con un **entorno** (*environment*) — no necesariamente con un usuario. El usuario puede *ser parte* del entorno en un caso de personalización, pero el marco general es **agente → acción → entorno → recompensa**. Además, para "siguiente mejor acción" lo preciso es hablar de **bandidos contextuales** (RL de un solo paso, sin cadena de estados), que es exactamente lo que hacía el Personalizer.

Regla para el examen: si te piden la definición de refuerzo, el marco correcto es **agente–entorno–recompensa**. Si el enunciado usa la frase del curso con "usuario", respóndele al curso — pero sabé que "entorno" es lo correcto, y que el propio PDF lo usa bien en el Nivel 4. "Bandidos contextuales" es enriquecimiento: el examen casi seguro espera "aprendizaje por refuerzo".

9 **Glosario**

Todos los términos técnicos de la Unidad 5. Los marcados con * son enriquecimiento (no están en el PDF, no son evaluables). El resto es vocabulario del curso que conviene dominar. Estos 33 términos son, uno a uno, las flashcards del archivo interactivo.

Término	Inglés	Definición en una línea
Análisis descriptivo	Descriptive Analytics	Resume y visualiza datos históricos para responder <i>qué ocurrió</i> .
Análisis diagnóstico	Diagnostic Analytics	Identifica los factores y relaciones que explican <i>por qué ocurrió</i> un resultado.
Analítica predictiva	Predictive Analytics	Usa el histórico para estimar <i>qué podría ocurrir</i> y reducir la incertidumbre.
Analítica prescriptiva	Prescriptive Analytics	Evalúa alternativas y recomienda <i>qué acción ejecutar</i> .
Cadena analítica de datos	Data → ... → Decision	La progresión de dato crudo a decisión (DIKW); cada nivel depende del anterior.
Consulta de Lenguaje Natural	NLQ · Natural Language Query	Preguntar a los datos en lenguaje humano y obtener visualizaciones automáticas.
Preguntas y Respuestas	Q&A	Herramienta de IA que responde consultas descriptivas escritas en lenguaje cotidiano.
Sinónimos de campo	Field Synonyms	Config. que enseña al sistema que varios términos de negocio apuntan al mismo campo.
Narrativa inteligente	Smart Narrative	Genera automáticamente resúmenes en texto de gráficos y tablas; se actualiza al filtrar.
Democratización de los datos	Data Democratization	Trasladar la exploración de datos a los usuarios de negocio, sin depender de especialistas.
Influenciadores clave	Key Influencers	Visualización que identifica qué factores más impactan una métrica de interés.
Árbol de descomposición	Decomposition Tree	Herramienta de causa raíz que sugiere en qué dimensión de los datos profundizar.
Causa raíz	Root Cause	El mecanismo profundo que origina un resultado, más allá de la correlación superficial.
Clasificación	Classification	Predice a qué <i>categoría</i> o etiqueta pertenecerá un evento futuro.
Regresión	Regression	Predice un <i>valor numérico</i> continuo (una cantidad específica).
Detección de anomalías	Anomaly Detection	Identifica comportamientos que se apartan significativamente de lo esperado en una serie.
Variable objetivo	Target Variable	La clase o el valor que el modelo intenta predecir.
Modelos supervisados	Supervised Learning	Aprenden de ejemplos históricos <i>etiquetados</i> con la respuesta correcta.

Término	Inglés	Definición en una línea
Serie temporal	Time Series	Secuencia de datos ordenados en el tiempo, con tendencia y estacionalidad.
Umbrales fijos / márgenes dinámicos	Fixed / Dynamic Bounds	Regla rígida vs. banda que se adapta al comportamiento histórico de la serie.
AutoML	Automated Machine Learning	Automatiza construir el modelo: preparación, algoritmo, ajuste e validación.
KPI	Key Performance Indicator	Indicador clave que mide el desempeño de un área del negocio.
Fuga del objetivo	Target Leakage	Usar una variable no disponible al predecir; el modelo "hace trampa" y falla en la realidad.
Prueba A/B	A/B Testing	Comparar dos variantes en dos grupos; estática y sin personalizar por caso.
Siguiente mejor acción	Next Best Action	La intervención con mayor probabilidad de lograr el resultado deseado, caso por caso.
Aprendizaje por refuerzo	Reinforcement Learning	Un agente aprende de la interacción con un entorno para maximizar la recompensa acumulada.
Agente	Agent	El que toma las decisiones en el aprendizaje por refuerzo.
Recompensa	Reward	La señal que premia o castiga cada acción del agente.
Rango y recompensa	Rank and Reward	El bucle donde el sistema propone acciones (rango) y recibe retroalimentación (recompensa).
Exploración vs. explotación *	Exploration / Exploitation	Balance entre probar acciones nuevas y usar la mejor conocida. <i>(enriquecimiento)</i>
Bandidos contextuales *	Contextual Bandits	Refuerzo de un solo paso (contexto→acción→recompensa); lo real detrás de NBA. <i>(enriquecimiento)</i>
ML.NET y regresión *	ML.NET	Biblioteca de ML de Microsoft; el motor real (log./lineal) de Influenciadores clave. <i>(enriquecimiento)</i>
Métricas de evaluación *	Accuracy · Recall · RMSE · AUC	Miden el desempeño del modelo; un valor "perfecto" suele delatar fuga del objetivo. <i>(enriquecimiento)</i>

Total: **33 términos** — 29 del curso + 4 de enriquecimiento (*). Este conteo debe coincidir exactamente con el número de flashcards del archivo interactivo (Etapa 2).

10 Mapa conceptual

La unidad completa como un árbol: la raíz es el viaje del dato, las cuatro ramas principales son los niveles de analítica (cada uno con su pregunta), y una quinta rama transversal reúne el rigor y los errores. Las etiquetas en *cursiva coral* nombran la relación entre nodos; las líneas *·····punteadas violeta·····* son conexiones no jerárquicas. Este mismo árbol es el mapa interactivo de la Etapa 2.

ANALÍTICA DE DATOS POTENCIADA POR IA · el viaje del dato: Datos → Información → Conocimiento

cadena: cada nivel depende de la calidad del anterior →→

[describe el pasado] **NIVEL 1 · DESCRIPTIVO** – ¿Qué ocurrió?

- └ Consulta de Lenguaje Natural (NLQ)
 - └ *necesita* Sinónimos de campo
 - └ *se ofrece como* Preguntas y Respuestas (Q&A)
- └ Narrativa inteligente (*resúmenes de texto, dinámicos*)
- └ *habilita la tendencia* → Democratización de los datos

[explica el porqué] **NIVEL 2 · DIAGNÓSTICO** – ¿Por qué ocurrió?

- └ Influenciadores clave ····· por dentro es → ML.NET / regresión +
- └ Árbol de descomposición (*sugiere en qué dimensión bajar*)
- └ Causa raíz ▲ *identifica asociación, NO causalidad absoluta*

[anticipa el futuro] **NIVEL 3 · PREDICTIVO** – ¿Qué podría ocurrir?

- └ *requisito* → Calidad de datos ("un modelo es tan bueno como sus datos")
- └ Clasificación (*predice una categoría*)
- └ Regresión (*predice un valor numérico*)
- └ Detección de anomalías
 - └ Umbrales fijos × vs. Márgenes dinámicos ✓
- └ *se entrena con* → AutoML
- └ Variable objetivo · Modelos supervisados

[recomienda la acción] **NIVEL 4 · PRESCRIPTIVO** – ¿Qué deberíamos hacer?

- └ Siguiendo mejor acción (NBA) (*personaliza; supera la regla fija*)
- └ Aprendizaje por refuerzo (*agente → acción → entorno → recompensa*)
 - └ Agente · Recompensa · Rango y recompensa
 - └ Exploración vs. explotación +
 - └ Bandidos contextuales + ····· supera a → Prueba A/B

[amenaza y límite transversal] **RIGOR Y ERRORES**

- └ Fuga del objetivo (target leakage) ····· delatada por → Métricas + ····· ataca a → Nivel 3
- └ El juicio humano no se reemplaza (*validación · ética · regulación*)

Lectura del árbol: los cuatro niveles se leen de arriba hacia abajo como una escalera de madurez (la flecha de la cadena analítica). La quinta rama, "Rigor y errores", es transversal: la fuga del objetivo golpea sobre todo al Nivel 3, y el límite del juicio humano aplica a los cuatro. Los dos servicios que se retiran (Discrepancias 1 y 2) viven bajo Detección de anomalías y bajo Aprendizaje por refuerzo.

11 El arco de la unidad **en una idea**

Si tuvieras que quedarte con una sola frase: **los datos dejaron de servir para describir el pasado y pasaron a ser un apoyo activo para decidir el futuro**. Esa es la Unidad 5. Todo lo demás — NLQ, narrativa, influenciadores, clasificación, refuerzo — son las herramientas que hacen posible ese ascenso, peldaño por peldaño, desde *qué ocurrió* hasta *qué deberíamos hacer*.

Dos hilos atraviesan la unidad de punta a punta y son candidatos seguros a pregunta de síntesis. El primero: **la cadena analítica** — los cuatro niveles no son independientes, cada uno depende de la calidad del anterior, y por eso la calidad de los datos (y el fantasma de la fuga del objetivo) es una obsesión que reaparece en cada nivel. El segundo: **la IA acelera pero no reemplaza el juicio humano** — lo dice en lo descriptivo (la narrativa no sustituye al analista), en lo diagnóstico (el diagnóstico no prueba causalidad), y en lo prescriptivo (la recomendación se valida en contexto estratégico, ético y regulatorio). Si te preguntan "¿qué tienen en común los cuatro niveles?", la respuesta son estos dos hilos.

EN FIBROMIN — LA UNIDAD ES TU PLANO

Esta unidad no describe una tecnología ajena: describe **lo que Fibromin es**. Tu app toma señales crudas de sensores (datos), las muestra en un tablero (descriptivo), encuentra qué explica las fallas (diagnóstico), predice cuándo fallará cada equipo (predictivo) y recomienda qué hacer al respecto (prescriptivo). El valor que vendes es, textualmente, subir a tus clientes por esta escalera — sacarlos del tablero que solo mira hacia atrás y llevarlos hasta la acción recomendada. Cuando expliques Fibromin a un cliente, este mapa de cuatro niveles es el pitch. Y cuando construyas el modelo, la regla temporal del leakage y el "un modelo es tan bueno como sus datos" son tus guardarraíles.

Dónde encaja en el Máster

Hacia atrás. La Unidad 5 cobra sentido sobre lo ya visto: **CRISP-DM** (U3) es el proceso que envuelve estos niveles; el **ground truth** (U3) es lo que hace confiable la etiqueta de cualquier clasificador; el **data drift** (U3) explica por qué hay que *mantener* los modelos, no solo construirlos; la **incertidumbre** (U4) es justo lo que el nivel predictivo busca reducir; la regla **"no te cases con los datos"** (U4) es la madre de la fuga del objetivo; **AutoML** ya lo conocías de U4 como herramienta de prototipado; y las **tres capas** (U4) ubican dónde vive cada herramienta — NLQ y narrativa en la capa de usuario, los modelos en la de análisis.

Hacia adelante. Con el recorrido analítico completo, lo que sigue naturalmente en un máster de IA es profundizar en el *cómo* de cada motor — el interior de los algoritmos de clasificación y regresión, las arquitecturas de detección de anomalías, la formulación completa del aprendizaje por refuerzo — y en el *gobierno* de estos sistemas: ética, sesgos, explicabilidad y regulación, que esta unidad ya asoma cada vez que insiste en que el juicio humano no se reemplaza.

Fin de la explicación · Unidad 5 — Análisis predictivo y prescriptivo potenciado por IA · Toma de decisiones basadas en datos con IA — Máster en IA

La Etapa 2 (mapa conceptual interactivo + 33 flashcards) transforma este documento en una herramienta de estudio.